

기능 정확성

(Functional Correctness)

목차

- ❖ 기능 정확성 개념
- ❖ 기능 정확성 평가 지표
- ❖ 기능 정확성 QA 시나리오
- ❖ 기능 정확성 테스트 케이스 설계

기능 정확성 개념

AI 시스템의 기능 정확성 정의

Degree to which a product or system provides the **correct results** with the needed degree of precision

[ISO/IEC 25059:2023 Quality model of AI-based systems]

❖ 사용자가 의도하는 정답을 요구되는 정밀도로 제공하는 능력

- **정확한 결과**(Correct Results): 시스템의 출력 값에 오류가 없어야 함
- **필요한 정밀도**(Needed Degree of Precision)
 - ✓ 해당 도메인이 요구하는 수준을 충족해야 함
 - ✓ 예: 수술 로봇의 0.1mm 오차 범위, 자율주행의 조향각 정밀도 등

AI 시스템의 불완전한 정확성

AI systems, and particularly those using machine learning models, **DO NOT** usually provide functional correctness **in all observed circumstances.**

[ISO/IEC 25059:2023 Quality model of AI-based systems]

❖ 원인

- 1) 확률론적 동작 특성
- 2) 일반화의 한계
- 3) 생성형 AI의 비결정론적 동작

1) 확률론적 동작 특성

❖ 머신러닝 모델은 데이터의 통계적 분포를 학습하여 가장 높은 확률을 가진 값을 출력함.

- 모델이 '정답'을 아는 것이 아니라 '가장 그럴듯한 결과'를 출력하는 것임
- 학습 데이터와 다른 입력에 대해서는 오답을 낼 가능성이 존재함

1) 확률론적 동작 특성: 시각 지능의 '배경 편향'

❖ 오동작 원인


- 학습 데이터셋에서 "하얀색 배경 = 북극곰"이라는 통계적 상관관계가 매우 높았기 때문
- 모델은 객체의 형태를 '이해'한 것이 아니라, 편향된 방식(배경 노이즈와 정답 사이의 가장 높은 확률적 동작)의 결과



1) 확률론적 동작 특성: 언어 모델의 '통계적 환각'

❖ 오동작 원인

- 모델은 확인된 사실 관계가 아니라, 문맥상 해당 위치에 올 가장 확률이 높은 단어(Token)를 예측
- 정보가 부족할수록 통계적으로 흔한 정보를 '그렇듯하게' 조합하여 출력




2) 일반화의 한계

- ❖ AI 시스템은 학습 데이터를 넘어 새로운 데이터(Unseen)에 대해서도 잘 작동하는 '일반화'를 목표로 함
- ❖ 하지만, 일반화 능력의 확보는 현실적인 한계가 존재함

원인	기술적 개념	설명
무한한 상황의 가짓수	Combinatorial Explosion	• 모든 조합을 학습 데이터셋에 포함하는 것은 물리적·논리적으로 불가능함.
희귀 사례의 희소성	The Long Tail	• 통계적 학습 모델은 빈도가 낮은 데이터를 노이즈로 취급하거나 무시하는 경향이 있어 오답 위험이 상존함.
세상의 변화	Data Drift	• 학습 시점의 데이터 분포와 운영 시점의 데이터 분포가 일치하지 않는 '분포 불일치' 현상이 필연적으로 발생함.


무한한 상황의 가짓수

- ❖ 개별 환경 변수(날씨, 조도, 도로, 돌발 객체 등)가 결합된 가능한 시나리오는 무한함.
- ❖ 모든 조합을 학습 데이터셋에 포함하는 것은 물리적·논리적으로 불가능함.




희귀 사례의 희소성

- ❖ 모델은 빈도가 낮은 데이터를 노이즈로 취급하거나 무시할 수 있음
- ❖ 낮은 발생 빈도로 인해서, 중요한 시나리오에 대한 불충분한 학습은 심각한 오동작을 유발할 수 있음



세상의 변화

- ❖ 운영 시점의 데이터 분포가 학습 시점의 데이터 분포와 다르면, 과거 데이터로 학습한 모델은 운영 시점에 정확한 추론을 수행하기 어려움



3) 생성형 AI의 비결정론적 동작

❖ 확률적 샘플링에 따른 비결정성

- 동일한 입력(Prompt)에 대해서 Temperature나 Top-p 같은 확률적 샘플링 파라미터로 인해 다른 결과가 산출될 수 있음
- 확률적 샘플링은 '창의적 표현'을 가능하게 하나, 동시에 사실이 아닌 '환각'을 유발할 수 있음

Parameter	역할	영향
Temperature	다음 토큰 확률 분포의 무작위성 조절	낮으면 일관성 증가, 높으면 다양성·창의성 증가
Top-p	누적 확률이 p가 될 때까지의 토큰만 후보로 선택	낮으면 후보 수가 줄어 일관성 증가, 높으면 후보 수가 늘어 다양성 증가
Top-k	확률 상위 k개의 토큰만 후보로 선택	낮으면 후보 수가 줄어 일관성 증가, 높으면 후보 수가 늘어 다양성 증가

3) 생성형 AI의 비결정론적 동작

❖ 입력 민감성

- 입력 표현의 미세한 변화가 출력 값의 큰 차이를 유발할 수 있음

입력 변화	영향
공백, 줄바꿈	같은 문장이라도 문장의 덩어리나 구조가 다르게 보일 수 있어, 모델이 강조점이나 문맥의 경계를 다르게 해석할 수 있음
문장 부호	물음표, 쉼표, 따옴표, 콜론 등의 차이로 질문인지 명령인지, 예시인지 조건인지에 대한 해석이 달라질 수 있음
단어 하나 변경	비슷한 뜻의 단어라도 뉘앙스가 달라져, 모델이 사용자의 의도나 답변 방향을 다르게 잡을 수 있음
예시 순서 변경	앞에 나온 예시를 더 중요한 기준처럼 받아들이거나, 마지막 예시의 방식에 맞춰 답변하려는 경향이 생길 수 있음
system/user instruction 표현 변화	지시문 표현이 달라지면 어떤 요구를 더 우선해야 하는지, 어느 정도로 엄격하게 따라야 하는지에 대한 판단이 달라질 수 있음

AI 신뢰성(Trustworthiness) 확보를 위한 추가 QA

❖ 배경

- AI 모델의 태생적 불완전성으로 인해, '기능 정확성'만으로는 시스템의 신뢰성(Trustworthiness)을 담보할 수 없음
- 따라서 정확성을 보강하는 '안전망'이자 '신뢰의 근거'로서 다른 품질 속성들을 고려해야 함

추가 QA	초점	질문	역할
강건성 (Robustness)	악조건 상황 대응	다양한 악조건 상황에서도 정확성을 유지할 수 있는가?	정확성의 범위 확장
기능 적응성 (Functional Adaptability)	운영 도메인 변화 대응	운영 도메인이 변해도 정확도를 유지할 수 있는가?	정확성의 수명 연장
제어 가능성 (Controllability)	모니터링 및 개입	모델이 틀렸을 때 강제로 멈출 수 있는가?	정확성의 안전판
설명 용이성 (Explainability)	결과 근거 제시	결과에 대해 인간이 납득할 근거를 주는가?	정확성의 신뢰 구축

추가 QA 예시: 도로 객체 인식

QA	요구사항 예	정확성 부족을 보완하는 논리
강건성	폭우, 폭설 등 악조건 환경에서도 객체 인식 정확도 저하 폭을 평시 대비 10% 이내로 유지해야 한다.	악조건에서도 정확성을 유지하여 안전을 확보함.
기능 적응성	배달 로봇 등 신규 이동 수단이 등장할 경우, 해당 객체를 '장애물'로 식별하고 고유 범주로 분류할 수 있어야 한다.	새로운 입력 유형에 대응하여 정확성의 시효를 연장함.
제어 가능성	객체 인식의 확신도가 70% 미만으로 떨어질 경우, 시스템은 즉시 운전자에게 경고하고 감속 명령을 생성해야 한다.	부정확성 결과가 위험을 초래하기 전, 사용자가 개입할 통로를 마련함.
설명 용이성	시스템이 전방 물체를 '긴급 장애물'로 판단했을 때, 판단의 근거가 되는 핵심 픽셀 영역을 로그에 기록해야 한다.	오작동 시 "왜" 틀렸는지 분석할 수 있게 하여 결과에 대한 신뢰 근거를 제공함.

Quiz: 음성 명령 인식

아래 QA 부분에 적당한 품질속성?

QA	요구사항 예	정확성 부족을 보완하는 논리
	"시원하게 해줘", "춥다" 등 동일한 목적의 다양한 관용적 표현이나 개인별 신조어를 이해하고 수행해야 한다.	고정된 규칙이 아닌 사용자별 문맥과 새로운 언어 규칙에 유연하게 대응함.
	100km/h 이상의 주행 소음이나 음악이 켜진 상태에서도 핵심 제어 명령어 인식률을 95% 이상 유지해야 한다.	입력 데이터의 노이즈(소음)가 정확성을 유지함.
	사용자의 명령을 수행할 수 없는 경우(예: 고속 주행 중 급제동 요청), 시스템은 거절 사유가 된 차량 상태나 안전 규칙을 음성으로 설명해야 한다.	결과의 도출 과정을 명확히 밝힘으로써 사용자가 시스템의 판단을 수긍하게 함.
	조향, 제동 등 안전과 직결된 음성 명령에 대해서는 확인 절차를 거치거나, 물리적 스위치에 의한 강제 취소가 가능해야 한다.	부정확성으로 인한 치명적 실행을 방지하고 인간의 최종 제어권을 보장함.

성능(Performance) 용어: SE 관점과 AI 관점

❖ AI 성능(Performance) = 소프트웨어 공학의 기능 정확성

구분	소프트웨어 공학 (SE)에서의 성능	인공지능 (AI)에서의 성능
핵심 의미	효율성 (Efficiency)	정확성 (Correctness)
측정 대상	소프트웨어가 얼마나 '효율적으로' 수행되는가?	시스템이 과업을 얼마나 '정확하게' 수행하는가?
측정 지표	실행 시간, 처리량, 자원 효율성	추론 정확도, 정밀도, 재현율
ISO 25059 표준 기준	Performance Efficiency (수행 효율성)	Functional Correctness (기능 정확성)

기능 정확성 평가 지표

AI Task 유형별 정확성

Task 유형	기능 정확성의 의미
분류	입력 데이터를 의도된 범주로 정확히 할당하여 오분류를 최소화하고, 객체 인식·진단 등에서는 오탐과 미탐을 방지함
회귀	연속적인 수치 값을 실제 참값에 가깝게 예측하여 오차를 최소화하고, 시간적 연속성이 필요한 경우 급격한 예측 변동을 억제함
군집화	유사한 데이터는 같은 그룹으로 응집시키고 서로 다른 데이터는 분리하여, 객체나 패턴의 의미 있는 경계를 형성함
추천	사용자의 의도, 상황, 선호에 부합하는 항목을 상위에 배치 하여 관련성 높은 선택지를 효과적으로 제공함
생성	주어진 맥락, 사실 관계, 사용자 요구, 형식 제약에 부합하는 결과물을 생성하고, 근거 없는 내용이나 환각을 최소화함

기능 정확성 평가 지표

Task 유형	평가 목적	평가 지표
분류	올바른 범주 판별 능력과 오탐·미탐 비용 관리	Accuracy, Precision, Recall, F1-Score ROC-AUC, PR-AUC, mAP
회귀	실제 참값과의 수치 오차 및 예측 신뢰도 측정	R^2 , MAE, MSE, RMSE, MAPE
군집화	군집 내부 응집도와 군집 간 분리도 평가	Inertia (WCSS), Silhouette, ARI, DB Index
추천	상위 추천 항목의 관련성, 순위 품질, 노출 다양성 평가	Recall@K, MRR, NDCG, Coverage
텍스트 생성	참조·문맥과의 의미 일치성, 유창성, 사실성 평가	BLEU, ROUGE, METEOR BERTScore, Cosine Similarity Perplexity, FactScore
이미지 생성	실제 이미지 분포와의 유사성, 조건 일치성, 시각적 품질·다양성 평가	FID, IS, SSIM, LPIPS

평가 지표: Classification

Measures	정의	적용 상황	적용 상황 예
Accuracy 정확도	전체 데이터 중 정답을 맞춘 비율	데이터 클래스 분포가 균일할 때	일반적인 사물 분류 (예: 개/고양이 식별)
Precision 정밀도	Positive로 예측한 것 중 실제 Positive인 비율	오탐(FP) 방지. 틀린 것을 맞다고 할 때의 비용이 클 때	스팸 메일 분류, 무죄 판결 등
Recall 재현율	실제 Positive 중 Positive로 예측한 비율	미탐(FN) 방지. 맞는 것을 놓칠 때의 비용이 클 때	암 진단, 보행자 인식, 화재 경보 등
F1-Score	정밀도와 재현율의 조화 평균	데이터 불균형이 심각하여 두 지표의 균형이 필요할 때	금융 사기 탐지, 제조 공정 불량 탐지
ROC-AUC	임계값 변화에 따른 TPR(Recall)-FPR 곡선 아래 면적	임계값에 상관 없이 모델의 전반적인 분류 변별력을 평가할 때	신종 질병 유무 판정 모델의 성능 비교 및 최적 임계값 선정
PR-AUC	임계값 변화에 따른 Precision-Recall 곡선 아래 면적	데이터 불균형이 심하거나, 희귀한 양성(Positive) 샘플을 찾는 정밀도가 중요할 때	신용카드 부정 거래 탐지, 제조 공정 내 희귀 결함 검출
mAP (mean Average Precision)	클래스 별 정밀도-재현율(PR) 곡선 아래 면적(AP)의 평균	다중 객체 검출(Object Detection) 성능을 종합적으로 평가할 때	자율주행 중 도로 위 다중 객체 인식

FPR : False Positive Rate (위양성률)

TPR : True Positive Rate (진양성률)

ROC : Receiver Operating Characteristic Curve (수신자 조작 특성 곡선)


AUC : Area Under the Curve (ROC 곡선 아래 면적)

평가 지표: Classification



1. Accuracy (정확도)

전체 데이터 중 정답을 맞춘 비율



전체 중
맞춘 비율



언제 유용한가?

데이터 클래스 분포가
균일할 때



예시 활용

일반적인 사물 분류
(예: 개/고양이 식별)



2. Precision (정밀도)

Positive로 예측한 것 중 실제 Positive인 비율



예측 Positive 중
얼마나 정확한가?



언제 유용한가?

오탐(FP) 방지: 틀린 것을
맞다고 할 때의 비용이 클 때



예시 활용

스팸 메일 오분류, 무죄 판결,
정상 메일 차단 방지



3. Recall (재현율)

실제 Positive 중 Positive로 맞춘 비율



실제 Positive를
얼마나 놓치지
않았는가?

검출됨 (TP)
놓침 (FN)



언제 유용한가?

미탐(FN) 방지: 맞는 것을
놓칠 때의 비용이 치명적일 때




예시 활용

암 진단, 자율주행 보행자 인식,
화재 경보



4. F1-Score

정밀도와 재현율의 조화 평균



언제 유용한가?

데이터 불균형이 심각하여
두 지표의 균형이 필요할 때



예시 활용

금융 사기 탐지(FDS),
제조 공정 불량 탐지



핵심 선택 기준



Accuracy:
전체 성능



Precision:
오탐 최소화



Recall:
미탐 최소화



F1:
균형 평가

$$\text{Precision} = \frac{\text{True Positives (TP)}}{\text{True Positives (TP)} + \text{False Positives (FP)}}$$


$$\text{Recall} = \frac{\text{True Positives (TP)}}{\text{True Positives (TP)} + \text{False Negatives (FN)}}$$

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

평가 지표: Classification

1. ROC-AUC

TPR(Recall)-FPR 곡선 아래 면적



임계값 변화와 무관하게 전반적인 분류 변별력 평가




유용한 경우:
모델 간 성능 비교,
최적 임계값 후보 탐색



예:
신종 질병
유무 판정 모델

2. PR-AUC

Precision-Recall 곡선 아래 면적



불균형 데이터에서 희귀 Positive 탐지 성능 평가에 유리



유용한 경우:
양성 샘플이 드문 상황에서
모델 성능 평가 및 비교


- ✓ 정밀도와 재현율의 균형
- ✓ 양성 샘플이 드문 상황에 적합



예:
카드 부정거래 탐지,
희귀 결함 검출

3. mAP

각 클래스 AP의 평균



다중 객체 검출 성능을 클래스별로 종합 평가



객체별 검출 정확도와 재현 특성을 함께 반영



예:
자율주행 도로 위
다중 객체 인식

$$\text{TPR(바르게 긍정적인 비율)} = \frac{TP}{TP+FN} = \text{Recall} \quad \text{FPR(잘못 긍정할 비율)} = \frac{FP}{TN+FP}$$

평가 지표 가이드라인: Classification

상황	추천 지표	설명
1) 임계값(Threshold)이 확정된 경우	Precision, Recall, F1-Score	특정 운영 조건에서의 분류 성능과 오탐/미탐 간 균형을 직접 평가함.
2) 임계값 확정 전(전반적 성능 평가)	AUC (Area Under the Curve)	임계값의 변화와 무관하게 모델이 가진 근본적인 변별력을 평가함.
- 데이터가 비교적 균등할 때	ROC-AUC	양성(P)과 음성(N)을 전체적으로 얼마나 잘 분리(Ranking)하는지 확인.
- 데이터 불균형 (Imbalance)이 심할 때	PR-AUC	희귀한 양성(P) 샘플을 얼마나 정밀하게 찾아내는지(Focus on Minority) 확인.

Quiz: Classification 평가 지표

- | | |
|--------------|------------|
| 1. Accuracy | 5. ROC-AUC |
| 2. Precision | 6. PR-AUC |
| 3. Recall | 7. mAP |
| 4. F1-Score | |

번호	문제	지표
1	개/고양이/토끼처럼 클래스별 데이터 수가 비교적 균일하고, 전체적으로 얼마나 많이 맞혔는지를 평가하려고 한다.	
2	정상 메일을 스팸으로 잘못 분류하면 중요한 업무 메일을 놓칠 수 있다. 즉, Positive로 예측한 결과가 실제로 맞는지가 중요하다.	
3	암 진단 모델에서 실제 암 환자를 놓치는 것이 가장 치명적이다. 실제 Positive 중 얼마나 많이 찾아냈는지를 평가하려고 한다.	
4	금융 사기 탐지에서 사기 거래는 매우 적고, 오탐과 미탐을 모두 적절히 관리해야 한다.	
5	여러 임계값을 바꿔 보면서 질병 유무 판정 모델의 전반적인 양성/음성 구분 능력을 비교하려고 한다.	
6	신용카드 부정 거래처럼 Positive 샘플이 매우 희귀하고, Positive 탐지 성능을 Precision-Recall 관점에서 평가하려고 한다.	
7	자율주행 인지 모델이 차량, 보행자, 표지판 등 여러 객체를 동시에 탐지하는 성능을 종합적으로 평가하려고 한다.	
8	제조 공정에서 불량품을 잘 찾아내는데도 중요하지만, 정상 제품을 불량으로 너무 많이 오판하지 않는지도 함께 보고 싶다.	
9	화재 경보 시스템에서 화재를 놓치는 것이 가장 위험하다. 경보가 조금 많더라도 실제 화재를 최대한 탐지하는 능력을 평가하려고 한다.	
10	불량으로 예측된 제품만 사람이 재검사하는 시스템이다. 재검사 대상 중 실제 불량품 비율이 높아야 검사 비용을 줄일 수 있다.	

Quiz: Classification 평가 지표

- | | |
|--------------|------------|
| 1. Accuracy | 5. ROC-AUC |
| 2. Precision | 6. PR-AUC |
| 3. Recall | 7. mAP |
| 4. F1-Score | |

번호	문제	지표
1	개/고양이/토끼처럼 클래스별 데이터 수가 비교적 균일하고, 전체적으로 얼마나 많이 맞혔는지를 평가하려고 한다.	Accuracy
2	정상 메일을 스팸으로 잘못 분류하면 중요한 업무 메일을 놓칠 수 있다. 즉, Positive로 예측한 결과가 실제로 맞는지가 중요하다.	Precision
3	암 진단 모델에서 실제 암 환자를 놓치는 것이 가장 치명적이다. 실제 Positive 중 얼마나 많이 찾아냈는지를 평가하려고 한다.	Recall
4	금융 사기 탐지에서 사기 거래는 매우 적고, 오탐과 미탐을 모두 적절히 관리해야 한다.	F1-Score
5	여러 임계값을 바꿔 보면서 질병 유무 판정 모델의 전반적인 양성/음성 구분 능력을 비교하려고 한다.	ROC-AUC
6	신용카드 부정 거래처럼 Positive 샘플이 매우 희귀하고, Positive 탐지 성능을 Precision-Recall 관점에서 평가하려고 한다.	PR-AUC
7	자율주행 인지 모델이 차량, 보행자, 표지판 등 여러 객체를 동시에 탐지하는 성능을 종합적으로 평가하려고 한다.	mAP
8	제조 공정에서 불량품을 잘 찾아내는지도 중요하지만, 정상 제품을 불량으로 너무 많이 오판하지 않는지도 함께 보고 싶다.	ROC-AUC
9	화재 경보 시스템에서 화재를 놓치는 것이 가장 위험하다. 경보가 조금 많더라도 실제 화재를 최대한 탐지하는 능력을 평가하려고 한다.	Recall
10	불량으로 예측된 제품만 사람이 재검사하는 시스템이다. 재검사 대상 중 실제 불량품 비율이 높아야 검사 비용을 줄일 수 있다.	Precision

평가 지표: Regression

Measures	정의	적용 상황	적용 상황 예
MAE (Mean Absolute Error)	$Avg(y - y')$: 실제값(y)과 예측값(y') 차이의 절대값을 평균	이상치의 영향력을 중립적으로 평가하고 싶을 때	통상적인 경로 주행 시 차량의 평균 위치 오차 측정
MSE (Mean Squared Error)	$Avg((y - y')^2)$: 오차의 제곱을 평균한 값	작은 오차보다 큰 오차에 대해 강한 페널티 를 부여할 때	허용 범위를 벗어나는 급격한 수치 변동 감시
RMSE (Root Mean Squared Error)	$\sqrt{MSE}$: MSE에 루트를 씌워 실제 단위와 맞춘 값	예측 오차의 크기를 실제 물리 단위 로 직관적으로 확인하고 싶을 때	자율주행 선행 차량과의 실제 거리 추정 오차
MAPE (Mean Absolute Percentage Error)	$Avg((y - y')/y) * 100\%$: 오차를 실제값 대비 백분율(%)로 변환하여 평균한 값	데이터의 스케일(단위)이 다른 여러 모델 의 성능을 비교할 때	경차와 대형 트럭 의 배터리 잔량 예측 정확도 비교
R² (R-Squared)	실제 데이터의 분산 대비 모델의 설명력을 0~1 사이로 표현	모델이 데이터의 경향성을 얼마나 잘 파악했는지 상대적 지능 을 평가할 때	주행 환경(노면, 날씨)이 연비에 미치는 영향력을 모델이 85% 설명함


평가 지표: Regression

1. MAE (Mean Absolute Error)

실제값(y)과 예측값(y') 차이의 절대값을 평균한 값



$$\text{Avg}(|y - y'|)$$



오차의 절대값 평균



언제 유용한가?

이상치의 영향력을
중립적으로 평가하고 싶을 때



예시 활용

통상적인 경로 주행 시
차량의 평균 위치 오차 측정


▮ 평균적인 오차 크기

2. MSE (Mean Squared Error)

오차의 제곱을 평균한 값



$$\text{Avg}((y - y')^2)$$



언제 유용한가?

작은 오차보다 큰 오차에 대해
강한 페널티를 부여할 때



예시 활용

제어 시스템에서 허용 범위를
벗어나는 급격한 수치 변동 감시

⚠ 큰 오차 민감

3. RMSE (Root Mean Squared Error)

MSE에 루트를 씌워 실제 단위와 맞춘 값



$$\text{sqrt}(\text{MSE})$$

제곱 오차 값들
1, 4, 9, 16, ...
(단위²)



최종 오차
(단위)



언제 유용한가?

예측 오차의 크기를 실제 물리 단위로
직관적으로 확인하고 싶을 때



예시 활용

자율주행 선행 차량과의
거리 추정 오차 (단위: m)



직관적 단위 해석



핵심 선택 기준



MAE: 전체적인 평균 오차



MSE: 큰 오차에 민감



RMSE: 실제 단위 해석

평가 지표: Regression

1 MAPE (Mean Absolute Percentage Error)

오차를 실제값 대비 백분율(%)로 변환하여 평균한 값

$$\text{Avg} \left(\left| \frac{y - y'}{y} \right| \right) \times 100\%$$

경차



상대 오차 10%



- 실제값 40%
- 예측값 44%
- 오차 +4%p

스케일이
달라도
% 기준으로
비교 가능

대형 트럭



상대 오차 10%



- 실제값 80%
- 예측값 88%
- 오차 +8%p

? 언제 유용한가?

데이터의 스케일(단위)이 서로 다른 여러 모델의 성능을 비교할 때

예시 활용

경차와 대형 트럭의 배터리 잔량 예측 정확도 비교




핵심: 상대 오차를 %로 해석

2 R² (R-Squared)

실제 데이터의 분산 대비 모델의 설명력을 0~1 사이로 표현

$$R^2 = \frac{\text{설명된 분산}}{\text{전체 분산}} \quad 0 \sim 1 \text{ 사이 값}$$




? 언제 유용한가?

모델이 데이터의 경향성을 얼마나 잘 파악했는지 상대적 설명력을 평가할 때

예시 활용


주행 환경(노면, 날씨)이 연비에 미치는 영향력을 모델이 85% 설명함



노면
(도로 상태)



날씨
(기온, 강수 등)



모델
(예측)



핵심: 데이터 경향성 설명력 평가



핵심 선택 기준



MAPE:

서로 다른 스케일 비교에 적합



R²:

모델 설명력 평가에 적합

$$R^2 = \frac{\text{설명된 분산}}{\text{전체 분산}} = 1 - \frac{\text{설명하지 못한 분산}}{\text{전체 분산}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

평가 지표 가이드라인: Regression

관점	설명	평가 지표
모델 적합도	예측값이 실제값과 몇 단위 차이 나는지를 보기보다, 입력 요인이 결과값의 변화를 얼마나 잘 설명하는지 평가	R^2
강건한 평가	"데이터에 노이즈나 튀는 값(Outlier) 이 섞여 있어도, 특정 이상치에 휘둘리지 않고 모델의 전반적인 정확도를 측정하고 싶을 때"	MAE
엄격한 안전 설계	"작은 오차 여러 개보다 큰 오차 하나가 시스템에 치명적인 결과를 초래하여, 큰 실수를 저지르는 모델을 강력하게 규제해야 할 때"	MSE
직관적 위험 관리	"MSE처럼 큰 오차에 엄격한 페널티를 유지하면서도, 그 결과를 실제 물리적 수준(m, m/s 등)에서 직접 해석하고 관리하고 싶을 때"	RMSE
스케일 독립 비교	"데이터의 절대적 크기와 상관없이(예: 저속 vs 고속 주행), 상대적인 오차 비율을 통해 모델 간의 범용적인 정확성을 비교하고 싶을 때"	MAPE

Quiz: Regression 평가 지표

1. R^2
2. MAE
3. MSE
4. RMSE
5. MAPE

번호	문제	지표
1	자율주행 차량에서 예측 위치와 실제 위치 사이의 평균적인 오차 크기를 확인하려고 한다. 이상치에 과도하게 민감하지 않은 지표가 필요하다.	
2	제어 시스템에서 작은 오차보다 허용 범위를 크게 벗어난 예측 오차를 더 강하게 벌점화하고 싶다.	
3	선행 차량과의 거리 예측 모델을 평가할 때, 오차를 실제 거리 단위인 m로 직관적으로 해석하고 싶다.	
4	경차와 대형 트럭처럼 배터리 용량 스케일이 다른 차량들의 잔량 예측 성능을 백분율 기준으로 비교하려고 한다.	
5	주행 환경, 노면 상태, 날씨 등의 입력 변수가 연비 변화를 얼마나 잘 설명하는지 평가하려고 한다.	
6	배송 시간 예측 모델에서 실제 시간과 예측 시간의 차이를 분 단위로 보고 싶다. 큰 오차 하나가 전체 평가를 지나치게 흔들지 않도록 하고 싶다.	
7	로봇 팔 제어값 예측에서 큰 오차가 발생하면 장비 충돌로 이어질 수 있다. 큰 오차를 특히 강하게 반영하는 지표가 필요하다.	
8	자율주행 차량의 차선 중심선과의 거리 오차를 평가할 때, 최종 결과를 실제 물리 단위인 cm 또는 m로 해석하고 싶다.	
9	매출 규모가 서로 다른 여러 매장의 수요 예측 모델을 비교하려고 한다. 절대 오차보다 실제값 대비 몇 % 틀렸는지가 중요하다.	
10	센서 입력들이 모터 온도 변화를 얼마나 잘 설명하는지, 모델의 전체적인 설명력을 확인하려고 한다.	

Quiz: Regression 평가 지표

1. R^2
2. MAE
3. MSE
4. RMSE
5. MAPE




번호	문제	지표
1	자율주행 차량에서 예측 위치와 실제 위치 사이의 평균적인 오차 크기를 확인하려고 한다. 이상치에 과도하게 민감하지 않은 지표가 필요하다.	MAE
2	제어 시스템에서 작은 오차보다 허용 범위를 크게 벗어난 예측 오차를 더 강하게 벌점화하고 싶다.	MSE
3	선행 차량과의 거리 예측 모델을 평가할 때, 오차를 실제 거리 단위인 m로 직관적으로 해석하고 싶다.	RMSE
4	경차와 대형 트럭처럼 배터리 용량 스케일이 다른 차량들의 잔량 예측 성능을 백분율 기준으로 비교하려고 한다.	MAPE
5	주행 환경, 노면 상태, 날씨 등의 입력 변수가 연비 변화를 얼마나 잘 설명하는지 평가하려고 한다.	R^2
6	배송 시간 예측 모델에서 실제 시간과 예측 시간의 차이를 분 단위로 보고 싶다. 큰 오차 하나가 전체 평가를 지나치게 흔들지 않도록 하고 싶다.	MAE
7	로봇 팔 제어값 예측에서 큰 오차가 발생하면 장비 충돌로 이어질 수 있다. 큰 오차를 특히 강하게 반영하는 지표가 필요하다.	MSE
8	자율주행 차량의 차선 중심선과의 거리 오차를 평가할 때, 최종 결과를 실제 물리 단위인 cm 또는 m로 해석하고 싶다.	RMSE
9	매출 규모가 서로 다른 여러 매장의 수요 예측 모델을 비교하려고 한다. 절대 오차보다 실제값 대비 몇 % 틀렸는지가 중요하다.	MAPE
10	센서 입력들이 모터 온도 변화를 얼마나 잘 설명하는지, 모델의 전체적인 설명력을 확인하려고 한다.	R^2

평가 지표 및 군집수 (K) 결정 지표: Clustering

지표	정의	적용 상황	적용 상황 예
Silhouette (실루엣 계수)	군집 내 데이터의 응집도와 인접 군집과의 분리도를 계산 (-1 ~ 1)	군집화 결과의 타당성 및 경계의 명확성 을 평가할 때 (0.5 이상 권장)	고객 세그먼트 분류 시 각 그룹이 서로 섞이지 않고 잘 나뉘었는지 확인
DB Index (Davies-Bouldin)	군집 내 분산과 군집 간 거리의 비율을 계산 (낮을수록 우수)	계산 복잡도가 낮아 대규모 데이터셋 의 군집 품질을 빠르게 모니터링할 때	실시간 교통 흐름 분석 시스템에서 유입되는 차량 데이터 군집의 품질 측정
ARI (Adjusted Rand Index)	예측된 군집 결과와 실제 정답(Ground Truth) 사이의 유사도 측정	정답 레이블이 있는 데이터 를 활용해 군집화 알고리즘의 유효성을 검증할 때	MNIST와 같은 레이블 데이터셋을 이용해 새로 설계한 군집화 모델의 정확도 테스트
Inertia (WCSS)	각 데이터와 해당 군집 중심점(Centroid) 사이 거리의 제곱합	최적의 군집 수(K) 를 결정하기 위해 오차 감소폭을 확인할 때	라이다(LiDAR) 점구름 데이터 처리 시 물리적 장애물 그룹의 최소 단위 결정

* WCSS: Within Cluster Sum of Squares

평가 지표 가이드라인: Clustering

단계	적용 지표	실무적 설명	핵심 역할	특징
 모델 학습 (Training)	WCSS (Inertia)		 최적 구조 (K) 결정	 Elbow Method용
	Silhouette		 전반적 군집화 평가	-1 ~ 1 (보통 0.5 이상이면 품질이 우수하다고 판단)
	ARI		 별 데이터 군집화 정확도 검증	정답 데이터가 있는 실험 환경에서만 가능
 모델 운영 (Operation)	DB Index		 실시간 품질 감시	낮을수록 우수. 실루엣보다 계산이 빨라 실시간 모니터링에 유리함. 

Quiz: Clustering 평가 지표

1. WCSS
2. Silhouette
3. DB Index
4. ARI

번호	문제	지표
1	고객 세그먼트를 군집화한 뒤, 각 그룹이 내부적으로 잘 뭉쳐 있고 다른 그룹과 명확히 분리되었는지 평가하려고 한다. -1에서 1 사이 값으로 해석되는 지표는?	
2	실시간 교통 흐름 데이터를 계속 군집화하면서, 계산 비용을 낮게 유지한 채 군집 품질을 빠르게 모니터링하려고 한다. 낮을수록 좋은 지표는?	
3	LiDAR 점구름 데이터를 몇 개의 장애물 그룹으로 나눌지 결정하려고 한다. K를 바꿔가며 군집 중심까지의 거리 제곱합 감소폭을 확인하려고 한다	
4	K-means에서 K를 늘릴수록 오차가 줄어드는데, 어느 지점부터 개선 폭이 완만해지는지 확인하여 적정 군집 수를 정하려고 한다. 적합한 지표는?	
5	새로 개발한 군집화 알고리즘이 실제 품종 라벨이 있는 꽃 데이터셋에서 얼마나 잘 그룹을 나누는지 확인하려고 한다. 예측 군집과 정답 레이블의 일치도를 평가하는 지표는?	
6	문서들을 주제별로 자동 군집화했는데, 한 문서가 자기 군집에 더 가까운지 아니면 인접 군집에 더 가까운지 확인하고 싶다. 적합한 지표는?	
7	차량 주행 패턴을 실시간으로 군집화하는 시스템에서 군집이 점점 흐려지는지 운영 중 빠르게 감시하려고 한다.	

Quiz: Clustering 평가 지표

1. WCSS
2. Silhouette
3. DB Index
4. ARI

번호	문제	지표
1	고객 세그먼트를 군집화한 뒤, 각 그룹이 내부적으로 잘 뭉쳐 있고 다른 그룹과 명확히 분리되었는지 평가하려고 한다. -1에서 1 사이 값으로 해석되는 지표는?	Silhouette
2	실시간 교통 흐름 데이터를 계속 군집화하면서, 계산 비용을 낮게 유지한 채 군집 품질을 빠르게 모니터링하려고 한다. 낮을수록 좋은 지표는?	DB Index
3	LiDAR 점구름 데이터를 몇 개의 장애물 그룹으로 나눌지 결정하려고 한다. K를 바꿔가며 군집 중심까지의 거리 제곱합 감소폭을 확인하려고 한다	Inertia / WCSS
4	K-means에서 K를 늘릴수록 오차가 줄어드는데, 어느 지점부터 개선 폭이 완만해지는지 확인하여 적정 군집 수를 정하려고 한다. 적합한 지표는?	Inertia / WCSS
5	새로 개발한 군집화 알고리즘이 실제 품종 라벨이 있는 꽃 데이터셋에서 얼마나 잘 그룹을 나누는지 확인하려고 한다. 예측 군집과 정답 레이블의 일치도를 평가하는 지표는?	ARI
6	문서들을 주제별로 자동 군집화했는데, 한 문서가 자기 군집에 더 가까운지 아니면 인접 군집에 더 가까운지 확인하고 싶다. 적합한 지표는?	Silhouette
7	차량 주행 패턴을 실시간으로 군집화하는 시스템에서 군집이 점점 흐려지는지 운영 중 빠르게 감시하려고 한다.	DB Index

평가 지표: Recommendation

지표	정의	적용 상황	적용 상황 예 (e-커머스)
Recall@K	전체 정답 아이템 중 상위 K개 안에 포함된 정답의 비율	제한된 화면(Slot) 내에 사용자가 원하는 것이 하나라도 있는지	[메인 하단 추천 슬롯] '이 상품은 어때요?' 상단 5개 슬롯 안에 고객이 장바구니에 담은 상품이 포함되었는지 확인
MRR	사용자가 처음으로 선택한 정답의 순위 역수를 평균한 값	사용자가 가장 원하는 정답을 먼저 추천하였는지	[목적성 상품 검색] '갤럭시 S24 케이스' 검색 시, 고객이 처음 클릭한 상품이 평균 몇 위에 있는지 측정
NDCG	상위 순위에 가중치를 둔 관련성 점수를 합산하고 정규화한 값	추천의 순위 (Ranking)가 사용자 기대와 일치하는지	[검색 결과 정렬] '노트북' 검색 시, 실제 구매 전환율이 높은 인기 모델이 1~3위에 배치되었는지 확인
Coverage	전체 상품(카탈로그) 중 최소 한 번 이상 추천 리스트에 포함된 비율	전체 상품 중에 차별(추천되지 않는) 상품은 얼마나 되는지	[카탈로그 순환율] 우리 물의 전체 신발 품목 1만 종 중, 지난 24시간 동안 추천 로직에 노출된 품목 비중 측정

* NDCG: Normalized Discounted Cumulative Gain

* MRR: Mean Reciprocal Rank

평가 지표: Recommendation

지표	정의	적용 상황
NDCG 	상위 순위에 가중치를 두어 관련성 점수를 합산하고 정규화한 값 NDCG: Normalized Discounted Cumulative Gain 	 추천의 순위(Ranking)가 사용자 기대와 일치하는지
MRR 	사용자가 처음으로 선택한 정답의 순위 역수($1/\text{rank}$)를 평균한 값 MRR: Mean Reciprocal Rank 	 사용자가 가장 원하는 정답을 먼저 추천하였는지
Recall@K 	전체 정답 아이템 중 상위 K개 안에 포함된 정답의 비율 원하는 상품 	 제한된 화면(Slot) 내에 사용자가 원하는 것이 하나라도 있는지
Coverage 	전체 상품(카탈로그) 중 최소 한 번 이상 추천 리스트에 포함된 비율  ☒ 추천에 노출된 상품 ☐ 노출되지 않은 상품	 전체 상품 중에 차별(추천되지 않는) 상품은 얼마나 되는지

평가 지표 가이드라인: Recommendation

관점	관점 설명	지표	수치 범위 및 해석
제한된 슬롯 관점	"제한된 화면(K개) 안에 사용자가 좋아할 만한 게 하나라도 있나요?"	Recall@K	[0 ~ 1] · 0.7 : 사용자가 선호하는 전체 아이템 중 70%를 상위 K개 안에 찾아냄.
검색 효율성	"사용자가 원하는 정답을 얼마나 '첫 번째'에 가깝게 배치했나요?"	MRR	[0 ~ 1] · 0.5 : 사용자가 원하는 첫 번째 정답이 평균적으로 2위(1/2)에 위치함.
랭킹의 완성도	"관련성이 높은 아이템일수록 상단에 배치되는 '황금 순서'를 지켰나요?"	NDCG	[0 ~ 1] · 0.8 : 이상적인 정답 순서 대비 현재 모델의 순서가 80% 정도의 품질을 가짐.
추천의 다양성	"인기 상품만 고집하지 않고, 우리가 가진 자산을 골고루 보여주나요?"	Coverage	[0 ~ 100%] · 20% : 전체 상품 중 20%만 추천에 활용됨 (나머지 80%는 사장됨).

* NDCG: Normalized Discounted Cumulative Gain

* MRR: Mean Reciprocal Rank

Quiz: Recommendation 평가 지표

1. Recall@K
2. MRR
3. NDCG
4. Coverage

번호	문제	지표
1	'노트북' 검색 결과에서 실제 구매 전환 가능성이 높은 상품이 1~3위에 잘 배치되었는지 평가하려고 한다. 상위 순위일수록 더 큰 가중치를 주는 지표는?	
2	사용자가 원하는 상품을 추천 목록에서 처음 클릭한 위치가 평균적으로 몇 번째인지 평가하려고 한다. 가장 적합한 지표는?	
3	메인 화면의 추천 슬롯 5개 안에 사용자가 실제로 관심 가질 만한 상품이 포함되었는지 평가하려고 한다. 상위 K개 안의 정답 포함 비율을 보는 지표는?	
4	전체 상품 1만 개 중 지난 24시간 동안 추천 목록에 한 번이라도 노출된 상품 비율을 평가하려고 한다. 적합한 지표는?	
5	추천 결과에서 관련 상품이 단순히 포함되었는지만이 아니라, 더 관련성 높은 상품이 더 위에 배치되었는지를 평가하려고 한다. 적합한 지표는?	
6	'갤럭시 S26 케이스'처럼 사용자의 목적이 명확한 검색에서, 사용자가 처음 선택한 정답 상품이 얼마나 앞쪽에 나오는지 평가하려고 한다.	
7	'이 상품은 어때요?' 추천 영역에서 상위 10개 상품 중 사용자가 실제 구매하거나 장바구니에 담을 상품이 포함되었는지 확인하려고 한다.	
8	추천 시스템이 인기 상품만 반복적으로 노출하는지, 아니면 전체 카탈로그의 다양한 상품을 추천하는지 평가하려고 한다.	

Quiz: Recommendation 평가 지표





1. Recall@K
2. MRR
3. NDCG
4. Coverage

번호	문제	지표
1	'노트북' 검색 결과에서 실제 구매 전환 가능성이 높은 상품이 1~3위에 잘 배치되었는지 평가하려고 한다. 상위 순위일수록 더 큰 가중치를 주는 지표는?	NDCG
2	사용자가 원하는 상품을 추천 목록에서 처음 클릭한 위치가 평균적으로 몇 번째인지 평가하려고 한다. 가장 적합한 지표는?	MRR
3	메인 화면의 추천 슬롯 5개 안에 사용자가 실제로 관심 가질 만한 상품이 포함되었는지 평가하려고 한다. 상위 K개 안의 정답 포함 비율을 보는 지표는?	Recall@K
4	전체 상품 1만 개 중 지난 24시간 동안 추천 목록에 한 번이라도 노출된 상품 비율을 평가하려고 한다. 적합한 지표는?	Coverage
5	추천 결과에서 관련 상품이 단순히 포함되었는지만이 아니라, 더 관련성 높은 상품이 더 위에 배치되었는지를 평가하려고 한다. 적합한 지표는?	NDCG
6	'갤럭시 S26 케이스'처럼 사용자의 목적이 명확한 검색에서, 사용자가 처음 선택한 정답 상품이 얼마나 앞쪽에 나오는지 평가하려고 한다.	MRR
7	'이 상품은 어때요?' 추천 영역에서 상위 10개 상품 중 사용자가 실제 구매하거나 장바구니에 담을 상품이 포함되었는지 확인하려고 한다.	Recall@K
8	추천 시스템이 인기 상품만 반복적으로 노출하는지, 아니면 전체 카탈로그의 다양한 상품을 추천하는지 평가하려고 한다.	Coverage

평가 지표: 텍스트 생성

분류	평가 방법	대표 지표	설명
전통적 NLP 지표	Reference-based 정답 비교	BLEU, ROUGE, METEOR BERTScore, Cosine Similarity	정답 또는 참조 문장과 생성 답변을 비교하여 단어 겹침, 문장 구조, 의미 유사도를 평가
LLM 특화 지표	Reference-free / Factuality / Judge-based	G-Eval, Accuracy, FActScore, Hallucination Rate	생성 답변을 원자 사실 단위로 분해해 검증하거나, LLM 평가자가 루브릭에 따라 논리성·사실성·유창성·지시 준수 여부를 평가하며, 실제 운영 질의 샘플을 통해 환각률을 측정
RAG 특화 지표	Systemic-Triad 파이프라인 평가	Faithfulness, Answer Relevance, Context Relevance	질문, 검색 문맥, 생성 답변 간의 관계를 기준으로 답변이 검색 근거에 충실한지, 질문에 적절한지, 검색 문맥이 충분하고 관련성이 높은지 평가

전통적 NLP 지표


구분	주요 지표	설명 및 핵심 특징	비고
어휘적 유사도 (Lexical) 	BLEU, ROUGE BLEU Precision 기반: 생성한 내용이 얼마나 정확한가? ROUGE Recall 기반: 정답 내용을 얼마나 포함하고 있는가?	Reference 문장과 생성 문장 간의 단어 겹침(n-gram overlap) 빈도를 수학적으로 산출함. 	 단순 매칭 중심이며 문맥 반영 미흡함. 최근 LLM 평가 비중 감소함.
언어적 유사도 (Linguistic) 	METEOR 	Reference 문장의 어근(Stemming) 및 유의어를 고려하여 생성 문장과와의 정렬(Alignment) 품질을 평가함. 	 인간의 판단과 상관관계 높음. 유연한 문장 품질 평가 시 유리함.
의미적 유사도 (Semantic) 	BERTScore, Cosine Similarity 토큰 단위 문장 단위 Reference 임베딩 Generated 임베딩 	Reference와 생성 문장을 임베딩 공간에 투영하여 두 벡터 간의 거리(유사도)를 측정함.  Cosine Similarity (거리/유사도 측정)	 어휘가 달라도 문장의 의미적 일치 여부를 판별함.

LLM 특화 지표

구분	주요 지표	설명	비고
생성/추론 품질 (LLM-as-a-Judge)	G-Eval	상위 모델(GPT-4o 등)이 단계별 평가 절차와 구체적인 평가기준을 바탕으로 생성물의 논리성, 유창성 등을 인간처럼 다각도로 평가함.	- 인간 판단과 가장 높은 상관관계 보임 - 정답(Reference)이 없어도 평가 가능 - 판정 모델의 비용 및 편향 주의 필요함.
사실 관계 무결성 (Factuality)	FActScore	생성된 문장을 여러 개의 '원자 사실(Atomic Facts)'로 분해 후, 각 사실의 진위 여부를 외부 지식 소스(Wikipedia 등)와 대조하여 정확도를 측정함.	- 장문 생성물의 환각 탐지에 매우 강력함. - 신뢰할 수 있는 지식 소스(External Reference) 연동이 필수적임.

RAG 특화 지표


❖ RAG Triad (by TruLens)



용어	측정 관계	설명
Context Relevance	Query ↔ Context	검색된 문맥이 사용자의 질문에 답하기 위해 얼마나 적절하고 충분한 정보를 포함하고 있는지 측정
Groundedness	Context ↔ Answer	생성된 답변이 오직 검색된 문맥에만 근거하고 있는지 확인하며, 모델의 내부 지식으로 인한 환각을 방지
Answer Relevance	Query ↔ Answer	최종 답변이 사용자의 원래 질문 의도에 얼마나 부합하며 유용한 정보를 제공하는지 평가

RAG 특화 지표

❖ RAG Triad (by TruLens)




RAGAS 평가 지표 (by RAGAS Framework)

RAGAS (Retrieval Augmented Generation Assessment)

An open-source framework designed specifically to evaluate, test, and monitor LLM applications built on RAG

분류	용어	RAG Triad 용어	설명												
 Generation (생성 단계)	Faithfulness 	Groundedness (근거 충실도) 	답변이 주어진 문맥(Context)에 얼마나 ‘충실’한가 (근거 기반 여부)를 측정함. 문맥 (Context)  ↔ 답변 (Answer)  문맥에 기반한 답변 생성 여부												
	Answer Relevance 	Answer Relevance (답변 관련성) 	답변이 질문(사용자 의도)과 얼마나 ‘관련’ 있는가를 측정함. 질문 (Question)  ↔ 답변 (Answer)  질문과 관련된 답변 여부												
 Retrieval (검색 단계)	Context Precision 	Context Relevance (문맥 정밀도) 	검색된 문서 중 정답과 관련된 정보가 상위에 랭킹되었는지(정밀도)를 측정함. 검색 결과 (Ranking)<table><tr><td>1</td><td></td><td></td></tr><tr><td>2</td><td></td><td></td></tr><tr><td>3</td><td></td><td></td></tr><tr><td colspan="3">...</td></tr></table> 관련 정보가 상위에 랭킹되었는가?	1			2			3			...		
	1														
2															
3															
...															
Context Recall 	(Triad에는 직접 대응 없음) 	실제 정답을 내기 위해 필요한 모든 정보가 검색 결과에 포함되었는지 (재현율)를 측정함. 필요한 정보 (정답 구성 요소)<table><tr><td></td><td></td><td></td><td></td></tr></table> 검색 결과에 모두 포함되었는가?													
															

평가 지표 가이드: 텍스트 생성

상황	권장 지표	설명	비고
 정밀 텍스트 생성 (번역, 기술 문서)	BLEU / METEOR	• BLEU: n-gram 일치도를 통해 용어 선택의 정확성 측정 • METEOR: 유의어 / 어근 매칭으로 의미 전달의 유연성 보완	Reference (정답) Generated (생성 문장)  ✓ Reference(정답)가 명확한 '클래식' 태스크에 필수적임
 정보 압축 서비스 (요약, 본문 추출)	ROUGE-N / L	• Recall 기반: 원문의 핵심 정보 (N-gram)와 문장 구조(LCS)가 요약문에 얼마나 보존되었는지 측정함	원문 (Source) 요약문 (Summary)  ✓ 원문 내용의 누락 없는 전달 여부가 핵심 평가지표임
 대화형/창의적 지능 (챗봇, 개인화 답변)	BERTScore / G-Eval	• Semantic & Reasoning: 벡터 공간의 의미 유사도(BERTScore)와 상위 모델의 논리 비평(G-Eval)을 병행함	Reference (여러 가능 답변) Generated (생성 답변)  ✓ 정답이 하나가 아닌 가변적 응답의 품질을 다각도로 평가함
 RAG 시스템 신뢰성 (지식 기반 답변)	RAGAS (Triad)	• 인과적 무결성: Faithfulness, Relevance, Precision을 통해 [질문-문맥-답변] 간의 논리적 결합을 검증함	질문 검색된 문맥 생성된 답변  ✓ 파이프라인 내 검색과 생성의 결합 품질을 총합 진단함
 핵심 요약  정답(Reference)이 명확하면 전통적 지표(BLEU, ROUGE 등)  정답이 가변적이면 의미 기반 지표(BERTScore, G-Eval)  RAG과 같은 파이프라인은 RAGAS로 종합 검증			

Quiz: 텍스트 평가 지표

1. BLEU
2. METOR
3. ROUGE
4. BERTScore
5. CosineSimilarity
6. Groundness
7. Answer Relevance
8. Context Relevance

번호	문제	지표
1	기계번역 결과가 reference 문장과 얼마나 많은 n-gram을 정확히 공유하는지, 특히 생성 문장의 단어 선택 정밀도를 평가하려고 한다.	
2	문서 요약 결과가 원문의 핵심 표현과 내용을 얼마나 많이 포함했는지, 즉 reference의 정보를 얼마나 빠뜨리지 않았는지 평가하려고 한다.	
3	생성 문장이 reference와 단어가 완전히 같지는 않지만, 어근이나 유의어까지 고려하여 문장 정렬 품질을 평가하려고 한다.	
4	reference 문장과 생성 문장을 각각 하나의 문장 벡터로 변환한 뒤, 두 문장의 전체 의미가 얼마나 가까운지 비교하려고 한다.	
5	reference와 생성 문장을 토큰 단위로 비교하되, 단어가 달라도 의미적으로 대응되는 표현이면 높은 점수를 주고 싶다.	
6	RAG 답변이 검색된 문서나 제공된 문맥에 실제로 근거하고 있는지, 문맥에 없는 내용을 만들어내지 않았는지 평가하려고 한다.	
7	생성된 답변이 사용자의 질문에 직접적으로 관련 있는지, 질문과 상관없는 내용을 포함하지 않는지 평가하려고 한다.	
8	검색 단계에서 가져온 문서들이 정답 생성에 필요한 정보와 관련이 높은지, 특히 관련 문서가 상위에 잘 배치되었는지 평가하려고 한다.	

Quiz: 텍스트 평가 지표

1. BLEU
2. METOR
3. ROUGE
4. BERTScore
5. CosineSimilarity
6. Groundness
7. Answer Relevance
8. Context Relevance

번호	문제	지표
1	기계번역 결과가 reference 문장과 얼마나 많은 n-gram을 정확히 공유하는지, 특히 생성 문장의 단어 선택 정밀도를 평가하려고 한다.	BLEU
2	문서 요약 결과가 원문의 핵심 표현과 내용을 얼마나 많이 포함했는지, 즉 reference의 정보를 얼마나 빠뜨리지 않았는지 평가하려고 한다.	ROUGE
3	생성 문장이 reference와 단어가 완전히 같지는 않지만, 어근이나 유의어까지 고려하여 문장 정렬 품질을 평가하려고 한다.	METEOR
4	reference 문장과 생성 문장을 각각 하나의 문장 벡터로 변환한 뒤, 두 문장의 전체 의미가 얼마나 가까운지 비교하려고 한다.	Cosine Similarity
5	reference와 생성 문장을 토큰 단위로 비교하되, 단어가 달라도 의미적으로 대응되는 표현이면 높은 점수를 주고 싶다.	BERTScore
6	RAG 답변이 검색된 문서나 제공된 문맥에 실제로 근거하고 있는지, 문맥에 없는 내용을 만들어내지 않았는지 평가하려고 한다.	Groundedness
7	생성된 답변이 사용자의 질문에 직접적으로 관련 있는지, 질문과 상관없는 내용을 포함하지 않는지 평가하려고 한다.	Answer Relevance
8	검색 단계에서 가져온 문서들이 정답 생성에 필요한 정보와 관련이 높은지, 특히 관련 문서가 상위에 잘 배치되었는지 평가하려고 한다.	Context Relevance

LLM 텍스트 평가 관점

- ❖ ChatGPT, Gemini, Grok 같은 상용 LLM은 품질을 단순히 “정답률” 하나로 평가하지 않음
- ❖ System card와 model card를 보면 대체로 다음과 같은 관점으로 평가를 수행함

평가 관점	평가 목적
일반 능력	지식, 추론, 코딩, 수학, 멀티모달, 긴 문맥, 에이전트 작업
사실성/환각	잘못된 사실 생성, Unsupported answer, Hallucination rate
안전성	유해 요청 거절, 과잉 거절, Jailbreak 저항성
프라이버시	개인정보 학습/노출 위험, Prompt injection에 의한 데이터 유출
공정성/편향	인구통계 편향, 정치적 편향, Stereotyping

평가 지표: 이미지 생성

지표	정의 및 특성	적용 상황	적용 상황 예
FID	실제와 생성 이미지 집단 간의 통계적 분포 차이 를 측정	생성된 이미지 전체 데이터셋의 실사도와 통계적 수렴도를 평가할 때	[자율주행 시뮬레이션] 가상으로 생성한 도로 주행 영상 데이터셋이 실제 도로 환경의 통계적 분포와 일치하는지 검증
IS	개별 이미지의 선명도 와 전체 집단의 다양성 을 동시에 측정	모델이 범주별 특징을 명확하게 구분하여 골고루 생성하는지 확인할 때	[커머스 가상 시연] 의류 생성 모델이 '상의', '하의' 등을 모호하지 않고 뚜렷하게 생성하며, 특정 품목에 치우치지 않는지 평가
SSIM	휘도, 대비, 구조적 특성을 활용한 픽셀 기반 유사도 계산	원본 대비 기하학적 왜곡이나 질감 손상 이 없어야 하는 고정밀 복원 분야	[의료 영상 및 보안] MRI 초해상도 복원이나 야간 감시 영상 개선 시, 해부학적 구조나 경계선이 왜곡 없이 유지되었는지 정밀 검증
LPIPS	딥러닝 피쳐 맵 을 통해 인간의 시각적 판단 과 유사한 오차 측정	픽셀 값의 미세한 차이보다 사람이 느끼는 자연스러움 과 심미적 품질이 중요할 때	[콘텐츠 생성/압축] 생성 AI 기반 화풍 변환(Style Transfer)이나 고효율 영상 압축 후, 사람이 보기에 화질 저하가 체감되는지 평가

평가 지표 가이드라인: 이미지 생성

핵심 비교 관점	지표 설명	판단 기준
통계적 분포 vs 개별 품질	FID 는 실제 데이터셋과의 분포 거리를 측정하여 모드 붕괴(Mode Collapse)나 환각을 감지하는 표준 지표인 반면, IS 는 생성된 개별 이미지의 범주 명확성과 집단 내 다양성을 측정함.	FID: 낮음 (↓) IS: 높음 (↑)
물리적 정밀도 vs 인지적 유사도	SSIM 은 휘도, 대비 등 기하학적 구조의 왜곡을 정밀 검증(의료/보안 등)하며, LPIPS 는 딥러닝 피쳐 맵을 활용해 인간이 느끼는 시각적 자연스러움과 심미적 품질을 수치화함.	SSIM: 1에 근접 (↑) LPIPS: 낮음 (↓)
도메인별 지표 채택 전략	정밀한 기하학적 복원이 생명인 도메인(V&V 강조) → SSIM 을 주지표 사용 인간과의 상호작용 및 실사도가 중요한 콘텐츠 생성 도메인 → FID 와 LPIPS 를 핵심 지표로 설정	

Quiz: Classification 평가 지표

번호	문제	Task 유형	지표
1	자율주행 인지 모델이 전방 객체를 차량, 보행자, 이륜차, 표지판으로 분류한다. 특히 실제 보행자를 놓치면 치명적이므로, 실제 보행자 중 모델이 얼마나 많이 보행자로 탐지했는지를 평가하려고 한다.		
2	스마트공장 설비에서 모터 온도를 예측하는 모델을 평가한다. 큰 예측 오차는 설비 손상으로 이어질 수 있으므로, 큰 오차에 더 강한 패널티를 주고 싶다.		
3	고객 행동 데이터를 기반으로 고객 세그먼트를 자동 군집화했다. 각 군집 내부는 잘 뭉쳐 있고, 서로 다른 군집은 명확히 분리되었는지 평가하려고 한다.		
4	e-커머스 메인 화면의 추천 슬롯 5개 안에 사용자가 실제로 클릭하거나 장바구니에 담은 상품이 포함되었는지 평가하려고 한다.		
5	RAG 기반 고객지원 챗봇이 검색된 매뉴얼 문서를 근거로 답변한다. 답변이 제공된 문서 내용에 충실하며, 문서에 없는 내용을 만들어내지 않았는지 평가하려고 한다.		

Quiz: Classification 평가 지표

번호	문제	Task 유형	지표
1	자율주행 인지 모델이 전방 객체를 차량, 보행자, 이륜차, 표지판으로 분류한다. 특히 실제 보행자를 놓치면 치명적이므로, 실제 보행자 중 모델이 얼마나 많이 보행자로 탐지했는지를 평가하려고 한다.	Classification	Recall
2	스마트공장 설비에서 모터 온도를 예측하는 모델을 평가한다. 큰 예측 오차는 설비 손상으로 이어질 수 있으므로, 큰 오차에 더 강한 페널티를 주고 싶다.	Regression	MSE
3	고객 행동 데이터를 기반으로 고객 세그먼트를 자동 군집화했다. 각 군집 내부는 잘 뭉쳐 있고, 서로 다른 군집은 명확히 분리되었는지 평가하려고 한다.	Clustering	Silhouette
4	e-커머스 메인 화면의 추천 슬롯 5개 안에 사용자가 실제로 클릭하거나 장바구니에 담은 상품이 포함되었는지 평가하려고 한다.	Recommendation	Recall@K
5	RAG 기반 고객지원 챗봇이 검색된 매뉴얼 문서를 근거로 답변한다. 답변이 제공된 문서 내용에 충실하며, 문서에 없는 내용을 만들어내지 않았는지 평가하려고 한다.	텍스트 생성	Faithfulness / Groundedness

Quiz: Classification 평가 지표

번호	문제	Task 유형	지표
6	금융 사기 탐지 모델이 거래를 정상 또는 사기로 분류한다. 사기 거래는 전체의 0.1%로 매우 희귀하므로, ROC-AUC보다 희귀한 Positive 탐지 성능을 더 민감하게 평가하고 싶다.		
7	자율주행 차량이 선행 차량과의 거리를 예측한다. 예측 오차를 실제 물리 단위인 m로 해석하여 운전자나 제어 시스템이 직관적으로 이해할 수 있게 평가하려고 한다.		
8	LiDAR 점구름 데이터를 장애물 후보 그룹으로 군집화하려고 한다. 군집 수 K를 3, 4, 5, 6으로 바꿔 보면서 오차 감소폭이 완만해지는 지점을 찾아 적절한 K를 결정하고자 한다.		
9	영화 추천 시스템에서 사용자가 높게 평가할 가능성이 큰 영화들이 추천 리스트 상단에 얼마나 잘 배치되었는지 평가하려고 한다. 상위 순위에 더 큰 가중치를 주는 지표는?		
10	기술 문서 번역 시스템이 생성한 번역문이 reference 번역문과 얼마나 유사한지 평가하려고 한다. 특히 용어 선택과 n-gram 단위의 표현 일치도를 정밀하게 보고 싶다.		

Quiz: Classification 평가 지표

번호	문제	Task 유형	지표
6	금융 사기 탐지 모델이 거래를 정상 또는 사기로 분류한다. 사기 거래는 전체의 0.1%로 매우 희귀하므로, ROC-AUC보다 희귀한 Positive 탐지 성능을 더 민감하게 평가하고 싶다.	Classification	PR-AUC
7	자율주행 차량이 선행 차량과의 거리를 예측한다. 예측 오차를 실제 물리 단위인 m로 해석하여 운전자나 제어 시스템이 직관적으로 이해할 수 있게 평가하려고 한다.	Regression	RMSE
8	LiDAR 점구름 데이터를 장애물 후보 그룹으로 군집화하려고 한다. 군집 수 K를 3, 4, 5, 6으로 바꿔 보면서 오차 감소폭이 완만해지는 지점을 찾아 적절한 K를 결정하고자 한다.	Clustering	Inertia / WCSS
9	영화 추천 시스템에서 사용자가 높게 평가할 가능성이 큰 영화들이 추천 리스트 상단에 얼마나 잘 배치되었는지 평가하려고 한다. 상위 순위에 더 큰 가중치를 주는 지표는?	Recommendation	NDCG
10	기술 문서 번역 시스템이 생성한 번역문이 reference 번역문과 얼마나 유사한지 평가하려고 한다. 특히 용어 선택과 n-gram 단위의 표현 일치도를 정밀하게 보고 싶다.	텍스트 생성	BLEU

기능 정확성 QA 시나리오

기능 정확성 QA 시나리오

항목	설명
Source	사용자, 외부 시스템, 센서(카메라/라이다 등) 내부 타이머
Stimulus	정상(Normal) 데이터: 일반(Ordinary) 값, 경계(Marginal) 값
Artifact	AI-based System, AI System, AI 추론 엔진
Environment	정상 운영 상태
Response	정상 데이터에 대한 기대되는 추론 결과 산출
Response Measure	Task 유형 별 평가 지표

정상(Normal) 데이터 유형

❖ Ordinary: 안정적 추론 영역 ❖ Marginal: 드문 경계 사례

1 일반값 (Ordinary Data)

Common · 학습 데이터에서 빈번함 / 대표성 높음

모델이 학습한 통계적 분포의 중심부에 있으며,
정답 판단에 필요한 핵심 피쳐도 충분히 포함된 일반적 입력



차체 윤곽 명확

전면/측면 식별 가능

핵심 피쳐 충분

비유: 맑은 날 도로 위를 주행하는 승용차

2 경계값 (Marginal Data / Edge Case)

Uncommon · 학습 데이터에서 드뭄 / 대표성 낮음

드문 상황이지만 정답 판단에 필요한 핵심 피쳐는 남아 있어,
모델이 조심스럽게 일반화해야 하는 입력



일부 가려짐

멀리 있음

그래도 핵심
단서 식별 가능

비유: 멀리 있거나 일부 가려졌지만 차량 핵심 단서는 식별 가능

도로 객체 및 교통 표지판 인식

❖ [정확성 요구사항]

- 시스템은 주행 중 센서에 포착된 도로 위 객체(보행자, 차량)와 교통 표지판 종류를 식별하고 정확한 범주로 분류해야 한다.

항목	기능 정확성 관점 예
Source	카메라 및 LiDAR 센서
Stimulus	일반적 상황(주간/야간 및 기상 조건(맑음, 우천 등)에서의 영상
Artifact	도로 객체 인식 모듈
Environment	정상 동작 상태
Response	영상에서 추출된 각 객체에 대해 '보행자', '차량', '표지판 종류' 등의 레이블을 부여함
Response Measure	• mAP (mean Average Precision): 95% 이상 달성 • 보행자 재현율 (Recall): 99.9% 이상 확보 (미탐 방지)

조향각 및 주행 속도 결정

❖ [정확성 요구사항]

- 시스템은 경로를 유지하기 위해 차선 중심선 좌표, 도로 곡률, 전방 차량과의 목표 이격 거리를 바탕으로 차량의 조향각과 속도를 정밀하게 출력해야 한다

항목	기능 정확성 관점 예
Source	경로 계획(Planning) 모듈
Stimulus	
Artifact	주행 제어 모듈
Environment	정상 동작 상태
Response	
Response Measure	

조향각 및 주행 속도 결정

❖ [정확성 요구사항]

- 시스템은 경로를 유지하기 위해 차선 중심선 좌표, 도로 곡률, 전방 차량과의 목표 이격 거리를 바탕으로 차량의 조향각과 속도를 정밀하게 출력해야 한다

항목	기능 정확성 관점 예
Source	경로 계획(Planning) 모듈
Stimulus	차선 중심선 좌표, 곡률 정보, 전방 차량과의 목표 이격 거리
Artifact	주행 제어 모듈
Environment	정상 동작 상태
Response	조향각과 속도 출력
Response Measure	• 목표 조향각 대비 실제 출력값의 RMSE ≤ 0.1 rad • 목표 속도 대비 실제 결정 속도의 MAE ≤ 0.5 km/h

기능 정확성 테스트 케이스 설계

테스트 케이스 생성 기법

❖ 목적

- 무한에 가까운 입력 조합 중 결함을 효과적으로 찾아낼 수 있는 부분집합을 선택하는 방법

❖ 방법 1) 조합 테스트(Combinatorial testing)

- 핵심 기법 (Pairwise Testing): 대부분의 결함은 2개 정도의 파라미터 상호작용에서 발생한다는 연구에 기반하여, 모든 가능한 쌍(Pair)을 최소 한 번은 테스트함
- 예시: 자율주행차 테스트 시 [도로 유형, 날씨, 시간대, 센서 오염도]가 있을 때 이 중에서 2개의 파라미터만을 조합하여 테스트 케이스를 관리 가능한 수준으로 축소할 수 있음

❖ 방법 2) 탐색적 테스트 (Exploratory Testing)

- 개념: 사전 설계된 스크립트 없이 테스터가 시스템을 직접 조작하며 학습하고, 그 과정에서 즉석으로 테스트 케이스를 설계하고 실행함
- 장점: 사양서가 불명확한 애자일 환경이나 AI 모델의 예측 불가능한 동작을 창의적으로 찾아낼 때 유리함

❖ 방법 3) 리스크 관리 기반 테스트 (Risk Management)

- 개념: 식별된 위험 시나리오(예: 오작동 시 치명적 사고)를 중심으로 시스템의 방어 동작에 초점을 두고 테스트 케이스를 설계함

테스트 오라클 전략

❖ 테스트 오라클(Oracle) 문제

- 전통적인 소프트웨어는 $f(x) = y$ 가 명확하지만, AI는 y 를 사전에 확정하기 어려움

❖ 테스트 오라클 문제에 대한 접근 방법

- '절대적 정답' 대신 '상대적 일관성'이나 '비교 우위'를 통해 오라클 문제를 접근함

기법	오라클의 성격	주요 이점
벤치마킹	기구축된 정답	객관적인 성능 지표 확보 가능
변형 테스트	논리적 일관성	정답 데이터 없이도 테스트 가능
전문가 패널	집단 지성	가장 높은 수준의 신뢰성 보장
백투백 테스트	상대적 차이	기존 자산 활용, 차이점 식별 용이
A/B 테스트	통계적 우위	실환경에서의 실질적 성능 확인

벤치마킹

❖ 정의

- 이미 표준화된 고품질의 공개 데이터셋(Ground Truth 포함)을 활용하여 모델의 정확성을 평가

❖ 오라클 문제 해결

- 데이터 구축 단계에서 이미 확보한 '라벨링된 정답(Golden Set)'을 테스트 오라클로 활용

❖ [사례] 표지판 인식

- 방법: Waymo Open Dataset이나 KITTI와 같이 정답이 포함된 공개 벤치마크 데이터 사용
- 결과: 데이터셋에 '80km 제한 표지판'으로 라벨링된 지점에서 모델이 동일한 값을 출력하는지 확인


벤치마킹

❖ 대표적인 벤치마크

Task 유형	벤치마크
분류	이미지: ImageNet, GTSRB 텍스트: GLUE, MMLU
객체 탐지·세그멘테이션	이미지: COCO, Cityscapes 자율주행 멀티센서: KITTI, Waymo, nuScenes, BDD100K
회귀·예측	주행 시퀀스·궤적·센서: KITTI, Argoverse, Waymo
이상 탐지	산업 이미지: MVTec AD 시계열: NAB
추천·랭킹	평점 데이터: MovieLens 광고 클릭 로그: Criteo
음성 인식	음성+전사 텍스트: LibriSpeech

Metamorphic Testing (변형 테스트)

	내용
정의	입력값을 특정 규칙에 따라 변형했을 때, 출력값도 그에 대응하는 변형 관계(Metamorphic Relation) 를 유지하는지 확인
오라클 문제 해결 방법	정답(y)이 무엇인지 몰라도, “ 입력이 A에서 A'로 변했을 때 출력도 B에서 B'로 변해야 한다 ”는 논리적 관계만으로 정답 유무를 판단
사례	장애물 인식 - 변형: 맑은 날 촬영된 보행자 영상에 ‘안개 필터’를 입히거나 이미지를 좌우로 반전시킴 - 기대 관계: 원본에서 ‘보행자’로 분류했다면, 안개가 끼거나 반전되어도 여전히 ‘보행자’로 분류해야 함



전문가 패널 방법

❖ 정의

- AI의 판단 결과에 대해 해당 분야의 전문가들이 모여 타당성을 검토하고 최종 합의안을 도출

❖ 오라클 문제 해결

- 인간의 전문 지식을 최상위 오라클로 설정하여, 기계가 판단하기 모호한 경계 케이스(Edge Cases)에 대한 정답을 확정

❖ [사례] 장애물 인식:

- 방법: 눈에 파묻힌 차량이나 특이한 복장을 한 보행자처럼 AI가 헛갈려 하는 영상을 추출
- 결과: 숙련된 운전자나 사고 분석 전문가 5명이 영상을 보고 "이것은 보행자로 간주해야 함"이라고 합의하면, 그 합의안을 해당 테스트 케이스의 정답으로 설정

Back-to-back Testing


❖ 오라클 문제 해결

- 신뢰할 수 있는 기존 모델(Reference Model)을 '임시 오라클'로 삼아, 신규 모델과의 차이점을 검증


❖ [사례] 표지판 인식:

- 기존에 검증된 '표지판 인식 v1.0'과 신규 'v2.0'에 동일한 도로 영상을 입력
- 두 모델이 모두 '정지 표지판'으로 인식하면 통과, v1.0은 '정지'인데 v2.0은 '속도 제한'으로 인식하면 해당 케이스를 정밀 분석 대상으로 간주

테스트 절차



비교 결과 예시



A/B 테스트

❖ 오라클 문제 해결

- 개별 데이터에 대한 정답을 따지기보다, 통계적인 성과 지표의 우위로 기능적 우수성을 정의

❖ 사례: 장애물 인식:

- 방법: 가상 시뮬레이터에서 50%의 시나리오는 알고리즘 A를, 나머지 50%는 알고리즘 B를 적용하여 주행하게 함
- 결과: 모델 A보다 모델 B에서 '장애물 미인식으로 인한 급제동' 발생 건수가 통계적으로 유의미하게 적다면, 모델 B의 정확성이 더 높다고 판단



멀티 오라클 전략

- ❖ 하나의 기법이 아니라 여러 오라클 전략이 필요함.
- ❖ 예를 들어 모델 개발 단계에서는 다음과 같이 여러 기법을 적용함
 - 벤치마킹으로 기본 실력을 다지고
 - 변형 테스트로 강건성을 확인하며,
 - 판단이 어려운 모호한 케이스는 전문가 패널의 도움을 받아 정답셋을 확장

Q & A
