

강건성 **(Robustness)**

목차

- ❖ 강건성 개념
- ❖ 강건성 유형
- ❖ 강건성 예시
- ❖ 강건성 평가 지표
- ❖ 강건성 QA 시나리오
- ❖ 강건성 테스트 케이스 설계

강건성 개념

일반 시스템의 강건성 정의

Degree to which a system or component can function correctly in the presence of **invalid inputs or stressful environmental conditions**

❖ "비정상적인 입력 값이나 가혹한 실행 환경에서도 ... "

- **1. 무효한 입력에 대한(Invalid Inputs):**

- ✓ 잘못된 형식의 데이터, 규격을 벗어난 값, 혹은 예상치 못한 입력에 대해서 시스템이 중단되지 않고, 적절한 결과를 산출해야 함

- **2. 악조건 환경에 대한(Stressful Environmental Conditions):**

- ✓ 메모리 부족, 네트워크 단절, 과도한 트래픽 부하 등 가혹한 운영 환경 속에서도 시스템의 핵심 기능이 붕괴되지 않고 유지되는 회복 탄력성(Resilience)을 보여야함


강건성 수준

Degree to which a system or component **can function correctly** in the presence of invalid inputs or stressful environmental conditions

- ❖ 시스템이 명시된 기능을 허용 가능한 정확성·성능·안전 기준 안에서 계속 제공하는 능력

유형		의미
Nominal robustness		원래 요구된 기능적 정확성/성능 수준을 유지
Operational robustness	Fail-operational	핵심 기능 또는 mission capability를 계속 제공
	Fail-degraded / graceful degradation	정의된 degraded 요구 수준 (제한된 기능 및 낮아진 성능 등) 안에서 계속 동작
Fail-safe (강건성보다는 Safety에 해당됨)		원래 기능 수행을 중단/차단하고 안전 상태로 전이

강건성 수준 예시: 영상의회의 시스템



AI 시스템의 강건성

❖ "다양한 악조건 속에서도 시스템의 기능 정확성(Functional Correctness)을 유지할 수 있는 능력"

Robustness is a new sub-characteristic of reliability. It is used to describe the ability of a system to **maintain its level of functional correctness under any circumstances** including:

- 1) the presence of unseen, biased, adversarial or invalid data inputs;
- 2) external interference;
- 3) environmental conditions encompassing generalization, resilience, reliability;
- 4) attributes related to the proper operation of the system as intended by its developers.


[ISO/IEC 25059:2023 Quality model of AI-based systems]

AI 시스템의 강건성

❖ AI 시스템이 다음의 4대 위협 상황에서도 원래 설계된 기능 정확성을 유지하는 것을 의미함

유형	강건성 위협 요인
1) 비정상적 입력	학습 시 보지 못한 데이터(Unseen), 편향된 데이터(Biased), 악의적 공격(Adversarial), 혹은 손상/오염된 값(Invalid)이 입력되는 상황
2) 외부 간섭	시스템 외부에서 발생하는 비의도적인 잡음이나 의도적인 신호 교란이 있는 상황
3) 외부 환경	학습 및 운영 환경 조건의 변화 • 일반화: 학습환경의 변화(학습하지 않은 새로운 데이터)에도 잘 작동 • 회복력: 운영환경의 변화(장애나 공격이 발생)에도 정상 상태로 회복하는 능력
4) 추론 컴퓨팅 환경	의도한 동작과 관련된 하드웨어 자원이나 소프트웨어 플랫폼 등 시스템 특성의 변화

AI 시스템의 강건성 예



일반 시스템 강건성 vs AI 시스템 강건성 비교

		일반 SW 강건성	AI SW 강건성
핵심 목표		 기능 유지: 시스템이 명시된 기능을 허용 가능한 정확성·성능·안전 기준 안에서 계속 제공	 기능 정확성 유지: 모델의 추론 정확도 유지
	데이터 위협	 Invalid 데이터	 비정상 데이터: Unseen, Biased, Adversarial, Invalid 데이터
악조건	환경적 스트레스	 외부 간섭: 신호 간섭, 교란  외부 환경: 일반화 실패, 복원력 저하, 신뢰성 저하를 유발하는 운영 환경 변화  운영 환경: 지연 시간, 처리량, 데이터 최신성, 가용성 등 계획된 운영을 저해하는 속성 문제	
	실패 양상	 crash, hang, exception, data corruption, service unavailable	 misclassification, false positive/negative, hallucinated output, confidence error, OOD failure
기대 동작	 Nominal robustness →  Operational robustness: Fail-operational →  Fail-degraded / graceful degradation		

강건성 유형

강건성 유형

강건성 유형	설명
입력 데이터 강건성	미학습 데이터, 편향 데이터, 적대적 데이터, 무효한 데이터 등 비정상 입력 데이터가 주어져도 정확성 수준을 유지하는 능력
외부 간섭 강건성	외부의 물리적·전자기적 교란 환경 하에서 시스템 수집 채널(센서, 통신 인터페이스 등)을 통해 유입되는 데이터의 유효성을 검증하고 시스템의 동작 무결성을 유지하는 능력
외부 환경 강건성	데이터 분포 변화, 일시적 운영 환경 변화, 입력 장치의 장기적·점진적 변화 등으로 실제 운영 입력이 학습 시 가정과 달라지더라도, 정확성 수준을 유지하는 능력
추론 컴퓨팅 환경 강건성	AI 시스템을 구성하는 소프트웨어 로직과 하부 실행 인프라의 불안정한 변동 환경 하에서 전체 시스템의 정확성을 유지하는 능력

Quiz: 강건성 유형

1. 입력 데이터 강건성
2. 외부 간섭 강건성
3. 외부환경 강건성
4. 추론 컴퓨팅 환경 강건성

번호	문제	유형
1	강한 전자기 간섭으로 인해 LiDAR 센서 데이터 일부가 왜곡되었을 때 데이터의 유효성을 검증하고, 위험한 입력이 모델에 전달되지 않도록 차단하려 한다.	
2	의료 영상 판독 모델에 노이즈가 심한 영상, 일부 잘린 영상, 편향된 촬영 조건의 영상, 적대적 변조가 포함된 영상이 입력되어도 정확성을 최대한 유지하고자 함	
3	객체 인식 모델은 주로 도심·주간·맑은 날 데이터로 학습되었지만, 실제 운영에 서의 농촌 도로, 야간, 눈길에서도 인식 정확성을 유지하려 한다.	
4	공격자가 GPS 신호를 조작하여 차량 위치가 실제와 다르게 인식되도록 공격할 때 탐지하고, 잘못된 위치 정보가 주행 판단에 사용되지 않도록 해야 한다.	
5	같은 모델과 같은 입력을 사용했지만 GPU와 CPU 실행 환경에 따라 confidence 가 0.801과 0.797처럼 미세하게 달라져 threshold 근처에서 결과가 뒤집힌다. 이 를 margin zone과 출력 검증으로 안정화하려 한다.	
6	객체 인식 모델이 학습 데이터에서 거의 보지 못한 눈길의 이륜차를 만났지만, 이를 차량 또는 배경으로 오인하지 않고 올바르게 인식하도록 설계하려 한다.	
7	음성 명령 인식 시스템이 고속 주행 중 풍절음, 빗소리, 동승자 대화, 터널 반향 이 있는 상황에서도 운전자의 명령 의도를 안정적으로 인식하도록 한다.	
8	동적 배치 때문에 요청 대기 시간이 길어져 latency SLA를 초과한다. timeout, autoscaling, fallback server 등을 통해 정확성과 가용성을 유지하려 한다.	

Quiz: 강건성 유형

1. 입력 데이터 강건성
2. 외부 간섭 강건성
3. 외부환경 강건성
4. 추론 컴퓨팅 환경 강건성

번호	문제	유형
1	강한 전자기 간섭으로 인해 LiDAR 센서 데이터 일부가 왜곡되었을 때 데이터의 유효성을 검증하고, 위험한 입력이 모델에 전달되지 않도록 차단하려 한다.	외부 간섭 강건성
2	의료 영상 판독 모델에 노이즈가 심한 영상, 일부 잘린 영상, 편향된 촬영 조건의 영상, 적대적 변조가 포함된 영상이 입력되어도 정확성을 최대한 유지하고자 함	입력 데이터 강건성
3	객체 인식 모델은 주로 도심·주간·맑은 날 데이터로 학습되었지만, 실제 운영에 서의 농촌 도로, 야간, 눈길에서도 인식 정확성을 유지하려 한다.	외부 환경 강건성
4	공격자가 GPS 신호를 조작하여 차량 위치가 실제와 다르게 인식되도록 공격할 때 탐지하고, 잘못된 위치 정보가 주행 판단에 사용되지 않도록 해야 한다.	외부 간섭 강건성
5	같은 모델과 같은 입력을 사용했지만 GPU와 CPU 실행 환경에 따라 confidence 가 0.801과 0.797처럼 미세하게 달라져 threshold 근처에서 결과가 뒤집힌다. 이를 margin zone과 출력 검증으로 안정화하려 한다.	추론 컴퓨팅 환경 강건성
6	객체 인식 모델이 학습 데이터에서 거의 보지 못한 눈길의 이륜차를 만났지만, 이를 차량 또는 배경으로 오인하지 않고 올바르게 인식하도록 설계하려 한다.	입력 데이터 강건성
7	음성 명령 인식 시스템이 고속 주행 중 풍절음, 빗소리, 동승자 대화, 터널 반향이 있는 상황에서도 운전자의 명령 의도를 안정적으로 인식하도록 한다.	외부 환경 강건성
8	동적 배치 때문에 요청 대기 시간이 길어져 latency SLA를 초과한다. timeout, autoscaling, fallback server 등을 통해 정확성과 가용성을 유지하려 한다.	추론 컴퓨팅 환경 강건성

유형 1. 입력 데이터 강건성

- ❖ 입력 데이터의 통계적 변이, 분포 이탈, 맥락 편향, 의도적 조작 및 무결성 결함 환경 하에서도 기능 정확성을 유지하는 능력

데이터 유형	설명
Unseen 데이터	• 학습 데이터에서 충분히 관찰되지 않았거나(In-scope) • 운영 도메인 외부의 새로운 객체·상황(Out-of-scope=OOD) 데이터
Biased 데이터	학습 데이터에서 과도하게 형성된 지배적 상관관계(배경 맥락, 속성 조합 등)로 모델의 편향된(부정확한) 추론을 유발할 수 있는 비전형적인 데이터
Adversarial 데이터	인간에게는 정상적이거나 사소한 변화로 보일 수 있으나, 모델의 수학적 취약점을 의도적으로 공격하여 부정확한 추론을 유도하도록 조작된 데이터
Invalid 데이터	노이즈, 센서 결함, 통신 유실, 포맷 오류, 신호 품질 저하 등으로 인해 데이터의 형식, 구조, 신호 무결성, 의미적 일관성 또는 시간적 일관성이 훼손된 데이터

Example : 도로 객체 인식

데이터 유형	핵심 질문	예시	세부 상황	추론 신뢰성 저하 위험
Unseen / OOD	운영 도메인 안의 객체인가?	도로 위 캥거루, 낙타, 비정형 이동체	학습 데이터셋의 통계적 지지집합(Support)을 벗어난 비정형 조형물 및 사고로 인해 기하학적 구조가 완전히 변형된 차량 유입	모델이 정의된 객체 클래스로 분류하지 못하고 '배경'으로 오판하여 장애물 회피 기동 및 제어 로직 수행에 실패할 위험
Biased	맥락이 달라도 본질을 인식하는가?	잔디밭 위 자동차, 수영장 속 자동차, 눈 속 흰색 차량	특정 노면(아스팔트)과 객체 간의 지배적 상관관계 (Spurious Correlation)에 고착되어, 비포장도로나 모래사장 등 이질적 맥락 에 객체가 위치한 상황	모델이 객체의 본질적 특징 대신 배경과의 상관 관계에 의존하여 객체 인지 불능 상태에 빠질 위험
Adversarial	의도적 기만에 속지 않는가?	스티커가 붙은 정지 표지판, 레이저 공격, 특수 패턴 부착 차량	도로 표지판에 인간의 시각으로는 인지 불가능하나 모델의 수치적 취약점을 타격하도록 설계된 미세 섭동 스티커 부착	모델이 '정지' 신호를 '직진' 혹은 '속도 제한'으로 잘못 분류하여 교차로 내 치명적 안전 사고를 유발할 위험
Invalid	데이터가 온전하고 일관적인가?	픽셀 깨짐, 노이즈, 센서 가림, 패킷 누락, 모순된 센서값	센서 데이터 전송 프로토콜 오류 또는 하드웨어 결함으로 인해 픽셀 데이터 무결성 파괴(Corruption/Dropped Packets) 발생	이미지 내 객체의 특징점(Feature Point) 추출이 불가능해져서 경계 상자(Bounding Box) 추정 및 거리 연산의 정밀도가 급격히 하락할 위험

Example : 음성 명령 인식

데이터 유형	핵심 질문	예시	세부 상황	추론 신뢰성 저하 위험
Unseen / OOD	지원 범위 안의 언어·방언·명령인가?	모델이 학습하지 않은 희귀 언어, 고립 지역 방언, 지원하지 않는 명령 표현	학습 모델에 모델링 되지 않은 극소수 희귀 언어 또는 음운 체계가 표준과 판이한 고립 지역 방언 의 입력	입력 신호를 유의미한 명령 체계로 변환하지 못해 사용자의 Safety-critical 명령 을 무시하거나 오동작 할 위험
Biased	음향 맥락이 달라도 운전자의 실제 명령을 인식하는가?	차량 소음, 동승자 대화, 라디오 음성과 명령이 섞일 때 오인식	정숙한 환경 데이터 중심의 학습으로 인해, 특수 차량 소음 과 음성 명령이 복합적으로 유입되는 희귀 음향 맥락 발생	소음과 신호의 상관관계를 분리하지 못해 명령어를 오인식 함으로써 사용자 의도와 무관한 시스템 기능이 활성화 될 위험
Adversarial	의도적 음향 기만에 속지 않는가?	인간은 잘 듣지 못하는 기만 변조 신호, 마스킹 공격, 스피커를 통한 은닉 명령	오디오 스트림 내에 사이코어쿠스틱 마스킹 (Psychoacoustic Masking) 기법을 이용해 인간이 청취할 수 없는 기만적 변조 신호 삽입	운전자가 인지하지 못한 상태에서 시스템이 ‘보안 해제’ 또는 ‘경로 변경’ 등을 실행하여 차량 보안 무결성 및 물리적 안전을 침해 할 위험
Invalid	음성 데이터가 온전하고 시간적으로 일관적인가?	오디오 프레임 단절, 샘플링 오류, 마이크 결함, Clipping, 패킷 유실	오디오 입력 버퍼의 물리적 결함 또는 샘플링 오류 로 인해 오디오 프레임이 불연속적으로 단절 되는 상황	발화의 핵심 키워드가 소실 되어 시스템이 부정확한 명령을 실행하거나 반복적인 입력 대기 상태에 빠질 위험

Quiz: 비정상 데이터 유형

1. Unseen/ OOD 데이터
2. Biased 데이터
3. Adversarial 데이터
4. Invalid 데이터

번호	문제	유형
1	학습 데이터에서 충분히 관찰되지 않았거나 운영 도메인의 통계적 지지집합에서 벗어난 새로운 객체·상황·클래스 데이터는 무엇인가?	
2	영상이 심하게 흐려지고 센서 패킷 일부가 누락되어 피쳐 추출이 신뢰하기 어려운 경우, 이는 어떤 데이터 유형인가?	
3	모델의 결정 경계나 수학적 취약점을 의도적으로 공격하여 오분류나 미탐을 유도하는 데이터는 무엇인가?	
4	자율주행 모델이 학습 중 보지 못한 새로운 형태의 전동 이동장치나 비정형 객체 조합을 만난 경우, 이는 어떤 데이터 유형인가?	
5	모델이 인식 가능한 클래스이지만, 학습 데이터의 배경 맥락이나 지배적 상관관계 때문에 편향된 판단을 유발할 수 있는 데이터는 무엇인가?	
6	모델이 “맑은 날 도심 도로의 승용차”에는 강하지만, 눈길·야간의 승용차에는 약한 경우 가장 관련 깊은 데이터 유형은 무엇인가?	
7	표지판에 작은 패턴을 붙여 사람이 보기에는 큰 변화가 없지만 AI가 다른 표지판으로 오인하게 만든 경우, 이는 어떤 데이터 유형인가?	
8	노이즈, 센서 결함, 통신 유실, 포맷 오류 등으로 데이터의 무결성이나 일관성이 훼손된 데이터는 무엇인가?	

Quiz: 비정상 데이터 유형

1. Unseen/ OOD 데이터
2. Biased 데이터
3. Adversarial 데이터
4. Invalid 데이터

번호	문제	유형
1	학습 데이터에서 충분히 관찰되지 않았거나 운영 도메인의 통계적 지지집합에서 벗어난 새로운 객체·상황·클래스 데이터는 무엇인가?	Unseen / OOD 데이터
2	영상이 심하게 흐려지고 센서 패킷 일부가 누락되어 피쳐 추출이 신뢰하기 어려운 경우, 이는 어떤 데이터 유형인가?	Invalid 데이터
3	모델의 결정 경계나 수학적 취약점을 의도적으로 공격하여 오분류나 미탐을 유도하는 데이터는 무엇인가?	Adversarial 데이터
4	자율주행 모델이 학습 중 보지 못한 새로운 형태의 전동 이동장치나 비정형 객체 조합을 만난 경우, 이는 어떤 데이터 유형인가?	Unseen / OOD 데이터
5	모델이 인식 가능한 클래스이지만, 학습 데이터의 배경 맥락이나 지배적 상관관계 때문에 편향된 판단을 유발할 수 있는 데이터는 무엇인가?	Biased 데이터
6	모델이 “맑은 날 도심 도로의 승용차”에는 강하지만, 눈길·야간의 승용차에는 약한 경우 가장 관련 깊은 데이터 유형은 무엇인가?	Biased 데이터
7	표지판에 작은 패턴을 붙여 사람이 보기에는 큰 변화가 없지만 AI가 다른 표지판으로 오인하게 만든 경우, 이는 어떤 데이터 유형인가?	Adversarial 데이터
8	노이즈, 센서 결함, 통신 유실, 포맷 오류 등으로 데이터의 무결성이나 일관성이 훼손된 데이터는 무엇인가?	Invalid 데이터

Invalid Data 유형: 무결성(Integrity) 측면

❖ 형식적 무결성

- **Syntactic quality**: 데이터가 사전에 정의된 Schema, Type, Format, Range를 준수하는가?

❖ 신호 품질 / 정보 충분성

- **Data fidelity / Signal quality**: 원본 데이터가 특징을 추출하기에 충분한 신호 품질과 정보량을 가지는가?

1 형식적 무결성

(Syntactic / Structural Integrity)

데이터가 사전에 정의된 Schema, Type, Format, Range를 준수하는가?

```
1 {  
2   "id": 123,  
3   "name": "Kim",  
4   "age": "thirty",  
5   "score": 150,  
6   "status": "unknown"  
7 }
```



잘못된 데이터 타입

```
1 {  
2   "id": 456,  
3   "name": null,  
4   "email": ,  
5   "age": 25  
6 }
```




누락 필드 / Null

```
<user>  
<id>789</id>  
<name>Lee</name>  
<age>28</age>  
<!-- missing </user>
```



깨진 JSON/XML



센서 패킷 필드 누락

2 신호 품질 / 정보 충분성

(Signal Quality / Data Fidelity)

원본 데이터가 특징을 추출하기에 충분한 신호 품질과 정보량을 가지는가?



심한 노이즈



모션 블러



저해상도



센서 렌즈 오염

Invalid Data 유형: 논리적(Logical Validity) 측면

❖ 개별 데이터 내부 일관성

- **Semantic consistency:** 동일 시점의 하나의 데이터 항목 안에서 서로 다른 피처들이 의미적으로 모순되지 않는가?


❖ 데이터 간 선후 일관성

- **Temporal / Causal consistency:** 연속된 시계열 흐름에서 물리적·맥락적 변화가 타당한가?

3 개별 데이터 내부 일관성

(Intra-item Consistency)

동일 시점의 하나의 데이터 항목 안에서 서로 다른 피처들이 의미적으로 모순되지 않는가?



속도 100km/h, RPM 0


브레이크 압력 높음, 제동등 Off

GPS는 도로 위, 지도 매칭은 건물 내부

4 데이터 간 선후 일관성

(Inter-item / Temporal Consistency)

연속된 시계열 흐름에서 물리적·맥락적 변화가 타당한가?



Quiz: Invalid 데이터 유형

1. 형식적 무결성
2. 신호 품질/ 정보 충분성
3. 개별 데이터 내부 일관성
4. 데이터 간 선후 일관성

번호	Quiz	유형
1	동일 시점의 하나의 데이터 항목 안에서 서로 다른 피처들이 의미적으로 모순되지 않는지 경우는?	
2	원본 데이터가 특징을 추출하기에 충분한 신호 품질과 정보량을 가지는지 확인하는 Invalid 데이터 유형은?	
3	데이터가 사전에 정의된 Schema, Type, Format, Range를 준수하는지 확인하는 Invalid 데이터 유형은?	
4	객체 위치가 프레임마다 비현실적으로 순간이동하거나, 차량 속도가 한 프레임 사이에 0에서 300km/h로 변한 경우는?	
5	센서 패킷에서 필수 필드가 누락되었고, ENUM 값이 허용 범위를 벗어났으며, JSON 구조가 깨져 파싱되지 않는 경우는?	
6	연속된 시계열 데이터 흐름에서 물리적·맥락적 변화가 시간 순서상 타당한지 확인하는 Invalid 데이터 유형은 무엇인가?	
7	차량 상태 데이터에서 속도는 100km/h로 기록되어 있지만 휠 회전수는 0이고, 브레이크 페달 압력은 높는데 제동등 상태는 Off로 나타난 경우는?	
8	자율주행 카메라 영상이 심한 모션 블러와 저해상도로 인해 보행자 윤곽을 식별하기 어렵고, 렌즈 오염으로 핵심 영역이 가려진 경우는?	

Quiz: Invalid 데이터 유형

1. 형식적 무결성
2. 신호 품질/ 정보 충분성
3. 개별 데이터 내부 일관성
4. 데이터 간 선후 일관성

번호	Quiz	유형
1	동일 시점의 하나의 데이터 항목 안에서 서로 다른 피처들이 의미적으로 모순되지 않는지 경우는?	개별 데이터 내부 일관성
2	원본 데이터가 특징을 추출하기에 충분한 신호 품질과 정보량을 가지는지 확인하는 Invalid 데이터 유형은?	신호 품질 / 정보 충분성
3	데이터가 사전에 정의된 Schema, Type, Format, Range를 준수하는지 확인하는 Invalid 데이터 유형은?	형식적 무결성
4	객체 위치가 프레임마다 비현실적으로 순간이동하거나, 차량 속도가 한 프레임 사이에 0에서 300km/h로 변한 경우는?	데이터 간 선후 일관성
5	센서 패킷에서 필수 필드가 누락되었고, ENUM 값이 허용 범위를 벗어났으며, JSON 구조가 깨져 파싱되지 않는 경우는?	형식적 무결성
6	연속된 시계열 데이터 흐름에서 물리적·맥락적 변화가 시간 순서상 타당한지 확인하는 Invalid 데이터 유형은 무엇인가?	데이터 간 선후 일관성
7	차량 상태 데이터에서 속도는 100km/h로 기록되어 있지만 휠 회전수는 0이고, 브레이크 페달 압력은 높는데 제동등 상태는 Off로 나타난 경우는?	개별 데이터 내부 일관성
8	자율주행 카메라 영상이 심한 모션 블러와 저해상도로 인해 보행자 윤곽을 식별하기 어렵고, 렌즈 오염으로 핵심 영역이 가려진 경우는?	신호 품질 / 정보 충분성

유형 2. 외부 간섭 강건성

❖ 외부의 물리적·전자기적 교란 환경 하에서 시스템 수집 채널(센서, 통신 인터페이스 등)을 통해 유입되는 데이터의 유효성을 검증하고 시스템의 동작 무결성을 유지하는 능력

● 2.1 비의도적 신호 왜곡

- ✓ 전자기 간섭(EMI), 전원 노이즈, 하드웨어의 열잡음(Thermal Noise)
- ✓ 외부 환경 및 물리적 특성에 의해 발생하는 우발적 신호 변질 상황.

● 2.2 의도적 신호 기만

- ✓ Jamming, Spoofing, Signal Injection 등
- ✓ 시스템의 오동작 유도 및 정보 조작을 목적으로 외부에서 의도적으로 인가된 인위적 간섭 및 신호 기만 상황.

유형 2. 외부 간섭 강건성 예시

2.1 비의도적 왜곡

고압선 인근 주행 시 발생하는 전자기 간섭(EMI)으로 인해
카메라 영상에 가로줄 노이즈(Rolling Noise) 발생



영상 신호의
신호 대 잡음비(SNR) 급격한 저하로
인해 객체 윤곽 추출이 불가능해지
며, 후행 제어 시스템에 불안정한 좌
표 데이터 전달 위험

센서가 가상의 장애물을
인식하거나 실제 장애물의
거리 측정을 방해받아,
비정상 급제동 혹은 충돌
방지 시스템 무력화 위험



2.2 의도적 기만


인접 차량이나 도로변 장치에서 발사된 레이저
재밍(Laser Jamming) 신호가 LiDAR 센서에 유입



유형 2. 외부 간섭 강건성 예시

2.1 비의도적 왜곡

차량 내 전자기기 구동 시 발생하는 전원 노이즈(Power Noise)가 마이크 입력 회로에 간섭하여 특정 주파수의 험(Hum) 노이즈 발생



❖ 음성 명령 인식

음성 신호의 특징값이 왜곡되어 인식률(Word Error Rate)이 급격히 하락하거나 시스템이 상시 입력 상태로 오인할 위험

2.2 의도적 기만

비가청 대역의 초음파를 활용하여 인간이 듣지 못하는 명령을 주입하는 돌핀 어택(Dolphin Attack) 감지

운전자가 인지하지 못하는 사이 시스템이 차량 설정 변경이나 인포테인먼트 결제 등 민감한 기능을 독단적으로 실행할 보안 위협 발생



유형 3. 외부 환경 강건성

❖ 정의

- 데이터 분포 변화, 일시적 운영 환경 변화, 입력 장치의 장기적·점진적 변화 등으로 실제 운영 입력이 학습 시 가정과 달라지더라도,
- 모델의 일반화 성능, 입력 신호 복원력, 추론 신뢰성을 허용 가능한 수준으로 유지하거나 필요 시 안전하게 fallback하는 능력

구분	설명
일반화 저해 환경	학습 데이터와 실제 운영 환경 간의 데이터 분포 변화 로 인해, 모델이 학습한 일반화 능력이 약화되는 환경
복원력 저해 환경	일시적·상황적 운영 환경 변화 로 인해 입력 데이터가 훼손되거나 정보가 불충분해지는 환경
신뢰성 저해 환경	입력 장치의 장기적 노후화 로 인해 입력 데이터 품질과 추론 신뢰도가 점진적으로 저하되는 환경

유형 3. 외부 환경 강건성

❖ 일반화 저해 환경

- 학습 데이터와 실제 운영 환경 간의 데이터 분포 변화로 인해, 모델이 학습한 일반화 능력이 약화되는 환경
- 입력 데이터 자체가 물리적으로 훼손된 것은 아니지만, 학습 시 충분히 대표되지 않은 환경·객체·배경·운영 맥락이 등장하여 인식 성능이 저하될 수 있음



유형 3. 외부 환경 강건성

❖ 복원력 저해 환경

- 일시적·상황적 운영 환경 변화로 인해 입력 데이터가 훼손되거나 정보가 불충분해지는 환경
- 모델이 원래 인식해야 하는 객체가 존재하더라도, 환경 요인 때문에 객체 피처가 흐려지거나 가려져 신호 복구와 안정적 추론이 요구됨



유형 3. 외부 환경 강건성


❖ 신뢰성 저해 환경

- 입력 장치의 장기적 노후화로 인해 입력 데이터 품질과 추론 신뢰도가 점진적으로 저하되는 환경
- 일시적 환경 변화가 아니라, 장기간 운용 과정에서 센서·카메라·라이다 등 입력 장치의 품질이 누적적으로 낮아지는 것이 핵심임

3 신뢰성 저해 환경

핵심 원인: 입력 장치의 장기적 노후화로 품질이 점진적으로 저하됨

시간 경과에 따른 품질 변화 (예시)



렌즈 스크래치



감도 저하



장착 각도 변화



외부 환경 강건성 예시: 음성 명령 인식

일반화 저해 환경



화자·표현·차량 실내 음향·
사용 맥락의 분포 차이



화자 다양성
(연령, 억양, 발음 등)



표현 다양성
(같은 의도, 다양한 표현)



차량 실내
음향 차이
(차량 모델, 마이크 위치, 말하는 자세 등)
실내 구조 등)



사용 맥락 차이
(마스크 착용, 청문 개방, 말하는 자세 등)

복원력 저해 환경



일시적 소음·반향·중첩 음성·
부분 손실로 입력 음성 훼손



에어컨 ... 낮춰줘
(일부 단어만 명화)

신뢰성 저해 환경



마이크·음향 입력 경로의
장기적 노후화



마이크 노후화
(감도 저하, 잡음 증가, 주파수 응답 저하 등)



입력 경로 오염
(먼지, 습기, 이물질 누적으로 음질 저하)




장착 상태 변화
(진동, 충격 등으로 위치·고정 상태 변화)



측정 안정성 저하
(신호 대 잡음비 감소, 인식 confidence 저하)

유형 4. 추론 컴퓨팅 환경 강건성

- ❖ 소프트웨어 로직과 하부 실행 인프라의 불안정한 변동 환경 하에서 전체 시스템의 기능 정확성을 유지하는 능력



유형 4. 추론 컴퓨팅 환경 강건성

❖ 4.1 추론 로직 (Inference Logic)

- 추론을 위한 데이터 준비, 입력 가드레일, 모델 서빙, 출력 가드레일 등 추론 어플리케이션 계층의 동작 불완전성에 대응하는 능력.

불안정 발생 주체	불안정성 예	강건성 대응: 주체 및 동작
Data Preparation	보정 실패, 표준화 오류, 피쳐 누락, 맥락 합성 오류	입력 가드레일: 모델 투입 전 차단·경고·fallback
Input Guardrail	부정확한 차단, 위험 입력 미탐지	운영 조치: 입력 가드레일의 정책/임계값 조정
Model Serving	threshold 부적절, confidence 불안정, 출력 흔들림, 제어값 급변	모델 서빙: 추론 결과 제어 파라미터를 적용하여 출력 불안정성을 완화 출력 가드레일: 결과값의 confidence, 보정 가능성, 위험도를 검토하여 보정·차단·fallback 처리함 운영 조치: precision mode, batching 정책 등 서빙 실행 제어 파라미터를 조정함
Output Guardrail	보정/차단 판단 충돌, 위험 출력 통과	운영 조치: 출력 가드레일 정책, 보정 허용 범위, 차단 임계값, fallback 조건을 조정함

유형 4. 추론 컴퓨팅 환경 강건성

❖ 4.2 추론 플랫폼 (Inference Platform)

- 모델 서빙 엔진, 모델 서빙 프레임워크, OS 등 하부 실행 인프라 계층의 환경적 변동 및 비결정성에 대응하는 능력

추론 플랫폼 불안정성	발생 문제	강건성 대응
GPU/CPU 수치 차이	같은 입력인데 confidence가 0.801 ↔ 0.797처럼 미세하게 달라짐	Model Serving: threshold 근처 결과에 대해 margin zone, tolerance 등 추론 결과 제어 파라미터를 적용 Output Guardrail: 경계값 결과의 confidence와 논리적 타당성을 재검증하고, 필요 시 WARN/BLOCK/FALLBACK 처리함 운영 조치: 모니터링 결과를 바탕으로 margin zone 폭, threshold, tolerance 기준을 조정하거나 특정 실행 환경을 제한함
동적 배치 지연	batch queue 때문에 latency SLA 초과	운영 조치: priority queue, autoscaling, batch 정책 조정, 고위험 요청 우선 처리, degraded mode 전환을 수행함
자원 부족 / memory pressure	응답 지연, 일부 요청 drop	운영 조치: retry, fallback model, resource isolation

기능 정확성 vs 강건성

❖ 품질 속성 요약

QA	대상 범위	집중 상황	QA 관점	핵심 능력
기능 정확성	도메인 동일	정상적 상황 - 정상 환경 - 도메인 요소들의 정상적 분포 데이터(일반/경계)	기본 지능	정상 환경 및 정상 데이터에 대하여 정확한 추론 결과를 생성하는 능력
강건성	도메인 동일	악조건 상황 - 비정상 환경 - 도메인 요소들의 비정상 데이터	내구력 (정확성 유지)	비정상 환경 및 비정상 데이터(OOD/Unseen, Biased, Adversarial, Invalid)에 대하여 기능 정확성을 유지하는 능력

강건성 평가 지표

강건성 평가 지표 유형

평가 지표 유형	평가 관점	평가 지표
정확성 기반 강건성 지표	비정상적 입력 하에서 정확성 보존력 및 내성 평가	- 강건성 지수 - 상대적 정확도 저하율 - 조건별 강건성 지수 - 평균 오염 오류율
적대적 기반 강건성 지표	의도적인 악의적 교란 하에서의 방어 능력 평가	- 강건 정확도 - 공격 탐지율 - 정상 입력 오거부율 - 공격 성공률
안정성 기반 강건성 지표	추론 과정의 시계열적 일관성 및 판단 결과의 안정성 평가	- 추론 안정성 지수 - 예측 변동률

정확성 기반 강건성 지표

❖ 강건성 지수

- Robustness Score, RS
- 정상 상황 대비 강건성 시나리오에서 모델이 정확성을 얼마나 보존하는지 평가


1 강건성 지수 (Robustness Score, RS)

정상 상황 대비 강건성 시나리오에서
모델이 정확성을 얼마나 보존하는지 평가

$$RS = \frac{Acc_{robust}}{Acc_{clean}} \times 100\%$$

값이 **100%**에 가까울수록
정상 데이터 대비 정확도 **보존력**이 높음

⚠ 단, Acc_{clean} 자체가 낮은 모델은
RS만으로 좋은 모델이라고
판단하면 안 됨



정확성 기반 강건성 지표

❖ 상대적 정확도 저하율

- Relative Correctness Degradation, RCD
- 정상 상황 대비 강건성 시나리오에서 정확도가 얼마나 하락했는지 평가
- $RCD = 1 - RS$

② 상대적 정확도 저하율 (Relative Correctness Degradation, RCD)


정상 상황 대비 강건성 시나리오에서
정확도가 얼마나 하락했는지 평가

$$RCD = 1 - \frac{Acc_{robust}}{Acc_{clean}}$$

또는 $RCD = 1 - RS$ (RS가 0~1 스케일일 때)

$$RCD(\%) = 100\% - RS(\%)$$

값이 작을수록 강건함




정확성 기반 강건성 지표

❖ 조건별 강건성 지수

- Condition-wise Robustness Score
- 환경 조건에 따른 정확도 유지 평가

$$RS_c = \frac{Acc_c}{Acc_{clean}} \times 100\%$$


- c 는 비, 눈, 안개, 소음, 방언, 센서 오염, frame drop 등 개별 조건
- 전체 RS만 보면 약한 조건을 놓칠 수 있으므로 **조건별 분석**이 필요함



정확성 기반 강건성 지표

❖ 평균 오염 오류율(mean Corruption Error, mCE)

- 표준 Corruption Benchmark에서 **기준 모델** 대비 **모델 오류율** 비교



$$mCE = \frac{1}{C} \sum_{c=1}^C \frac{E_c}{E_c^b} \times 100$$

E_c : 오염조건 c에서 평가모델 오류율

E_c^b : 오염조건 c에서 기준모델 오류율

C : 오염 유형수

데이터셋 명	Baseline / 비교 기준	오염 종류 및 구성
ImageNet-C	AlexNet을 기준 모델로 사용	15종 오염 / 5단계 강도. Noise, blur, weather, digital corruption 범주로 구성
MNIST-C	연구별로 정의한 baseline classifier 를 기준으로 mCE를 계산	MNIST 테스트셋에 적용한 15종의 오염
MangoLeafDB-C	ResNet-50/101, VGG-16, Xception, LCNN 등을 기준모델로 사용	19종 오염 / 5단계 강도. 원본 MangoLeafDB 4,000장에 synthetic corruption을 적용하여 생성

적대적 기반 강건성 지표


❖ 의도적인 기만 공격에 대해 모델의 판단 무결성이 얼마나 유지되는지 측정

지표	관점	좋은 방향
강건 정확도 (Robust Accuracy, RA)	방어자 관점의 피공격 후 정확도	높을수록 좋음
공격 탐지율 (Attack Detection Rate)	공격을 탐지/거부하는 능력	높을수록 좋음
정상 입력 오거부율 (False Rejection Rate, FRR)	정상 입력을 잘못 막는 부작용	낮을수록 좋음
공격 성공률 (Attack Success Rate, ASR)	공격자 관점의 공격 성공 정도	낮을수록 좋음

적대적 기반 강건성 지표

❖ 강건 정확도

- Robust Accuracy, RA
- 최악의 공격 상황에서 모델이 유지할 수 있는 실질적 정확도 하한선 평가




적대적 기반 강건성 지표

❖ 공격 탐지율 / 차단률

- Attack Detection Rate

- 공격성 입력을 실행 전에 탐지할 수 있는지 평가



적대적 기반 강건성 지표

❖ 정상 입력 오거부율

- False Rejection Rate, FRR
- 정상 입력까지 과도하게 차단하지 않는지 평가



적대적 기반 강건성 지표

❖ 공격 성공률 (Attack Success Rate, ASR)

- 공격자 관점에서 본 공격 성공 비율
- 시스템 취약점의 치명도와 공격자의 침투 효율 평가
- $ASR = \text{공격으로 오답이 된 샘플 수} / \text{정상 상황에서 정답이었던 공격 대상 샘플 수}$

❖ AI red teaming / 취약점 평가


- 특정 공격 유형, 입력 조건, 대상 클래스, 센서 종류, 모델 버전별로 공격 성공률을 분석하여 취약한 조건과 구성요소를 식별

안정성(Stability) 기반 강건성 지표

❖ 추론 안정성 지수

- Stability Index

- 연속값 변동성 평가




안정성(Stability) 기반 강건성 지표

❖ 예측 변동률

● Flicker Rate

- 판단 결과의 시간적 일관성 측정



Quiz: 강건성 평가 지표

정확성 기반 지표: 강건성 지수, 상대적 정확도 저하율, 조건별 강건성 지수, 평균 오염 오류율
 적대적 기반 지표: 강건 정확도, 공격 탐지율, 정상 입력 오거부율, 공격 성공률
 안전성 기반 지표: 추론 안정성 지수, 예측 변동률

번호	Quiz	지표
1	비, 눈, 안개, 소음, 방언, 센서 오염 등 개별 조건별로 정상 대비 정확성 보존 정도를 평가하는 지표는 무엇인가?	
2	정상 데이터 대비 강건성 시나리오에서 모델이 정확성을 얼마나 보존하는지를 Acc_robust / Acc_clean으로 평가하는 지표는 무엇인가?	
3	corruption type과 severity별 오류율을 기준 모델의 오류율로 정규화한 뒤 평균하여 오염 조건에서의 강건성을 비교하는 지표는 무엇인가?	
4	정상 입력 중 시스템이 공격 또는 비정상 입력으로 잘못 판단하여 거부·차단한 비율을 나타내는 지표는 무엇인가?	
5	정상 상황 대비 강건성 시나리오에서 정확도가 얼마나 하락했는지를 $1 - \text{Acc_robust} / \text{Acc_clean}$ 으로 평가하는 지표는 무엇인가?	
6	공격 입력 중 시스템이 공격 의심 또는 비정상 입력으로 탐지하거나 거부한 비율을 나타내는 지표는 무엇인가?	
7	인접 시간 프레임 또는 유사 입력 사이에서 최종 예측 label, class, intent, decision이 바뀌는 빈도를 평가하는 지표는 무엇인가?	
8	정상 상황에서는 정답이었던 샘플이 공격 후 오답으로 바뀐 비율을 나타내는 지표는 무엇인가?	
9	동일하거나 유사한 입력 또는 연속된 시간 프레임에서 출력값이 얼마나 안정적으로 유지되는지를 평가하는 지표는 무엇인가?	
10	공격이 적용된 입력에 대해서도 모델이 여전히 정답을 맞힌 비율을 나타내는 지표는 무엇인가?	

Quiz: 강건성 평가 지표

정확성 기반 지표: 강건성 지수, 상대적 정확도 저하율, 조건별 강건성 지수, 평균 오염 오류율
 적대적 기반 지표: 강건 정확도, 공격 탐지율, 정상 입력 오거부율, 공격 성공률
 안전성 기반 지표: 추론 안정성 지수, 예측 변동률

번호	Quiz	지표
1	비, 눈, 안개, 소음, 방언, 센서 오염 등 개별 조건별로 정상 대비 정확성 보존 정도를 평가하는 지표는 무엇인가?	조건별 강건성 지수
2	정상 데이터 대비 강건성 시나리오에서 모델이 정확성을 얼마나 보존하는지를 Acc_robust / Acc_clean으로 평가하는 지표는 무엇인가?	강건성 지수
3	corruption type과 severity별 오류율을 기준 모델의 오류율로 정규화한 뒤 평균하여 오염 조건에서의 강건성을 비교하는 지표는 무엇인가?	평균 오염 오류율
4	정상 입력 중 시스템이 공격 또는 비정상 입력으로 잘못 판단하여 거부·차단한 비율을 나타내는 지표는 무엇인가?	정상 입력 오거부율
5	정상 상황 대비 강건성 시나리오에서 정확도가 얼마나 하락했는지를 $1 - \text{Acc_robust} / \text{Acc_clean}$ 으로 평가하는 지표는 무엇인가?	상대적 정확도 저하율
6	공격 입력 중 시스템이 공격 의심 또는 비정상 입력으로 탐지하거나 거부한 비율을 나타내는 지표는 무엇인가?	공격 탐지율 / 차단률
7	인접 시간 프레임 또는 유사 입력 사이에서 최종 예측 label, class, intent, decision이 바뀌는 빈도를 평가하는 지표는 무엇인가?	예측 변동률
8	정상 상황에서는 정답이었던 샘플이 공격 후 오답으로 바뀐 비율을 나타내는 지표는 무엇인가?	공격 성공률
9	동일하거나 유사한 입력 또는 연속된 시간 프레임에서 출력값이 얼마나 안정적으로 유지되는지를 평가하는 지표는 무엇인가?	추론 안정성 지수
10	공격이 적용된 입력에 대해서도 모델이 여전히 정답을 맞힌 비율을 나타내는 지표는 무엇인가?	강건 정확도

Quiz: 강건성 평가 지표

정확성 기반 지표: 강건성 지수, 상대적 정확도 저하율, 조건별 강건성 지수, 평균 오염 오류율

적대적 기반 지표: 강건 정확도, 공격 탐지율, 정상 입력 오거부율, 공격 성공률

안전성 기반 지표: 추론 안정성 지수, 예측 변동률

번호	Quiz	지표
1	자율주행 객체 인식 모델의 정상 날씨 정확도는 95%이고, 폭우·안개·눈길 평가셋에서 정확도는 76%이다. 정상 대비 가혹 조건에서 정확성을 얼마나 보존했는지 평가하려면?	
2	ImageNet-C처럼 Gaussian noise, motion blur, fog, JPEG compression 등 여러 corruption type과 severity에 대해 기준 모델 대비 오류율을 비교하고 싶다면?	
3	입력 가드레일이 adversarial patch가 포함된 표지판 이미지나 spoofing 신호를 얼마나 잘 탐지하고 차단하는지 평가하려 한다. 어떤 지표가 적절한가?	
4	공격 탐지 장치를 강화했더니 실제로는 정상인 음성 명령이나 정상 카메라 프레임까지 너무 많이 차단되는 문제가 발생했다. 이 부작용을 평가하려면?	
5	공격자가 이미지에 adversarial perturbation을 추가했지만, 모델이 여전히 올바른 class를 예측한 비율을 평가하려고 한다. 어떤 지표를 사용해야 하는가?	
6	음성 명령 인식 모델이 조용한 실내에서는 96% 정확도를 보였지만, 고속 주행 소음 환경에서는 72%로 하락했다. 정상 대비 성능 하락 정도를 보고 싶다면?	
7	모델 전체 강건성 점수는 괜찮지만, 실제로는 '야간', '눈길', '공사 구간', '역광' 중 어느 조건에서 성능이 가장 취약한지 알고 싶다면?	
8	정상 입력에서는 '정지 표지판'을 올바르게 인식했지만, 공격 패턴을 붙인 후 '속도 제한 표지판'으로 잘못 인식한 비율을 측정하려 한다면?	
9	음성 명령 인식 시스템이 동일한 명령을 연속으로 듣고도 "에어컨 켜기", "창문 열기", "에어컨 켜기"처럼 최종 intent를 자주 바꾸는지 평가하려면?	
10	연속 주행 중 동일한 차량을 추적하는데 bounding box 위치, 거리 추정값, confidence가 프레임마다 크게 흔들리는지 확인하려면?	

Quiz: 강건성 평가 지표

정확성 기반 지표: 강건성 지수, 상대적 정확도 저하율, 조건별 강건성 지수, 평균 오염 오류율
 적대적 기반 지표: 강건 정확도, 공격 탐지율, 정상 입력 오거부율, 공격 성공률
 안전성 기반 지표: 추론 안정성 지수, 예측 변동률

번호	Quiz	지표
1	자율주행 객체 인식 모델의 정상 날씨 정확도는 95%이고, 폭우·안개·눈길 평가셋에서 정확도는 76%이다. 정상 대비 가혹 조건에서 정확성을 얼마나 보존했는지 평가하려면?	강건성 지수
2	ImageNet-C처럼 Gaussian noise, motion blur, fog, JPEG compression 등 여러 corruption type과 severity에 대해 기준 모델 대비 오류율을 비교하고 싶다면?	평균 오염 오류율
3	입력 가드레일이 adversarial patch가 포함된 표지판 이미지나 spoofing 신호를 얼마나 잘 탐지하고 차단하는지 평가하려 한다. 어떤 지표가 적절한가?	공격 탐지율 / 차단률
4	공격 탐지 장치를 강화했더니 실제로는 정상인 음성 명령이나 정상 카메라 프레임까지 너무 많이 차단되는 문제가 발생했다. 이 부작용을 평가하려면?	정상 입력 오거부율
5	공격자가 이미지에 adversarial perturbation을 추가했지만, 모델이 여전히 올바른 class를 예측한 비율을 평가하려고 한다. 어떤 지표를 사용해야 하는가?	강건 정확도
6	음성 명령 인식 모델이 조용한 실내에서는 96% 정확도를 보였지만, 고속 주행 소음 환경에서는 72%로 하락했다. 정상 대비 성능 하락 정도를 보고 싶다면?	상대적 정확도 저하율
7	모델 전체 강건성 점수는 괜찮지만, 실제로는 '야간', '눈길', '공사 구간', '역광' 중 어느 조건에서 성능이 가장 취약한지 알고 싶다면?	조건별 강건성 지수
8	정상 입력에서는 '정지 표지판'을 올바르게 인식했지만, 공격 패턴을 붙인 후 '속도 제한 표지판'으로 잘못 인식한 비율을 측정하려 한다면?	공격 성공률
9	음성 명령 인식 시스템이 동일한 명령을 연속으로 듣고도 "에어컨 켜기", "창문 열기", "에어컨 켜기"처럼 최종 intent를 자주 바꾸는지 평가하려면?	예측 변동률
10	연속 주행 중 동일한 차량을 추적하는데 bounding box 위치, 거리 추정값, confidence가 프레임마다 크게 흔들리는지 확인하려면?	추론 안정성 지수

강건성 QA 시나리오

강건성 QA 시나리오

항목	설명
Source	사용자, 외부 시스템, 센서(카메라/라이다 등), 공격자
Stimulus	비정상 데이터 • 편향(Biased) 데이터: 모델의 편향된 판단을 유발할 수 있는 데이터 • 무효한(Invalid) 데이터: 무결성 측면, 논리적 측면 • 적대적(Adversarial) 데이터 • 운영범위 외부(Unseen, Out-of-distribution(OOD)) 데이터
Artifact	AI-based System, AI System, AI 추론 엔진
Environment	비정상 상황: • 외부 간섭: 신호 간섭, 교란 • 외부 환경: 일반화 실패, 복원력 저하, 신뢰성 저하를 유발하는 운영 환경 변화 • 운영 환경: 지연 시간, 처리량, 데이터 최신성, 가용성 등 계획된 운영을 저해하는 속성 문제
Response	• 편향 데이터: 정답 추론 • 무효한 데이터: 정답 추론 or 입력 차단 • 적대적 데이터: 입력 차단(필터링) • 운영 범위 외부 데이터: 입력 차단(필터링)
Measure	강건성 평가 지표: 정확성 기반, 적대적 기반, 안정성 기반 지표

도로 객체 및 교통 표지판 인식

❖ [정확성 요구사항]

- 시스템은 주행 중 센서에 포착된 도로 위 객체(보행자, 차량)와 교통 표지판 종류를 식별하고 정확한 범주로 분류해야 한다.

항목	기능 정확성 관점 예
Source	카메라 및 LiDAR 센서
Stimulus	일반적 상황(주간/야간 및 기상 조건(맑음, 우천 등)에서의 영상
Artifact	도로 객체 인식 모듈
Environment	정상 동작 상태
Response	영상에서 추출된 각 객체에 대해 '보행자', '차량', '표지판 종류' 등의 레이블을 부여함
Response Measure	• mAP (mean Average Precision): 95% 이상 달성 • 보행자 재현율 (Recall): 99.9% 이상 확보 (미탐 방지)

도로 객체 및 교통 표지판 인식

❖ [강건성 요구사항]

- 시스템은 폭우, 짙은 안개, 광원 변화 등 가혹한 기상 조건이나 센서 오염 및 물리적 노이즈가 발생하는 상황에서도 객체 인식의 정확도 하락을 최소화해야 한다

항목	내용
Source	성능이 저하된 카메라 및 LiDAR 센서
Stimulus	가혹 환경에서의 영상: 폭우(시간당 30mm 이상), 짙은 안개(가시거리 10m 미만), 직접적인 태양 역광(Glare), 혹은 센서 렌즈의 부분적 오염
Artifact	도로 객체 인식 엔진
Environment	과부하 상황
Response	급격한 환경 변화에도 불구하고 인식 레이블의 깜빡임(Flicker) 을 억제하고, 객체 식별의 연속성을 보장 함
Response Measure	• 강건성 지수 (Robustness Score): 정상 기후 대비 정확성 유지율 90% 이상 • 예측 변동률 (Flicker Rate): 동일 객체에 대한 레이블 번복 발생률 0.5% 이하 • 상대적 정확도 저하율 (RCD): 극한 조건에서의 mAP 하락 폭 10% 이내

조향각 및 주행 속도 결정

❖ [정확성 요구사항]

- 시스템은 경로를 유지하기 위해 차선 중심선 좌표, 도로 곡률, 전방 차량과의 목표 이격 거리를 바탕으로 차량의 조향각과 속도를 정밀하게 출력해야 한다

항목	기능 정확성 관점 예
Source	경로 계획(Planning) 모듈
Stimulus	차선 중심선 좌표, 곡률 정보, 전방 차량과의 목표 이격 거리
Artifact	주행 제어 모듈
Environment	정상 동작 상태
Response	조향각과 속도 출력
Response Measure	• 목표 조향각 대비 실제 출력값의 RMSE ≤ 0.1 rad • 목표 속도 대비 실제 결정 속도의 MAE ≤ 0.5 km/h

조향각 및 주행 속도 결정

❖ [강건성 요구사항]

- 시스템은 입력 데이터에 고주파 노이즈가 섞이거나, 통신 지연으로 입력 데이터가 늦게 들어오며, 시스템 리소스 부족 등의 상황에서도 정상 상황 대비 15% 이내의 정확도 저하만 허용하며, 조향 및 속도의 변동폭도 0.05 이하이어야 한다

항목	내용
Source	경로 계획(Planning) 모듈
Stimulus	고주파에 의한 입력 좌표값의 변조, 계획 모듈의 일시적 지연된 입력
Artifact	주행 제어 모델
Environment	시스템 자원 부족 상황
Response	입력값의 흔들림에도 불구하고 출력값의 평탄화(Smoothing) 를 유지하며, 차선 이탈이나 급격한 가감속을 방지하는 제어 일관성 을 확보함
Response Measure	• 상대적 정확도 저하율 (RCD) 극한 상황에서의 RMSE 상승 폭이 정상 대비 15% 이내 • 추론 안정성 지수 (Stability Index): 입력 미세 변동 시 출력값의 변화율(Variance)을 0.05 이하

주변 차량 경로 예측

❖ [정확성 요구사항]

- 시스템은 매 1초마다 주변 차량 3대의 과거 3초간 정보(위치, 속도, 방향지시등)을 분석하여 향후 5초 동안의 이동 궤적을 정확하게 예측해야 한다

항목	기능 정확성 관점 예
Source	타이머
Stimulus	1초 주기의 실행 트리거
Artifact	경로 예측 모듈
Environment	주변 차량(3대 이상)의 과거 3초간 시계열 데이터(위치, 속도, 방향지시 등)가 확보된 정상 운영 상태
Response	각 주변 차량에 대한 5초 동안의 예상 궤적 생성
Response Measure	• 예측 경로와 실제 이동 경로 간의 ADE(Average Displacement Error) 1.0m 이내 • 최종 도달 지점 오차: FDE(Final Displacement Error) 2.0m 이내 달성

주변 차량 경로 예측

❖ [강건성 요구사항]

- 시스템은 센서 오염이나 장애물에 의한 부분적 가림으로 데이터 결측이 존재해도 물리적으로 타당한 미래 궤적을 산출하고, 추론 주기 간 예측 결과의 급격한 변동을 억제해야 한다

항목	내용
Source	타이머
Stimulus	1초 주기의 실행 트리거
Artifact	경로 예측 모듈
Environment	센서 노이즈 또는 일부 데이터 유실이 발생한 시계열 데이터 버퍼
Response	데이터 일부 누락 시에도 과거 이력을 기반으로 물리적 궤적을 복원하며, 연속된 추론 프레임 간 예측 궤적 추론
Response Measure	• 강건성 지수 (Robustness Score): 데이터 결측/노이즈 상황 하의 ADE 정확성 유지율 85% 이상 • 추론 안정성 지수 (Stability Index): 연속된 추론 주기 간 예측 궤적의 종단/횡단 변동폭(Variance)을 1.5m 이내 • 상대적 정확도 저하율 (RCD): FDE(최종 지점 오차) 증가 폭을 정상 대비 20% 이내

기능 정확성 vs 강건성 QA 시나리오

항목	기능 정확성	강건성
목적	(정상적 상황에서의 지능의 정밀도) 학습된 지식의 정밀한 재현 및 오판 최소화	(비정상 상황에서의 지능의 견고성) 외부 공격 및 비정상/가혹 조건에서의 지능 유지
Source	사용자, 외부 시스템, 센서(카메라/라이다 등), 내부 타이머	
Stimulus	정상 데이터: 일반값, 경계값	운영 도메인 외부 (Unseen/OOD) 데이터, 학습 인과관계 미충족(Biased) 데이터, 손상된(Invalid) 데이터, 적대적(Adversarial) 데이터
Artifact	AI-based System, AI System, AI 추론 엔진	
Environment	정상 동작 상황	악의적 상황(전파 방해, 공격 상황)
Response	결과 출력	결과 출력, 입력 거부, 출력 거부
Measure	기능 정확성 평가 지표 (Task 유형별 지표)	강건성 평가 지표 (정확성 기반, 적대적 기반, 안정성 기반)

강건성 테스트 케이스 설계

강건성 테스트 케이스 설계

- ❖ 강건성 테스트는 "시스템이 마주할 수 있는 가혹한 상황"에 집중함
- ❖ 유형 2(외부 간섭)와 유형 3(외부 환경)이 데이터에 미치는 영향을 유형 1(입력 데이터)의 형태로 투영하여 모델의 강건성을 테스트

강건성 테스트 케이스 설계

데이터 설계 기법	설명
Unseen 테스트 데이터 설계	모델이 학습 데이터 또는 운영 도메인의 통계적 지지집합 밖에 있는 입력에 대해 기존 클래스로 억측하지 않고 Unknown로 감지하거나, 도메인 변화 상황에서도 허용 가능한 성능을 유지하는지 검증함.
Biased 테스트 데이터 설계	모델이 학습 데이터에 존재할 수 있는 가짜 상관관계(spurious correlation)를 지름길 학습(shortcut learning)을 하지 않고, 본질적 특징을 근거로 판단하는지 검증함.
적대적(Adversarial) 테스트 데이터 설계	의도적으로 설계된 기만 입력이 모델의 판단을 오분류·오탐·미탐 또는 과대 확신으로 유도하는지 평가하고, 시스템의 방어 무결성을 검증함.
Invalid 테스트 데이터 설계	데이터의 형식적 무결성, 신호 품질/정보 충분성, 개별 데이터 내부 일관성, 데이터 간 선후 일관성이 훼손된 상황에서 시스템이 오작동하지 않고 입력 거부, degraded mode 등으로 전환하는지 검증함.

Unseen 테스트 데이터 설계

Semantic OOD Test

학습 또는 운영 도메인에서 정의하지 않은 새로운 객체·명령·상황을 투입하여, 모델이 이를 기존 클래스로 억지 분류하지 않고 Unknown, Other, OOD, 미분류 객체 등으로 처리하는지 검증함.

자율주행 객체 인식 예시



차량 음성 명령 인식 예시



예: 자율주행 객체 인식 — 도로 위 캥거루, 코끼리, 비정형 이동체 / 차량 음성 명령 — 지원하지 않는 언어·방언·명령 표현

Domain Shift Test

객체나 명령의 의미는 같지만 입력 분포가 학습 데이터와 크게 다른 환경에서 성능 저하 폭을 측정함.

자율주행 객체 인식 예시



차량 음성 명령 인식 예시



예: 한국 도로 데이터 중심 학습 후 유럽 도로 주행, 맑은 날 데이터 중심 학습 후 폭설 환경, 정숙 차량 데이터 중심 학습 후 고속 주행 소음 환경

핵심 차이



Semantic OOD:
새로운 의미 범주 유입

VS

Domain Shift:
같은 의미, 다른 분포



Biased 테스트 데이터 설계

Cross-context Test

객체와 배경·맥락의 관계를 의도적으로 바꾸어, 모델이 배경에 의존하지 않고 객체 본질을 인식하는지 검증함.

예시



잔디밭 위 자동차



수영장 속 자동차



전시장 위 트럭



눈 속 흰색 차량



핵심: 배경과 맥락이 바뀌어도 객체의 본질을 인식하는가?

Counterfactual Test

정답 label은 유지하면서 배경, 색상, 조명, 속성, 주변 객체 등 비본질적 요인을 바꾼 counterfactual 데이터를 만들어 모델 판단이 유지되는지 평가함.

예시



도로 배경
동일한 차량



잔디 배경
동일한 차량



눈 배경
동일한 차량



전시장 배경
동일한 차량



핵심: 비본질적 요인이 바뀌어도 label이 유지되는가?



Cross-context:

객체-배경 관계를 깨뜨려 shortcut learning을 드러냄



핵심 차이



Counterfactual:

label은 유지한 채 비본질적 요인만 변경



적대적(Adversarial) 테스트 데이터 설계

1 Digital Evasion Attack Test

입력 이미지, 음성, 텍스트 등에 미세한 perturbation을 주입하여 모델이 오분류·오탐·미탐을 일으키는지 평가함.

FGSM, PGD 같은 알고리즘을 적용한 디지털 섭동 기반 회피 공격 데이터를 생성

이미지 예시 (표지판)



핵심 포인트: 미세 섭동은 인간이 거의 인지하지 못하지만, AI 모델에는 큰 영향을 미칠 수 있음.

2 Physical Attack Simulation

실제 물리 환경에서 발생 가능한 공격을 모사함.

표지판 스티커



차량 외부 특수 패턴



레이저 교란 (LiDAR/카메라)



카메라 눈부심 (Glare/Dazzle)



비가청 음향 명령 / 스피커를 통한 은닉 명령



예: 표지판 스티커, 차량 외부 특수 패턴, 레이저 교란, 카메라 눈부심, 비가청 음향 명령, 스피커를 통한 은닉 명령

3 Sensor / Channel Spoofing Test

센서나 통신 채널에 위조 신호를 주입하여 시스템이 이를 정상 입력으로 오인하는지 검증함.

LiDAR Spoofing



GPS Spoofing



V2X 메시지 위조



마이크 입력에 은닉 명령 삽입



예: LiDAR spoofing, GPS spoofing, V2X 메시지 위조, 마이크 입력에 은닉 명령 삽입



핵심 차이



Digital Evasion

디지털 입력 내부에 미세 섭동을 삽입



Physical Attack

현실 세계에서 재현 가능한 기반 자극을 모사



Sensor/Channel Spoofing

센서·통신 채널 자체에 위조 신호를 주입


무결성 유형의 Invalid 테스트 데이터 설계

형식적 무결성 (Syntactic / Structural Integrity)

사전에 정의된 Schema, Type, Format, Range를 준수하는가?



1 Schema / Format Violation Test

schema, type, format, range, required field, length, enum 값 등을 의도적으로 위반한 데이터를 생성

 123 ❌ 잘못된 데이터 타입 (string 대신 숫자)	 name: null ❌ NULL 필드 (필수 필드가 null)	 status: "X" ❌ enum: [A,B,C] ENUM 값 범위 초과	 { "id": 1, "name": "Kim" } ❌ 깨진 JSON / XML 구조	 .txt ❌ 잘못된 이미지 포맷
---	---	--	---	--

2 Packet / Field Mutation Test

센서 패킷, API 메시지, JSON/XML, 이미지 metadata 등에서 필드 누락, 타입 변경, 순서 변경, 잘못된 header, 깨진 파일 구조를 주입

 { "id": 123, "ts": "2024-05-20" } ❌ 필드 누락 (필수 필드 제거)	 MAGIC: 0xABCD LEN: 1024 TYPE: IMG ... MAGIC: 0xFFFF ❌ 손상된 Header (잘못된 시그니처)	 { a: 1, b: 2, c: 3 } → { c: 3, a: 1, b: 2 } ❌ 필드 순서 변경 (의도적 재정렬)	 EXIF: Make: Model: Date: ... ❌ 깨진 Metadata (불완전 / 손상)
---	---	--	---



핵심 : 데이터 구조와 형식이 깨지면 시스템은 입력 거부, 오류 처리, fallback이 가능해야 함

신호 품질 / 정보 충분성 (Signal Quality / Data Fidelity)

특징을 추출하기에 충분한 신호 품질과 정보량을 가지는가?


1 Signal Quality Degradation Test

노이즈, 블러, 저해상도, clipping, compression artifact, 센서 오염, 렌즈 가림 등을 주입

 블러 (초점 흐림)	 노이즈 (고/저주파)	 렌즈 오염 (먼지/오염)	 클리핑 오디오 (신호 포화)	 저해상도 (픽셀화)
--	---	---	---	--

2 Information Loss / Extreme Corruption Test

데이터가 추론 가능한 임계치를 넘어서 훼손되는 경우를 생성

 심각한 손상 이미지 (글리치/깨짐)	 포화된 센서 신호 (과포화/밝기 과다)	 심각하게 손상된 오디오 (왜곡/신호 붕괴)	 거의 판독 불가 (정보 거의 없음)
--	--	--	--



핵심 : 정보량이 부족하거나 신호가 심각하게 손상되면 시스템은 억지 추론 대신 **safe handling**이 필요함

논리성 유형의 Invalid 데이터 설계

개별 데이터 내부 일관성 (Intra-item Consistency)

동일 시점의 하나의 입력 record 안에서 관련 피쳐들이 서로 모순되지 않는가?

1 Cross-field Consistency Violation Test

동일 시점의 하나의 입력 record 안에서 서로 관련된 피쳐를 모순되게 조작함



2 Physical / Semantic Constraint Test

도메인 물리 법칙이나 의미 제약을 위반하는 값을 생성함




핵심: 동일 시점 내부의 의미적 / 물리적 모순을 찾아야 함

데이터 간 선후 일관성 (Inter-item / Temporal Consistency)

연속된 시계열 흐름에서 시간적·인과적 변화가 타당한가?

1 Temporal Sequence Mutation Test

frame, audio segment, sensor packet의 순서, timestamp, 간격을 조작하여 시간 흐름을 깨뜨림



2 Spike / Jump / Drift Injection Test

물리적으로 불가능한 급격한 변화, 순간 이동, spike, 장기 drift를 주입함



3 Frame Drop / Reordering Test

영상 frame, LiDAR scan, audio frame, sensor packet 일부를 누락하거나 순서를 바꾸어 시계열 일관성을 무너뜨림



핵심: 시간 흐름과 인과 관계가 깨지면 safe handling이 필요함

요약: 강건성 테스트 케이스 설계

데이터 유형	테스트 데이터 생성 기법
Unseen	Semantic OOD, Domain Shift
Biased	Cross-context, Counterfactual
Adversarial	Digital Evasion, Physical Attack Simulation, Sensor/Channel Spoofing
Invalid	Schema / Format Violation Data Generation Packet / Field Mutation Data Generation
	Signal Quality Degradation Data Generation Information Loss / Extreme Corruption Data Generation
	Cross-field Consistency Violation Data Generation Physical / Semantic Constraint Data Generation
	Temporal Sequence Mutation Data Generation Spike / Jump / Drift Injection Data Generation Frame Drop / Reordering Data Generation

Q & A
