

공정성
(Fairness)

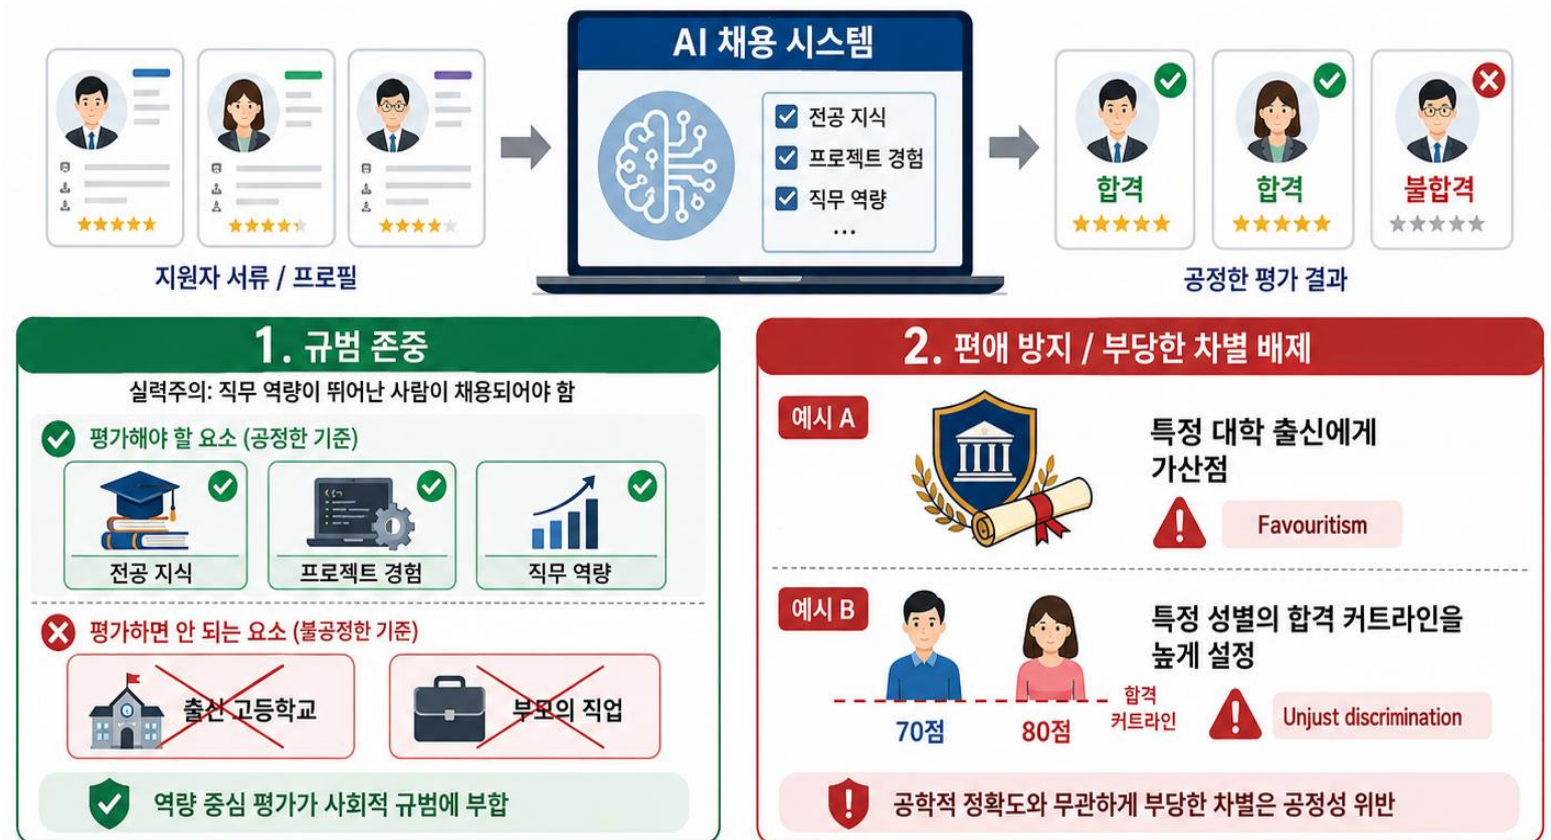
목차

- ❖ 공정성 개념
- ❖ 개인 공정성 vs 그룹 공정성
- ❖ 그룹 공정성 평가 지표
- ❖ 개인 공정성 평가 지표
- ❖ 공정성 평가 지원 도구
- ❖ Task 유형과 공정성
- ❖ LLM 공정성

공정성 개념



1. 핵심 정의: 규범 존중과 차별의 배제

❖ "기획립된 규범을 존중하며, 부당한 차별 없이 결과가 도출되는가?"




2. 사회적 영향력: 파급 효과 고려

❖ "시스템의 결과가 개인의 삶과 사회 구조에 어떤 영향을 미치는가?"



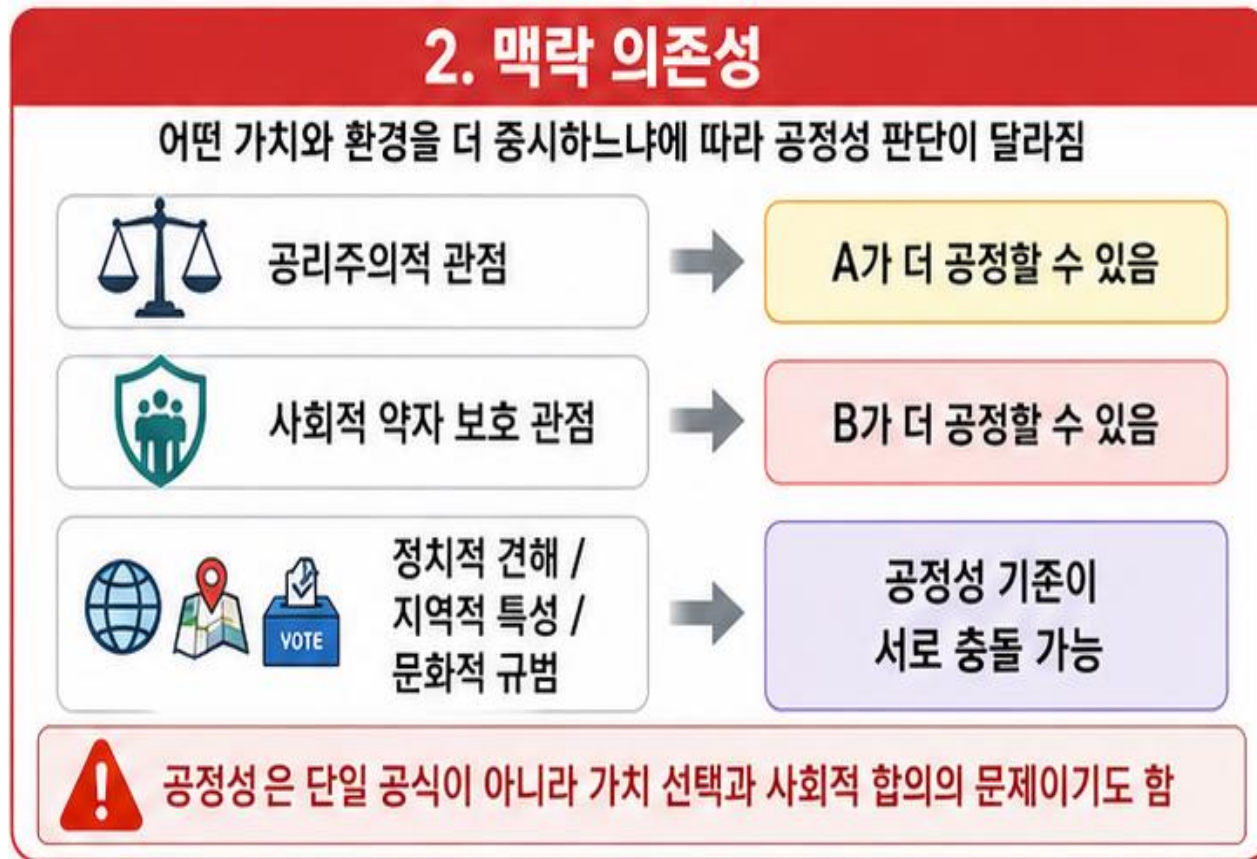
3. 상대성 및 복잡성: 맥락 의존성과 가치의 충돌

- ❖ "보편적이고 고정된 하나의 답이 아니라, 문화, 상황, 가치의 우선순위에 따라 공정성의 정답은 달라질 수 있음"



3. 상대성 및 복잡성: 맥락 의존성과 가치의 충돌

- ❖ "보편적이고 고정된 하나의 답이 아니라, 문화, 상황, 가치의 우선순위에 따라 공정성의 정답은 달라질 수 있음"



보호 속성

❖ 법적·윤리적으로 차별의 근거가 되어서는 안 되는 속성

분류	한국 (헌법/국가인권위 원회법 등)	미국 (EEOC/민권법 등)	EU (GDPR/AI Act 등)
인적 특성	성별, 연령, 장애, 외모(신체조건)	성별(임신 포함), 연령(40세 이상), 장애	성별, 연령, 장애, 신체적 특징
사회적 배경	인종, 국적, 출신 지역, 학력	인종, 피부색, 출신 국가	인종, 민족, 사회적 출신
신념/가치관	종교, 정치적 의견, 사상	종교	종교, 신념, 정치적 견해

민감 속성과 보호 속성

❖ 민감 속성: 프라이버시 보호

- 외부로 노출될 경우
프라이버시 침해나 사회적
낙인을 초래할 수 있는 모든
주관적·객체적 특성

❖ 보호 속성: 공정성 기준

- 민감 속성 중에서도 법률이나
사회적 합의에 의해 "이
속성을 근거로 차별적 결정을
내려서는 안 된다"라고
명시적으로 규정된 속성



대리(Proxy) 속성

- ❖ 보호 속성과 통계적으로 강하게 연결되어 보호 속성의 추론을 가능케 하는 속성
- ❖ 예시
 - '성별' 열을 지워도, '쇼핑 목록(화장품 등)'이나 '커뮤니티 활동'이 성별을 추론하게 함.
 - '인종' 열을 지워도, '우편번호(주소)'가 특정 인종의 거주 지역을 나타내는 대리 변수 역할을 함.
- ❖ 따라서 보호 속성을 제거하는 것뿐만 아니라, 대리 변수에 의한 영향도 고려할 필요가 있음

개인 공정성 VS 그룹 공정성

개인 공정성 vs 그룹 공정성


구분	 그룹 공정성 (Group Fairness)	 개인 공정성 (Individual Fairness)
공정성 대상	집단 (거시적)	개인 (미시적)
핵심 철학	자격 있는 사람을 놓치지 않는 정도가 그룹 간 균등한가? (집단간 평등)	유사한 개인들이 유사한 결과를 받는가? (판단의 일관성)
주요 질문	“실제로 긍정 결과를 받을 자격이 있는 그룹 A와 그룹 B의 구성원이 긍정 판정을 받을 확률이 유사한가?”	“나와 조건이 거의 같은 저 사람이 나와 똑같은 결과를 받았는가?”

그룹 공정성 사례

대출심사: 성별

✓ 공정성 충족


남성 신청자의 대출 승인율이 40%일 때,
여성 신청자의 승인율도 약 40% 수준으로 유지됨.



집단 간 승인율 균형

! 공정성 위반


남성은 60%가 승인되지만,
여성은 유사한 경제 조건을 가졌음에도 20%만 승인됨.



! Demographic Parity 위반


! 상환 능력이 유사한 경우에는 Equal Opportunity 위반

특정 소수 인종 그룹에서 자격을 갖춘 지원자가
합격할 확률이 다수 인종 그룹과 동일함.



자격 보유자 기준 합격률 균형

동일하게 우수한 능력을 갖췄음에도
특정 인종 그룹의 탈락률이 통계적으로 유의미하게 높음.



Equal Opportunity 위반


서류전형: 인종

개인 공정성 사례

신용카드 한도: 종교, 지역

✓ 공정성 충족

연봉, 직업, 신용 점수가 거의 동일한 두 고객이 서로 다른 거주지에 살더라도 비슷한 한도를 부여받음.



! 공정성 위반

모든 조건이 같지만, 특정 고객이 '특정 종교'를 가졌거나 '특정 동네'에 산다는 이유로 한도가 대폭 삭감됨.



건강 상태와 생활 습관 점수가 1점 차이 나는 두 가입자의 보험료 격차가 아주 미세하게 산정됨.



건강 점수는 거의 같으나, 모델의 민감도 오류로 인해 한 사람은 10만 원, 다른 사람은 30만 원의 보험료가 책정됨.




의료 보험료 산정

그룹 공정성 평가 지표

그룹 공정성 평가 지표 요약

	공정성 지표	핵심 질문	방지하는 불공정 유형
 결과 배분 지향	1 Demographic Parity	결과의 배분 자체가 그룹 간 균등한가?	선정·승인·배분 결과의 집단 간 불균형
	2 Disparate Impact	집단 간 선정률의 비율이 허용 기준을 충족하는가?	표면적으로 중립적인 기준이 특정 집단에 미치는 불리한 영향
 예측 정확도 지향	3 Predictive Parity	긍정 판정의 신뢰도가 그룹 간 균등한가?	긍정 판정의 품질·신뢰도 차이
	4 Equal Opportunity	자격 있는 사람을 놓치지 않는 정도가 그룹 간 균등한가?	자격 있는 사람에 대한 기회 박탈 또는 과소 선발
 오류 패턴 지향	5 Equalized Odds	탐지 성공률과 오탐률이 모두 그룹 간 균등한가?	탐지 실패와 오탐이 특정 집단에 집중되는 복합 오류 불공정
	6 Treatment Equality	오류의 상대적 성격이 그룹 간 균등한가?	거짓 양성·거짓 음성 오류 부담의 집단 간 불균형

결과 배분 중심 평가 지표

지표	핵심 질문	설명	예시
 인구 통계학적 패리티 (Demographic Parity)	결과의 배분 자체가 그룹 간 균등한가?	보호 집단별 긍정 판정률 또는 선정률이 유사한지를 평가함. 실제 자격 여부는 직접 고려하지 않음	● 채용: 남성 지원자 중 선발되는 비율과 여성 지원자 중 선발되는 비율이 동일함 ● 마케팅: 소득 수준과 관계없이 모든 지역에 쿠폰을 동일한 비율로 발송함
 불균등 영향 (Disparate Impact)	집단 간 선정률의 비율이 허용 기준을 충족하는가?	두 그룹 간 긍정 판정률 또는 선정률의 비율이 일정 기준, 예: 80% rule, 이상인지 평가함	● 채용: 소수 인종 그룹의 선발률을 다수 또는 최고 선발률 집단의 선발률로 나눈 값이 0.8 이상임 ● 신용카드: 여성 고객의 승인율이 남성 고객 승인율 대비 일정 기준 이상으로 유지됨

예측 정확도 중심 평가 지표

지표	핵심 질문	설명	예시
 예측 패리티 (Predictive Parity)	긍정 판정의 신뢰도가 그룹 간 균등한가?	긍정 판정을 받은 대상 중 실제 적격자의 비율, 즉 PPV/Precision이 그룹 간 균등한지를 평가함	● 재범 예측: 모델이 '고위험'으로 분류한 사람 중 실제 재범자의 비율이 인종별로 동일함 ● 성적 예측: AI가 '우수'로 예측한 학생 중 실제 우수생 비율이 지역별로 동일함
 기회의 평등 (Equal Opportunity)	자격 있는 사람을 놓치지 않는 정도가 그룹 간 균등한가?	실제 자격이 있는 사람들 중 긍정 판정을 받는 비율, 즉 TPR/Recall이 그룹 간 균등한지를 평가함	● 대출: 실제 상환 능력이 있는 남성과 여성이 승인받는 비율이 동일함 ● 대학 입학: 실제 입학 역량이 충분한 흑인과 백인 학생의 합격률이 동일함

오류 양상 중심 평가 지표

지표	핵심 질문	설명	예시
 균형된 오차 (Equalized Odds)	탐지 성공률과 오탐률이 모두 그룹 간 균등한가?	실제 양성 집단의 TPR과 실제 음성 집단의 FPR이 모두 그룹 간 균등한지를 평가함	● 얼굴 인식: 실제 동일 인물인 경우 맞게 인식하는 비율과, 실제 다른 인물을 동일 인물로 잘못 매칭하는 비율이 인종 집단 간 유사함 ● 부정행위 탐지: 모든 연령대에서 부정행위자를 탐지하는 비율과 정상 사용자를 잘못 차단하는 비율이 동일함
 처우의 평등 (Treatment Equality)	오류의 상대적 성격이 그룹 간 균등한가?	거짓 양성 오류와 거짓 음성 오류의 상대적 비율, 즉 FP/FN 또는 FPR/FNR 비율이 그룹 간 균등한지를 평가함	● 보험: 실제 승인 가능자를 거절하는 오류와 실제 고위험자를 승인하는 오류의 비율이 성별 간 유사함 ● 치안: 무고한 사람을 고위험자로 오인하는 오류와 실제 고위험자를 놓치는 오류의 상대적 비율이 인종 집단 간 유사함

도메인별 공정성 평가 지표 선택 가이드

도메인 성격	우선 지표	설명
 사회적 배려/혜택 장학금, 공공 지원, 복지 서비스	Demographic Parity / Disparate Impact	역사적 편향이나 구조적 불이익을 완화하기 위해, 보호 집단 간 혜택 배분 또는 선정률의 과도한 차이를 줄이는 데 초점을 둠
 기회 제공 채용, 대입, 대출 승인	Equal Opportunity	실제 자격이 있는 사람이 성별, 인종, 지역, 장애 여부 등 보호 속성 때문에 소외되지 않도록, 자격자에 대한 긍정 판정률, 즉 TPR/Recall의 균등성을 중시함
 위험 탐지/처벌/제재 범죄 예측, 부정행위 탐지, 세무 감사, 보험 사기 탐지	Equalized Odds	실제 위험 대상을 탐지하는 비율과 무고한 대상을 잘못 위험하다고 판단하는 비율이 특정 집단에 불리하게 치우치지 않도록, TPR과 FPR의 균등성을 함께 관리함



핵심 메시지

도메인에 따라 공정성의 우선 기준은 달라지며, 적용 맥락에 맞는 평가 지표 선택이 중요함

기능 정확성 vs 공정성 요약

구분	기능 정확성	공정성
 핵심 질문	예측이 맞는가?	맞고 틀림이 집단/개인에게 부당하게 분포하지 않는가?
 주된 기준	전체 정확도	집단별/개인별 정확도 차이
 평가 지표	Task 유형 별 평가 지표	그룹 공정성 평가 지표 개인 공정성 평가 지표
 분석 단위	전체 데이터셋 또는 전체 사용자	보호 집단, 취약 집단, 유사 개인 쌍
 실패 상황	전체적으로 예측이 부정확함	전체 정확도는 높지만 특정 집단/개인이 지속적으로 불리함
 설계 관심	모델 정확도 개선	데이터 편향, 보호 속성, 대리 변수, 집단/개인 간 격차



핵심 메시지

기능 정확성은 전체 예측 성능을 평가하고,
공정성은 그 성능과 결과가 집단과 개인에게 어떻게 분포하는지를 평가함.

개인 공정성 평가 지표

개인 공정성 평가 지표 요약

지표 유형	지표 명칭	핵심 질문	방지하는 불공정 유형
 일관성 중심	 유사도 기반 일관성	유사한 개인들이 유사한 결과를 받는가?	유사 개인 간 판단 불일치 및 개별적 차별
	 립시츠 연속성	입력값의 작은 차이가 결과값의 과도한 차이를 만들지 않는가?	작은 차이가 큰 불이익으로 증폭되는 불안정한 판정
 불평등 분포 중심	 테일 지수	예측 혜택, 손실, 오류 부담이 개인들 사이에 불평등하게 집중되는가?	오류·불이익 부담의 개인 간 불평등
 인과 기반	 반사실적 공정성	동일한 개인의 보호 속성만 바꾸어도 결과가 유지되는가?	보호 속성에 의한 직접적 차별
	 인과적 공정성	보호 속성이 부당한 인과 경로를 통해 결과에 영향을 주지 않는가?	대리 변수와 구조적 경로를 통한 간접 차별



개인 공정성은 유사 개인의 일관성, 개인 간 불이익 분포, 보호 속성의 인과적 영향까지 함께 고려함


일관성 중심 평가 지표

입력 특성이 비슷한 개인들이 AI 시스템으로부터 비슷한 예측값이나 의사결정 결과를 받는지를 분석함.

지표	핵심 질문	설명	예시
유사도 기반 일관성 (Consistency Score) 	유사한 개인들이 유사한 결과를 받는가?	입력 특성이 매우 유사한 개인 또는 객체들이 서로 유사한 예측값이나 의사결정 결과를 받는지를 평가함. 개인 공정성의 기본 원칙인 '유사한 개인은 유사하게 대우되어야 한다'를 직접 측정함	• 대출: 나이, 소득, 신용등급이 거의 같은 두 사람이 단지 거주지가 다르다는 이유로 대출 한도나 승인 여부가 크게 달라지지 않음 • 채용: 경력, 기술, 프로젝트 경험이 유사한 두 지원자에게 AI가 부여한 직무 적합도 점수가 거의 같음
립시츠 연속성 (Lipschitz Continuity) 	입력값의 작은 차이가 결과값의 과도한 차이를 만들지 않는가?	개인 간 입력 특성의 차이가 작다면, 모델 출력 또는 의사결정 결과의 차이도 작아야 한다는 수학적 기준임. 유사한 개인 사이에서 결과가 갑자기 크게 바뀌는 불연속적·민감한 판정을 방지함	• 보험: 건강검진 점수가 1점 차이 나는 두 가입자의 보험료가 비정상적으로 크게 벌어지지 않음 • 대학 입학: 수능 점수나 평가 점수가 거의 같은 두 지원자의 합격 확률이 계단식으로 크게 달라지지 않음



불평등 분포 중심 평가 지표

‘비슷한 사람을 비슷하게 대우했는가’보다, ‘모델의 오류와 불이익이 특정 개인들에게 집중되고 있는가’를 평가함

지표	핵심 질문	설명	예시
테일 지수 (Theil Index) 	예측 혜택, 손실, 오류 부담이 개인들 사이에 불평등하게 집중되는가?	모델의 예측 결과, 혜택, 손실, 오류가 전체 개인에게 얼마나 불균등하게 분포하는지를 평가함. 값이 클수록 특정 개인이나 소수 집단에게 오류 또는 불이익이 집중되어 있음을 의미함	• 의료: AI 암 진단 모델의 오진이 전체 환자에게 고르게 발생하는 것이 아니라 특정 소수 환자에게 반복적으로 집중되지 않는지 평가함 • 사기 탐지: 이상 거래 탐지 모델의 오탐으로 인한 계정 정지, 추가 인증, 거래 지연 등의 부담이 특정 사용자 패턴을 가진 소수에게만 집중되지 않는지 평가함

인과 기반 평가 지표

인과 관점에서 평가하는 기준으로, 보호 속성 또는 그 대리 경로가 특정 개인의 결과를 부당하게 바꾸는지를 분석함

지표	핵심 질문	설명	예시
반사실적 공정성 (Counterfactual Fairness) 	동일한 개인의 보호 속성만 바꾸어도 결과가 유지되는가?	특정 개인에 대해 성별, 인종, 종교, 국적 등 보호 속성만 다른 값으로 바꾼 가상 상황을 만들었을 때, AI의 예측 결과나 의사결정 결과가 달라지지 않는지를 평가함. 즉 “이 사람이 다른 성별/인종/종교였더라도 같은 결정을 받았을까?”를 확인함	• 인사 고과: 직원 A의 성과, 경력, 프로젝트 기여도는 그대로 두고 성별만 ‘여성’에서 ‘남성’으로 바꾸어도 승진 추천 여부가 동일함 • 광고 노출: 특정 사용자의 검색 이력, 직무 경험, 관심사는 그대로 두고 종교 정보만 바꾸어도 고소득 직종 광고 노출 빈도가 동일함
인과적 공정성 (Causal Fairness) 	보호 속성이 부당한 인과 경로를 통해 결과에 영향을 주지 않는가?	보호 속성이 결과에 직접 사용되지 않더라도, 거주 지역, 학력, 소득, 네트워크, 변호사 선임 여부 같은 대리 변수나 중간 변수를 통해 결과에 부당하게 영향을 미치는지를 인과 관계 관점에서 분석함. 단순 상관관계가 아니라 “어떤 경로를 통해 차별적 결과가 발생하는가”를 평가함	• 신용 평가: 인종을 직접 입력 변수로 사용하지 않더라도, 인종과 강하게 연관된 거주 지역이 신용 점수 하락의 경로로 작동하지 않도록 함 • 형사 판결: 국적이 변호사 선임 여부나 과거 수사 이력과 연결되어 최종 형량에 부당하게 영향을 주지 않도록 함

공정성 평가 지원 도구

그룹 공정성 지표 평가 도구

- ❖ 그룹 공정성 지표는 민감 속성별 선정률과 오류율을 비교하므로, 개인 공정성 지표보다 표준화된 도구 지원이 상대적으로 잘 갖추어져 있음

평가도구	특징
AIF360	IBM에서 시작된 공정성 평가 오픈소스 도구 • Statistical Parity Difference, Disparate Impact, Equal Opportunity Difference 등 다양한 그룹·개인 공정성 지표 제공
Fairlearn	Microsoft가 주도하는 공정성 평가 오픈소스 도구 • MetricFrame을 이용한 민감 속성별 성능·선정률 비교
Amazon SageMaker AI Clarify (SageMaker Claify)	AWS SageMaker에서 제공하는 편향 분석 도구 • Disparate Impact 등 모델 예측 편향을 분석하는 11개의 학습 후 지표 제공
Azure Machine Learning (Azure ML)	Microsoft Azure에서 제공하는 책임 있는 AI 분석 플랫폼 • Responsible AI Dashboard를 통해 민감 속성별 성능·선정률 차이 분석

그룹 공정성 지표별 평가 지원도구

평가 지표	AIF360	Fairlearn	SageMaker Clarifai	Azure ML
Demographic Parity	● Statistical Parity Difference	● demographic_parity_difference	● DPPL	○ 집단별 Selection Rate의 차이·비율
Disparate Impact	● disparate_impact	● demographic_parity_ratio	● DI	○ 집단별 Selection Rate의 비율
Predictive Parity	○ 집단별 positive_predictive_value 비교	○ precision_score를 MetricFrame을 이용하여 비교	● DAR	○ 집단별 Precision 비교
Equal Opportunity	● equal_opportunity_difference	○ true_positive_rate 또는 Recall을 MetricFrame 이용하여 비교	● Recall Difference(RD)	○ 집단별 TPR (Recall) 비교
Equalized Odds	● equalized_odds_difference 또는 average_odds_difference	● equalized_odds_difference/ratio	○ RD와 SD(=1-FPR)를 함께 해석	○ 집단별 TPR과 FPR을 함께 비교
Treatment Equality	△ 집단별 FN/FP를 계산하여 비교	△ 집단별 FN/FP 비율을 사용자 정의로 계산·비교	● Treatment Equality(TE)	△ 집단별 FN/FP를 계산하여 비교

- 해당 공정성 지표 또는 실질적으로 동일한 지표를 직접 제공 .
- 기본 성능지표를 집단별로 비교하여 평가 .
- △ 별도 계산 또는 사용자 정의 구현 필요

개인 공정성 지표 평가 도구

- ❖ 개인 공정성 지표는 개인·인과 공정성은 개인 간 유사성, 거리함수 또는 인과모형을 정의해야 하므로 그룹 공정성보다 표준화된 도구 지원이 제한적임.

평가도구	특징
AIF360	IBM에서 시작된 공정성 평가 오픈소스 도구 • Consistency Score를 통해 유사한 개인에게 유사한 예측이 제공되는지 평가 • Theil Index-Generalized Entropy Index를 통해 개인별 편익과 오류의 불평 등 정도 측정
Fairlearn	Microsoft가 주도하는 공정성 평가 오픈소스 도구 • MetricFrame을 이용한 민감집단별 성능 차이 분석에 강점 • 개인 공정성 전용 지표는 제한적이며, 유사도 기반 지표는 사용자가 별도로 정의하여 계산해야 함
What-If Tool	Google이 개발한 모델 탐색·시각화 오픈소스 도구 • 입력 특성을 변경하고 예측 결과가 어떻게 달라지는지 반사실적으로 탐색 가능 • 공정성을 수치적으로 입증하기보다, 개별 사례의 민감도와 모델 행동을 시각적으로 점검하는 데 활용
DoWhy Tool	Microsoft에서 시작되어 현재 PyWhy에서 개발하는 오픈소스 인과추론 도구 • 구조적 인과모형을 기반으로 보호 속성을 반사실적으로 변경했을 때 예측이 유지되는지 분석

개인 공정성 지표 평가 지원도구

평가 지표	AIF360	Fairlearn	What-If	DoWhy
유사도 기반 일관성	● Consistency Score로 유사한 이웃 간 예측 차이 측정	○ 사용자 정의 유사도·개인별 지표 필요	△ 유사 사례와 예측 결과를 시각적으로 비교	
립시츠 연속성	○ 사용자 정의 거리함수로 입력 거리 대비 출력 차이 계산	○ 사용자 정의 지표로 구현	△ 입력 변화에 따른 예측 민감도를 시각적으로 탐색	
테일 지수	● theil_index와 generalized_entropy_index 제공	○ 개인별 편익을 정의한 후 사용자 정의 계산		
반사실적 공정성	△ FACTS 등을 활용한 공정성 인식 반사실 분석 가능하지만 전용 평가에는 한계	○ 반사실 표본을 생성한 후 사용자 정의 지표로 비교	△ 보호 속성 변경 전후의 예측 변화를 시각적으로 탐색	● 구조적 인과모형을 기반으로 실제·반사실 세계의 예측 비교
인과적 공정성				● 보호 속성의 총 효과와 직접·간접 인과효과를 추정하여 평가

● 전용 지표 또는 공식 분석 사례 제공.
○ 사용자 정의를 통해 정량 평가 가능.
△ 탐색·보조 분석에 활용

TASK 유형과 공정성

Task 유형과 공정성

❖ 공정성의 정의가 분류 task로 한정되는 것은 아님.

- 다만 지금까지 널리 소개된 대표 지표들이 승인/거절, 합격/불합격, 양성/음성처럼 이진 분류 문제에서 가장 먼저 정식화되었기 때문에, 공정성 지표가 분류 중심으로 보이는 것임.

❖ 공정성은 더 일반적으로 보면 다음 질문을 다룸.

- AI 시스템의 예측, 점수, 순위, 추천, 할당, 설명, 오류가 개인 또는 집단에게 부당하게 불리하게 작용하지 않는가?
- 따라서 분류뿐 아니라 회귀, 랭킹, 추천, 생성형 AI에서도 공정성은 다룰 수 있음.

Task 유형 별 공정성 의미

Task 유형	Task 출력 형태	공정성 의미
분류	승인/거절, 양성/음성	집단 간 긍정률·오류율이 공정한가?
회귀	점수, 가격, 위험도	집단별 예측값·오차·과소/과대 예측이 공정한가?
랭킹	순위	상위 노출과 주목도가 공정한가?
추천	추천 리스트	사용자·제공자 모두에게 공정한가?
클러스터링	군집	특정 집단이 부당하게 분리·배제되는가?
생성형 AI	텍스트/이미지/코드	특정 집단에 대한 표현·응답 품질·거부 정책이 공정한가?

LLM 공정성

LLM 공정성

❖ LLM 공정성

- 단순히 분류 결과의 개인/집단별 정확도의 균형이 아니라
- 생성·요약·추천·평가·거부·도구 호출 과정에서
- 특정 집단, 언어권, 문화권, 개인에게 부당하게 낮은 품질, 높은 위험, 불리한 판단이 발생하지 않도록 하는 요구사항이다.

❖ LLM 공정성 유형

공정성 유형	핵심 질문	대표 요구사항	미충족 상황
표현·내용 공정성	특정 집단을 어떻게 묘사하고 표현하는가?	• 고정관념·편견 생성 금지 • 혐오·차별 표현 금지 • 요약·번역·재작성 왜곡 방지	• 특정 집단을 고정관념적으로 묘사함 • 혐오·비하·차별 표현을 생성함 • 요약·번역·재작성 과정에서 특정 집단의 관점이나 피해를 축소
응답·정책 공정성	사용자 집단별로 같은 품질과 정책을 제공하는가?	• 사용자 집단·언어·문화권별 응답 품질 균등성 • 거부 정책 균형성	• 특정 언어·비서구 문화권 사용자에게 답변 품질 낮음 • 특정 집단 관련 질문만 과도하게 거부함
판단·행동 공정성	평가·추천·도구 행동이 특정 집단에 불리하지 않은가?	• 보호 속성 변화에 따른 판단·추천·평가 일관성 • 도구 호출·에이전트 행동의 차별적 영향 방지	• 성별, 국적만 바뀌었는데 추천 결과가 달라짐 • 특정 집단의 요청만 도구 호출 실패율이 높음

LLM 공정성 테스트

테스팅 방식	설명	주로 확인하는 요구사항
정적 테스트 세트 기반 평가	보호 속성, 이름, 언어, 지역, 종교, 성별, 장애 여부 등을 조합한 사전 정의 프롬프트 세트를 반복 실행하고, 응답품질·거부율·독성·고정관념·정중함의 차이를 측정함	- 고정관념·편견 생성 금지 - 혐오·차별 표현 금지 - 사용자 집단·언어·문화권별 응답 품질 균등성 - 거부 정책 균형성
벤치마크·자동 평가 기반 평가	공개 편향·차별 벤치마크(BBQ/KoBBQ, StereoSet 등)와 혐오·독성 벤치마크(RealToxicityPrompts, ToxiGen 등)를 내부 테스트 세트와 함께 사용하고, toxicity classifier, stereotype detector, LLM judge, fairness rubric으로 자동 평가함	- 고정관념·편견 생성 금지 - 혐오·차별 표현 금지 - 사용자 집단·언어·문화권별 응답 품질 균등성

LLM 공정성 테스트

테스팅 방식	설명	주로 확인하는 요구사항
반사실적 프롬프트 기반 평가	동일한 질문이나 업무 시나리오에서 성별, 인종, 종교, 국적, 이름, 지역, 학교명 등 보호 속성 또는 대리 속성만 바꾼 쌍대 프롬프트를 구성하고, 판단·추천·평가·요약·설명·거부 결과가 부당하게 달라지는지 확인함	• 보호 속성 변화에 따른 판단·추천·평가 일관성 • 거부 정책 균형성 • 요약·번역·재작성 왜곡 방지
전문가 레드팀 및 운영 로그 평가	전문가·취약 집단 대표·도메인 전문가가 다단계 공격과 실제 사용 시나리오를 테스트하고, 운영 로그에서 집단별 품질·거부율·도구 성공률 격차를 분석함	• 고정관념·편견 생성 금지 • 혐오·차별 표현 금지 • 요약·번역·재작성 왜곡 방지 • 사용자 집단·언어·문화권별 응답 품질 균등성 • 거부 정책 균형성 • 도구 호출·에이전트 행동의 차별적 영향 방지

편향/차별 중심 벤치마크

Benchmark	평가 대상	설명
BBQ / KoBBQ	QA 편향, 보호 집단 편향	질문응답 상황에서 보호 집단 관련 고정관념과 편향된 판단을 평가
StereoSet	고정관념 선호	성별, 직업, 인종, 종교 영역에서 stereotypical 문장 선호 여부 평가
CrowS-Pairs	사회적 고정관념 편향	고정관념적 문장과 덜 고정관념적 문장 쌍을 비교
BOLD	자유형 생성 편향	open-ended generation에서 직업, 성별, 인종, 종교, 정치 이념 관련 편향 평가
HolisticBias / Multilingual HolisticBias	포괄적·다국어 정체성 편향	다양한 정체성 descriptor와 언어권 별 편향 평가

혐오/독성 중심 벤치마크

Benchmark	평가 대상	설명
RealToxicity Prompts	독성 생성	프롬프트에 이어 모델이 toxic continuation을 생성하는지 평가
ToxiGen	암묵적 혐오·소수집단 대상 독성	13개 minority group 대상 toxic/benign 문장으로 암묵적 혐오 탐지·평가
Civil Comments / Jigsaw Unintended Bias	독성 분류와 identity bias	정체성 언급이 포함된 댓글을 과잉 독성 분류하는지 평가
HateCheck	혐오 표현 탐지 기능	hate speech detector가 다양한 혐오·비혐오 케이스를 구분하는지 테스트
HONEST	hurtful completion	정체성 관련 prompt에 대해 해로운 문장 완성을 생성하는지 평가

Q & A
