

수행 효율성

(Performance Efficiency)

목차

- ❖ 수행 효율성 개념
- ❖ 수행 효율성 유형
- ❖ 수행 효율성 평가 지표
- ❖ 수행 효율성 QA 시나리오

수행 효율성 개념

수행 효율성(Performance Efficiency) 정의

Capability of a product to perform its functions within specified time and throughput parameters and be efficient in the use of resources under specified conditions

[ISO/IEC 25010:2023 SQuaRE – Product quality model]

❖ 명시된 조건 하에서, 명시된 시간 및 처리량 기준을 만족하며 기능을 수행하고 자원을 효율적으로 사용하는 제품의 능력

- **Under specified conditions**

- ✓ 하드웨어 사양, 운영체제 및 런타임 환경, 네트워크 환경, 동시 사용자 수, 요청 빈도, 입력 데이터 특성 등 시스템이 운영되는 구체적인 환경과 부하 조건

- **Within Specified time and throughput parameters**

- ✓ Time: Response Time, Latency, Processing Time, Turnaround Time 등
- ✓ Throughput: 단위 시간당 처리 가능한 요청 수, 트랜잭션 수 또는 데이터 량

- **Be efficient in the use of resources**


- ✓ CPU, 메모리, 저장장치, 디스크 I/O, 네트워크 대역폭, GPU/NPU, 전력 등 자원을 요구 성능을 만족하는 범위에서 효율적으로 사용

수행 효율성 대상 기능(Functions)

- ❖ AI 시스템이 특정 품질 속성을 달성하기 위해 수행하는 기능적 동작이 명시된 시간·처리량 기준을 만족하면서 자원을 효율적으로 사용하는 정도임

기초 QA	수행 효율성 설명
기능 정확성	추론 서비스가 동작할 때의 수행 효율성. 예) 모델이 정답을 도출하는 과정에서의 자원 대비 속도.
강건성	이상 입력, 잡음, OOD 입력, 공격적 입력, 부분 장애 등에도 기능을 유지하거나 안전하게 저하·복구하는 동작의 수행 효율성
프라이버시	익명화/비식별화, 접근 제어, 암호화, 프라이버시 보존 추론 등 개인정보 보호 기능이 동작하는 과정에서의 수행 효율성
공정성	편향을 탐지·완화하고 집단 또는 개인 간 부당한 차이를 줄이기 위한 기능 동작의 수행 효율성
기능 적응성	시스템이 환경 변화에 맞춰 재학습(Retraining)하거나 모델을 업데이트하는 적응 동작의 수행 효율성
제어 가능성	시스템을 안전한 상태로 전이시키거나 제어하는 기능 동작의 수행 효율성
설명 용이성	AI의 결정 근거(XAI)를 생성하고 사용자에게 전달하는 기능 동작의 수행 효율성

AI-based System Architecture



수행 효율성 유형

❖ 시간 효율성(Time Behavior)


- 사건 발생 시 반응 시간(Latency) 및 단위 시간당 처리량(Throughput)이 요구사항을 만족하는 정도



수행 효율성 유형

❖ 자원 활용성(Resource Utilization)

- 기능을 수행할 때 사용하는 하드웨어 자원(GPU, 메모리, 에너지 등)의 양이 최적화된 정도



수행 효율성 유형

❖ 용량(Capacity)

- 시스템이 성능 저하 없이 수용할 수 있는 최대 부하(데이터 규모, 동시 사용자 등)의 한계점



수행 효율성 예시: 도로 객체 인식


❖ Time Behavior

- 센서 데이터 입력 후 차선, 보행자, 주변 차량의 식별 및 위치 산출을 **프레임당 33ms(30 FPS)** 이내에 완료해야 한다.



❖ Resource Utilization

- 다중 객체 인식 모델이 가동될 때 차량용 NPU(신경망 처리 장치) **점유율을 평균 70% 이하**로 유지해야 한다.



❖ Capacity


- 시야 내에 존재하는 **최대 100개 이상의 개별 객체**(차량, 이륜차, 보행자 등)를 동시에 추적하더라도 인식 정확도나 처리 속도가 저하되지 않아야 한다.



수행 효율성 예시: 도로 객체 인식

❖ Time Behavior

- 사용자의 음성 명령 종료 후 의도 파악 및 제어 신호(예: 온도 조절, 차선 변경) 발생까지의 **지연 시간을 500ms 이내로** 유지해야 한다




❖ Resource Utilization

- 음성 상시 대기 및 인식 프로세스가 점유하는 **메모리를 512MB 이내로** 제한하여 주행 제어 등 미션 크리티컬 프로세스의 메모리 영역을 간섭하지 않아야 한다




❖ Capacity

- 주행 제어, 공조, 인포테인먼트 등 동시에 유입되는 다중 음성 명령(복합 명령)을 성능 저하 없이 구분하여 처리할 수 있어야 한다



수행 효율성 평가 지표

시간 효율성 평가 지표



평가 지표	핵심 의미	대표 측정값
1 End-to-End Latency	입력 요청 도착부터 최종 결과 반환까지의 전체 시간 (전체 사용자 경험 지연)	평균 / p50 / p95 / p99 (tail latency)
2 Model Inference Latency	모델 입력 전달부터 모델 출력 생성까지의 순수 추론 시간 (모델 실행 성능)	평균 / p50 / p95 / p99 (tail latency)
3 Throughput	단위 시간당 성공적으로 처리한 요청, 샘플, 데이터 또는 토큰의 수 (처리 능력)	requests/sec, samples/sec, images/sec, records/sec, tokens/sec

자원 활용성 평가 지표

- ❖ 시스템이 기능을 수행하는 동안 CPU, GPU, 메모리, 저장장치, 네트워크, 에너지 등을 얼마나 효율적으로 사용하는지 평가하는 지표

평가 지표	정의	설명	측정 방법
Memory Footprint	실행 중 시스템이 점유하는 RAM, VRAM, 기타 메모리의 양	모델 크기, 배치 크기, 동시 요청 수, KV cache 크기와 밀접함. 엣지 AI나 LLM serving에서 중요함	평균/최대 RAM, VRAM 사용량. MB, GB 단위
Peak Memory Usage	작업 수행 중 발생한 최대 메모리 사용량	Out Of Memory 오류 가능성, 최대 배치 크기, 최대 입력 길이 판단에 중요함	실행 중 관측된 최대 RAM/VRAM 사용량
Compute Utilization	CPU, GPU, NPU 등 연산 장치의 사용률	연산 자원이 실제 작업에 투입되는 정도를 나타냄. 단, 사용률이 높다고 항상 효율적이라는 뜻은 아님	CPU/GPU/NPU utilization %, GPU SM utilization, accelerator utilization 등
Resource Efficiency	일정 성능을 달성하기 위해 사용한 자원량	단순 자원 사용률보다 성능 대비 자원 효율을 평가하는 데 적합함	throughput/GPU, tokens/sec/GPU, requests/sec/core, 성능/메모리 등

자원 활용성 평가 지표

- ❖ 시스템이 기능을 수행하는 동안 CPU, GPU, 메모리, 저장장치, 네트워크, 에너지 등을 얼마나 효율적으로 사용하는지 평가하는 지표

평가 지표	정의	설명	측정 방법
Energy Consumption	특정 작업을 수행하는 데 소비된 총 에너지	AI 시스템의 지속 가능성, 배터리 기반 시스템, 데이터센터 비용과 관련됨	J, Wh, kWh 단위. 추론 1회, 1,000 token, 학습 1회 단위로 측정
Energy Efficiency	단위 에너지당 처리 성능	총 에너지보다 비교 가능성이 높음. MLPerf Power도 성능과 전력/에너지 효율 측정을 강조함	inferences/J, tokens/J, samples/W, tokens/sec/W 등
Network I/O Usage	기능 수행 중 사용한 네트워크 대역폭	분산 추론, RAG, 멀티에이전트, 클라우드-엣지 연동 시스템에서 중요함	MB/s, GB/s, network latency, request/response payload size
Storage I/O Usage	데이터 로딩, 검색, 로그 저장, 벡터 DB 접근 등에 사용되는 저장장치 I/O	RAG, 대규모 학습, 데이터 파이프라인 병목 분석에 중요함	read/write throughput, IOPS, I/O wait time

용량 평가 지표

- ❖ 시스템이 성능 요구사항을 위반하지 않고 감당할 수 있는 최대 부하, 입력 크기, 동시 요청 수, 데이터 처리량을 평가하는 지표

평가 지표	정의	설명	측정 방법
Max Concurrent Requests under SLO	SLO(지정된 응답 시간, 오류율, 품질 기준)를 만족하면서 동시에 처리 중일 수 있는 최대 요청 수	시스템이 SLO를 위반하지 않고 수용할 수 있는 최대 동시 부하를 나타냄	동시 요청 수를 증가시키며 p95 latency, error rate, 품질 기준을 모두 만족하는 최대 동시 요청 수를 측정
Goodput	SLO를 만족하는 단위 시간당 처리 완료된 요청 수	단순 throughput보다 실서비스 품질을 잘 반영함. 처리량이 높아도 latency나 error rate 기준을 위반하면 goodput은 낮아짐	SLO를 만족한 완료 요청 수 / 측정 시간
Scalability Efficiency	자원을 추가했을 때 처리량이 얼마나 비례적으로 증가하는지	분산 학습, 분산 추론, GPU scale-out 시스템에서 중요함	실제 speedup / 이상적 linear speedup
Performance Degradation Rate	부하, 입력 크기, 사용자 수 증가에 따라 latency 또는 throughput이 저하되는 비율	용량 한계와 포화 지점을 찾는 데 유용함	부하 증가율 대비 latency 증가율 또는 throughput 감소율

LLM 서비스 평가 지표

평가 지표	정의	의미	측정 방법
TTFT (Time to First Token)	사용자의 요청 이후 첫 번째 토큰이 출력될 때까지의 시간	사용자가 “시스템이 반응하기 시작했다”고 느끼는 시점을 결정함. 인터랙티브 LLM 서비스에서 매우 중요함	요청 전송 시점부터 첫 토큰 수신 시점까지의 시간
E2E (End-to-End) Latency	요청 제출부터 최종 토큰 수신까지의 전체 시간	짧은 응답뿐 아니라 긴 응답에서 전체 사용자 대기 시간을 평가함	요청 시점부터 마지막 토큰 수신 시점까지의 시간
TPOT (Time Per Output Token) ITL (Inter-Token Latency)	첫 토큰 이후 후속 토큰 간 평균 생성 간격	스트리밍 응답의 자연스러움과 생성 속도를 나타냄.	$(\text{E2E latency} - \text{TTFT}) / (\text{output tokens} - 1)$
Token Throughput TPS (Token per Second)	단위 시간당 전체 사용자에게 생성·전달한 출력 토큰 수	GPU 자원 대비 전체 처리 능력과 운영 효율을 나타냄	$\text{total output tokens} / \text{benchmark duration}$ 또는 측정 구간
Energy per Token Energy per Request	토큰 또는 요청 단위 에너지 소비량	지속가능성 및 운영 비용 평가에 유용함	J/token, Wh/1K tokens, J/request 등


Agent 평가 지표

지표	의미
LLM Calls per User Request	사용자 요청 1건당 LLM 호출 수
LLM Calls per Task	task 1개당 평균 LLM 호출 수
Token Cost per Request	요청 1건당 input/output token 비용
Expensive Model Invocation Ratio	고가 모델 호출 비율
Replan Rate	실행 중 재계획 발생 비율
Deterministic Execution Ratio	LLM 없이 실행된 task 비율
Task Success Rate	최종 목표 달성률

Agent → LLM

❖ Prompt/Response 규모를 줄이기 위한 방법

- LLM 호출 최소화: 필요할 때만 호출, One-shot plan than Incremental plan
- LLM 호출 Prompt 규모 최소화: 필요한 Context만 구성, 필요한 Tool만 구성
- LLM Response 규모 최소화: Response 형식/규모 구체화



수행 효율성 QA 시나리오

수행 효율성 QA 시나리오

항목	수행 효율성 관점 예시
Source	부하 발생원 및 물리적 규모 • 유형: 사용자, 외부 시스템, 센서(카메라/라이다 등), 내부 타이머 • 규모: 얼마나 많은 수의 Source가 Stimulus를 생성하는지?. 예) 자극을 생성하는 소스의 총 개수(예: 카메라 8대, 동시 접속자 1,000명)
Stimulus	데이터의 물리적 부하량과 유입 빈도 • 규모: 단일 데이터의 크기(해상도, 파라미터 수, 페이로드 용량) • 빈도: 단위 시간당 유입 횟수(FPS, TPS, Sampling Rate)
Artifact	성능 최적화 대상 실체 AI-based System, AI System, AI 추론 엔진
Environment	실행 시점의 자원 가용성 및 제약 조건 정상 운영 상황, 하드웨어 가용 자원 부족 상황(Low Memory/GPU), 네트워크 대역폭 제한 상황, 동시 접속자 폭증 상황
Response	추론 결과 출력
Measure	수행 효율성 평가 지표 (시간 반응성, 자원 활용성, 용량)

도로 객체 및 교통 표지판 인식

❖ [수행 효율성 요구사항]


- 시스템은 다중 센서로부터 유입되는 고해상도 데이터를 바탕으로 최대 120개의 동적 객체 및 교통 표지판을 30ms 이내 식별해야 한다

시스템은 다중 센서로부터 유입되는 고해상도 데이터를 실시간으로 병렬 처리하여, 최대 120개 이상의 동적 객체 및 교통 표지판을 33ms 이내에 오차 없이 식별하고 분류해야 한다.

자율주행 차량의 도로 객체 인지 모듈은 복잡한 도심 교차로의 최대 부하 상황에서 다중 센서 허브로부터 동시에 유입되는 고해상도 카메라 및 LiDAR 데이터를 실시간으로 처리해야 한다. 센서 허브는 전·후·측방 카메라 6대와 고정형 및 회전형 LiDAR 센서 2대로 구성되며, 카메라는 각 채널당 FHD 해상도의 영상을 30 FPS로 전송하고, LiDAR는 각 채널당 10Hz 주기로 약 10만 포인트 규모의 point cloud 데이터를 전송한다.

도로 객체 인지 모듈은 카메라 및 LiDAR 데이터를 수신한 뒤 전처리, 센서 융합, 객체 탐지 및 분류를 수행하여 차량, 보행자, 이륜차, 교통 표지판 등 도로 상의 객체에 대한 위치, 객체 유형, 분류 레이블, 신뢰도 값을 반환해야 한다. 이때 센서 데이터 수신부터 객체 인지 결과 반환까지의 End-to-End Latency는 p95 기준 33ms 이내여야 하며, 모든 센서 입력 스트림을 손실 없이 지속 처리해야 한다. 또한 프레임당 최대 120개 객체까지 지정된 latency 및 오류율 기준을 만족하면서 동시에 추론할 수 있어야 한다.


도로 객체 및 교통 표지판 인식



도로 객체 및 교통 표지판 인식

항목	내용
Source	다중 센서 허브(Multi-Sensor Hub) • 고해상도 전/후/측방 카메라 6대 • 고정형 및 회전형 LiDAR 센서 2대
Stimulus	각 소스별 동시 입력 및 부하 상황 • Camera: 6개 채널에서 각 30 FPS, FHD 해상도 영상 스트리밍 데이터 유입 • LiDAR: 2개 채널에서 각 10Hz, 채널당 10만 포인트 규모의 point cloud 데이터 유입
Artifact	도로 객체 인지(Perception) 모듈
Environment	최대 부하 상황(Peak Load) 복잡한 도심 교차로에서 차량, 보행자, 이륜차 등 다수의 동적 객체가 혼재되어 센서 입력량과 객체 수가 동시에 증가한 상황
Response	카메라 및 LiDAR 데이터를 실시간으로 전처리·융합하고, 도로 상의 개별 객체를 식별하여 객체 위치, 객체 유형, 분류 레이블, 신뢰도 값을 반환함
Measure	• End-to-End Latency: 센서 데이터 수신부터 객체 인지 결과 반환까지 p95 기준 33ms 이내 • Throughput: 카메라 6채널 × 30 FPS 및 LiDAR 2채널 × 10Hz 입력을 손실 없이 지속 처리 • Object Capacity under SLO: 프레임당 최대 120개 객체까지 지정 latency 및 오류율 기준을 만족하며 동시 추론 가능

도로 객체 및 교통 표지판 인식



조향각 및 주행 속도 결정

❖ [수행 효율성 요구사항]

- 시스템은 과부하 상태에서 경로 계획 모듈로부터 10ms 간격으로 차선에 대한 50개의 중심선 좌표, 곡률 정보, 전방 차량과의 목표 이격 거리를 받으면 차량의 조향각과 속도를 5ms 이내의 산출해야 한다


자율주행 차량의 주행 제어(Control) 모듈은 상위의 경로 계획(Planning) 모듈로부터 주기적으로 전달되는 경로 추종 정보를 이용하여 차량의 조향각과 가속도 제어값을 실시간으로 산출해야 한다.

경로 계획 모듈은 주행 경로, 차선 중심선, 곡률 정보, 전방 차량과의 목표 이격 거리 등 제어 입력을 생성하며, 주행 제어 모듈은 이를 기반으로 차선 이탈을 방지하고 안정적인 경로 추종이 가능하도록 제어값을 산출해야 한다.

주행 제어 모듈은 고속도로 및 도심 주행 중 급커브, 정체 구간, 도심 교차로 등 경로 변화가 빈번하고 초당 제어 연산량이 증가하는 상황에서도 정상적으로 동작해야 한다. 특히 경로 계획 모듈은 10ms 간격으로 차선 중심선 좌표 50개, 도로 곡률 정보, 전방 차량과의 목표 이격 거리 정보를 주행 제어 모듈에 전달한다.

주행 제어 모듈은 각 입력 주기마다 제어 입력을 수신한 뒤 조향각, 가속도, 감속 제어값을 산출해야 하며, 제어 입력 수신부터 제어값 산출 완료까지의 End-to-End Latency는 p95 기준 10ms 이내여야 한다. 또한 10ms 주기의 제어 입력을 손실 없이 지속 처리하여 100Hz 제어 주기를 유지해야 하며, 실시간 제어 주기에서 10ms 마감시간을 초과하는 요청 비율은 지정 기준 이하로 유지되어야 한다. 실시간 제어 우선순위가 부여된 상태에서도 CPU, GPU 또는 NPU 사용량은 지정된 자원 한계를 초과하지 않아야 한다

조향각 및 주행 속도 결정



조향각 및 주행 속도 결정

항목	내용
Source	경로 계획(Planning) 모듈
Stimulus	고속도로 및 도심 주행 중 복잡한 경로 추종 입력 발생 • 10ms 간격으로 차선 중심선 좌표 50개 유입 • 곡률 정보 및 전방 차량과의 목표 이격 거리 유입 • 급커브, 정체 구간, 도심 교차로 등에서 경로 추종 연산 부하 증가
Artifact	주행 제어(Control) 모듈
Environment	실시간 제어 우선순위 점유 상황 도심 교차로, 급커브, 고속도로 정체 구간 등에서 경로 변화가 빈번하고 초당 제어 연산량이 증가하는 복잡한 주행 상황
Response	입력된 차선 중심선, 곡률, 목표 이격 거리 정보를 기반으로 차선 이탈을 방지하고 안정적인 경로 추종이 가능하도록 최적의 조향각과 가속도 제어값을 산출함
Measure	• End-to-End Latency: 제어 입력 수신부터 조향각·가속도 제어값 산출 완료까지 p95 기준 10ms 이내 • Control Update Throughput: 10ms 주기의 제어 입력을 손실 없이 지속 처리하여 100Hz 제어 주기 유지 • Deadline Miss Rate: 실시간 제어 주기에서 10ms 마감시간을 초과한 요청 비율이 지정 기준 이하 • Resource Usage under Real-Time Priority: 실시간 제어 우선순위가 부여된 상태에서 CPU/GPU/NPU 사용량이 지정 한계 이내 유지

주변 차량 경로 예측

❖ [수행 효율성 요구사항]

- 시스템은 매 1초마다 주변 차량 10대의 과거 5초간 정보(위치, 속도, 방향지시등)을 분석하여 향후 5초 동안의 이동 궤적을 500ms 이내에 예측해야 한다


자율주행 차량의 주변 차량 경로 예측 모듈은 차량 주행 중 주기적으로 주변 차량의 과거 주행 정보를 분석하여 향후 이동 궤적을 예측해야 한다. 이 기능은 타이머에 의해 매 1초마다 실행되며, 주변 객체 추적 모듈로부터 주변 차량의 상태 정보를 입력받는다.

주변 객체 추적 모듈은 자율주행 차량 주변의 차량 10대에 대해 과거 5초간의 시계열 정보를 제공한다. 입력 정보에는 각 차량의 위치, 속도, 방향지시등 상태가 포함된다.

주변 차량 경로 예측 모듈은 입력된 시계열 정보를 기반으로 각 주변 차량에 대해 향후 5초 동안의 예상 이동 궤적을 생성해야 한다. 이 기능은 주변 차량 10대의 과거 상태 정보가 정상적으로 확보된 운영 상태에서 수행되며, 매 1초마다 새로운 예측 결과를 갱신해야 한다.

시스템은 각 예측 주기마다 입력 수신부터 주변 차량 10대의 궤적 예측 결과 생성 완료까지의 End-to-End Latency를 p95 기준 500ms 이내로 유지해야 한다. 또한 1초 주기의 예측 요청을 손실 없이 지속 처리해야 하며, 주변 차량 10대에 대해 지정된 latency 기준을 만족하면서 동시에 궤적을 예측할 수 있어야 한다.


주변 차량 경로 예측




주변 차량 경로 예측

항목	내용
Source	타이머 및 주변 객체 추적 모듈 - 타이머: 1초 주기로 경로 예측 실행을 트리거함 - 주변 객체 추적 모듈: 주변 차량의 위치, 속도, 방향지시등 상태 등 과거 주행 정보를 제공함
Stimulus	1초 주기의 주변 차량 경로 예측 요청 발생 - 매 1초마다 경로 예측 기능 실행 - 주변 차량 10대에 대해 과거 5초간의 시계열 정보 입력 • 입력 정보: 위치, 속도, 방향지시등 상태
Artifact	주변 차량 경로 예측 모듈
Environment	정상 운영 상태 주변 차량 10대에 대한 과거 5초간의 위치, 속도, 방향지시등 시계열 데이터가 확보되어 있으며, 고속도로 또는 도심 주행 중 주기적 예측이 수행되는 상황
Response	주변 차량 10대 각각에 대해 향후 5초 동안의 예상 이동 궤적을 생성하고 반환함
Measure	End-to-End Latency: 예측 입력 수신부터 주변 차량 10대의 향후 궤적 출력 완료까지 p95 기준 500ms 이내 Prediction Update Throughput: 1초 주기의 예측 요청을 손실 없이 지속 처리하여 차량별 궤적 예측 결과를 주기적으로 갱신 Object Capacity under SLO: 주변 차량 10대에 대해 지정 latency 기준을 만족하며 동시 예측 가능

AI-based System 수행 효율성



추론 서비스 엔진 수행 효율성



Q & A
