

제어 가능성 (Controllability)

목차

- ❖ 제어 가능성 개념
- ❖ 제어 기능 유형
- ❖ 제어 수준
- ❖ 제어 가능성 평가 지표
- ❖ 제어 가능성 QA 시나리오

제어 가능성 개념

제어가능성 정의

- ❖ 제어 주체(Controller, 인간 또는 외부 에이전트)가 AI 시스템의 기능 수행에 개입(Intervene)하여 신뢰성 회복을 지원하는 능력

시스템	설명
자율 주행차	시스템은 악천후나 센서 오작동으로 인해 차선 인식 신뢰도가 급락할 경우, 즉각 운전자에게 알람을 제공하고 운전 주도권을 안전하게 이양(Take-over)하거나 비상 갓길 정차를 수행해야 함
로봇 청소기	시스템은 복잡한 가구 배치로 인해 자율 탈출이 불가능한 고립 상황에 빠질 경우, 사용자에게 상황을 알리고 사용자가 앱을 통해 직접 방향을 조종하여 탈출시킬 수 있는 수단을 제공해야 함



제어 가능성의 필요성: AI 시스템 한계에 대한 보완책


❖ AI 시스템의 한계를 인정하고 '외부의 제어'를 통해서 위험을 관리하고 신뢰할 수 있는 AI 시스템을 구축함

AI 시스템의 한계

1. 동작 예측의 불확실성

(Uncertainty in Predictability)

AI 모델의 비결정성은
시스템 동작에 대한
완벽한 예측은 불가능



2. 완전 보증의 한계

(Imperfect Assurance)

AI 시스템의 모든
시나리오에 대한
100% 품질 보증
불가능



모든 시나리오 100% 보증 불가능

현실적 접근 방법(보완책)

개입을 통한 시스템 신뢰성 확보

- AI 시스템의 한계를 수용
- 그 위험을 관리하기 위하여 시스템 동작에 개입함



개입(Intervene)
위험 감지 및 판단



신뢰성 확보
(안전한 결과)

개입을 통한 위험 관리 및 보완



AI의 한계로 인해
발생 가능한
예외 상황/위험



인간/외부 에이전트가
개입하여 상황 파악
및 대응



시스템 실패 방지 및
안전성/신뢰성 유지

제어의 목적: 신뢰성(Trustworthiness) 확보

목적	설명	제어의 역할
비즈니스 연속성 (Business Continuity)	시스템이 정의된 설계 의도(Intended Use) 및 비즈니스 로직을 중단 없이 수행하도록 보장함.	AI 모델의 추론 오류나 성능 저하 발생 시, 제어 주체가 개입하여 거동을 교정함으로써 기능 정확성(Functional Correctness)을 회복함.
안전성 확보 (System Safety)	시스템의 오작동으로 인해 이해관계자에게 물리적·경제적·사회적 해(Harm)를 끼치는 것을 방지함.	통제 불능이나 위험 상황 감지 시, 제어 주체가 즉각 개입하여 손실을 최소화하고 시스템을 안전 상태(Fail-safe State)로 강제 전환함.


제어 사례

사례	제어 요구사항	제어 목적	제어의 역할
자율주행차	악천후나 센서 오작동으로 차선 인식 신뢰도가 급락할 경우, 운전자에게 알림을 제공하고 주도권을 안전하게 이양(Take-over)하거나 비상 정차를 수행해야 함.	안전성 확보 (System Safety)	[판단] 센서 신뢰도(<60%) 및 기상 데이터를 분석하여 '위험' 상태로 판정함 [수행] 알람 발생 → 서행 → 개입 대기 → 비상 정차
로봇청소기	복잡한 가구 배치로 인해 자율 탈출이 불가능한 고립 상황 시, 사용자에게 상황을 알리고 앱을 통해 직접 방향을 조종하여 탈출시킬 수 있는 수단을 제공해야 함.	목적 완수 (Business Continuity)	[판단] 바퀴 슬립률 및 이동 거리(<10cm)를 분석하여 '고립' 상태로 판정함 [수행] 자율 주행 중지 → 수동 조종 인터페이스 활성화 → 탈출 후 복귀

제어 기능 유형(CONTROL FUNCTION TYPE)

제어 기능 개념

- ❖ 제어 가능성은 제어 기능을 통해 실현되며, 이는 시스템이 불완전할 때 신뢰성을 회복하기 위한 수단임
- ❖ 제어 기능은 제어 대상이 제공하며, 이를 통해서 제어 대상 시스템의 신뢰성을 회복하게 됨



제어 기능 유형

- ❖ 제어 기능은 제어 목적에 따라서 2가지 유형으로 분류됨
- ❖ **비즈니스 연속성 지원 기능**: 외부 개입을 통해서 본연의 목적을 완수할 수 있도록 돕는 기능임
 - **교정 기능 (Correction)**
 - ✓ 시스템 내부 로직이나 파라미터를 변경하여 신뢰성을 근본적으로 회복
 - **보완 기능 (Supplementation):**
 - ✓ 저효율적이나 확실한 기초(Primitive) 기능으로 목적을 일시적으로 달성
- ❖ **안전성 확보 지원 기능** : 시스템이 위험한 상태(Unsafe State)에 진입하거나 진입할 징후가 보일 때, 피해를 방지하기 위해 개입하는 기능임
 - **위험차단**
 - ✓ 위기 감지 시 즉각적으로 운영을 중단하거나 보호 모드로 진입하여 해(Harm)를 방지

비즈니스 연속성 지원 기능

❖ 교정 기능



터보/맥스 모드를 명시적으로 설정



터보/맥스 모드 설정



이후부터
보다 강한 흡입력으로 청소



❖ 보완 기능



명시적으로 다양한 기능을 제어하여 목적을 달성

① 청소 위치로 이동



② 청소 시작



③ 청소 중단



④ 충전 위치로 이동



비즈니스 연속성 지원 기능

❖ 교정 기능

주차 환경 인식 오류로
주차에 실패할 때
(센서 감도 문제 등)



센서가 기둥이나 벽면을 잘못 인식하여
공간을 좁게 판단

주차 알고리즘의 감도 및 센서 임계치를 명시적으로 조정



① 감도 및 임계치 조정



② 변경된 설정값 적용



③ 주차 재시도 및 성공

변경된 설정값에 따라 주차 재시도를 수행하여 목적을 달성

❖ 보완 기능

복잡한 구조로 인해
스스로 주차를
수행하지 못할 때




공간이 협소하거나 경로가 복잡하여
자동 주차가 불가능

스마트폰 앱의 화살표 버튼 등을 이용하여 차량을 직접 제어하여 주차 완수



① 앱으로 수동 제어



② 경로를 보며 직접 조작



③ 주차 완료

사용자의 직접 제어를 통해 목적(주차)을 완수

비즈니스 연속성 지원 기능

❖ 사례: 자율 주행 물류 로봇

- 물류 창고 내에서 물품을 운반하는 로봇의 경우, 환경 변화에 따른 효율성 저하나 시스템 정지 상황에 대응함.

개입 필요 상황	제어 기능 유형	제어 내용
이동 경로에 장애물이 많아 배송 시간이 지연될 때	교정 기능	주행 알고리즘을 '최단 거리'에서 '최소 정체' 모드로 변경함; 회피 기동 민감도를 높여 가동률을 최적화함
로봇이 복잡한 지형에서 경로를 찾지 못하고 고립될 때	보완 기능	운영자가 수동으로 로봇을 안전 구역으로 원격 이동시킴; 목적지를 강제로 재할당하거나 시스템을 리셋함

안전 상태 전환 기능

사례 1: 로봇 청소기

개입 필요 상황

기기 이상 징후 감지
(배터리 과열, 굉음 발생, 불규칙 이동 등)



배터리 과열



굉음 발생



불규칙 이동

제어 내용

이상 징후 감지 → 즉각 청소 중단 → 안전한 장소로 이동 → 대기 모드 전환



① 이상 징후 감지



② 즉각 청소 중단



③ 안전한 장소로 이동
(충전 스테이션 등)



④ 대기 모드 전환
(안전 상태)

즉각적인 청소 프로세스 중단 및 최대한 안전한 장소(충전 스테이션 등)로 이동 후 대기 모드(안전 상태)로 전환

사례 2: 자율주행 주차 시스템

개입 필요 상황

물리적 충돌 위험 감지
(보행자 또는 장애물 급작 출현)



제어 내용

충돌 위험 감지 → 출력 차단 → 긴급 제동 → 안전 정지



① 충돌 위험 감지



② 출력 차단
(구동부 엔진/모터)



③ 긴급 제동
(Emergency Braking)



④ 안전 정지
(안전 상태)


구동부 엔진/모터 출력 차단 및 강제 긴급 제동(Emergency Braking) 수행

안전 상태 전환 기능

사례 1: 스마트 제조 (협동 로봇)

개입 필요 상황

작업자의 보호 구역 무단 침범
또는 로봇 암(Arm)에 예기치
못한 물리적 저항(충돌) 감지 시



제어 내용

Category
0 Stop

기계적
브레이크 체결

수동 복구
모드 전환

안전 확인 전
재가동 차단



즉시 정지

모든 운동 정지

복구 절차 시작

재가동 불가

사례 2: 스마트 홈 (인덕션/전기레인지)

개입 필요 상황

조리 용기 없이 장시간 가동되거나,
상판의 이상 과열 및 화재 징후
(연기 등)가 감지될 시



제어 내용

해당 화구
전력 즉각 차단

냉각 팬
최대 속도 가동

모바일 위험
알림 송신

모든 조작 버튼
잠금 전환



출력 즉시 차단

과열 신속 냉각

원격 알림 전송

조작 잠금 상태

사례 3: 에너지 관리 시스템 (ESS: 에너지 저장 장치)

개입 필요 상황

배터리 셀 간 전압 불균형이
임계치를 초과하거나 급격한
온도 상승(열폭주 초기 징후)
확인 시



제어 내용

배터리 랙 전기적
연결 물리적 분리
(Contactors Open)

전류 흐름
차단

자동 소화
설비 연동 가동

열 배출 시스템
활성화



회로 물리적 분리

전류 완전 차단

화재 확산 억제

온도 안정화

사례 4: 의료기기 (자동 약물 주입기)

개입 필요 상황

약물 카트리지 잔량 인식 오류
또는 주입 펌프의 기계적 고착으로
과다 투여 위험 감지 시



제어 내용

즉시 주입
프로세스 중단

역류 방지
밸브 폐쇄

환자·의료진
시각·청각적 비상 경고

주입 이력 로그
기록 후 대기 모드 전환





주입 즉시 중단

약물 역류 차단

즉시 경고 알림

기록 후 대기 전환

제어 기능 유형 사례 요약

사례	유형 1.1 (수정) 교정 기능 (Correction)	유형 1.2 (보완) 보완 기능 (Supplementation)	유형 2 (안전 전이) 안전 상태 전환 기능 (Safety Transition)
로봇 청소기 	흡입력 파라미터 조정 (터보 모드 설정으로 성능 교정)  더 강한 흡입력으로 청소 성능 교정	수동 위치 이동 (앱을 통한 수동 이동 및 시작/중단)  사용자가 직접 위치 이동 및 청소 시작/중단, 충전 복귀 제어	배터리 과열 시 강제 정지 또는 충전 복귀  청소 즉시 중단 후 안전한 장소로 이동하여 대기 모드(안전 상태) 전환
자율주행 주차 시스템 	주차 알고리즘 감도 수정 (센서 임계치 조정을 통한 재시도)  감도/임계치 조정 후 주차 재시도 수행	원격 수동 조작 (스마트폰 화살표 버튼으로 직접 주차)  스마트폰 화살표 버튼을 이용하여 전진, 후진, 조향을 직접 제어하여 주차 완수	충돌 위험 감지 시 긴급 제동 (Emergency Braking)  구동부 엔진/모터 출력 차단 및 강제 긴급 제동 수행

제어 수준

제어 주체와 제어 대상

- ❖ 제어 가능성은 제어 주체가 제어 대상을 관측하고 개입함으로써 완성됨



제어 수준: AI Application 제어 vs AI 시스템 제어

제어 수준	제어 대상 (Controlled)	제어 주체 (Controller)	제어의 목적
AI Application	전체 응용 시스템 (예: 로봇 청소기 본체, 자율주행차 전체)	최종 사용자, 원격 관제 시스템	비즈니스 목표 달성 및 물리적 안전 확보
AI 시스템	지능 서비스 엔진 (예: 장애물 인식 모델, 경로 예측 모델)	AI 시스템 운영자, AI 애플리케이션	추론 및 학습 서비스의 기술적 신뢰성 확보

AI Application 제어



AI 시스템 제어

사례 1. 로봇 청소기 - 장애물 인식 시스템 제어

제어 주체 (Controller)

1 AI 시스템 운영자 (AI System Operator)



- 모델 정확도 및 성능 모니터링
- 임계치, 파라미터 조정
- 모델 버전 교체

2 AI Application (로봇 청소기 본체)



- 애플리케이션의 신뢰성 확보를 위해 AI 시스템 제어 요청
- 예: 배터리 부족 시 저전력 모드 추론 요청 (효율성 조정)

모니터링 정보
(정확도, 오탐/미탐률 등)



제어 명령
(파라미터 조정, 모델 교체)

제어 요청
(저전력 모드, 추론 빈도 조정 등)



제어 응답
(설정 반영 결과)

제어 대상 (Controlled Entity) - AI System



장애물 인식 시스템 (AI System)

- 추론 서비스: 실시간 장애물 인식
- 학습 서비스: 장애물 데이터 학습 및 모델 업데이트

추론 서비스



학습 서비스



AI 시스템 제어

사례 2. 자율주행 주차 시스템 - 보행자 경로 예측 시스템 제어

제어 주체 (Controller)

1 AI 시스템 운영자 (AI System Operator)



- 모델 정확도 및 성능 모니터링
- 임계치, 파라미터 조정
- 모델 버전 교체

2 AI Application (자율주행 주차 시스템)



- 애플리케이션의 신뢰성 확보를 위해 AI 시스템 제어 요청
- 예: 복잡한 환경에서 예측 민감도(임계치) 조정 요청 (안전성 우선 모드)

모니터링 정보
(정확도, 예측 오차 등)



제어 명령
(파라미터 조정, 모델 교체)


제어 요청
(민감도 조정, 안전 모드 요청 등)



제어 응답
(설정 반영 결과)




제어 대상 (Controlled Entity) - AI System



보행자 경로 예측 시스템 (AI System)

- 추론 서비스: 보행자 이동 경로 예측
- 학습 서비스: 보행자 행동 데이터 학습 및 모델 업데이트

추론 서비스



학습 서비스



제어 가능성 평가 지표


제어 가능성 평가 관점

제어 정확성

제어 기능 수행 결과,
의도한 수준의 **신뢰성 회복**을 달성하였는가?



이상 상태




정상 상태
(Expected)

측정 항목 예시

- 신뢰성 회복 성공률
- 정상 상태 복귀율
- 기능 목표 달성도

"개입 후 시스템이 다시 정상 궤도(Expected)로 복귀했는가?"



예시: 개입 후 성능이 정상 수준 이상으로 복귀하고 유지되는지 확인

제어 기능이 시간적·물리적 자원 관점에서
최적으로 수행되었는가?



개입 명령



수행 시간



자원 사용



완수

측정 항목 예시

- 개입 반응 시간 (지연 시간)
- 자원 사용량 (전력, 연산, 통신 등)
- 작업 완료 시간 (제어 수행 시간)

"개입 명령이 지연 없이 가용 자원 내에서 완수되었는가?"



지연 없이
신속하게 수행



가용 자원 내에서
효율적으로 수행



목표 시간/자원 내
완수

예시: 명령 후 일정 시간 내 수행 완료, 자원 사용이 임계치 이하로 유지

제어 효율성

Application 제어 평가 지표

평가 지표 유형	목적	평가 지표 예
제어 정확성	제어 개입 후 사용자가 의도한 개입의 목적이 달성되었는가?	• 제어 성공률
제어 효율성	개입의 목적이 효율적으로 달성되었는가?	• 제어 완료 시간 • 제어 자원 활용율

평가 지표 예시: 로봇 청소기

유형	개입 목적	제어 정확성 지표	제어 효율성 지표
보완 방식	운영 연속성 확보 (고립 구역 탈출 및 임무 완수)	수동 조종 개입을 통해 고립 구역에서 이탈하였는가? (탈출 성공률)	제어 입력 시점부터 구동부 반응까지의 응답 지연 시간
교정 방식	기능 신뢰성 회복 (지능적 청소 품질 최적화)	흡입력 상향 교정 후 오염물 제거율이 목표치에 도달하였는가? (품질 회복률)	모드 변경 명령 시점부터 목표 흡입력에 도달하기까지의 시간
안전 상태 전환	위해 방지 및 보호 (이상 거동 시 시스템 안전 확보)	중단 명령 시 모든 기능을 정지하고 정의된 안전 상태로 전이되었는가? (Fail-safe 성공률)	비상 정지 명령 시점부터 구동부의 완전 정지 및 전원 차단까지의 긴급 제어 시간

AI 시스템 제어 평가 지표

❖ AI 시스템의 학습/추론 서비스 및 인프라 제어에 대한 평가 지표

제어 대상	제어 정확성	제어 효율성
학습 서비스	모델 품질 복구율: 재학습 완료 후, 목표 정확성 지표가 설계된 최소 임계치(Baseline)를 상회하는가?	학습 파이프라인 지연 시간: 재학습 트리거 발생 시점부터 전체 학습 완료 시간
추론 서비스	추론 신뢰도 개선도: 모델 교체 또는 파라미터 조정 후, 추론 결과의 확신도 및 드리프트 지표 가 개선되었는가?	서비스 가용성: 모델 스와핑 과정에서 발생하는 서비스 일시 중단 시간
서비스 인프라	자원 할당 무결성: 요청한 컴퓨팅 자원의 쿼터가 물리적/논리적으로 격리 및 할당 되어 다른 서비스에 간섭을 주지 않는가?	인프라 프로비저닝 속도: 자원 증설 또는 서비스 격리 명령 후, 실제 인프라 적용 완료 되기까지의 시간

제어 가능성 QA 시나리오

제어 가능성 QA 시나리오

항목	AI Application 수준의 제어 설명
Source	제어 주체: 최종 사용자, 또는 상위 관제 시스템
Stimulus	제어 개입을 유발하는 사건 또는 요청: 신뢰성 저하, 비정상 동작, 위험 상황, 사용자의 수동 제어 요청, 관제 시스템의 제어 명령 등
Artifact	제어 대상: AI 시스템을 활용하여 실제 서비스를 수행하는 AI Application 전체. 예: 로봇 청소기 본체, 자율주행 주차 시스템
Environment	제어 필요성이 발생한 운영 상황 예: 가구 고립, 장애물 급출현, 시스템 과부하, 물리적 충돌 위험 등
Response	요청된 제어 기능 실행 예: 수동 제어권 확보, 동작 모드 전환, 설정값 조정, 안전 구역 이동, 비상 정지, 안전 상태 전이 등
Measure	제어 정확성 • 의도한 신뢰성 수준 또는 안전 상태를 달성했는가? • 예: 탈출 성공률, 안전 상태 전이 성공률, 사고 방지율 제어 효율성 • 제어가 지연 없이 자원 제약 내에서 수행되었는가? • 예: 제어 응답 시간, 긴급 정지 시간, 모드 전환 시간, 에너지 소모량

고립 발생 시 수동 탈출

❖ [요구사항]

- 로봇 청소기가 자율적으로 목적을 완수하지 못하는 고립 상황에서, 사용자가 앱을 통해 수동 조종 기능을 통해 물리적 이동을 직접 제어함으로써 운영 연속성을 회복해야 함

항목	내용
Source	로봇 청소기 사용자
Stimulus	수동 방향 조종 요청 사용자가 고립 알림을 확인한 후 앱 인터페이스를 통해 전진, 후진, 좌회전, 우회전 등의 물리적 이동 명령을 입력함
Artifact	로봇 청소기 AI Application
Environment	비정상 운영 상황 복잡한 가구 배치로 인해 로봇 청소기가 고립되었거나 동일 경로를 반복하는 Livelock 상태에 진입함. 자율 주행 알고리즘이 30초 이상 유효한 탈출 경로를 생성하지 못하여 고립 상태가 통보된 상황
Response	수동 방향 조종 기능 수행. 1. 자율 주행 모드를 즉시 중단하고 수동 제어 모드를 활성화함. 2. 사용자의 방향 입력 신호를 실시간으로 모터 구동 신호로 변환하여 집행함. 3. 수동 조종 중에도 충돌 방지, 속도 제한, 통신 끊김 시 정지 등의 안전 제한을 유지함. 4. 고립 구역 이탈이 확인되면 자율 주행 모드로 복귀함
Measure	1. 제어 정확성: 수동 조작 후 로봇이 고립 구역을 이탈하여 정상 주행 경로로 복귀함. 예: 정의된 고립 시나리오 기준 탈출 성공률 100% 또는 95% 이상. 2. 제어 효율성: 앱 입력 시점부터 로봇 모터 구동까지의 응답 지연 시간이 200ms 이하를 유지함.

청소기 위험 상황 발생 시 안전 상태로 전환

❖ [요구사항]

- 로봇 청소기가 위험 상황에 진입했을 때, 관제 시스템이 원격 제어 명령을 통해 청소 기능을 중단시키고 로봇을 안전 상태로 전환함으로써 위험을 방지하는지를 평가하는 안전 상태 전환해야 함

항목	내용
Source	로봇 청소기 관제 시스템
Stimulus	안전 상태 전환 명령 (이상 징후 통보 수신 즉시 관제 서버에서 발송되는 강제 제어 명령)
Artifact	로봇 청소기 시스템
Environment	위험 상황 (Critical Malfunction) 배터리 온도 임계치 초과, 모터 과부하(굉음), 또는 자이로 센서 오류(불규칙 이동)로 인한 비정상 경고 신호가 연속 발생 중인 상황
Response	안전 상태 전이 및 격리 (Fail-safe Execution) 1. 현재 수행 중인 모든 청소 프로세스 즉시 중단 및 흡입 모터 전원 차단 2. 최단 경로를 통한 충전 스테이션 복귀 시도 3. 복귀 완료 후 모든 구동 시스템을 대기 모드(안전 상태)로 잠금(Lock)
Response	- 정의된 '안전 상태(충전 위치 및 대기 모드)'로의 전이에 100% 성공함 - 명령 수신 시점부터 물리적 구동 중단까지 500ms 이내

AI 추론 엔진 배터리 부족 시 저전력 모드로 제어

❖ [요구사항]

- 로봇 청소기 AI엔진이 배터리 부족 상황에서 로봇 청소 애플리케이션에게 통보하면, 청소 애플리케이션은 로봇 청소기 AI 엔진에게 저전력 모드로 동작할 수 있도록 AI 추론 엔진의 구성을 조정한다

항목	내용
Source	로봇 청소 애플리케이션
Stimulus	저전력 추론 모드 설정 명령 (자원 효율성 최적화를 위한 파라미터 재설정 요청)
Artifact	로봇 청소기 AI 추론 엔진
Environment	자원 부족 상황 (Resource Constraint) 배터리 잔량이 하락하여 AI 엔진으로부터 배터리 부족 이벤트가 발생하고 상황
Response	추론 엔진 구성 변경 (Configuration Adjustment) 1. 입력 가드레일: 데이터 샘플링 주기 및 입력 해상도 하향 조정 2. 모델 서빙: 고사양 모델에서 경량화 모델로 스와핑 또는 양자화 파라미터 적용 3. 출력 가드레일: 후처리 로직 간소화
Response	1. 제어 정확성: - 저전력 모드 전환 후, 추론 엔진의 전력 소모량 기존 대비 30% 절감 - 정확도가 급격히 하락하지 않고 최소 허용치(예: Baseline의 85%) 유지 2. 제어 효율성 - AI 엔진이 모든 가드레일 및 서빙 구성을 변경 완료100ms 이내

Q & A
