

설명 용이성 (Explainability)

목차

- ❖ 설명 용이성 개념
- ❖ 모델의 설명 용이성 수준
- ❖ 설명 모드
- ❖ 설명 용이성 평가 기준 및 지표
- ❖ 설명 용이성 QA 시나리오

설명 용이성 개념

설명 용이성 정의

Property of an AI system that enables a given **human audience to comprehend the reasons for the system's behaviour**

[ISO/IEC TS 6254:2025 Objectives and approaches for explainability and interpretability of machine learning (ML) models and artificial intelligence (AI) systems]

Explainability is the property of an AI system that means that the **important factors influencing a decision can be expressed in a way that humans can understand**

[ISO/IEC 22989:2022 Artificial intelligence concepts and terminology]

❖ AI 시스템이 도출한 '결과'에 대하여

- '이유'와 '타당성'을
- 인간이 납득할 수 있는 방식으로 표현하는 능력

설명 용이성: 예

❖ 결과: 설명의 대상


- 자율주행차가 시속 60km로 주행하다 전방의 검은 물체를 감지하고 '0.5초 이내에 급제동'을 수행하여 정지한 상태임



설명 용이성: 예

❖ 결과에 대한 이유: 시스템 동작 메커니즘 수준으로 설명

- 1) 전방 LiDAR 및 카메라 센서가 20m 거리에서 물체와의 상대 속도 급감을 감지함
- 2) 제어 알고리즘이 충돌 위험 지수(0.48초)가 임계치(0.6초) 이하임을 판단
- 3) 최대 유압 브레이크를 즉시 활성화하여 물리적 정지를 유도함



설명 용이성: 예

❖ 타당성: 사회적 근거 지식 및 제도적 근거 수준으로 설명

● 근거 지식

- ✓ 해당 물체의 외곽선 및 반사율 데이터가 학습 데이터셋 내 '보행자' 혹은 '고정 장애물' 패턴과 99.8% 일치함
- ✓ 물리 법칙상 60km 속도에서 충돌을 피하기 위한 유일한 생존 확률 경로가 급제동임을 입증함

● 제도적 근거

- ✓ ISO 26262(기능 안전성) 및 SAE J3016 표준의 비상 제동 가이드라인을 준수함
- ✓ 사고 시 '인명 보호 최우선 원칙'에 따라 승객의 일시적 불편(급정거 충격)보다 타인의 생명권 보호를 우선시한 윤리적 설계 지침에 부합함

설명 용이성: 설명 형식 관점

❖ 복잡한 라이다(LiDAR) 점구름 데이터나
텐서 연산 값이 아니라, 인간의 인지
체계에 맞는 방식으로 설명

❖ 예시:

- **시각적 방식**: 대시보드 화면에 보행자의 위치를 **빨간색 상자(Bounding Box)**로 강조하고, 차량과의 거리 및 예상 충돌 시간을 **직관적인 바(Bar) 그래프로 표시함**
- **언어적 방식**: "야간 시야 확보가 어려워 보행자로 추정되는 물체를 발견하고, 사고 방지를 위해 선제적으로 급제동을 실시했습니다"라고 **안내 음성을 제공함**
- **논리적 납득**: "급제동은 승객에게 불편을 주지만, 인명 사고를 막기 위한 최선의 적절한 조치였습니다"라는 **맥락을 전달함**



분야별 XAI 필요 예

❖ 의료: 진단 결과에 대한 신뢰성

- 의료 데이터를 분석하여 의사의 의사결정을 지원하고, 예방적 조치를 가능하게 함



대표 설명 예시



• 의료 영상 내 미세 이상 징후 식별 및 근거 제시



• 약물 반응 예측 결과에 대한 근거 제시

분야별 XAI 필요 예

❖ 금융: 규제 준수 및 공정성

- 공정 대출 정책을 준수하고, 데이터 편향을 제거하여 금융 기관의 법적 책무를 다하기 위함



분야별 XAI 필요 예

❖ 자율주행: 사용자 신뢰

- 생명과 직결된 안전 관련 결정의 이유를 사용자에게 납득시켜 시스템에 대한 신뢰를 구축함.



분야별 XAI 필요 예

❖ 국방: 전략적 통제 및 관리

- 군 관계자가 자율 시스템을 효과적으로 관리하고, 시스템의 판단을 신뢰하기 위함



대표 설명 예시



- 자율 무기 체계 및 전투 시스템의 동작 근거 제시

XAI 역할

❖ 디버깅 및 최적화

- 설명 기능을 통해 학습 데이터의 편향이나 모델의 취약점을 찾아내어 모델의 신뢰성을 개선할 수 있음

❖ 신뢰의 도구

- 자율주행이나 의료처럼 Critical한 분야에서 인간이 AI의 결정을 수용하게 만드는 수단임

❖ 법적·윤리적 방어권

- 금융이나 사법 분야에서 AI의 결정이 차별적이지 않았음을 입증하는 정당성(Justification)의 근거가 됨

설명 용이성 관련 개념

개념	대상	목적 (대상에게 어떤 의미인가?)	관련 질문	신뢰의 수준
Transparency (투명성)	개발자, 엔지니어	시스템의 설계 품질과 엔지니어링 표준이 신뢰할 수 있는지 대외적으로 증명	이 시스템은 믿을 수 있는 재료로 만들어졌는가?	공적 신뢰
Interpretability (해석 가능성)	개발자, 엔지니어	모델 내부 로직이 설계 의도대로 작동하는지 검증하고 즉각 수정하기 위함	우리가 시스템을 완벽히 통제하고 고칠 수 있는가?	기술적 신뢰
Explainability (설명 가능성)	사용자, 서비스 운영자	AI가 내린 판단의 핵심 이유를 나의 상식과 경험 수준에서 수용하기 위함	사용자에게 이 판단의 근거를 설명할 수 있는가?	개인적 신뢰
Justification (정당화)	사용자, 규제기관	사고나 분쟁 발생 시, 시스템의 결정이 법적·사회적 원칙을 준수했는지 입증	이 판단이 원칙적으로 옳다고 사회적으로 입증 가능한가?	윤리적 신뢰

Transparency

The degree to which appropriate information about the AI system is communicated to stakeholders.

Transparency of AI systems can help potential users of AI systems to choose a system to fit their requirements, improving stakeholders' knowledge about the applicability and the limitations of an AI system, and assisting with the explainability of AI systems.

[ISO/IEC 25050:2023 Quality model for AI systems]

❖ AI 시스템의 투명성

- AI 시스템의 사용자가 자신의 요구사항에 적합한 시스템을 선택하도록 도울 수 있으며,
- AI 시스템의 적용 가능성과 한계에 대한 이해관계자의 지식을 향상시키고,
- AI 시스템의 설명 가능성을 지원할 수 있다

Transparency

❖ Transparency 정보 항목

정보 유형	내용 예
시스템 기능	AI 시스템이 수행하는 기능, 입력·출력, 적용 업무
구성요소	데이터 처리 모듈, 모델, 추론 엔진, 설명 모듈, 가드레일
인터페이스	외부 시스템 연동 방식, API, 입력 데이터 형식, 출력 형식
사용 모델	모델 종류, 버전, 구조, 학습 방식, 적용 범위
학습 데이터	데이터 출처, 수집 기간, 주요 특성, 데이터 한계
검증·평가 데이터	테스트셋, 벤치마크, 검증 절차
성능 지표	정확도, 오류율, 공정성 지표, 강건성 지표, 설명 지표
로그와 추적성	입력, 출력, 모델 버전, 처리 단계, 예외, 오류 로그
설계 목표와 가정	어떤 목적을 위해 설계되었는지, 어떤 환경을 가정했는지
운영 관리 방식	모니터링, 업데이트, 재학습, 승인 절차, 책임 조직

Transparency

❖ 실제 현황: Model Card 중심의 Transparency

❖ Hugging Face의 Model Card

Model Card 항목	포함 내용
Model Details	모델명, 요약, 개발자, 모델 유형, 언어, 라이선스, 기반 모델, 버전, 아키텍처
Uses	직접 사용, downstream 사용, 적용 대상 사용자, 사용 가능한 범위
Out-of-Scope Use	부적절한 사용, 오용 가능성, 금지 또는 비권장 사용
Bias, Risks, and Limitations	편향, 사회적 위험, 기술적 한계, 실패 가능 조건
Training Details	학습 데이터, 전처리, 학습 절차, 학습 시간, 모델 크기, checkpoint
Evaluation	테스트 데이터, 평가 요인, 평가 지표, 평가 결과, 조건별·집단별 성능






Transparency

❖ 최근의 대규모 AI 모델에서는 단순한 Model Card보다 더 넓은 형태의 System Card가 많이 사용됨

산출물	주요 내용	공개 수준	Transparency 관점의 역할
Model Card	모델 정보, 사용 범위, 학습·평가 데이터, 성능, 한계, 위험	공개 가능, 특히 공개 모델 저장소에서 일반적	잠재 사용자가 모델의 적용 가능성과 한계를 이해하도록 지원
System Card	시스템 기능, 안전성 평가, 위험 완화, 배포 정책	공개 가능하나 제공 범위는 조직별로 다름	고위험 AI 시스템의 안전성·책임성 설명
Audit / Compliance Report	검증 결과, 주요 증거, 기준 충족 여부	규제기관·감사자 대상 제한 공유	외부 검증과 법적·제도적 책임 대응
Lineage / Audit Log	데이터·코드·실험·모델· 배포·승인 이력	원칙적으로 내부 관리, 필요 시 제한 공유	설명과 책임 추적을 뒷받침하는 내부 감사 로그

Interpretability

- ❖ 모델의 내부 구조나 출력 의미를 인간이 이해할 수 있게 하여
- ❖ 모델이 목적에 맞게 작동하는지 검증·개선할 수 있도록 하는 특성

구성 요소 & 의미	충족 예	미충족 예
1 Simulatability  인간이 모델 전체를 따라가 최종 출력을 재현할 수 있는가	 작은 결정 트리, 간단한 규칙 모델	 깊은 트리, 너무 많은 규칙
2 Decomposability  입력, 파라미터, 중간 변수, 계산 단계가 의미 있게 해석되는가	 도메인 의미와 연결된 요소	 의미를 알기 어려운 내부 변수
3 Algorithmic Transparency  학습 알고리즘이 어떻게 동작하고 수렴하는지 이해 가능한가	 선형 회귀, 단순한 학습 절차	 복잡한 딥러닝 최적화

AI Model interpretability vs 소스 코드 Analyzability

- ❖ Analyzability(ISO/IEC 25010): 프로그램을 이해·진단·변경 영향 분석하기 쉬운 정도
- ❖ Interpretability: 모델을 이해·진단·개선하기 쉬운 정도에 대응

구성 요소	AI Model Interpretability	프로그램 Analyzability
Simulatability	모델 전체의 판단 흐름을 사람이 따라가 최종 출력을 재현할 수 있는 정도	프로그램 전체 실행 흐름을 개발자가 따라가 최종 결과를 예측할 수 있는 정도
Decomposability	입력 feature, 파라미터, 중간 변수, 규칙, 계산 단계 각각이 인간이 이해할 수 있는 의미를 갖는 정도	변수, 함수, 모듈, 중간 상태가 의미 있는 이름과 역할로 표현되어 있는 정도
Algorithmic Transparency	학습 알고리즘과 최적화 과정의 동작 원리를 이해할 수 있는 정도	핵심 알고리즘의 동작 원리, 종료 조건, 계산 방식이 이해 가능한 정도


Interpretability vs Explainability

구분	Interpretability	Explainability
성격	모델 구조, 구성 요소, 출력 의미가 인간에게 이해 가능한 정도	AI가 산출한 특정 결과에 대해 사람이 이해할 수 있는 설명을 생성·전달하는 능력
핵심 질문	이 모델의 판단 구조와 출력 의미를 사람이 이해하고 추적할 수 있는가?	이 결과가 왜 나왔고, 어떤 근거로 타당한지 사람이 이해할 수 있는가?
주요 사용자	개발자, 데이터 사이언티스트, 도메인 전문가	사용자, 운영자, 의사결정자, 규제기관, 감사자
중심 대상	모델 구조, 내부 로직, feature, parameter, 중간 변수, 출력 의미	특정 예측·분류·추천·판단·제어 결과의 이유와 근거
설계 방향	모델 자체를 가능한 한 해석 가능한 구조로 설계함	모델 결과에 대해 이해관계자 목적에 맞는 설명을 생성·시각화·전달함
대표 설계 기법	Inherently Interpretable Model 적용 - 단순 선형 모델 - 얇은 Decision Tree - Rule-based model - GAM, EBM 등	Post-hoc Explanation 적용 - Local: LIME, instance-level SHAP, counterfactual explanation, ICE - Global: PFI, PDP, ALE, SHAP - Presentation: 자연어 설명, 시각화 등

Post-hoc Explanation

❖ Local explanation: 특정 사례의 판단 근거

- 하나의 추론 결과에 대해 "왜 이 결과가 나왔는가"를 설명




LIME 근사 경계: 검은색 별 주변에서만 원래 모델의 판단을 단순 모델로 흉내 낸 국소적 결정 경계

Post-hoc Explanation

❖ Global explanation: 모델의 전체적 판단 로직

- 전체 데이터셋을 통해 모델이 가진 평균적인 판단 로직을 설명

SHAP 값: 각 특성이 모델의 예측값을 높이거나 낮추는 데 얼마나 기여했는지를 수치로 계산한 값



설명 유형(MODE OF EXPLANATION)

설명 유형 요약

설명 유형	핵심 질문	설명 수준	설명 관점	관련 개념	주요 이해관계자
인과적 (Causal)	시스템이 어떻게 작동하는가	시스템 중심	알고리즘 메커니즘, 인과적 추적	Interpretability	개발자, 엔지니어
인식적 (Epistemic)	이 결과가 왜 사실인가	사회적 사실/원칙	현실 세계 논리/사실	Truthfulness	도메인 전문가, 데이터 사이언티스트
정당성 (Justificatory)	어떤 근거로 정당화되는가		사회적 원칙, 윤리 기준, 법적 규제 및 표준	Accountability	사용자, 규제기관

설명 유형 예: 대출 승인 거절 시나리오

❖ 대출 신청 거절 상황을 이해관계자 대상으로 설명함

설명 유형	설명 관점	설명 키워드	설명 내용	주요 이해관계자
인과적	알고리즘 수준	알고리즘, 가중치, 인과 사슬	최종 출력 레이어에서 DTI 가중치(0.85)가 임계치 (40%)를 초과하여, 알고리즘 연산 결과가 인과적으로 거절 경로로 도출됨	AI 엔지니어/개발자: 가중치 튜닝 및 모델 최적화
인식적	현상학적 수준	도메인 지식, 현상 간의 논리	DTI 수치와 상환 능력 저하 사이의 실질적 상관관계가 금융 데이터로 입증되므로, 모델의 판단이 현실의 경제적 진실과 부합함	리스크 관리자: 모델의 타당성 및 금융 리스크 검증
정당성	사회/법적 수준	규제, 윤리 표준, 조직 프로세스	금감원 지침 및 금융회사의 공정 대출 원칙을 준수하여, 과잉 대출로부터 소비자를 보호하며, 객관적 지표를 통해 차별 없이 정당하게 처리됨	규제 기관/법무팀/신청자: 법적 정당성 확인 및 이의 제기

설명 유형 예: 자율주행 급정거 시나리오

❖ 사고 발생 후 사고 조사관, 피해자, 그리고 제조사가 사건을 이해하고 정당화하는 상황

설명 유형	설명 관점	설명 키워드	설명 내용	주요 이해관계자
인과적	알고리즘 수준	센서 데이터, 가중치, 제어 로직	LiDAR 센서 데이터와 신경망 가중치 분석을 통해 장애물을 분류하고, 시스템 내부 로직에 따라 비상 제동 명령을 인과적으로 출력함	개발자: 시스템 디버깅
인식적	현상학적 수준	물체 인식 논리, 상황적 타당성	물리적 모델과 학습 데이터를 기반으로 전방 물체를 위험 요소로 인지하였으며, 이는 현실 세계의 위험 회피 원칙에 비추어 진실된 판단임을 입증함	사고 조사관: 판단의 진실성 확인
정당성	사회/법적 수준	안전 표준(ISO), 윤리 규정, 법규	ISO 26262 및 윤리 가이드라인의 안전 우선 원칙을 준수하였으며, 관련 법규와 제조사 정책에 근거하여 사회적으로 정당한 조치임을 증명함	법원/보험사: 책임 소재 및 정당성 판정

설명 용이성 평가 기준

설명 용이성 평가 기준 유형

구분	핵심 가치	평가 질문	평가 기준
기술적 신뢰성	정확성	"이 설명을 믿어도 되는가?"	설명 요구 정합성 충실성 재현성 강건성
사용자 경험	이해 수준	"이 설명이 나에게 유용한가?"	가독성 시뮬레이션 가능성 실행 가능성

설명 용이성 평가 기준 유형

평가 관점	평가 기준	의미
기술적 신뢰성 관점	설명 요구 정합성	설명이 사전에 정의한 설명 목적, 이해관계자, 사용 맥락, 설명 수준, 설명 범위와 부합하는 정도
	충실성	설명에서 제시한 판단 근거와 결과가 AI 시스템의 실제 행동 및 결정과 일치하는 정도
	재현성	동일 조건에서 동일하거나 허용 오차 내에서 일관된 설명이 산출되는 정도
	강건성	의사결정 과정의 사소한 변화에는 설명이 불필요하게 흔들리지 않고, 의미 있는 변화에는 설명도 적절히 변화하는 정도
사용자 경험(UX) 관점	가독성	설명이 대상 이해관계자가 읽고 이해하기 쉬운 형태로 전달되는 정도
	시뮬레이션 가능성	사용자가 설명을 바탕으로 AI 시스템의 판단 방식을 머릿속에 이해하고, 유사한 새로운 사례의 결과를 어느 정도 예측할 수 있는 정도
	실행 가능성	설명이 이해관계자의 목적에 맞는 후속 판단이나 조치를 실제로 수행하는 데 도움이 되는 정도

설명 용이성 평가 기준 유형: 설명 예

평가 관점	평가 기준 (Criteria)	예시
기술적 신뢰성	설명 요구 정합성	대출 신청자가 “왜 거절되었는가?”를 물었을 때, 설명이 DTI 초과, 연체 이력, 소득 안정성 등 실제 심사 맥락과 관련된 정보를 제공하는가?
	충실성	설명을 단순 규칙처럼 적용했을 때, 설명이 유도하는 승인/거절 결과가 실제 AI 시스템의 승인/거절 결과와 일치하는가?
	재현성	동일한 입력, 동일한 모델 버전, 동일한 설명 조건에서 다시 설명 요청을 보냈을 때 동일하거나 허용 오차 내에서 일관된 설명을 제공하는가?
	강건성	대출 판단 결과를 바꾸지 않는 미세한 입력 변화에는 핵심 설명이 유지되고, 판단 결과를 바꾸는 의미 있는 변화에는 설명도 그 원인을 반영하는가?
사용자 경험 (UX)	가독성	수천 개 변수 나열 대신 상위 3가지 핵심 요인을 막대 그래프와 짧은 문장으로 제시하는가?
	시뮬레이션 가능성	설명을 본 사용자가 유사한 신청자의 승인/거절 결과를 예측할 수 있는가?
	실행 가능성	‘부채가 많음’ 대신 ‘카드 잔액을 500만 원 이하로 줄이면 승인 가능성이 증가함’처럼 구체적이고 실행 가능한 조치를 제시하는가?

Quiz: 설명 용이성 평가 기준

다음 각 사례에서 문제가 되는 **설명 용이성 평가 기준**을 고르시오.

평가 기준:

① 설명 요구 적합성 ② 충실성 ③ 재현성 ④ 강건성 ⑤ 가독성 ⑥ 시뮬레이션 가능성 ⑦ 실행 가능성

번호	Quiz	정답
1	자율주행차가 야간 주행 중 전방 보행자를 감지하고 급정거하였다. 사고 조사관은 “왜 차량이 조향 회피가 아니라 급정거를 선택했는가?”를 질문하였다. 그런데 시스템 설명은 센서 종류와 모델 버전만 나열하고, 급정거 선택 이유는 설명하지 않았다.	
2	대출 심사 AI가 신청자의 대출을 거절하였다. 실제 모델 로그를 확인해보니 가장 큰 영향 요인은 DTI 초과였지만, 설명 리포트는 “소득 부족”을 가장 큰 거절 사유로 제시하였다.	
3	동일한 의료 영상에 대해 같은 모델과 같은 설명 모듈을 사용하여 설명을 세 번 생성하였다. 첫 번째 설명은 “폐 결절 의심 영역 A”를 강조했지만, 두 번째와 세 번째 설명은 각각 다른 영역 B, C를 주요 근거로 제시하였다.	
4	자율주행차의 입력 데이터에서 보행자 위치가 1cm 정도만 달라졌고, 차량의 판단 결과는 여전히 “급정거”였다. 하지만 설명은 기존의 “보행자와의 충돌 위험”에서 갑자기 “차선 이탈 위험”으로 크게 바뀌었다.	

Quiz: 설명 용이성 평가 기준

다음 각 사례에서 문제가 되는 **설명 용이성 평가 기준**을 고르시오.

평가 기준:

① 설명 요구 적합성 ② 충실성 ③ 재현성 ④ 강건성 ⑤ 가독성 ⑥ 시뮬레이션 가능성 ⑦ 실행 가능성

번호	Quiz	정답
5	금융 AI가 대출 거절 사유를 설명하면서 120개의 변수명, SHAP 값, 내부 feature ID를 긴 표로 그대로 제공하였다. 일반 신청자는 어떤 요인이 핵심 거절 사유인지 이해하지 못했다.	
6	AI가 대출을 거절한 이유를 "DTI가 높고 최근 연체 이력이 있기 때문"이라고 설명하였다. 설명을 들은 사용자는 이후 다른 신청자의 DTI와 연체 이력을 보고, 그 신청자가 승인될지 거절될지 상당히 정확하게 예측할 수 있었다.	
7	대출 거절 설명에서 시스템은 "신용 상태가 좋지 않습니다"라고만 안내하였다. 반면 사용자는 "무엇을 개선하면 다음 신청에서 승인 가능성이 높아지는가?"를 알고 싶어 했다. 설명에는 카드 잔액 축소, DTI 개선, 추가 소득 증빙 등 구체적 후속 조치가 포함되지 않았다.	

설명 용이성 평가 지표

기술적 신뢰성 평가 지표

평가 기준	평가 지표	정의
설명 요구 정합성	설명 요구 속성 충족률	사전에 정의한 설명 요구 속성 (예, 설명 대상, 이해관계자, 설명 목적, 설명 범위, 설명 깊이, 표현 방식) 중 실제 충족한 비율
	질의-설명 적합도	사용자의 질문 의도, 업무 맥락, 도메인 상황과 제공된 설명 내용이 논리적으로 부합하는 정도
충실성	행동 정확도 / 설명- 결정 일치율	설명을 기준으로 유도한 결과가 실제 AI 시스템의 decision 또는 behaviour와 일치하는 비율
	국소 설명 충실도	특정 입력 주변 영역에서 설명 모델 또는 설명 근거가 원본 모델의 출력 변화를 얼마나 정확히 묘사하는 정도. LIME 계열에서는 local accuracy, R^2 , RMSE 등으로 측정 가능
재현성	동일 입력 설명 일치율	동일 입력, 동일 모델 버전, 동일 설명 조건에서 반복 실행했을 때 동일하거나 허용 오차 내 설명이 산출되는 비율
	설명 안정성 지수	반복 실행된 설명들 사이의 유사도. 예: 특징 중요도 순위 (Spearman 상관계수, Kendall tau), 상위 k개 특징의 집합 (Top-k Jaccard 유사도), 설명 벡터 cosine similarity
강건성	설명 민감도	모델 판단이 변하지 않는 작은 입력 변화에 대해 설명이 얼마나 민감하게 변하는지 측정한 값. (낮을수록 안정적인 설명)
	예측-설명 변화 정합도	모델의 예측 또는 decision process가 의미 있게 변했을 때, 설명도 그 변화 원인을 같은 방향으로 반영하는 정도

사용자 경험 평가 지표

평가 기준	평가 지표	의미
가독성	설명 복잡도	설명에 포함된 feature 수, 규칙 수, 문장 수, 전문 용어 수, 시각 요소 수 등 사용자의 인지 부하를 유발하는 정보량
	정보 습득 시간	사용자가 설명을 읽고 핵심 질문, 예를 들어 “왜 거절되었는가?”, “무엇을 바꾸면 되는가?”에 답하기까지 걸리는 시간
	핵심 정보 이해율	설명을 본 사용자가 핵심 이유, 주요 근거, 위험 요인, 개선 방향 등을 정확히 이해한 비율
시뮬레이션 가능성	인간 예측 정확도	설명을 제공받은 사용자가 새로운 사례에 대해 AI 시스템의 결과를 예측했을 때 실제 AI 결과와 일치한 비율
	사용자 확신도 보정 오차	사용자가 자신의 예측에 대해 가진 확신도와 실제 예측 정답률 간의 차이. (낮을수록 사용자가 모델의 강점과 약점을 잘 이해한 것)
실행 가능성	대안 유효성 비율	설명이 제시한 개선 대안을 적용했을 때 실제 모델 결과가 목표 방향으로 개선되는 비율
	실행 제약 준수율	제시된 대안 중 사용자가 현실적으로 수정 가능한 변수만 사용한 대안의 비율
	정보 구체성 지수	설명이 현재 값, 목표 값, 조치 방향, 예상 효과, 조건 등 즉각적인 후속 조치에 필요한 구체 정보를 포함하는 정도

설명 용이성 QA 시나리오

설명 용이성 QA 시나리오

항목	설명
Source	• 사용자, 서비스 운영자 • 개발자, 도메인 전문가 • 사고 조사관
Stimulus	• AI 시스템의 결과에 대한 설명 요청 • 결과 예시: 예측, 분류, 추천, 경고, 거절 판단, 위험 판단 등
Artifact	AI-based system, AI 시스템
Environment	정상 운영 상황
Response	• 인과적 설명, 인식적 설명, 정당성 설명 • 시스템은 AI가 산출한 결과에 대해 입력 데이터, 주요 영향 요인, 모델 판단 근거, 도메인 지식, 정책·윤리·법적 기준을 바탕으로 이해관계자 수준에 맞는 설명을 생성하고 제시함
Measure	• 기술적 신뢰성 평가 관점: 설명 요구 정합성, 충실성, 재현성, 강건성 • 사용자 경험 평가 관점: 가독성, 시뮬레이션 가능성, 실행 가능성 • 설명 수행 효율성

대출 심사 거절에 대한 설명 요구사항

항목	설명
Source	대출 신청자
Stimulus	AI가 대출 신청을 거절하였고, 신청자가 거절 사유에 대한 설명을 요청함
Artifact	대출 심사 AI 시스템
Environment	금융 서비스 운영 중
Response	시스템은 대출 거절 결과에 대해 주요 영향 요인, 예를 들어 DTI 초과, 최근 연체 이력, 신용 점수 하락 등을 제시하고, 해당 판단이 금융 리스크 기준 및 공정 대출 원칙에 부합함을 설명함
Measure	질의-설명 적합도 90% 이상, 설명-결정 일치율 90% 이상, 동일 입력 설명 일치율 100% 핵심 정보 이해율 80% 이상

자율주행 급제동에 대한 설명 요구사항

항목	설명
Source	사고 조사관
Stimulus	자율주행차가 주행 중 전방 장애물을 감지하고 급제동을 수행함. 사고 조사 과정에서 급제동 이유와 정당성 설명이 요구됨
Artifact	자율주행 AI 시스템
Environment	사고 조사 및 책임 판단 상황
Response	시스템은 LiDAR·카메라 데이터, 객체 인식 결과, 충돌 예상 시간, 제어 알고리즘의 판단 경로를 바탕으로 급제동 이유를 설명하고, 안전 우선 원칙 및 관련 표준에 따른 정당성을 제시함
Measure	설명 요구 속성 충족률 95% 이상, 설명-결정 일치율 90% 이상, 동일 입력 설명 일치율 100% 핵심 정보 이해율 80% 이상

Q & A
