

품질 우선순위 및 Trade-off

목차

- ❖ AI 응용 분야 별 QA 우선 순위
- ❖ AI 시스템 QA Trade-off

AI 응용 분야 별 QA 우선 순위

AI 응용 분야 별 중요 QA 요약

AI 응용 유형	강건성	프라이버시	공정성	기능 적응성	제어 가능성	설명 용이성
개인화·추천 AI		O	O	O		
인지·지각 AI	O			O	O	
생성형·대화형 AI		O	O		O	O
예측·진단 분석 AI	O			O		O
의사결정 최적화·에이전트 AI	O			O	O	O

개인화·추천 AI

❖ 주요 서비스 사례

- 커머스 상품 랭킹, OTT 콘텐츠 큐레이션
맞춤형 금융 상품 추천, 개인별 광고·뉴스 추천



❖ 기술 특징

- 사용자 행동 이력, 선호도, 위치, 시간, **상황 맥락을 결합하여 사용자별 관심도를 예측**하고, 후보 아이템의 **우선순위를 결정**함.
- 핵심은 **사용자-아이템-맥락 기반 랭킹 최적화**임.

❖ 주요 QA

- **프라이버시**: 사용자 행동, 취향, 위치, 구매 이력, 맥락 정보 등 **개인 관련 데이터를 많이 활용**함
- **공정성**: 추천 결과가 특정 집단, 인기 콘텐츠, 기존 선호에 과도하게 치우치면 **추천 편향, 인기 편향, 집단 차별 문제가 발생할 수 있음**
- **기능 적응성**: 사용자의 취향, 생활 패턴, 시장 트렌드가 계속 변하므로 이러한 **변화에 맞게 추천 기준과 모델 동작을 조정**할 수 있어야 함

인지·지각 AI

❖ 주요 서비스 사례

- 자율주행 객체 탐지·분할, 제조 비전 검사
지능형 CCTV 이상행동 감지, 음성 명령 인식



❖ 기술 특징

- 이미지, 영상, 음성, 센서 데이터 등 비정형 데이터를 해석하여 **객체, 상태, 행동, 상황을 식별**
- 핵심은 **비정형 입력을 의미 있는 상태 정보로 변환하는 것**임

❖ 주요 QA

- **강건성**: 조명, 날씨, 가림, 노이즈, 센서 품질 저하와 같은 입력 변화에 민감하므로 **비정상적·변동적 환경에서도 안정적으로 동작**해야 함
- **기능 적응성**: 새로운 객체, 새로운 장소, 새로운 상황이 계속 등장하므로 **운영 환경 변화에 대응**해야 함
- **제어 가능성**: 자율주행, 의료 영상, 지능형 CCTV처럼 안전과 연결되는 경우에는 **잘못된 인식 결과가 위험한 행동으로 이어지지 않도록 사람이 개입하거나 시스템 동작을 제한**할 수 있어야 함

생성형·대화형 AI

❖ 주요 서비스 사례

- 멀티모달 챗봇, 문서 요약·작성
이미지·영상·음악 생성, RAG 기반 지식 질의응답



❖ 기술 특징

- 대규모 언어모델, 멀티모달 모델, 확산 모델 등을 활용하여 텍스트, 이미지, 영상 등 콘텐츠를 생성하거나 사용자와 자연어로 상호작용함

❖ 주요 QA

- **프라이버시**: 사용자 질문, 문서, 대화 이력에 **민감 정보가** 포함될 수 있으므로 **입력·출력·저장 과정에서 중요함**
- **공정성**: **생성 결과에는** 성별, 인종, 직업, 지역 등에 대한 **편향이나 차별적 표현이 포함될 수 있음**
- **설명 용이성**: 환각, 부정확한 답변, 편향된 판단이 발생했을 때 **사용자가** **응답의 근거와 한계를 이해할 수 있어야 함**
- **제어 가능성**: 부적절한 응답 생성, 프롬프트 인젝션, 위험한 **도구 실행을** **방지하거나 중단할 수 있어야 함**

예측·진단 분석 AI

❖ 주요 서비스 사례

- 수요·재고·공급망 예측, 설비 고장 예지
환자 악화 위험 예측, 차량 배터리 수명 예측



❖ 기술 특징

- 정형 데이터, 시계열 데이터, 로그 데이터를 분석하여 미래 수치, 사건 발생 확률, 이상 징후를 예측함
- 핵심은 **현재와 과거 데이터를 바탕으로 미래 상태나 위험을 조기에 추정하는 것임**

❖ 주요 QA

- **기능 정확성**: 예측·진단 결과가 의사결정의 근거로 사용되므로 **요구되는 정밀도 수준에서 올바른 결과를 제공해야 함**
- **강건성**: 입력 데이터의 잡음, 결측, 이상치, 운영 조건 변화에도 **예측 정확도 유지가 필요함**
- **설명 용이성**: 결과의 근거가 중요한 분야에서는 **왜 그런 예측이나 진단이 나왔는지 이해할 수 있는 설명이 필요함**
- **기능 적응성**: 시간이 지나면서 사용자 행동, 장비 상태, 시장 조건이 변할 수 있으므로 **drift를 감지하고 재평가·재학습·기준 조정 필요함**

의사결정 최적화·에이전트 AI

❖ 주요 서비스 사례

- 스마트 그리드 전력 배분, 물류 경로 최적화, 자율형 업무 워크플로우 수행, 자율형 AI 에이전트



❖ 기술 특징

- 예측 결과와 제약 조건을 바탕으로 최적의 행동, 경로, 순서, 자원 배분을 결정함.
- 단순 추천을 넘어 **목표 달성을 위한 계획·도구 사용·실행 자동화**로 확장되고 있음

❖ 주요 QA

- **강건성**: 잘못된 입력, 불완전한 상태정보, 도구 오류, 계획 실패 등 **비정상 상황에서도 안전하게 동작할 수 있는 있어야 함**
- **기능 적응성**: 운영 환경, 목표, 제약 조건, 사용자의 의도가 계속 변할 수 있으므로 **상황 변화에 맞게 계획과 행동 전략을 조정할 수 있어야 함**
- **제어 가능성**: 잘못된 실행을 중단하거나 사람이 개입할 수 있어야 함
- **설명 용이성**: 에이전트가 **어떤 근거로 계획을 세우고 행동을 선택했는지 이해할 수 있어야 함**

QA TRADE-OFF

QA Trade-off

- ❖ 품질 강화 vs 수행 효율성
- ❖ 공정성 vs 기능 정확성
- ❖ 프라이버시 vs 기능 정확성
- ❖ 설명 용이성 vs 기능 정확성

품질 강화 vs 수행 효율성

- ❖ 신뢰할 수 있는 AI를 위한 품질 확보 활동은 **추가적인 검증, 감시, 보정, 보호, 설명, 제어 절차를 요구**하며, 이는 응답 지연, 처리량 저하, 메모리·GPU 사용량 증가 등 **수행 효율성 저하 요인이 될 수 있음**

품질 강화 항목	수행 효율성 저하 요인
기능 정확성	높은 정확도를 확보하기 위해 대형 모델, 앙상블 모델, 다단계 추론 등을 적용할 경우 모델 파라미터 수와 호출 횟수가 증가하여 응답 지연 및 GPU 사용량 증가 가능
강건성	입력 유효성 검사, OOD 탐지, 노이즈 제거, adversarial defense, fallback 판단 등의 절차가 추가되면 추론 전처리 및 의사결정 단계가 길어져 추론 지연과 처리량 저하 발생 가능
프라이버시	Privacy-preserving inference 기법을 적용하면 암호화 연산, 격리 실행, 보안 통신 비용으로 인해 추론 지연과 자원 사용량이 증가 가능
공정성	개인/집단 별 정확도 검증, 편향 탐지, threshold 조정, 후처리 보정 로직을 운영 경로에 포함할 경우 추가 시간이 발생 가능
기능 적응성	드리프트 탐지, 정확도 저하 징후를 감지하기 위한 운영 데이터 수집, 통계 분석, 재평가, 재학습, 모델 재배포 절차가 필요함. 특히 실시간 모니터링이나 온디바이스 재학습을 수행할 경우 기존 추론 작업과 자원 경합이 발생 가능
제어 가능성	권한 확인, 실행 승인, human-in-the-loop, emergency stop 등을 위한 추가 작업이 필요함. 즉, 제어 판단을 위한 상태 수집 및 통보, 제어를 위한 실행 차단·재시도 비용이 발생 가능
설명 용이성	판단 근거를 산출하기 위해 LIME, SHAP, counterfactual explanation 등을 병행하면 추가 모델 호출이나 반복 추론이 필요할 수 있음. 특히 개별 요청마다 실시간 설명을 생성하는 경우 연산 비용과 응답 시간이 크게 증가 가능

공정성 vs 기능 정확성

❖ 개념


- 모델의 전체적인 정확성을 높이려다 보면 특정 소수 집단에 대한 편향이 발생하기 쉽고
- 반대로 편향을 강제로 억제하다 보면 모델의 전체적인 정확성이 하락하는 현상이 발생함



공정성 vs 기능 정확성


❖ 다수결의 원리 vs 소수의 가치

- 대부분의 ML 알고리즘은 전체 손실 함수를 최소화하도록 학습함
- 데이터 분포가 적은 소수 집단의 특성은 무시되면서 전체 정확도가 상승함



❖ 유용 정보의 제외

- 특정 인종이나 성별 등 보호 속성과 상관관계가 높은 변수를 모델에서 제거할 경우, 편향 완화에는 도움이 되나, 모델이 데이터를 구분하는 '변별력' 자체가 약화될 수 있음




공정성 vs 기능 정확성

❖ Fairness-Accuracy Pareto Frontier

- AI 모델에서 정확도와 공정성 사이의 최적 절충안들을 연결한 경계선
- 프런티어 위의 각 모델은 공정성을 더 높이려면 정확도를 일부 낮추거나, 정확도를 더 높이려면 공정성을 일부 낮춰야 하는 절충 관계에 있음

❖ 모델 비교 및 의사결정

- 프론티어 선 아래의 모델은 다른 후보보다 정확도와 공정성이 모두 낮거나, 한 지표는 같고 다른 지표는 낮으므로 선택할 이유가 적음
- 프론티어 선 위에서 비즈니스 상황을 고려한 최적의 점(Point)을 선택 필요




프라이버시 vs 기능 정확성

❖ 개념

- 데이터 보호를 위한 **마스킹 및 노이즈 추가** 작업은 예측 정확도를 **저하시키는** 원인이 됨
- 양질의 개인 데이터를 **가공 없이 그대로 사용할수록** 모델의 정확성은 높아지지만, 그만큼 개인의 민감한 정보가 노출될 위험도 정비례하여 상승함

❖ Privacy-Utility Pareto Frontier




- 데이터나 AI 모델에서
프라이버시 보호 수준과
데이터 유용성을 함께 고려했을 때
선택할 가치가 있는
최적 절충안들의 경계선



설명 용이성 vs 기능 정확성

❖ 개념

- 모델의 복잡도(Complexity)와 해석 가능성(Interpretability)은 반비례하며, 성능 극대화는 판단 과정의 불투명성을 수반함



주요 충돌 상황

블랙박스(Black-box)의 역설: 딥러닝과 같은 고차원 모델은 데이터 내의 미세하고 비선형적인 패턴을 학습하여 정확성을 높이지만, 그 내부 연산 과정은 너무 방대하고 복잡하여 인간이 논리적으로 추론하거나 설명하는 것이 불가능

표현력(Expressivity)의 희생: 인간이 이해할 수 있는 단순한 모델 (Decision Tree, Linear Regression 등)은 설명하기는 쉽지만, 데이터의 복잡한 상관관계를 담아 내기에는 수학적 표현력이 부족하여 정확성이 낮아짐

AI 품질 충돌 해결을 위한 의사결정

❖ 품질 간 상충 관계를 정량적으로 분석하고, 도메인 특성에 따른 우선순위를 기반으로 최적의 아키텍처를 도출함

❖ 의사결정 프로세스

단계	설명
1. 품질 요구사항 우선순위 설정	도메인 성격(의료, 금융, 자율주행 등)에 따라 필수 QA와 부가 QA를 구분함. 예: 채용 AI는 공정성/설명성이 필수, 자율 주행 AI는 정확성/강건성이 필수
2. 상충 관계 분석	선택한 아키텍처 요소(예: 딥러닝 채택)가 다른 품질(예: 설명성)에 미치는 부정적 영향을 파악함.
3. 완화 전략 수립	기술적 도구(XAI, 차분 프라이버시, 모델 경량화 등)를 도입하여 충돌의 폭을 최소화함

AI 품질 충돌 해결을 위한 의사결정

❖ 상충 완화 전략 예

충돌 쌍	의사결정 기준	완화 전략 예
설명용이성 vs 기능 정확성	법적 설명 의무가 있는 '고영향 AI'인가?	Post-hoc Explainability: LIME, SHAP 및 피쳐 중요도 시각화 및 반사실적 설명 기법 활용
프라이버시 vs 기능 정확성	민감 개인정보 유출 시 법적/사회적 리스크가 큰가?	PETs(Privacy Enhancing Techs): 합성 데이터 사용, 차분 프라이버시(DP) 노이즈 주입 및 연합 학습 검토
공정성 vs 기능 정확성	사회적 약자 보호 및 차별 금지 규제 대상인가?	In-processing & Post-processing: 공정성 최적화 학습, 결과값의 임계값 재조정을 통한 집단 간 격차 해소
수행 효율성 vs 품질 전체	Edge 환경인가, Cloud 환경인가? 인프라 비용 절감이 시급한가?	Model Compression: 양자화, 가지치기, 지식 증류를 통해 거대 모델의 지능을 소형 모델로 전이

Q & A
