

# 데이터 품질

# 목차

---

## ❖ 데이터 품질 개념

## ❖ 데이터 품질 특성

- 데이터 관리 관점
- 데이터 설계 관점
- 데이터 값 관점
- 데이터 운영 관점

## ❖ QA 별 주요 데이터 품질 특성

- 기능 정확성, 강건성, 프라이버시, 공정성, 수행효율성, 설명용이성

# 데이터 품질의 중요성

❖ 데이터 품질은 모델의 지능을 넘어, 시스템의 수명과 수용성을 결정적 요소임

| 관점                           | 설명                                                                                         | 주요 DQ 특성                                                                             |
|------------------------------|--------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|
| 모델의 지능<br>(Intelligence)     | 모델의 본질적 <b>예측 정밀도 극대화</b><br>데이터가 참값에 얼마나 부합하며, 모델 학습에 유효한 정보력을 제공하는지를 결정함.                | Currentness<br>Effectiveness<br>Relevance<br>Accuracy<br>Completeness<br>Consistency |
| 모델의 수명<br>(Survival)         | 운영 환경에서의 <b>강건성 및 성능 보장</b><br>변화하는 환경(Drift)에 대응하고, 한정된 자원 내에서 <b>시스템이 수행 가능한지</b> 를 결정함. | Diversity<br>Representativeness<br>Timeliness<br>Efficiency                          |
| 모델의 수용성<br>(Trustworthiness) | 신뢰 확보 및 법적·윤리적 리스크 통제<br>인간이 <b>시스템의 판단을 신뢰하고 수용할</b> 수 있는 통계적·절차적 정당성을 결정함.               | Balance<br>Compliance<br>Traceability<br>Understandability                           |

# 데이터 품질 모델

| 데이터 품질<br>표준                    | 목적                                                                                                            | 주요 품질 특성                                                                                                                                                                                                                                                                                                |
|---------------------------------|---------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>ISO/IEC 25012<br/>:2008</b>  | <p><b>일반 정보 시스템의 정적 데이터 품질 관리</b></p> <p>컴퓨터 시스템 내에 구조화된 형태로 저장된 데이터의 품질을 평가하기 위한 고전적 모델</p>                  | <p><b>[15개 특성]</b></p> <ul style="list-style-type: none"> <li>- <b>고유 품질:</b> Accuracy, Completeness, Consistency, Credibility, Currentness</li> <li>- <b>시스템 의존 품질:</b> Accessibility, Efficiency, Precision, Traceability, Availability 등</li> </ul>                                                  |
| <b>ISO/IEC 5259-2<br/>:2024</b> | <p><b>AI/ML 시스템의 학습 및 추론용 데이터 품질 관리</b></p> <p>분석 및 머신러닝 생애주기(학습, 검증, 운영) 전반에 걸쳐 데이터셋이 모델 성능에 미치는 영향을 관리함</p> | <p><b>[23개 특성]</b></p> <ul style="list-style-type: none"> <li>- <b>값(Value) 중심:</b> Currentness, Relevance, Effectiveness, Accuracy, Completeness, Consistency, Diversity, Balance, Representativeness 등</li> <li>- <b>관리/설계/운영:</b> Compliance, Identifiability, Auditability, Timeliness 등</li> </ul> |

---

# 데이터 품질 특성

# 데이터 품질 특성 분류

| 유형                        | 설명                                                                                                                                                                                                                                                                                                               | DQ 수 | 품질 특성                                                                                                                                                                                                                                                                        |
|---------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 데이터 관리 관점<br>(Governance) | 데이터 수집 및 처리 전 과정이<br>법적·윤리적 규제( <b>Compliance</b> )를 준수하며,<br>출처의 신뢰성( <b>Credibility</b> ) 있으며<br>이력 추적( <b>Traceability</b> )이 가능하며,<br>사후 감사( <b>Auditability</b> )가 확보했는가?                                                                                                                                   | 4개   | <ul style="list-style-type: none"> <li>· Compliance</li> <li>· Credibility</li> <li>· Traceability</li> <li>· Auditability</li> </ul>                                                                                                                                        |
| 데이터 설계 관점                 | 개별 객체의 고유한 식별성( <b>Identifiability</b> )을 정의하고,<br>모델의 목적 달성에 필요한 데이터의 상세 수준( <b>Precision</b> )과<br>명확한 명세( <b>Understandability</b> )를 설계했는가?                                                                                                                                                                  | 3개   | <ul style="list-style-type: none"> <li>· Identifiability</li> <li>· Precision</li> <li>· Understandability</li> </ul>                                                                                                                                                        |
| 데이터 값 관점                  | 데이터가 최신 상황( <b>Currentness</b> )이고,<br>정확한 추론 결과를 위하여 관련된( <b>Relevance</b> ),<br>유효하며( <b>Effectiveness</b> ), 정확하고( <b>Accuracy</b> ), 완전하고<br>( <b>Completeness</b> ), 일관된( <b>Consistency</b> ) 값이며,<br>다양한( <b>Diversity</b> ) 상황을 균등하게(Balance) 포함하며,<br>실제 환경의 특성( <b>Representativeness</b> )을 반영하고 있는가? | 10개  | <ul style="list-style-type: none"> <li>· Currentness</li> <li>· Relevance</li> <li>· Effectiveness</li> <li>· Accuracy</li> <li>· Completeness</li> <li>· Consistency</li> <li>· Diversity</li> <li>· Balance</li> <li>· Representativeness</li> <li>· Similarity</li> </ul> |
| 데이터 운영 관점                 | 모델이 요구하는 적시성( <b>Timeliness</b> )과<br>처리 효율성( <b>Efficiency</b> ), 데이터의 접근( <b>Accessibility</b> ),<br>가용성( <b>Availability</b> )을 보장하며, 장애 시<br>복구( <b>Recoverability</b> )와 환경 이전( <b>Portability</b> )을 지원하는가?                                                                                                | 6개   | <ul style="list-style-type: none"> <li>· Timeliness</li> <li>· Efficiency</li> <li>· Accessibility</li> <li>· Availability</li> <li>· Recoverability</li> <li>· Portability</li> </ul>                                                                                       |

# 데이터 관리 관점 품질 특성

---

## ❖ Compliance

- 데이터가 법령, 표준, 지침 또는 계약상의 규정을 준수하는 정도
- 예시
  - ✓ 개인정보보호법에 따라 주행 영상 데이터 내 보행자의 얼굴이나 차량 번호판을 비식별화(Blurring) 처리했는지 확인하는 경우



# 데이터 관리 관점 품질 특성

## ❖ Credibility

- 특정 사용 맥락에서 데이터가 사용자에게 진실하고 신뢰할 수 있다고 간주되는 정도
- 예시
  - ✓ 정밀하게 보정된 고해상도 LiDAR 센서에서 수집된 원천 데이터인지,  
아니면 신뢰도가 낮은 웹 수집 영상인지 소스의 권위를 확인하는 경우





# 데이터 관리 관점 품질 특성

## ❖ Traceability

- 특정 사용 맥락에서 데이터의 접근 및 변경 이력에 대한 감사 추적(Audit trail)을 제공하는 정도
- 예시
  - ✓ 도로 상의 '정지 표지판' 이미지에 누가, 언제, 어떤 라벨링 도구를 사용하여 태그를 달았는지 **전체 처리 경로를 기록하고 추적**하는 경우



# 데이터 관리 관점 품질 특성

## ❖ Auditability

- 데이터셋의 전체 또는 일부가 감사를 거쳤거나, 이해관계자가 감사를 수행할 수 있도록 데이터가 준비된 특성
- 예시
  - ✓ 안전 인증 기관이 사고 발생 시 학습 데이터의 무결성을 검증할 수 있도록, 데이터 정제 과정과 어노테이션 가이드라인 준수 여부를 감사 가능한 형태로 보관하는 경우



# 데이터 품질 특성 분류

| 유형                        | 설명                                                                                                                                                                                                                                                                                                               | DQ 수 | 품질 특성                                                                                                                                                                                                                                                                        |
|---------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 데이터 관리 관점<br>(Governance) | 데이터 수집 및 처리 전 과정이<br>법적·윤리적 규제( <b>Compliance</b> )를 준수하며,<br>출처의 신뢰성( <b>Credibility</b> ) 있으며<br>이력 추적( <b>Traceability</b> )이 가능하며,<br>사후 감사( <b>Auditability</b> )가 확보했는가?                                                                                                                                   | 4개   | <ul style="list-style-type: none"> <li>· Compliance</li> <li>· Credibility</li> <li>· Traceability</li> <li>· Auditability</li> </ul>                                                                                                                                        |
| 데이터 설계 관점                 | 개별 객체의 고유한 식별성( <b>Identifiability</b> )을 정의하고,<br>모델의 목적 달성에 필요한 데이터의 상세 수준( <b>Precision</b> )과<br>명확한 명세( <b>Understandability</b> )를 설계했는가?                                                                                                                                                                  | 3개   | <ul style="list-style-type: none"> <li>· Identifiability</li> <li>· Precision</li> <li>· Understandability</li> </ul>                                                                                                                                                        |
| 데이터 값 관점                  | 데이터가 최신 상황( <b>Currentness</b> )이고,<br>정확한 추론 결과를 위하여 관련된( <b>Relevance</b> ),<br>유효하며( <b>Effectiveness</b> ), 정확하고( <b>Accuracy</b> ), 완전하고<br>( <b>Completeness</b> ), 일관된( <b>Consistency</b> ) 값이며,<br>다양한( <b>Diversity</b> ) 상황을 균등하게(Balance) 포함하며,<br>실제 환경의 특성( <b>Representativeness</b> )을 반영하고 있는가? | 10개  | <ul style="list-style-type: none"> <li>· Currentness</li> <li>· Relevance</li> <li>· Effectiveness</li> <li>· Accuracy</li> <li>· Completeness</li> <li>· Consistency</li> <li>· Diversity</li> <li>· Balance</li> <li>· Representativeness</li> <li>· Similarity</li> </ul> |
| 데이터 운영 관점                 | 모델이 요구하는 적시성( <b>Timeliness</b> )과<br>처리 효율성( <b>Efficiency</b> ), 데이터의 접근( <b>Accessibility</b> ),<br>가용성( <b>Availability</b> )을 보장하며, 장애 시<br>복구( <b>Recoverability</b> )와 환경 이전( <b>Portability</b> )을 지원하는가?                                                                                                | 6개   | <ul style="list-style-type: none"> <li>· Timeliness</li> <li>· Efficiency</li> <li>· Accessibility</li> <li>· Availability</li> <li>· Recoverability</li> <li>· Portability</li> </ul>                                                                                       |

# 데이터 설계 관점 품질 특성

## ❖ Identifiability


- 데이터 내의 개별 객체나 항목을 중복 없이 고유하게 식별하고 구분할 수 있는 정도
- 예시
  - ✓ 교차로 영상 내의 수많은 차량들에 대해 각각 '고유 Track ID'를 부여하여, 프레임이 바뀌어도 동일 차량임을 중복 없이 식별하도록 설계하는 경우



# 데이터 설계 관점 품질 특성

## ❖ Precision


- 데이터가 **정확하거나(exact)** 목적에 부합하도록 충분한 상세 수준과 **변별력**을 갖춘 정도
- 예시
  - ✓ 객체의 위치 좌표를 설계할 때, 단순 정수(Pixel) 단위가 아닌 소수점 단위(Sub-pixel)나 **cm 단위의 정밀도**를 갖도록 데이터 타입을 설계하는 경우



# 데이터 설계 관점 품질 특성

## ❖ Understandability

- 데이터의 의미, 형식, 문맥이 명확하게 해석될 수 있는 정도
- 예시
  - ✓ 객체 클래스 분류 시 '1, 2, 3' 같은 코드 대신 'Pedestrian, Cyclist, Bus'로 명세화하고, 속도 단위를 'm/s' 또는 'km/h'로 표현하는 경우



# 데이터 품질 특성 분류

| 유형                        | 설명                                                                                                                                                                                                                                                                                                               | DQ 수 | 품질 특성                                                                                                                                                                                                                                                                        |
|---------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 데이터 관리 관점<br>(Governance) | 데이터 수집 및 처리 전 과정이<br>법적·윤리적 규제( <b>Compliance</b> )를 준수하며,<br>출처의 신뢰성( <b>Credibility</b> ) 있으며<br>이력 추적( <b>Traceability</b> )이 가능하며,<br>사후 감사( <b>Auditability</b> )가 확보했는가?                                                                                                                                   | 4개   | <ul style="list-style-type: none"> <li>· Compliance</li> <li>· Credibility</li> <li>· Traceability</li> <li>· Auditability</li> </ul>                                                                                                                                        |
| 데이터 설계 관점                 | 개별 객체의 고유한 식별성( <b>Identifiability</b> )을 정의하고,<br>모델의 목적 달성에 필요한 데이터의 상세 수준( <b>Precision</b> )과<br>명확한 명세( <b>Understandability</b> )를 설계했는가?                                                                                                                                                                  | 3개   | <ul style="list-style-type: none"> <li>· Identifiability</li> <li>· Precision</li> <li>· Understandability</li> </ul>                                                                                                                                                        |
| 데이터 값 관점                  | 데이터가 최신 상황( <b>Currentness</b> )이고,<br>정확한 추론 결과를 위하여 관련된( <b>Relevance</b> ),<br>유효하며( <b>Effectiveness</b> ), 정확하고( <b>Accuracy</b> ), 완전하고<br>( <b>Completeness</b> ), 일관된( <b>Consistency</b> ) 값이며,<br>다양한( <b>Diversity</b> ) 상황을 균등하게(Balance) 포함하며,<br>실제 환경의 특성( <b>Representativeness</b> )을 반영하고 있는가? | 10개  | <ul style="list-style-type: none"> <li>· Currentness</li> <li>· Relevance</li> <li>· Effectiveness</li> <li>· Accuracy</li> <li>· Completeness</li> <li>· Consistency</li> <li>· Diversity</li> <li>· Balance</li> <li>· Representativeness</li> <li>· Similarity</li> </ul> |
| 데이터 운영 관점                 | 모델이 요구하는 적시성( <b>Timeliness</b> )과<br>처리 효율성( <b>Efficiency</b> ), 데이터의 접근( <b>Accessibility</b> ),<br>가용성( <b>Availability</b> )을 보장하며, 장애 시<br>복구( <b>Recoverability</b> )와 환경 이전( <b>Portability</b> )을 지원하는가?                                                                                                | 6개   | <ul style="list-style-type: none"> <li>· Timeliness</li> <li>· Efficiency</li> <li>· Accessibility</li> <li>· Availability</li> <li>· Recoverability</li> <li>· Portability</li> </ul>                                                                                       |



# 데이터 값 관점 품질 특성

## ❖ Currentness(최신성)

- 데이터가 사용 시점의 현실을 정확하게 반영한 최신 상태인 정도
- 예시
  - ✓ 최근 변경된 **교통 표지판 디자인이나 도로 마킹 규정**이 반영된 최신 주행 데이터를 학습에 사용하는 경우





# 데이터 값 관점 품질 특성

---

## ❖ Relevance

- 데이터의 피처나 샘플이 해결하려는 도메인 문제 및 모델 학습 목적에 적합한 정도
- 예시
  - ✓ 도심 주행 시스템 학습을 위해 **비행기나 선박 데이터는 제외**하고 도로 위 객체(차량, 보행자) 위주로 구성하는 경우



포함 (도로 위 객체)



제외 (비행기)



제외 (선박)

# 데이터 값 관점 품질 특성

---

## ❖ Effectiveness

- 데이터가 의도한 ML 과제의 목표 성능 달성에 실질적으로 기여하고 유효한 정도
- 예시
  - ✓ 안개나 역광으로 인해 형체를 알아볼 수 없는 이미지 대신, 식별이 가능한 수준의 조도와 해상도를 가진 유효 데이터를 선별하는 경우



유효하지 않은 데이터



유효한 데이터

# 데이터 값 관점 품질 특성

---

## ❖ Accuracy

- 데이터가 실제 세계의 사실이나 의도된 속성의 참값을 정확하게 반영하는 정도
- 예시
  - ✓ 영상 내 '트럭' 객체에 대해 오답인 '버스'가 아닌 정답인 '트럭'으로 정확하게 라벨링된 경우



# 데이터 값 관점 품질 특성

## ❖ Consistency

- 데이터가 모순 없이 일치하거나, 시간적 흐름 속에서 논리적 정합성을 유지하는 정도
- 예시
  - ✓ 동일한 차량이 주행 프레임(Time-series) 내에서 갑자기 '승용차'에서 '자전거'로 바뀌지 않고 일관되게 유지되는 경우



# 데이터 값 관점 품질 특성

---

## ❖ Completeness

- 특정 목적을 위해 필요한 데이터 레코드나 속성이 빠짐없이 포함된 상태
- 예시
  - ✓ 화면에 나타난 10대의 차량 중 누락 없이 10대 모두에 대해 바운딩 박스(BBox)가 쳐져 있는 상태



# 데이터 값(셋) 관점 품질 특성

## ❖ Diversity

- 데이터셋이 다양한 범위의 피쳐, 라벨, 시나리오(예외 상황 포함)를 충분히 포괄하는 수준
- 예시
  - ✓ 맑은 날 뿐만 아니라 눈, 비, 터널 진출입, 야간 등 을 포함하여 예외 상황 포함





# 데이터 값(셋) 관점 품질 특성

## ❖ Balance


- 데이터셋 내 각 클래스나 주요 속성의 분포가 편향되지 않고 적절한 비율을 유지하는 정도
- 예시
  - ✓ '구급차'나 '경찰차' 같은 **희귀 객체 샘플을 충분히 확보**하여 모델이 특정 다수 클래스에만 치우치지 않게 하는 경우



# 데이터 값(셋) 관점 품질 특성

## ❖ Representativeness(대표성)

- 샘플 데이터의 통계적 특성과 분포가 실제 운영 환경(모집단)을 충실히 대변하는 정도
- 예시
  - ✓ 학습 데이터셋의 '차종별 비율'이 실제 고속도로나 시내 도로에서 관측되는 차종 분포와 통계적으로 일치하도록 구성하는 경우





# 데이터 값(셋) 관점 품질 특성

## ❖ Similarity(유사성)

- 데이터셋 내의 개별 샘플들이 주요 특징 측면에서 서로 닮은 정도 (중복성)
- 예시
  - ✓ 정차 중 수집된 수천 장의 동일 이미지들이 포함되어 모델이 특정 상태에 과도하게 학습하는 경우



# 데이터셋 구성 전략

❖ 다양한 상황에 대하여 편향없이 학습하고, 실전 상황을 대상으로 검증

| 단계                               | 중점 DQ              | 역할 및 목표                                                                                           | 도로 객체 인식 예                                                                       |
|----------------------------------|--------------------|---------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------|
| 1단계:<br>원천 데이터 수집<br>(Ingestion) | Diversity          | <b>[영토 확보]</b><br>현실의 분포와 상관없이<br>모델이 경험할 수 있는 <b>모든</b><br><b>시나리오와 예외의 절대량</b> 을<br>확보하는 단계     | 맑은 날 영상 뿐만 아니라,<br><b>안개, 폭설, 야간, 공사 현장</b> 등<br>희귀하지만 치명적인 환경<br>데이터를 최대한 수집    |
| 2단계:<br>모델 학습                    | Balance            | <b>[편향 교정]</b><br>학습 데이터 내의 다수<br>클래스 쓸림을 방지하여,<br>소수 객체에 대한 모델의<br>민감도(Recall)를<br>끌어올리는 단계      | 실제 도로엔 승용차가<br>압도적이지만, 학습 시엔<br>구급차나 보행자 샘플에 높은<br>가중치를 두어 편중된 학습을<br>방지함        |
| 3단계:<br>검증 및 평가                  | Representativeness | <b>[실전 검증]</b><br>구축된 모델이 <b>실제 운영</b><br><b>환경에서 얼마나 잘</b><br><b>작동할지</b> 를 평가하기 위해<br>현실 분포를 복제 | 실제 고속도로 통행량<br>통계(95:5)와 동일한 비율로<br>테스트 셋을 구성하여, 배포 시<br>발생할 <b>하락 가능성</b> 을 확인함 |

# 데이터 품질 특성 분류

| 유형                        | 설명                                                                                                                                                                                                                                                                                                               | DQ 수 | 품질 특성                                                                                                                                                                                                                                                                        |
|---------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 데이터 관리 관점<br>(Governance) | 데이터 수집 및 처리 전 과정이<br>법적·윤리적 규제( <b>Compliance</b> )를 준수하며,<br>출처의 신뢰성( <b>Credibility</b> ) 있으며<br>이력 추적( <b>Traceability</b> )이 가능하며,<br>사후 감사( <b>Auditability</b> )가 확보했는가?                                                                                                                                   | 4개   | <ul style="list-style-type: none"> <li>· Compliance</li> <li>· Credibility</li> <li>· Traceability</li> <li>· Auditability</li> </ul>                                                                                                                                        |
| 데이터 설계 관점                 | 개별 객체의 고유한 식별성( <b>Identifiability</b> )을 정의하고,<br>모델의 목적 달성에 필요한 데이터의 상세 수준( <b>Precision</b> )과<br>명확한 명세( <b>Understandability</b> )를 설계했는가?                                                                                                                                                                  | 3개   | <ul style="list-style-type: none"> <li>· Identifiability</li> <li>· Precision</li> <li>· Understandability</li> </ul>                                                                                                                                                        |
| 데이터 값 관점                  | 데이터가 최신 상황( <b>Currentness</b> )이고,<br>정확한 추론 결과를 위하여 관련된( <b>Relevance</b> ),<br>유효하며( <b>Effectiveness</b> ), 정확하고( <b>Accuracy</b> ), 완전하고<br>( <b>Completeness</b> ), 일관된( <b>Consistency</b> ) 값이며,<br>다양한( <b>Diversity</b> ) 상황을 균등하게(Balance) 포함하며,<br>실제 환경의 특성( <b>Representativeness</b> )을 반영하고 있는가? | 10개  | <ul style="list-style-type: none"> <li>· Currentness</li> <li>· Relevance</li> <li>· Effectiveness</li> <li>· Accuracy</li> <li>· Completeness</li> <li>· Consistency</li> <li>· Diversity</li> <li>· Balance</li> <li>· Representativeness</li> <li>· Similarity</li> </ul> |
| 데이터 운영 관점                 | 모델이 요구하는 적시성( <b>Timeliness</b> )과<br>처리 효율성( <b>Efficiency</b> ), 데이터의 접근( <b>Accessibility</b> ),<br>가용성( <b>Availability</b> )을 보장하며, 장애 시<br>복구( <b>Recoverability</b> )와 환경 이전( <b>Portability</b> )을 지원하는가?                                                                                                | 6개   | <ul style="list-style-type: none"> <li>· Timeliness</li> <li>· Efficiency</li> <li>· Accessibility</li> <li>· Availability</li> <li>· Recoverability</li> <li>· Portability</li> </ul>                                                                                       |

# 데이터 운영 관점 품질 특성

| DQ 특성                      | 설명                                                             | 자율주행 객체 인식 시스템 예시                                                                       |
|----------------------------|----------------------------------------------------------------|-----------------------------------------------------------------------------------------|
| <b>Timeliness</b><br>(적시성) | 현상이 발생한 시점부터 데이터가 기록되어 사용 가능해질 때까지의 지연(Latency)이 요구사항을 충족하는 정도 | 차량 센서(Lidar/Camera)가 포착한 장애물 정보가 수 밀리초(ms) 이내에 인식 모델에 전달되어 즉각적인 판단을 지원하는 경우             |
| <b>Efficiency</b>          | 데이터 처리 및 관리 과정에서 소요되는 시간, 메모리, 연산 자원 등이 적절한 수준으로 최적화된 정도       | 대용량 주행 영상을 처리할 때 TFRecord나 Parquet와 같은 효율적인 데이터 저장 형식을 사용하여 GPU 로드 시간과 스토리지 비용을 절감하는 경우 |
| <b>Accessibility</b>       | 적절한 도구, 권한, 인터페이스를 통해 필요한 데이터에 쉽고 원활하게 접근하여 획득할 수 있는 용이성       | 개발자가 검증을 위해 '야간 보행자 사고 데이터셋'을 Feature Store에서 API 호출 한 번으로 즉시 추출하여 사용할 수 있는 환경          |

# 데이터 운영 관점 품질 특성

| DQ 특성          | 설명                                                               | 자율주행 객체 인식 시스템 예시                                                             |
|----------------|------------------------------------------------------------------|-------------------------------------------------------------------------------|
| Availability   | 권한이 있는 사용자나 애플리케이션이 필요로 하는 시점에 데이터가 즉시 제공되고 사용 가능한 상태(가동률)       | 재학습 파이프라인이 가동될 때 데이터 레이크 서버가 중단 없이 안정적으로 데이터를 공급하여 학습 프로세스가 지연되지 않는 상태        |
| Recoverability | 시스템 장애나 데이터 손상 발생 시, 데이터를 손실 없이 원래의 정상 품질 상태로 되돌릴 수 있는 복구 능력     | 스토리지 서버 결함으로 라벨링 데이터가 유실되었을 때, 전일 백업본을 통해 즉시 복구하여 자율주행 학습 일정을 차질 없이 유지하는 경우   |
| Portability    | 데이터를 기존의 시스템 환경에서 다른 플랫폼이나 인프라(클라우드 등)로 품질 저하 없이 손쉽게 이전할 수 있는 역량 | 로컬 서버에서 학습하던 수십 PB의 주행 데이터셋을 퍼블릭 클라우드(AWS/Azure 등)로 이전해도 포맷 충돌 없이 그대로 가동되는 경우 |

# Quiz: 데이터 품질 유형

다음은 자율주행 학습데이터의 품질을 개선한 사례이다.  
각 사례와 가장 관련성이 높은 **데이터 품질 유형**을 제시하시오.

| 번호 | 문제                                                                                                              | DQ 유형 |
|----|-----------------------------------------------------------------------------------------------------------------|-------|
| 1  | 자율주행 학습 데이터에서 동일한 오토바이가 연속 프레임마다 다른 객체로 새로 생성되지 않도록, 객체별로 고유 ID를 부여해 추적 가능하게 설계하였다.                             |       |
| 2  | 차량의 전방 카메라 데이터에서 보행자 위치를 단순히 "왼쪽/가운데/오른쪽"으로 저장하지 않고, 실제 좌표계 기준의 세밀한 위치값으로 저장하도록 데이터 스키마를 설계하였다.                 |       |
| 3  | 센서 로그의 컬럼명이 v1, v2, c3처럼 모호해서 분석자가 의미를 알기 어려워, vehicle_speed_kmh, object_class, distance_m처럼 명확한 이름과 단위를 부여하였다. |       |
| 4  | 최근 새로 도입된 어린이 보호구역 표지와 변경된 차선 색상 규칙이 기존 데이터셋에는 반영되어 있지 않아, 최신 도로 환경 데이터를 추가 수집하였다.                              |       |
| 5  | 자율주행 도로 객체 인식 모델을 만들기 위해 병원 내부 CCTV 영상, 공장 설비 영상, 실내 로봇 영상은 제외하고 실제 도로 주행 영상만 사용하였다.                            |       |
| 6  | 야간 주행 영상 중 너무 어둡거나 흔들림이 심해 객체 윤곽을 전혀 판별할 수 없는 이미지는 학습에 도움이 되지 않는다고 판단하여 제거하였다.                                  |       |

# Quiz: 데이터 품질 유형

다음은 자율주행 학습데이터의 품질을 개선한 사례이다.  
각 사례와 가장 관련성이 높은 **데이터 품질 유형**을 제시하시오.

| 번호 | 문제                                                                                                | DQ 유형 |
|----|---------------------------------------------------------------------------------------------------|-------|
| 7  | 데이터셋에서 실제로는 '자전거'인 객체가 '오토바이'로 잘못 라벨링되어 있어, 원본 영상을 확인한 뒤 올바른 라벨로 수정하였다.                           |       |
| 8  | 연속 주행 데이터에서 같은 보행자의 객체 클래스가 프레임마다 '보행자 → 표지판 → 보행자'로 흔들리는 문제가 발견되어, 시간 흐름상 동일 객체 라벨이 유지되도록 정제하였다. |       |
| 9  | 교차로 이미지에 보행자 6명, 차량 4대, 신호등 2개가 나타나지만 일부 객체에만 라벨이 붙어 있어, 모든 객체에 빠짐없이 라벨과 바운딩 박스를 추가하였다.           |       |
| 10 | 학습 데이터가 대부분 맑은 낮 시간의 직선 도로 장면으로만 구성되어 있어, 곡선 도로, 비보호 좌회전, 역광, 터널 내부, 사고 현장 데이터를 추가하였다.            |       |
| 11 | 학습 데이터에서 일반 승용차가 대부분을 차지하고 자전거·킥보드·긴급차량 샘플이 매우 적어, 소수 클래스 데이터를 추가 확보하거나 가중치를 조정하였다.               |       |
| 12 | 테스트 데이터셋을 만들 때 실제 도심 주행 환경에서 관측되는 승용차, 버스, 트럭, 이륜차, 보행자의 출현 비율과 유사하도록 샘플을 구성하였다.                  |       |

---

# QA 별 주요 데이터 품질 특성



# QA 별 주요 데이터 품질 특성

| 시스템<br>QA | 긍정적 영향<br>DQ 특성                                                                                                                                               | 부정적<br>영향<br>DQ 특성 | 설명                                                                                                                                                                                                                                                                                                                                                                                                                 |
|-----------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 기능<br>정확성 | <p>Currentness,<br/>Relevance,<br/>Effectiveness</p> <p>Accuracy,<br/>Completeness,<br/>Consistency</p> <p>Diversity,<br/>Balance,<br/>Representativeness</p> | Similarity         | <p>최신 현실을 반영한 데이터(Currentness), 목적에 적합한 데이터(Relevance), 실제 학습에 유효한 데이터(Effectiveness)는 모델이 올바른 입력 특성을 학습하도록 기여함.</p> <p>또한 참값을 정확히 반영한 라벨(Accuracy), 누락 없는 객체 주석(Completeness), 시간 흐름상 모순 없는 데이터(Consistency)는 정답 학습의 기반이 됨.</p> <p>다양한 상황(Diversity), 클래스 분포의 균형(Balance), 실제 운영 환경을 대변하는 분포(Representativeness)는 실전 정확도 향상에 기여함.</p> <p>하지만 중복된 패턴(Similarity)은 특정 상황에 대한 과적합을 유발하여 실제 환경에서의 정확성을 저하시킬 수 있음.</p> |

# QA 별 주요 데이터 품질 특성

| 시스템<br>QA | 긍정적 영향<br>DQ 특성                                                                  | 부정적 영향<br>DQ 특성 | 설명                                                                                                                                                                                                                                                                                                                                               |
|-----------|----------------------------------------------------------------------------------|-----------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 강건성       | Diversity(Biased)<br>Completeness<br>Relevance(Unseen)<br>Effectiveness(Invalid) | N/A             | <p>다양한 환경과 예외 상황을 포함한 데이터(Diversity)는 모델이 날씨, 조명, 센서 변화 등 다양한 조건을 경험하도록 함.</p> <p>강건성 평가와 학습에 필요한 객체, 상황, 속성이 누락 없이 포함된 상태(Completeness)는 비정상·희귀 조건에서도 모델이 필요한 단서를 충분히 학습하도록 지원함.</p> <p>목적과 관련된 비정상·희귀 상황 데이터(Relevance)는 실제 운영 중 마주칠 수 있는 변화 조건에 대응하는 데 기여함.</p> <p>식별 가능한 수준의 유효 데이터(Effectiveness)는 손상·저품질 입력 상황에서도 의미 있는 특성을 학습하도록 지원함.</p> |

# QA 별 주요 데이터 품질 특성

| 시스템<br>QA | 긍정적 영향<br>DQ 특성         | 부정적 영향<br>DQ 특성              | 설명                                                                                                                                                                                                                                     |
|-----------|-------------------------|------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 프라이버시     | Compliance<br>Relevance | Identifiability<br>Precision | <p>법적 규제 준수(Compliance)와 목적에 적합한 데이터만 활용하는 것(Relevance)은 개인정보 수집·처리 범위를 제한하는 방어막 역할을 함.</p> <p>하지만 데이터 내 개별 항목의 식별성(Identifiability)은 재식별을 통한 프라이버시 침해 위험과 직결됨.</p> <p>높은 정밀도(Precision)의 위치, 시간, 영상, 센서 데이터는 개인의 식별 가능성을 높일 수 있음.</p> |

# QA 별 주요 데이터 품질 특성

| 시스템<br>QA | 긍정적 영향<br>DQ 특성                      | 부정적 영향<br>DQ 특성 | 설명                                                                                                                                                                                                                                                                                                                                                              |
|-----------|--------------------------------------|-----------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 공정성       | Diversity<br>Balance<br>Completeness | Similarity      | <p>다양한 집단, 환경, 객체 유형을 포함한 데이터(Diversity)는 특정 조건이나 집단에 치우친 학습을 줄이는 데 기여함.</p> <p>클래스나 주요 속성의 분포 균형(Balance)은 다수 클래스 중심의 편향을 완화하고, 소수 클래스나 희귀 조건에 대한 정확성 저하를 방지하는 데 기여함.</p> <p>공정성 판단에 필요한 집단별 속성, 라벨, 평가 항목이 누락 없이 포함된 상태(Completeness)는 특정 집단에 대한 성능 저하나 차별적 결과를 발견할 수 있게 함.</p> <p>반면 중복된 데이터(Similarity)는 특정 집단, 환경, 객체 유형의 패턴을 반복 학습하게 하여 편향을 강화할 수 있음.</p> |

# QA 별 주요 데이터 품질 특성

| 시스템 QA    | 긍정적 영향<br>DQ 특성                       | 부정적 영향<br>DQ 특성 | 설명                                                                                                                                                                                                                                                                   |
|-----------|---------------------------------------|-----------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 수행<br>효율성 | Efficiency<br>Relevance<br>Timeliness | Similarity      | <p>처리하기 쉬운 형식과 구조를 가진 데이터(Efficiency)는 저장, 전송, 전처리, 학습 비용을 낮추는 데 기여함.</p> <p>목적에 적합한 데이터(Relevance)는 불필요한 입력과 노이즈 처리를 줄임.</p> <p>필요한 시점에 제공되는 데이터 (Timeliness)는 지연과 재처리 비용을 줄이는 데 기여함.</p> <p>하지만 중복된 데이터(Similarity)는 저장 공간과 학습 자원 사용량을 증가시켜 수행 효율성을 저하시킬 수 있음.</p> |

# QA 별 주요 데이터 품질 특성

| 시스템 QA    | 긍정적 영향<br>DQ 특성                                                      | 부정적 영향<br>DQ 특성 | 설명                                                                                                                                                                                                                                                                                                                                                |
|-----------|----------------------------------------------------------------------|-----------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 설명<br>용이성 | Understandability<br>Identifiability<br>Traceability<br>Auditability | N/A             | <p>데이터의 의미와 형식이 명확한 상태(Understandability)는 입력 데이터와 모델 결과를 해석하기 쉽게 만듦.</p> <p>데이터 내 개별 항목을 고유하게 식별할 수 있는 특성(Identifiability)은 특정 학습 샘플, 라벨, 오류 사례를 구분하여 설명 근거를 추적하는 데 기여함.</p> <p>데이터의 수집·정제·라벨링·변경 이력 추적성(Traceability)은 특정 결과가 어떤 데이터에 근거했는지 설명할 수 있게 함.</p> <p>감사 가능한 데이터 관리 상태(Auditability)는 데이터 품질 활동과 모델 판단 근거를 검증 가능하게 하여 설명의 신뢰성을 높임.</p> |

# Q & A

---