

기능 정확성 (Functional Correctness) 설계

❖ 기능 정확성 설계 개요

❖ 활동 기반 설계

- 데이터 설계
- 모델 학습 설계
- 추론 서비스 설계
- 배포 · 운영 설계

❖ 구조적 설계 패턴

기능 정확성 설계 개요

- ❖ 데이터·모델 학습·추론·운영 전 단계에서 오류를 줄이고, 요구된 기능을 정확하게 수행하도록 설계
- ❖ 운영 결과를 지속적으로 감시하고 모델 제어·교체·재학습에 반영하여 정확성을 유지·개선

01

데이터 설계

- 도메인 기반 피처 설계
- 대표성·경계 사례 확보

02

모델 학습 설계

- 전이학습·NAS
- 커리큘럼 학습
- 앙상블·모델가중치평균

03

추론서비스 설계

- 입력 표준화
- 맥락 데이터 합성
- 도메인 논리 기반 출력 보정

03

배포 · 운영 설계

- 성능·드리프트 감시
- 상황기반 추론제어·재학습
- 정확성 강화 모델 전환

구조적 설계 패턴

입력 정규화·맥락 보강 | 다중 모델 결합 | 전문 모델 라우팅 | 정확성 피드백 제어

데이터 설계

기능 정확성을 위한 데이터 설계 기법

기법	설명
DD-1 도메인 기반 피쳐 설계	도메인 지식을 활용해 예측에 중요한 업무 요인을 식별하고, 모델이 학습할 수 있는 입력 피쳐로 정의·변환하는 설계 기법
DD-2 대표성·경계 사례 확보	운영 조건, 희귀·경계 사례 및 클래스 분포를 반영하여 일반화 성능 확보.

DD-1: 도메인 기반 피처 설계

❖ 개념

- 도메인 지식을 활용하여 **예측 대상과 업무적으로 관련된 핵심 요인을 식별**하고, 이를 모델이 학습할 수 있는 **입력 특성으로 정의·변환**
- 비율, 집계, 구간, 변화량 및 시계열 요약 등을 통해 원시 데이터의 업무적 의미를 효과적으로 표현

❖ 적용 절차

1. **핵심 요인 식별**: 무엇이 예측에 중요할 수 있는가?
2. **피처 정의·변환**: 이를 데이터로 어떻게 측정하고 표현할 것인가?
3. **피처 유효성 검증**: 실제 성능에 도움이 되고 운영 시에도 안전하게 사용할 수 있는가?

❖ 예시 (쇼핑몰에서 고객의 다음 달 재구매 여부 예측)

적용 절차	쇼핑몰 재구매 예측 예시
1. 핵심 요인 식별	최근성, 구매 빈도, 구매금액 변화, 구매전환 정도
2. 피처 정의·변환	구매 경과일, 3개월 구매 횟수, 구매액 증가율, 구매전환율
3. 유효성 검증	성능 향상, 운영 시 계산 가능 여부 확인

❖ 주의

- 피처와 결과의 상관성을 인과관계로 해석하지 않으며, 독립된 데이터와 성능 비교를 통해 예측 피처로서의 유효성을 검증

DD-2: 대표성·경계 사례 확보

❖ 개념

실제 운영환경에서 나타날 수 있는 **다양한 조건**과, 모델이 구분하기 어려운 **경계·희귀 사례**를 데이터셋에 충분히 포함하는 설계

❖ 세부 기술

- 사용자·지역·시간·장비·환경 조건별 데이터 수집
- 클래스별 표본 수와 분포 분석
- 소수·희귀 클래스 추가 수집
- 과표본화·과소표본화 등 불균형 조정
- 판단 경계 주변 사례의 집중 샘플링
- 회전·밝기·노이즈 등을 이용한 데이터 증강
- 실제 오류 사례와 어려운 사례의 반복 보강

❖ 주의

- 데이터 수의 균형이 곧 실제 운영 분포의 대표성을 의미하지는 않음
- 인위적인 증강 데이터가 현실적으로 가능한 사례인지 확인해야 함
- 경계 사례에 지나치게 집중하면 일반 사례의 성능이 저하될 수 있음

모델 학습 관점 설계

모델 학습 설계 기법 요약

유형	기법	설명
아키텍처 및 전략	MT-1 전이 학습 (Transfer Learning)	사전 학습된 지식을 이식하여 데이터 부족 환경에서 안정적인 베이스라인 확보
	MT-2 NAS (Neural Architecture Search)	알고리즘이 특정 Task에 최적화된 신경망 구조를 스스로 탐색하여 최적의 정확도 확보
학습 로직 고도화	MT-3 커리큘럼 학습 (Curriculum Learning)	쉬운 개념부터 어려운 순으로 난이도를 조절하여 복잡 과업의 정확도 향상
결합 및 최적화	MT-4 앙상블	여러 모델의 추론을 결합하여 오답 보정 및 단일 모델의 한계를 넘는 정확도 확보
	MT-5 모델 가중치 평균 (Model Soups)	상이한 하이퍼파라미터 모델들의 가중치를 평균하여 모델 구축

MT-1: 전이 학습(Transfer Learning)


❖ 개념: 지식의 상속

- 방대한 양의 범용 데이터셋(예: ImageNet, Wikipedia)으로 구축된 **사전 학습 모델(Pre-trained Model)**의 **지능**을, **데이터가 부족하거나 특수한 목적을 가진 새로운 작업에 이식**
- 하부 레이어가 학습한 '범용적 특징(점, 선, 질감 등)'은 유지하고 상부 레이어의 '고수준 논리(특정 객체 판별)'만을 타겟 도메인에 맞춰 미세 조정(Fine-tuning)하는 지능적 상속 과정임

❖ 목적: 콜드 스타트 극복과 효율적 지능 고도화

- **지능의 초기 품질(Cold Start) 보장**: 바닥부터(From Scratch) 무작위 가중치로 시작하는 모델보다 훨씬 높은 정확도 지점에서 학습을 시작할 수 있어, 데이터 확보가 어려운 특수 도메인에서 유용
- **연산 자원 및 시간 최적화**: 기초적인 시각/언어 지능을 배우는 데 소모되는 많은 GPU 연산 비용을 절감
- **일반화 능력 향상**: 거대 데이터셋에서 학습한 지능을 이어받음으로써, 소량의 데이터만 학습했을 때 발생하기 쉬운 과적합 문제를 억제

전이 학습 기법



학습 범위	Head만	일부 Layer	전체	소수 추가 파라미터
비용	낮음	중간	높음	낮음
적응력	낮음	중간	높음	중간~높음



MT-2: NAS (Neural Architecture Search)

❖ 개념: 신경망 구조 설계의 자동화와 최적화

- 인간 설계자가 수동으로 레이어의 종류, 개수, 연결 방식을 결정하던 기존 방식에서 벗어나, 주어진 제약 조건에 최적화된 신경망 아키텍처를 알고리즘이 스스로 탐색하고 설계

❖ 기존 방식:

- 인간 설계자가 수동으로 신경망 층을 쌓는 대신, 알고리즘이 주어진 데이터와 제약 조건(속도, 메모리 등) 하에서 가장 성능이 좋은 최적의 신경망 구조를 스스로 탐색

❖ NAS 방식:

- 시나리오: 자율주행 차량의 임베디드 제어기(ECU)에서 실시간으로 동작하는 '경량형 보행자 인식 모델' 설계
- 방법
 - ✓ '지연 시간 10ms 이하'와 '정확도 95% 이상'이라는 제약 조건을 NAS 알고리즘에 부여
 - ✓ 알고리즘은 수천 개의 레이어 조합(Convolution, Pooling, Attention 등)을 시뮬레이션하여, 해당 차량의 하드웨어 가속기(NPU)에서 가장 효율적으로 돌아가는 독자적인 신경망 아키텍처 결정

MT-3: 커리큘럼 학습(Curriculum Learning)

❖ 개념: 단계별 성장을 유도하는 인간 중심적 학습 모델링

- 데이터를 무작위로 학습시키는 대신, 인간이 쉬운 개념부터 배우고 점진적으로 심화 과정을 밟는 교육 방식을 모사한 기법
- **학습 초기에는 판별하기 쉬운 저난이도 데이터**, 학습이 진행됨에 따라 **점차 복잡하거나 노이즈가 섞인 고난이도 데이터**를 입력

❖ 예시

- 자율주행 모델이 '악천후 보행자 탐지'라는 고난도 과업을 수행해야 할 때
 - ✓ **1단계 (기초)**: 대낮, 맑은 날씨, 시야가 확보된 직선 도로의 보행자 데이터만 학습. (모델에게 '사람'의 표준 형태를 각인)
 - ✓ **2단계 (심화)**: 해질녘, 그림자가 길게 드리운 상황이나 약간의 가림(Occlusion)이 있는 데이터 추가.
 - ✓ **3단계 (전문)**: 야간, 폭우, 안개 상황 등 형태를 알아보기 힘든 극한 환경 데이터를 투입.

MT-4: 앙상블(Ensemble)

❖ 개념: 다중 지능의 전략적 결합과 메타 추론

- 서로 다른 알고리즘이나 구조를 가진 여러 모델의 추론 결과를 투표(**Bagging**), 가중 평균(**Boosting**), 별도의 메타 모델을 통한 추론(**Stacking**) 등의 방식으로 결합하여 최종 판단을 도출
- 데이터의 다양한 측면을 학습한 개별 모델들을 논리적으로 통합하여 추론 정확성을 높이기 위한 다중 모델 통합 전략

❖ 목적: 오차 상관관계 해소와 집단 지성형 정확도 달성


- **편향(Bias)과 분산(Variance)의 동시 제어**: 개별 모델이 특정 데이터 분포에 치우쳐 발생하는 편향 에러와 데이터의 작은 변동에 민감하게 반응하는 분산 에러를 보완하여 전체적인 추론 오차를 최소화함.
- **추론 안정성 강화**: 특정 데이터에 대해 한 모델이 비정상적인 추론을 하더라도, 다른 모델들의 결과를 통해 이를 보정함으로써 운영 단계에서의 급격한 정확도 하락을 방지함

앙상블(Ensemble)


Bagging

핵심 목표: 분산 감소
모델의 변덕(흔들림) 제어

1 학습 방식 (병렬 구조)



2 추론 및 결과 산출




정확도 강점: 안정성 확보

이상치나 노이즈가 섞인 데이터에서도
일관된 정확도 유지


Boosting

핵심 목표: 편향(Bias) 감소
모델의 근본적 오차(명칭함)를 해결

1 학습 방식 (순차 구조)



2 추론 및 결과 산출




정확도 강점: 정교함 확보

학습이 어려운 복잡한 패턴과
미세 오차까지 끝까지 정확성 달성 노력

Stacking

핵심 목표: 예측 정밀도 극대화
단일 알고리즘의 한계 극복

1 학습 방식 (계층 구조)



2 추론 및 결과 산출



정확도 강점: 사각지대 제거

서로 다른 시각을 가진 모델들이 결합하여
최상의 정확도 달성

MT-5: 모델 가중치 평균(Model Soups)

❖ 개념: 가중치 공간에서의 지능 통합

- **동일한 신경망 구조를 바탕으로** 하이퍼파라미터 (학습률, 데이터 증강 전략 등)만 다르게 설정하여 학습시킨 **여러 모델의 가중치(Weights) 값들을 직접 평균 내어 하나의 최종 모델을 생성**
- 추론 결과를 합치는 앙상블과 달리, 모델의 '뇌(파라미터)' 자체를 수학적으로 결합하여 단일 가중치 세트를 도출하는 전략임.

❖ 목적: 비용 효율적인 앙상블 효과

- **추론 효율성 극대화:** 앙상블은 모델 수만큼 연산량이 늘어나지만, **Model Soups는 단일 모델이므로 추론 속도와 메모리 점유율이 기존과 동일함**. 자원 제약이 심한 임베디드 환경에서 앙상블의 정확도를 누릴 수 있는 유일한 대안임.
- **개별 학습 편향 완화 및 일반화 안정성 향상** : 여러 모델의 가중치를 평균하여 개별 학습의 편향을 완화하고, 다양한 학습 조건에서 안정적으로 작동할 가능성이 높은 모델을 생성함.

앙상블 vs Model Soups

구분	앙상블 (Output Aggregation)	Model Soups (Weight Aggregation)
방식	결과값의 순차/병렬 통합: 여러 모델을 모두 구동하여 최종 추론값을 합성	가중치 공간의 수치 통합: 여러 모델의 파라미터(뇌)를 평균 내어 단일 모델 생성
지식 활용	각 모델이 독립적으로 존재하며, 추론 시점에 지능을 결합함	여러 하이퍼파라미터의 지식을 단일 가중치 세트 에 응축함
추론 비용	모델 수에 비례: 연산량 및 메모리 점유가 배수로 증가	단일 모델 수준 : 앙상블 효과를 누리면서 추가 비용 제로
수행 효율성	[낮음] 높은 추론 지연(Latency) 발생으로 실시간 제어에 부담	[매우 높음] 기존 단일 모델과 동일한 속도로 실시간성 완벽 보장
주요 이점	개별 모델의 특성을 유지하며 정밀도를 극한으로 향상	가성비 극대화 : 자원 제약 환경(Embedded)에서 앙상블 급 정확성 확보

Quiz

	문제	정답
1	사전 학습된 모델의 지식을 새로운 task에 이식하여 데이터 부족 상황에서도 안정적인 베이스라인을 확보하는 기법은?	
2	알고리즘이 특정 task에 최적화된 신경망 구조를 자동으로 탐색하는 기법은?	
3	쉬운 데이터나 개념부터 학습시키고 점차 어려운 사례로 난이도를 높이는 학습 방식은?	
4	여러 모델의 예측 결과를 결합하여 단일 모델보다 높은 정확도와 안정성을 얻는 기법은?	
5	여러 모델의 가중치를 평균하여 추가 추론 비용 없이 안정성을 높이는 기법은?	
6	전이 학습에서 사전학습된 Backbone은 동결하고 마지막 분류층 또는 탐지 Head만 새로 학습하는 방식은?	
7	전이 학습에서 모델의 모든 레이어 가중치를 새로운 도메인 데이터에 맞춰 업데이트하는 방식은?	
8	전이 학습에서 기존 가중치는 고정하고 소규모 추가 파라미터만 학습하는 방식은?	
9	앙상블에서 여러 모델을 독립적으로 병렬 학습한 뒤 평균 또는 다수결로 결과를 결합하는 방식은?	
10	앙상블에서 앞 모델의 오류를 뒤 모델이 순차적으로 보완하도록 학습하는 방식은?	
11	앙상블에서 여러 기초 모델의 예측 결과를 다시 메타 모델이 학습하여 최종 예측을 만드는 방식은?	

추론 서비스 설계

정확성을 위한 추론 서비스 설계 기법 요약

단계 세부 영역	핵심 설계 기술	
데이터 준비	IS-1 입력 데이터 표준화	입력 형식·단위·범위·품질을 검증하고 학습 시 기준에 맞게 변환
	IS-2 맥락 데이터 합성	시간·위치·환경·사용자 이력 등 보조 정보를 결합하여 입력 의미를 보완
출력 통제	IS-3 도메인 논리 기반 출력 보정	업무 규칙·물리 법칙·값의 범위 및 일관성 규칙으로 오류 출력을 보정·보류

❖ 개념: 모델에 맞춘 수치적·논리적 규격 동기화

- 운영 환경에서 입력되는 데이터를 모델이 학습할 때 사용한 것과 **동일한 형식·단위·범위·표현 체계**로 변환하는 전처리 설계 기법
- 학습-추론 간 입력 규격의 일관성을 확보하여, 데이터 표현 차이로 인한 **예측 오류와 성능 저하를 방지**

❖ 수치형 데이터 표현 표준화

단계	설명
단위 표준화	거리, 속도, 온도 등의 단위를 학습 시 사용한 단위로 변환
범위 표준화	최솟값-최댓값을 이용하여 값을 0~1, -1~1 등 일정 범위로 변환
정밀도 표준화	FP32, FP16, 정수형 등 모델과 실행 환경에 적합한 자료형으로 변환

입력 데이터 표준화

❖ 비정형 데이터 표현 표준화

- 이미지, 영상, 오디오 등 원천 데이터를 **모델이 학습 시 사용한** 입력 형식, 크기, 채널 구조, 값 범위, 품질 조건과 일치시키는 과정

단계	설명
형식 표준화	이미지 포맷·코덱·채널 수 등 입력의 기술적 형식을 모델 규격과 일치
공간·시간 표준화	이미지 크기, 영상 FPS, 오디오 샘플링률·길이 등을 학습 조건에 맞게 조정
표현 체계 표준화	RGB/BGR 순서, 좌표계, 모노/스테레오 등 데이터 해석 방식을 학습 환경과 일치시킴
값 범위 표준화	픽셀값, 음성 신호, 센서 신호의 수치 범위를 학습 시점의 분포와 동일하게 변환
품질 조건 표준화	해상도, 압축률, 신호 대 잡음비 등 최소 입력 품질 기준을 검사·보정

IS-2: 맥락(Contextual) 데이터 합성

❖ 개념: 의사결정을 위한 다각적 주변 정보의 동적 결합

- 현재 입력 데이터에 외부 환경 정보와 과거 이력을 결합하여, 모델이 입력이 발생한 상황까지 고려하도록 하는 설계 기법
- 센서·사용자 입력만으로 판단하지 않고 기상, 교통, 위치, 시간, 사용자 이력, 장비 상태 등의 데이터를 함께 활용하여 상황 인지 능력과 추론 정확성을 높임
- 결합된 데이터는 하나의 특징 벡터로 구성 (전제: 입력 가드레일은 현재 입력과 맥락 데이터를 함께 처리하도록 사전에 학습되거나 규칙이 설계되어 있어야 함)

기술	주요 내용
맥락 데이터 선정	예측에 유효한 시간, 위치, 날씨, 교통, 사용자 이력, 장비 상태 등의 정보 선정
실시간 데이터 조회	외부 API, 센서 스트림, 운영 DB 등에서 현재 상황과 관련된 데이터 수집
이력 데이터 조회	사용자 행동, 과거 예측 결과, 장비의 누적 가동 시간 등 과거 패턴 조회
시간·공간 정렬	동일하거나 허용 가능한 시간대·위치 범위의 데이터끼리 결합
특징 생성·인코딩	시간대, 날씨 상태, 최근 사용 빈도 등을 모델이 처리할 수 있는 특징으로 변환
데이터 결합	키 기반 조인, 시계열 조인, 특징 벡터 연결 또는 모델 내부 융합 적용
캐싱·사전 계산	자주 사용하는 맥락이나 변화가 느린 정보를 캐시 또는 특징 저장소에 보관하여 조회 시간 단축
폴백 설계	맥락 데이터를 얻지 못하면 기본값, 최근 유효값 또는 맥락 제외 모델로 전환

맥락(Contextual) 데이터 합성

❖ 주의: 데이터 정합성 유지와 시스템 응답성 확보

● 조회 지연(Lookup Latency)

- ✓ 외부 API나 대규모 데이터베이스(DB)에서 맥락 정보를 가져오는 시간이 추론 시간보다 길어질 경우, 전체 시스템의 실시간성이 붕괴됨.
- ✓ 이를 방지하기 위한 캐싱(Caching)이나 인메모리 DB 활용이 필수적임.

● 시간적 정합성(Temporal Join Issue)

- ✓ '현재의 센서 데이터'와 결합되는 '맥락 데이터'가 다른 시점의 것이라면 (예: 5분 전의 기상 정보), 모델은 왜곡된 상황 판단을 내리게 됨.
- ✓ 데이터 조인(Join) 시점의 동기화가 엄격히 관리되어야 함.

● 데이터 부재(Data Availability)

- ✓ 통신 장애 등으로 외부 맥락 정보를 가져오지 못할 경우를 대비한 폴백(Fallback) 전략(예: 기본값 사용 혹은 맥락 제외 추론 모드 전환)이 고려되어야 함.

❖ 개념: 도메인 논리를 활용한 출력값의 현실적 타당성 검증 및 수정

- 모델이 산출한 결과가 물리 법칙, 사회적 규칙, 시계열적 연속성, 사회적 규칙 등 '**도메인 논리**'에 부합하는지 검사하고, 범위를 벗어날 경우 최적의 상식적인 값으로 강제 조정
- 모델의 계산 과정에서 발생할 수 있는 미세한 수치적 비약이나 시계열 데이터의 불연속성(급격한 튀는 값)을 출구에서 즉시 바로잡음으로써, 최종 출력물이 실제 운영 환경의 제약 조건을 충족하게 함.

❖ 주의

● 도메인 지식의 유효성

- ✓ 도메인 논리의 변화를 반영하지 못할 경우, 오히려 모델의 정확한 판단을 오답으로 간주하여 시스템의 전체 정확도를 하락시킬 수 있음.

✓ 예,

대출 심사 모델이 새로운 정책과 최신 데이터를 반영하여 신청자를 **대출 가능**으로 판단했지만, 출력 보정 규칙이 과거의 소득·부채 기준을 그대로 사용하면 결과를 **대출 불가**로 변경

도메인 논리 기반 출력 보정

❖ 상황

- 제어 모델이 장애물을 피하기 위해 0.1초 후의 목표 위치를 현재 위치에서 20m 앞선 지점으로 예측함
- 그러나 이는 약 200m/s의 이동 속도를 요구하므로 차량의 현재 속도와 가속 성능을 고려할 때 물리적으로 실현할 수 없는 출력임

❖ 출력 보정 가드레일의 개입

- **물리 제약 검증**
현재 속도, 최대 가속도, 조향 한계 등을 기준으로 예측 위치가 차량의 물리적 도달 가능 범위에 있는지 확인
- **시간적 연속성 검증**
이전 프레임의 위치·속도·가속도 및 경로 변화와 비교하여 출력이 갑자기 튀거나 급격하게 변하는지 확인
- **안전성 검증**
보정된 경로가 장애물과의 최소 안전거리, 도로 경계 및 차량 안정성 조건을 만족하는지 확인
- **보정 조치**
비정상 출력을 그대로 사용하지 않고, 물리적으로 도달 가능한 범위 안에서 가장 안전하고 연속적인 목표 위치 또는 회피 경로로 보정하여 제어기에 전달

❖ 결과

- 순간적인 예측 오류로 인한 비현실적인 급가속·급조향 명령을 방지
- 차량의 물리적 한계와 안전 조건 안에서 연속적이고 부드러운 회피 기동을 수행


배포 · 운영 설계

정확성을 위한 배포 · 운영 설계 기법 요약

단계 세부 영역	핵심 설계 기술	
운영감시	DO-1 운영 성능 모니터링	운영 예측과 실제 결과를 비교하여 정확도와 오류 수준의 유지·저하를 감시
	DO-2 드리프트 기반 정확성 모니터링	입력·결과·개념의 변화를 탐지하여 정확성 저하 가능성을 조기에 경고
운영 조치	DO-3 상황 기반 추론 제어	운영 성능과 입력 상황을 감시하고, 정확도 저하가 감지되면 임계값·생성 파라미터·탐색 범위 등의 추론 설정을 조정한 후 결과를 재검증하는 운영 제어 기법
	DO-4 정확성 강화 재학습	운영 오류와 드리프트 원인을 데이터·레이블·특성·학습 목표에 반영하여 재학습
배포	DO-5 정확성 강화 모델로 교체	정확도 저하 시 해당 조건에서 성능이 검증된 전문·고정밀 모델로 전환하거나 롤백

❖ 개념

- 배포된 AI 시스템의 **실제 운영 데이터와 예측 결과를 지속적으로 수집·평가**하여, 모델의 기능 정확성이 목표 수준을 유지하는지 확인하는 운영 감시 기법
 - ✓ 운영 중 정확도, 정밀도, 재현율, 오류율 등의 성능을 추적
 - ✓ 전체 평균뿐 아니라 입력 조건, 사용자 집단, 시간대, 지역, 모델 버전별 성능을 구분하여 분석
 - ✓ 성능 저하가 발견되면 원인을 진단하고 재학습, 모델 교체 또는 추론 정책 조정 등의 운영 조치로 연결



운영 성능 모니터링

❖ 주의

- **정답 확보 가능성:** 실제 정답이 없으면 정확도나 F1과 같은 기능 성능을 직접 측정할 수 없음
- **정답 지연:** 대출 상환이나 질병 예후처럼 정답이 늦게 확인되면 현재 성능 저하의 탐지가 지연될 수 있음

❖ 개념: 학습 환경과 운영 환경의 변화 감지

- 학습·검증 데이터와 현재 운영 데이터의 **입력 분포**, **모델 출력** 및 **입력-정답 관계**가 달라지는지 지속적으로 감시
- 정답이 없거나 지연되는 동안 성능 저하 가능성을 조기에 탐지.

❖ 주요 드리프트 유형

유형	의미	예시
데이터 드리프트 $P(X)$	입력 특성의 분포가 변화	폭설로 저조도·가림이 심한 영상이 증가
타겟 드리프트 $P(Y)$	실제 결과 클래스나 목표값의 분포가 변화	겨울철 차량 배터리 고장 비율 증가
개념 드리프트 $P(Y X)$	같은 입력이 의미하는 결과가 변화	경기 침체로 동일한 고객 조건에서도 부도 확률 증가

드리프트 기반 정확성 모니터링

❖ 운영 흐름

1. 변화 감지: 입력 분포·예측 비율·신뢰도·불확실성 감시
2. 영향 확인: 지속 기간, 영향 구간, 데이터 품질 및 업무 영향 분석
3. 성능 검증: 표본 정답 또는 지연 도착한 정답으로 정확도 확인
4. 대응 결정: 관찰 유지, 데이터 수정, 모델 보정·교체 또는 재학습

❖ 주의: 단순 변동과 실제 결함의 구분

- 드리프트가 발생해도 모델의 정확도가 유지될 수 있으며, 드리프트가 감지되지 않아도 개념 변화로 성능이 저하될 수 있음

DO-3 상황 기반 추론제어

❖ 개념

- 운영 성능 모니터링과 드리프트 감시 결과, 특정 입력 조건에서 정확도 저하가 확인되거나 예상되면 **판단 임계값, 생성 파라미터, 탐색 범위** 등의 추론 설정을 동적으로 조정
- 조정된 설정으로 재추론한 결과를 다시 평가하고, 정확성이 회복되지 않으면 다중 추론, 대체 모델, 인간 검토 또는 재학습으로 연계

❖ 설계 기법

추론 설정 조정 대상	구체적인 조정
분류·탐지 임계값	오류 유형별 비용을 고려하여 임계값을 조정하고 오탐 또는 미탐을 감소
Temperature·Top-k·Top-p	사실성과 일관성이 중요한 상황에서는 검증된 범위에서 생성의 임의성을 제한
후보 수·Beam width·탐색 깊이	복잡하거나 저신뢰 입력은 탐색 범위를 확대하고 후보 결과를 비교·재순위화




❖ 주의

- 임계값 조정은 오탐과 미탐 사이의 상충을 발생시키고, 반복 추론·대형 모델 전환은 지연시간과 비용을 증가시킬 수 있음

❖ 개념

- 운영 중 확인된 반복 오류, 특정 조건·클래스의 성능 저하 또는 데이터·개념 드리프트의 원인을 학습 데이터, 특성, 레이블, 학습 목표에 반영하여 후보 모델을 재학습
- 후보 모델의 전체 성능과 오류 유형별 성능을 독립적인 검증 데이터로 평가하고, 기존 모델보다 정확성이 개선되었을 때 단계적으로 배포
- 단순히 최신 운영 데이터를 추가하는 것이 아니라, 성능 저하 원인에 대응하도록 학습 구성 자체를 수정하는 운영 조치



정확성 회복 재학습

❖ 예시

- 야간 영상에서 보행자 미탐이 반복되면 다음 원인을 분석
 - 야간·저조도 데이터 부족, 특정 거리 구간의 표본 부족, 레이블 누락, 전처리 오류
- 원인에 따라 다음 조치를 적용하여 후보 모델 재학습
 - 야간 데이터 보강·재표본화, 레이블 정제, 특징·전처리 수정을 반영한 손실함수 적용
- 별도 검증 데이터에서 야간 보행자 Recall·F1과 전체 성능을 함께 검증하고, 기준을 충족하면 카나리 방식으로 단계적 배포

❖ 주의

- 전체 정확도뿐 아니라 **문제가 발생한 조건·클래스의 성능과 기존 주요 조건의 성능**을 함께 검증해야 함
- 배포 후 성능 악화에 대비하여 카나리 배포, 이전 모델 롤백 및 재학습 이력 관리를 적용해야 함

DO-5: 정확성 강화 모델 전환

❖ 개념

- 운영 성능 모니터링에서 현재 모델의 정확도가 허용 기준 이하로 저하되거나 특정 입력 조건에서 반복적인 오류가 확인되면, 해당 조건에서 더 높은 정확성이 검증된 대체 모델로 전환
- 일시적인 설정 조정이나 재추론으로 정확도가 회복되지 않을 때 적용하며, 필요하면 이전 안정 모델로 롤백하거나 인간 검토로 전환.

❖ 예시

- 일반 영상에서는 경량 모델을 사용하지만, 야간·악천후 영상에서 보행자 미탐률이 기준을 초과하면 해당 환경에 특화된 고정밀 모델로 전환

❖ 주의

- 전체 정확도만 비교하지 말고 클래스·환경·입력 품질별로 대체 모델의 성능을 검증해야 함.
- 정확도 향상과 함께 지연시간, 연산 비용 및 시스템 호환성도 확인해야 함

❖ 계층적 모델 관리 체계:

- **챔피언 모델 (Standard):** 평상시 운영되는 기본 모델로, 전체 입력에서 목표 정확도와 처리 성능을 충족.
- **전문·고정밀 모델(Specialist):** 특정 환경·클래스·고난도 입력에서 더 높은 정확도를 갖도록 검증된 대체 모델
- **롤백 모델(Rollback):** 신규 모델의 성능 저하나 장애 발생 시 복귀하는 이전의 안정 모델

구조적 설계 패턴


기능 정확성 설계 패턴 개요

구조적 패턴	핵심 목적
입력 정규화·맥락 보강 파이프라인 패턴	입력 의미와 변환의 일관성 확보
다중 모델 결합 패턴	복수 모델의 상호 보완으로 오답 감소
전문 모델 라우팅 패턴	입력 조건에 적합한 모델 선택
정확성 피드백 제어 패턴	성능 감시 결과에 따라 추론을 동적으로 조정

입력 정규화·맥락 보강 파이프라인 패턴

❖ 개념

원시 입력을 곧바로 모델에 전달하지 않고, 입력 검증·표준화·특징 변환·맥락 보강을 독립된 계층에서 수행하여 학습 시 정의된 입력 의미를 유지하는 구조



❖ 장점

- 학습과 운영 사이의 입력 처리 불일치를 방지
- 모델이 필요한 업무 의미와 맥락을 일관되게 제공
- 전처리 오류의 위치와 원인을 분리하여 진단 가능


❖ 주의점

- 학습과 운영에서 동일한 변환 로직과 버전을 사용해야 함
- 잘못된 맥락 정보가 추가되면 오히려 정확도가 저하될 수 있음

다중 모델 결합 패턴

❖ 기본 개념

서로 다른 모델이나 학습 결과를 병렬로 실행하고, 투표·평균·가중 결합·재순위화를 통해 단일 모델의 오답과 편향을 보완하는 구조



❖ 장점

- 단일 모델의 우발적인 오답을 줄일 수 있음
- 모델마다 잘 처리하는 입력 영역을 상호 보완
- 결과 간 불일치를 불확실성 신호로 활용 가능


❖ 주의점

- 유사한 모델만 결합하면 동일한 오류를 반복할 수 있음
- 결합 규칙과 모델별 가중치를 검증 데이터로 결정해야 함
- 연산 비용과 응답 지연이 증가할 수 있음

전문 모델 라우팅 패턴

❖ 개념

입력의 유형·환경·난이도·신뢰도를 분석하여 전체 입력을 하나의 모델로 처리하지 않고, 해당 조건에서 정확도가 검증된 모델로 전달하는 구조



❖ 장점

- 특정 조건의 정확도를 전체 모델 재구축 없이 강화
- 고비용 모델을 필요한 입력에만 적용 가능
- 모델 전환과 롤백을 체계적으로 관리


❖ 주의점

- 라우터가 입력 조건을 잘못 판단하면 부적합한 모델이 선택됨
- 전문 모델의 적용 범위와 전환 조건을 명확히 정의해야 함

정확성 피드백 제어 패턴

❖ 개념

운영 환경의 입력 변화와 실제 성능을 지속적으로 감시하고,
그 결과에 따라 추론 설정·실행 방식·사용 모델을 조정하는 폐루프 구조



❖ 장점

- 배포 후 발생하는 정확성 저하를 지속적으로 발견·완화
- 감시와 운영 조치가 자동 또는 반자동으로 연결됨

❖ 주의점

- 자동 조정은 사전에 검증된 정책과 허용 범위 내에서만 수행해야 함
- 빈번한 설정 전환을 방지하기 위한 최소 유지시간과 복귀 조건이 필요함

Q & A
