

강건성(Robustness) 설계

목차

❖ 강건성 설계 개요

❖ 활동 기반 설계

- 데이터 설계
- 모델 학습 설계
- 추론 서비스 설계
- 배포 · 운영 설계

❖ 구조적 설계 패턴

강건성 설계 개요

- ❖ 예상되는 입력 변화·교란·장애에도 핵심 기능과 허용 가능한 성능을 유지하고, 한계를 넘으면 안전하게 전환·복구하도록 설계

01

데이터 설계

- 가혹 상황 증강
- 가혹 상황 샘플링

02

모델 학습 설계

- 교란·환경 변화 기반 강건 학습
- 불안정한 특성 의존성 분석 및 완화
- 앙상블 기반 강건 예측

03

추론서비스 설계

- 원시 데이터 무결성 보정
- 공격·이상·불충분 데이터 입력 차단
- 확신도기반·논리적이상 출력 차단

03

배포·운영 설계

- 강건성 지표 영향 분석
- 운영제어 파라미터 조정
- 자원 제약 대응 추론 플랫폼 운영 제어

구조적 설계 패턴

다층 방어 · 다양성 기반 중복 추론 · 감시-판단-적응 피드백 · 단계적 성능 저하

데이터 설계

강건성을 위한 데이터 설계 기법

기법	설명
DD-1 가혹 상황 증강	정상 데이터를 변형하거나 시뮬레이션을 통해 악천후, 조명 변화, 센서 결함, 데이터 손상, adversarial perturbation, 희귀 상황 등을 새로 생성 하여, 모델이 가혹 입력 조건에 적응하도록 학습 분포를 확장하는 기법
DD-2 가혹 상황 샘플링	실제 로그, 오류 사례, 검증 실패 사례, 시뮬레이션 결과, 생성 후보 데이터 중에서 corner case, under-represented/biased data, hard example, high-risk case를 전략적으로 선별·가중 배치 하여, 모델의 취약 분포 대응력을 높이는 기법

DD-1: 가혹 상황 증강

❖ 개념

- 예상 가능한 비정상·극한 조건을 반영한 학습 데이터를 생성하여 모델의 상황 변화 대응력을 강화
- 증강 데이터는 원본의 정답 의미와 물리적 타당성을 유지하도록 설계

❖ 설계 기법

- 맥락·환경 변화 증강(Context and Environment Augmentation)
 - ✓ 예측 대상은 유지하면서 배경·날씨·조명·계절·촬영 조건 등 비본질적 맥락을 다양하게 변경.
 - ✓ 예: 맑은 날뿐 아니라 비·눈·안개·야간 환경에도 동일한 차량을 합성하여 학습.
- 적대적 예제 기반 증강(Adversarial Example Augmentation)
 - ✓ 원본 데이터에 모델의 오판을 유도하는 제한된 교란을 생성하고 이를 학습 데이터에 포함
 - ✓ 예: 표지판 이미지에 사람이 거의 인지하지 못하는 미세 교란을 추가하고 원래 정답으로 학습
- 오염·결손 상황 증강(Corruption and Missing-data Augmentation)
 - ✓ 노이즈·흐림·가림·압축 손상·센서 오류·채널 결손 등 운영 중 발생 가능한 데이터 품질 저하를 모사
 - ✓ 예: 카메라 영상의 일부를 가리거나 특정 센서 채널을 제거한 데이터를 함께 학습

DD-1: 가혹 상황 증강 (계속)

❖ 주의:

● 데이터 정확성 유지

- ✓ 증강 데이터가 물리 법칙과 도메인 규칙을 위반하거나 정답의 의미를 바꾸지 않도록 검증해야 함
- ✓ 부적절한 증강은 잘못된 레이블과 비현실적 특징을 학습시킬 수 있으므로, 필요하면 재레이블링 하거나 학습에서 제외함

● 도메인별 상황 다양성 확보

- ✓ 노이즈·흐림 같은 일반적인 변형만으로는 실제 산업 현장의 다양한 가혹 상황을 충분히 대표하기 어려움
- ✓ 도메인의 사고 사례, 운영 로그, 전문가 지식 등을 바탕으로 도메인별 OOD·위험·희귀 상황을 발굴해야 함

● 데이터 균형 유지

- ✓ 가혹 상황 데이터를 지나치게 많이 사용하면 정상 상황의 성능과 확률 신뢰도 보정이 나빠지고 오탐이 증가할 수 있음
- ✓ 따라서, 정상/비정상 데이터 비율, 가혹성 수준, 희귀 사례의 가중치, 난이도 높은 사례의 비중을 통제해야 함

DD-2: 가혹 상황 샘플링

❖ 개념: 가혹 상황 정밀 타격 훈련

- 실제 운영 로그, 사고 사례, 오류 사례, 시뮬레이션 결과, 검증 데이터, 생성 후보 데이터 중에서 **corner case**, **under-represented/biased data**, **hard example**, **high-risk case** 샘플을 전략적으로 선별하여 학습 데이터에 반영하는 기법
- 모델의 성능이 **임계점에서 무너지는 지점의 데이터를 집중적으로 학습**

구분	설명	예
1-1) 희귀 사례	운영 환경에서 드물게 발생하는 상황	야간 보행자, 눈길 이륜차, 특이한 객체 조합, 드문 도로 공사 배치
1-2) 대표성 부족 · 편향 데이터	중요하지만 특정 조건이나 집단의 데이터가 부족하거나 편중된 경우	특정 날씨·지역·연령·성별·차종·조명 조건이 과소 표집된 데이터
2) 어려운 사례	현재 모델이 틀리거나 확신하지 못하는 데이터	낮은 confidence 샘플, 결정 경계 근처 샘플, 혼동 클래스
3) 고위험 사례	오판하면 피해가 큰 상황	어린이 보행자, 중증 의심 의료 영상, 응급 상황

모델 학습 설계

모델 학습 설계 기술 요약

❖ 비정상 입력이나 맥락 변화에서도 올바른 예측을 유지하는 직접적인 모델 설계 기법

설계 기술	설명
MT-1 교란·환경 변화 기반 강건 학습	예상되는 비정상 입력을 직접 학습하여 견디게 함
MT-2 불안정한 특성 의존성 분석 및 완화	배경이나 특정 센서 등 잘못된 판단 근거에 대한 의존을 줄임
MT-3 앙상블 기반 강건 예측	여러 모델의 판단을 결합하여 개별 모델의 오류를 상쇄함

MT-1: 교란·환경 변화 기반 강건 학습

❖ 개념

- 운영 중 발생할 수 있는 **노이즈**, **데이터 오염**, **센서 결손**, **적대적 공격** 및 **환경 변화**가 반영된 입력을 모델이 학습하도록 설계하는 기법

❖ 구체적인 방법

- **데이터 오염 생성**: 정상 입력에 노이즈·블러·가림·압축 손상을 강도별로 적용
- **센서 이상 모사**: 센서값에 오차를 추가하거나 일부 값·센서 채널을 제거
- **환경·맥락 변화 반영**: 날씨·조명·배경·지역·촬영 장비를 변경한 데이터 수집 또는 생성
- **적대적 예제 생성**: FGSM·PGD 등으로 모델의 오분류를 유도하는 입력을 생성
- **정상-교란 데이터 혼합 학습**: 교란 유형별 혼합 비율과 강도를 설정하여 정상 데이터와 함께 학습
- **강건 학습 손실 적용**: 정상 입력과 교란 입력이 모두 정답을 예측하도록 **손실함수**를 구성

L_{normal} : 정상 데이터의 예측손실

$$L_{total} = (1-\alpha)L_{normal} + \alpha L_{perturbed}$$

$L_{perturbed}$: 교란 데이터의 예측손실

❖ 예시

- 자율주행 객체 인식 모델에 맑은 날 영상뿐 아니라 **비·눈·안개·야간 영상**과 **노이즈가 포함된 영상**을 함께 학습

❖ 주의

- 예상하지 못한 교란까지 모두 견딘다고 보장할 수는 없음

MT-2: 불안정한 특성 의존성 분석 및 완화

❖ 개념


- 입력 데이터에서 객체의 **본질적인 특징**은 유지하되 **배경, 조명, 촬영 각도** 등 판단에 혼선을 주는 **환경적 변수의 변화**에는 모델의 내부 반응이 달라지지 않도록 학습

$$L_{total} = L_{task} + \lambda L_{consistency}$$

L_{task} : 정답을 맞추기 위한 일반적인 분류 손실

$L_{consistency}$: 원본과 변경 입력의 예측 차이에 대한 페널티

❖ 구체적인 방법



❖ 예시

- 소를 인식하는 모델에서 초원 배경을 도로나 실내로 변경했을 때 예측이 달라지는지 확인
- 소 이미지를 다양한 배경에 합성하여 학습하고, 배경이 달라도 동일하게 '소'로 예측하도록 일관성 손실 적용

❖ 주의

- 특성 분석 결과가 실제 인과관계를 의미한다고 단정해서는 안 됨
✓ 예, '배경' 특성이 소를 판단하는 중요 특성이라 분석 되었더라도, '배경'과 '소 판정'에 인과 관계를 있다고 보기 힘들.

MT-3: 앙상블 기반의 강건 예측

❖ 개념

- 구조, 학습 데이터 또는 사용하는 특성이 서로 다른 여러 모델의 출력을 **다수결·평균·가중 결합**하여 최종 결과를 결정하는 기법


❖ 구체적인 설계

- 개별 모델 구성 및 다양성 확보
 - ✓ **구조 다양화**: CNN, ViT 등 서로 다른 모델 구조로 구성
 - ✓ **학습 방법 다양화**: 일반 학습 모델, 노이즈 강건 학습 모델, 적대적 학습 모델을 함께 구성
 - ✓ **특성 다양화**: 각 모델이 서로 다른 특성 또는 센서 조합을 사용하도록 구성
- 모델 출력 결합
 - ✓ **다수결**: 각 모델이 선택한 클래스를 투표하여 가장 많은 표를 받은 클래스로 결정
 - ✓ **확률 평균**: 모델별 클래스 예측 확률을 평균하고 가장 높은 클래스로 결정
- 불일치에 대한 안전 조치
 - ✓ 모델 간 투표가 분산되거나 예측 확률 차이가 큰지 측정
 - 최종 확률이 임계값보다 낮으면 판단 보류
 - 모델 간 불일치가 임계값을 넘으면 재입력·재추론 수행
 - 고위험 판단은 안전 모드 또는 전문가 검토로 전환

MD-3: 앙상블 기반의 강건 예측

❖ 예시

- 자율주행차 - 보행자 인식



❖ 주의

- 모든 모델이 같은 특성에 의존하면 동시에 오판할 수 있음
- 다수결의 일치가 반드시 정답을 보장하는 것은 아님

추론 서비스 설계

강건성을 위한 추론 서비스 설계 기법 요약


단계 세부 영역	핵심 설계 기술	
데이터 준비	IS-1 원시 데이터 무결성 보정	실시간 유입되는 데이터의 물리적·구조적 이상·결함을 탐지하고 필터링·보간·정규화·재동기화 등으로 보정
입력 통제	IS-2 적대적 공격 차단	입력 교란 크기, 비정상 패턴, 공격 탐지 모델 등을 이용하여 FGSM·PGD·패치 공격과 같은 의도적 공격 입력을 탐지하고 차단 또는 안전 경로로 전환
	IS-3 심각한 손상·오염 데이터 차단	노이즈·블러·가림·압축 손상·센서 오류가 허용 기준을 초과하면 차단
	IS-4 정보 불충분 입력 차단·보류	필수 특성 누락, 낮은 해상도, 짧은 관측 시간 등으로 신뢰할 만한 추론이 어려우면 판단을 보류하고 추가 정보 수집 또는 재측정을 요청
	IS-5 논리적 이상 데이터 차단	물리법칙, 데이터 관계, 업무규칙에 맞지 않는 입력 조합을 검증하여 오류 데이터가 모델에 전달되는 것을 방지
출력 통제	IS-6 확신도 기반 출력 차단	최대 예측 확률, 불확실성, 앙상블 불일치 등이 기준을 충족하지 못하면 출력을 보류하고 재추론·대체 모델·전문가 검토로 전환
	IS-7 논리적 이상 출력 차단	모델 출력이 물리적 제약, 업무규칙, 시간적 일관성 또는 다른 출력과의 관계를 위반하면 차단·재산정·안전 출력으로 전환

❖ 개념: 물리적 파손 데이터의 가용성 복원 단계

- 모델에 입력되기 전, 데이터 자체의 형식적 무결성이나 신호 품질이 훼손된 상태를 탐지하고, 복구 가능한 범위 내에서 추론 가능한 형태로 보정.

무결성 결함 유형	설명	대표 보정
Schema / Type / Format 결함	데이터가 모델 입력 규격을 만족하는가?	validation, normalization, format repair, type casting
Range / Outlier 결함	값이 물리적·구조적 허용 범위 안에 있는가?	clipping, filtering, outlier correction
Missing / Null 결함	필요한 값이 빠지지 않았는가?	imputation, interpolation, forward/backward fill
Noise / Blur / Artifact 결함	특징 추출이 가능할 정도의 신호 품질인가?	denoising, deblurring, restoration, filtering
Occlusion / Saturation 결함	핵심 정보가 가려지거나 포화되지 않았는가?	masking, sensor fusion, exposure correction

입력 차단 설계 기법



핵심 역할

위험하거나 부적격한 입력을 모델 추론 전에 걸러내어 오판과 안전 사고 가능성을 줄임.

IS-2: 적대적 공격 차단

❖ 개념: 의도적 입력 변조 의심 신호의 탐지 및 격리

- 모델의 예측을 의도적으로 왜곡하기 위해 생성된 **adversarial perturbation, adversarial patch, spoofing 신호, 비정상적 패턴 삽입** 등 공격 의심 입력을 탐지하고 차단

❖ 설계 기법

공격 시그니처 탐지	알려진 적대적 패치, 비정상 픽셀, 스푸핑 신호, 악성 명령 패턴과 입력을 비교
통계적 이상·OOD 탐지	입력값과 특징 표현을 정상 데이터 분포와 비교하여 이상 점수 또는 OOD 점수 산출
다중 입력원 교차검증	카메라·LiDAR·Radar 등 서로 다른 센서의 입력을 비교하여 조작·위조 가능성 판정

❖ 주의: 탐지 지연 시간과 적응형 공격의 위협

- **실시간 연산 오버헤드:** 탐지 로직이 복잡하면 지연 시간(Latency)이 늘어나 자율주행 등 실시간 시스템의 가용성이 떨어질 수 있음.
- **적응형 공격 리스크:** 우회 공격에 대응하려면 고정된 규칙 대신 지속적인 위협 모델 업데이트가 필수적임.
- **오탐(False Positive) 리스크:** 정상적인 환경 노이즈를 공격으로 잘못 판단하면 서비스 연속성이 저하될 수 있음.

❖ 개념: 복구 불가능한 물리적 손상 입력의 차단

- 원시 데이터 무결성 보정 단계에서 보간, 필터링, 정규화, 재동기화 등의 복구를 시도했음에도 불구하고, 여전히 **최소한의 신호 품질이나 정보량을 확보하지 못한 입력을 모델 추론 전에 차단**

❖ 설계 기법

최소 품질 임계값 적용	결측률 상한, 신호대잡음비(SNR) 하한, 해상도·샘플 수·유효 센서 비율 등 추론에 필요한 최소 기준을 설정하고 미달 입력 차단
필수 정보량 검사	필수 필드·센서 채널·영상 영역·시계열 길이 등 모델이 판단하는 데 필요한 정보가 충분히 남아 있는지 확인

❖ 주의: 가용성(Availability)과 안전성(Safety)의 트레이드오프

- **거부 오류(False Rejection)** : 차단 기준이 너무 엄격하면 일시적 환경 변화까지 고장으로 판단해 시스템 가동률이 저하됨.
- **오판 초래(False Acceptance)** : 차단 기준이 너무 느슨하면 오염 데이터가 유입되어 치명적인 오판을 일으키므로 정교한 임계치 설계가 필요함.

❖ 개념: 판단 근거가 부족한 입력의 추론 보류

- 모델이 신뢰할 만한 판단을 내리기에 필요한 **핵심 피처나 맥락 정보가 충분하지 않은 경우** 추론을 차단하거나 보류

❖ 설계 기법

필수 피처·필드 완전성 검사	판단에 반드시 필요한 항목의 존재 여부와 결측 상태를 검사하고, 하나라도 누락되면 추론 입력을 차단
맥락 정보 충족 여부 검사	단일 값뿐 아니라 판단에 필요한 시간·위치·대상·조건·이력 등 맥락 정보가 함께 제공되었는지 확인

❖ 주의

- **판정 기준의 정교한 설계:** 입력의 형식적 존재 여부뿐 아니라 모델의 지식 범위와 업무 판단에 필요한 정보의 품질·맥락을 고려하여 차단·보류 기준을 설정.
- **차단 데이터의 개선 활용:** 차단·보류 사례를 원인별로 분석하고, 개인정보 제거와 전문가 검토를 거쳐 입력 구조 개선 및 오프라인 재학습·평가에 활용

IS-5: 논리적 이상 데이터 차단 (Logically Invalid Data Blocking)

❖ 개념: 피처 간 물리적·시간적·도메인 규칙 위반의 차단

- 입력 데이터의 형식, 신호 품질, 피처 추출 결과는 정상처럼 보이지만, 추출된 피처들 사이의 관계가 물리 법칙, 시간적 연속성, 도메인 규칙을 위반하는 경우 이를 탐지하고 추론을 거부

❖ 설계 기법

물리 법칙·가능 범위 검증	개별 값은 정상 범위에 있더라도 피처 조합이 속도·거리·에너지 등 물리 법칙을 위반하는지 확인 예: 이동 거리와 측정 시간으로 계산한 속도가 차량의 물리적 한계를 초과하면 차단
시간적 순서·연속성 검사	타임스탬프 순서, 상태 변화의 선후관계, 변화량과 변화율이 허용 조건을 만족하는지 검증 예: 대출 승인 전에 실행 기록이 존재
도메인 규칙 검사	개별 피처는 정상 범위에 있어도, 피처들 사이의 조합이 도메인 지식과 모순되는지 검증 예: 차량 속도계 = 100km/h, RPM = 0

❖ 주의:

- **유연한 대응 저해(False Rejection):** 규칙이 너무 경직되면 비상 제동이나 급격한 차선 변경 등 정상적인 예외 상황까지 오류로 판정할 수 있음.
- **규칙 설계의 복잡도:** 현실의 모든 예외를 규칙화하는 것은 불가능하므로, 치명적 사고와 관련된 핵심 물리 법칙 위주로 우선순위를 설정해야 함

입력 가드레일 차단 유형

출력	의미	심각도 / 개입 수준
PASS	입력이 해당 가드레일을 통과하여 다음 필터 또는 모델 추론 단계로 전달됨	정상
WARN	추론은 허용하되 입력 품질 저하, 공격 의심, 근거 부족, 논리 이상 가능성 등의 risk metadata를 함께 전달함	경미한 위험 / 감시 필요
BLOCK	해당 입력 데이터가 위험하거나 부적격하다고 판단되어 그 입력에 대한 모델 추론을 금지함	입력 단위 차단
FALLBACK	기본 모델 추론 경로를 신뢰하기 어렵거나 시스템 위험이 커서 대체 모델, 규칙 기반 처리, human review, 안전 모드 전환 등 운용 조치로 전환함	시스템/운용 수준 대응

IS-6: 확신도 기반 출력 차단

❖ 개념: 추론 결과의 수치적 신뢰도 검증 및 선제적 폐기

- 모델이 산출한 개별 **추론 값과 함께 확신도를 실시간으로 측정**하여, 이 수치가 사전에 정의된 **안전 임계치에 미달할 경우** 해당 결과를 최종 시스템 출력으로 전달하지 않음
- Task별 확신도 예

Task 유형	확신도 / 불확실성 지표 예
분류	softmax probability, logit margin, entropy, calibrated confidence
객체 탐지	detection confidence, class score, objectness score, box uncertainty
회귀	prediction interval, variance, uncertainty estimate
시계열 예측	forecast interval, residual uncertainty, ensemble variance
생성형 AI	token probability, sequence log probability, self-consistency score, verifier score

❖ 주의: 가용성 저하와 '잘못된 확신'의 위험

- **시스템 가용성 위축**: 임계치가 너무 높으면 작은 노이즈에도 답변을 거부해 시스템이 멈추는 '보수적 마비'가 발생할 수 있음
- **과대 확신(Overconfidence)의 한계**: 모델은 틀린 답에도 높은 확신도를 부여할 수 있어, 확신도만으로 차단하면 오답이 통과할 수 있음. 따라서 모델의 확신도가 실제 정답 가능성과 일치하도록 사전에 교정해야 함

IS-7: 논리적 이상 출력 차단

❖ 개념: 추론 결과의 '물리적·시공간적 타당성' 최종 검증 및 차단

- 모델이 산출한 최종 추론 결과가 물리 법칙, 시공간적 연속성, 혹은 도메인 규칙을 위반하는지 검증하여 차단
- 도출된 결론이 현실 세계의 논리적 개연성을 결여했을 경우 이를 '지능적 환각'으로 규정하고 제어 명령 집행을 거부함.

❖ 설계 기법

물리적 실현 가능성 검사	제어 명령이 장치의 속도·거리·각도·출력 한계와 물리 법칙을 위반하는지 검증 예: 로봇이 1초 안에 20m 이동하라는 명령을 생성하면 실행을 거부
시공간적 연속성 검사	이전 출력이나 현재 상태와 비교하여 위치·속도·시간·상태가 비정상적으로 급변하는지 확인 예: 직전 프레임과 연결되지 않는 위치로 차량이 갑자기 이동한 것으로 판단하면 출력을 보류
도메인·업무 규칙 검사	모델의 결정이 법률, 업무 절차, 상품 정책 등의 명시적 규칙을 위반하는지 검증 예: 필수 서류가 누락된 신청을 자동 승인한 경우

❖ 주의: 제어 주기 (Latency) 최적화 및 규칙의 유연성 확보

- **실시간성 확보를 위한 경량화:** 검증 로직이 복잡하면 실시간 대응력이 떨어지므로, 핵심 물리 법칙 위주로 엔진을 경량화해야 함.
- **규칙의 경직성 경계:** 검사가 너무 엄격하면 위급상황 시 예외적인 안전 조치를 방해할 수 있음
✓ 예, 평상시 규칙: "차량은 차선을 벗어나거나 중앙선을 침범해서는 안 됨"

입력/출력 가드레일

논리적 이상 데이터 차단 vs 논리적 이상 출력 차단

구분	입력 단계 논리 검증	출력 단계 논리 검증
기법 명칭	논리적 이상 데이터 차단	논리적 이상 출력 차단
핵심 관점	"내가 보고 있는 이 세상(입력)이 가능한가?"	"모델이 내린 이 결론(출력)이 물리적/사회적으로 타당한가?"
검증 대상	추출된 피처(Feature)들 간의 정합성	모델의 추론 결과(Result) 및 제어 명령
차단 목적	센서 오류, 환경 오염 등으로 인한 '이상 상황 데이터'가 모델로 유입되는 것을 방지	데이터는 정상이나 모델의 지능적 한계로 발생한 '비논리적 환각(오판)'이 실행되는 것을 방지
데이터 상태	Logically Invalid Data (데이터 형상은 정상이나 관계가 모순됨)	Logically Invalid Output (수치적 확신도는 높으나 결론이 비상식적임)
비유	"눈앞에 사람이 순간이동을 한다면, 내 눈(센서)이 이상하다고 판단하여 눈을 감음"	"앞차와의 거리가 1m인데 100km로 가속하라는 명령이 나오면, 명령을 거부함"

배포 · 운영 설계

강건성을 위한 배포 · 운영 설계 기법 요약

단계 세부 영역	핵심 설계 기술	
운영 감시	DO-1 운영 드리프트에 따른 강건성 지표 영향 분석	입력 분포, 레이블 비율, 입력-정답 관계, 센서·환경 및 데이터 품질의 변화를 탐지하고, 변화 전후와 조건별 강건성 지표를 비교하여 모델의 성능과 예측 안정성에 미치는 영향을 분석
	DO-2 추론 플랫폼 환경 변화 기반 강건성 영향 분석	추론 플랫폼(소프트웨어, 하드웨어)의 환경 변화가 예측 결과와 안정성에 미치는 영향을 분석
운영 조치	DO-3 강건성 지향 운영제어 파라미터 조정	운영 중 강건성 저하가 확인되면 승인된 범위에서 입력 품질 기준, 결정 임계값, 출력 일관성 기준, 모델 라우팅 및 장애 대응 파라미터를 조정하여 서비스의 안정성을 유지
	DO-4 자원 제약 대응 추론 플랫폼 운영 제어	자원 부족이나 요청 폭주 시 사전에 검증된 경량 모델, 처리 기한 및 우선순위 정책으로 전환하여 핵심 기능과 허용 가능한 추론 품질을 유지

❖ 개념

- 입력 분포, 정답 분포, 센서·환경 및 데이터 품질의 변화를 탐지하고, 변화 전후 강건성 지표를 비교하여 모델의 성능과 예측 안정성에 미치는 영향을 분석

❖ 설계기법

설계 영역	구체적인 방법
데이터 드리프트 탐지	PSI, KS 검정, Wasserstein distance 등을 이용하여 입력 분포 ($P(X)$) 변화 측정
타겟 드리프트 탐지	운영 정답이 확보되면 정답 비율 ($P(Y)$)의 변화 비교
컨셉 드리프트 탐지	입력-정답 관계 ($P(Y X)$)가 시간에 따라 변하는지 분석
환경·센서 변화 탐지	날씨·조명·지역·장비 버전·센서 보정값·결손률·노이즈 수준 변화 감시
강건성 영향 평가	변화 전후의 오염 조건 정확도, 최악 조건 성능, 예측 변동률, 불일치율 등을 비교
영향 관계 분석	드리프트 크기가 증가할수록 강건성 지표가 얼마나 저하되는지 조건별·기간별 분석

❖ 주의

- 드리프트와 강건성 저하의 상관관계를 인과관계로 단정하지 않으며, 사후 정답의 지연·표본 부족·조건별 성능 차이·시스템 변경 등 교란 요인을 고려하여 충분한 기간과 다수의 지표로 판단해야 한다.

DO-2: 추론 실행 인프라 영향 분석

❖ 개념

- 모델 서빙 엔진·서빙 프레임워크·런타임·라이브러리·OS 등 추론 실행 인프라의 버전 및 설정 변경이 모델의 출력 일관성, 조건별 예측 성능 및 추론 안정성에 미치는 영향을 분석

❖ 설계기법

설계 영역	구체적인 설계 방법
실행 환경 기준선 관리	검증된 서빙 엔진·프레임워크·OS·드라이버·하드웨어·라이브러리 버전과 추론 설정을 기준선으로 등록
추론 실행 인프라 구성 변경 감시	버전, 설정, 컨테이너 이미지, 양자화·정밀도, 배치 크기, 병렬화 방식 등의 추론 실행 인프라 구성 변경을 자동 탐지하고 변경 시점과 내용을 기록
강건성 영향 분석	변경 전후 환경에 동일한 대표·경계·OOD 입력을 적용하여 예측 변동률, 조건별 정확도, 최악 조건 성능, 추론 실패율 및 대체 처리 성공률을 비교

❖ 주의

- 인프라 변경의 영향만 비교할 수 있도록 모델 버전, 입력 데이터, 전처리·후처리, 추론 파라미터 및 판단 임계값을 동일하게 유지

DO-3: 강건성 지향 운영 제어 파라미터 조정

❖ 개념

- 운영 중 강건성 지표가 허용 범위를 벗어나고 그 변화가 통계적으로 유의한 것으로 확인되면, 모델을 즉시 재학습하지 않고 승인된 범위 안에서 입력·출력 가드레일, 결정 임계값, 모델 라우팅, 재시도·타임아웃 등의 제어 파라미터를 조정
- 조정 후에는 성능·안전성·처리 지연을 다시 검증하고, 회복되지 않으면 안전 모드 전환, 대체 모델 적용 또는 재학습으로 연계

❖ 설계기법

적용 지점	조정 파라미터	구체적인 조정
입력 가드레일	입력 품질 기준	결손·노이즈·센서 불일치가 큰 입력을 자동 추론에서 제외하고 검토로 전환
모델 결정	신뢰도·불확실성 임계값	저신뢰 예측의 자동 결정을 제한하도록 임계값을 조정
출력 가드레일	출력 일관성·안전성 기준	반복 추론이나 이상불 결과의 불일치가 크면 출력을 차단하고 안전 응답 또는 기본 동작으로 전환
모델 서빙	모델 라우팅 가중치	특정 입력·환경 조건에 강건성이 검증된 대체 모델로 일부 요청을 전환
실행 인프라	재시도·타임아웃·회로 차단 기준	일시적 서빙 오류에는 제한적으로 재시도하고, 반복 장애 시 트래픽을 우회하거나 회로를 차단

❖ 주의

- 제어 파라미터는 사전에 검증·승인된 범위에서만 조정하며, 단기 지표 변동만으로 자동 변경하지 않는다

DO-4: 자원 제약 대응 추론 플랫폼 운영 제어

- ❖ 개념 : 자원 제약이나 장애 상황에서도 허용 가능한 출력과 핵심 기능을 유지
 - 메모리·연산 자원·전력·처리시간이 부족하거나 요청이 급증할 때, 사전에 검증된 경량 추론 방식과 우선순위 정책으로 전환하여 핵심 기능을 유지하는 운영 제어 기법
 - 연산 정밀도, 모델 경로, 처리 기한, 등을 조정하고, 정상화되면 기본 모드로 복귀

❖ 설계기법

스트레스 유형	제어 파라미터	강건성 대응 정책
메모리·연산 자원 부족	연산 정밀도·모델 경로	자원 사용량이 임계치를 넘으면 FP32→FP16/INT8, 정밀 모델→경량 모델로 전환하고 배치 크기를 축소
응답 지연	모델 경로, 처리 기한, 생성 길이·반복 횟수	지연시간이 임계치를 넘으면 경량 모델로 전환하고, 생성 길이·반복 연산을 제한하며 기한 초과 시 안전 기본값을 반환
전력 부족	실행 기능 수준, 추론 주기, 자원 할당량	비핵심 추론의 실행 주기를 늘리거나 일시 중지하고, 핵심 안전 기능에 전력·연산 자원을 우선 할당

❖ 주의

- 파라미터를 지나치게 낮추면 서비스 품질이 급격히 떨어질 수 있으므로, 안전에 필요한 핵심 기능은 유지하면서 단계적으로 조정해야 함

구조적 설계 패턴


강건성 설계 패턴 개요

구조적 패턴	핵심 목적
다층 방어 가드레일 패턴	입력 전처리-모델 추론-출력 검증을 연속적인 방어 계층으로 구성하여 한 계층이 놓친 이상을 다음 계층에서 차단
다양성 기반 중복 추론 패턴	서로 다른 모델-센서-전처리 경로의 결과를 비교-결합하여 단일 구성요소의 오류가 최종 판단으로 전파되는 것을 방지
감시-판단-적응 피드백 패턴	운영 로그를 수집하고 드리프트와 강건성 영향을 분석한 후, 제어 파라미터 조정-모델 전환-재학습으로 환류
단계적 성능 저하 패턴	정상 추론이 어려울 때 서비스를 즉시 중단하지 않고, 경량 모델-보수적 결정-핵심 기능 중심의 안전 모드로 단계적으로 전환

다층 방어 가드레일 패턴

❖ 기본 개념

입력부터 최종 실행까지 여러 검증 계층을 배치하여, 오류·공격·불확실성이 다음 구성요소로 그대로 전파되지 않도록 하는 구조



❖ 장점

- 오류·공격의 단계적 전파 차단
- 재수집·재추론·안전 모드 전환 지원


❖ 주의점

- 과도한 차단과 정상 입력 오탐 방지
- 검증 계층 증가에 따른 응답 지연
- 보류·재수집·안전 전환 경로를 사전에 검증

다양성 기반 중복 추론 패턴

❖ 기본 개념

같은 입력을 서로 다른 모델이나 처리 경로에서 독립적으로 추론하고, 결과를 결합하거나 상호 검증하는 구조



❖ 장점

- 일부 모델이나 센서가 실패해도 다른 경로를 통해 서비스 지속 가능
- 다수결·가중 평균·규칙 검증으로 예측 안정성과 신뢰성 향상


❖ 주의점

- 모델별 성능 차이를 고려하여 결합 방식과 불일치 허용 기준을 검증
- 중복 추론에 따른 연산 비용과 응답 지연 증가를 고려

감시-판단-적응 피드백 패턴

❖ 기본 개념

운영 상태를 계속 관찰하고 강건성 저하를 판단한 후, 시스템 설정이나 모델을 조정하는 폐루프 구조



❖ 장점

- 운영 중 강건성 저하의 지속적 탐지
- 실패 사례를 재학습과 개선에 활용


❖ 주의점

- 검증·승인된 범위에서만 자동 조정
- 조정 전후의 강건성·정확성·지연시간을 함께 검증하고 **변경 이력과 롤백 경로**를 관리

단계적 성능 저하 패턴

❖ 개념

- 자원 부족, 입력 품질 저하 또는 모델 불확실성이 발생했을 때 전체 기능이 갑자기 실패하지 않도록, 제공 기능과 추론 수준을 단계적으로 축소하는 구조



❖ 장점

- 장애·자원 부족 시에도 **핵심 기능을 가능한 범위에서 유지**
- 안전 모드·수동 처리로 전환하여 **위험한 자동 판단을 제한**

❖ 주의점

- 빈번한 모드 전환을 막도록 **히스테리시스와 최소 유지시간 적용**
- 성능 저하 상태를 정상 서비스로 오인하지 않도록 **사용자에게 현재 모드와 제한사항을 안내**

Q & A
