

공정성 (Fairness) 설계

목차

❖ 공정성 설계 개요

❖ 활동 기반 설계

- 데이터 설계
- 모델 학습 설계
- 추론 서비스 설계
- 배포 · 운영 설계

❖ 구조적 설계 패턴

공정성 설계 개요

데이터 구성부터 모델 학습, 서비스 운영, 이의제기 절차까지 전 과정에서 부당한 집단 간 차이를 예방·탐지·완화하는 활동

01

데이터 설계

- 계층화 표본 추출
- 재샘플링
- 반사실적 데이터 증강
- 대리변수 탐지

02

모델 학습 설계

- 비용 민감 학습
- 공정성 제약 학습
- 일관성 제약 학습

03

추론서비스 설계

- 보호속성 최소화
- 대리 속성 정밀도 축소
- 고위험 입력의 판정 보류
- 차별 유도 공격 차단
- 차별 편향 출력 통제
- 개인공정성 기반 출력 일관성

03

배포 · 운영 설계

- 공정성 지표 모니터링
- 데이터·환경 변화 모니터링
- 운영제어 파라미터 조정
- 공정성 강화 학습
- 공정성 강화 모델 교체

구조적 설계 패턴

분리·격리 | 중복·대체 | 추적·증거

데이터 설계

공정성을 위한 데이터 설계

❖ 데이터가 편향되면 아무리 좋은 모델도 편향된 결과를 냅니다.

➤ 공정성을 위한 데이터 설계는 학습 데이터에 들어 있는 편향을 발견하고 완화하는 활동

설계 기술	설명
DD1. 계층화 표본 추출	전체 모집단에서 각 집단의 비율이나 중요도를 고려 하여 데이터를 추출합니다.
DD2. 재샘플링	집단별 표본 수의 불균형을 조정 합니다
DD3. 반사실적 데이터 증강	개인의 데이터에서 보호 속성만 반대로 변환한 가상의 쌍(Pair) 데이터를 생성
DD4. 프록시(대리변수) 탐지	보호속성을 간접적으로 나타내는 변수를 탐지

DD-1: 계층화 표본 추출

❖ 개념

- 전체 모집단에서 **각 집단의 비율이나 중요도를 고려**하여 데이터를 추출하는 방법
- 학습·검증·시험 데이터 모두에 적절한 비율로 포함되도록 구성

❖ 예시

- 고령 지원자가 전체의 10%인데 무작위 추출로 시험 데이터에 3명만 포함되면, 그 집단의 정확도를 신뢰할 수 있게 측정할 수 없습니다

❖ 주의

- 비율만 맞추는 것이 아니라, **절대 개수도 충분**해야 합니다. 성능 측정에 필요한 **최소 표본 수(예: 100건)**는 확보하세요

👁 시각적으로 보기

전체 지원자 (모집단)



❌ 잘못된 무작위 추출



→ 고령 데이터 거의 없음. 모델이 고령자 판단 학습 불가

✅ 계층화 추출



→ 모든 집단의 비율을 정확히 반영하여 학습 가능

DD-2: 재샘플링

❖ 개념


- 집단별 표본 수의 불균형을 조정합니다
- 오버샘플링(Over-sampling) : 단순 복제, 유사 샘플 생성
- 언더샘플링(Under-sampling): 무작위 언더샘플링, 클러스터 기반 축소

❖ 예시

- 의료 진단 AI 학습 시 특정 환자군(고령층, 소아 환자, 희귀 질환자 등)의 데이터 비율이 매우 낮다면 오버샘플링

❖ 주의

- 재샘플링이 과도할 경우 특정 데이터에 과적합(Overfitting)되어 모델의 범용성이 떨어질 수 있음



DD-3: 개인 공정성을 위한 반사실적 데이터 증강


❖ 개념

- 개인의 데이터에서 결과값은 그대로 유지한 채 성별, 인종, 종교 등 보호 속성만 반대로 변환한 가상의 쌍(Pair) 데이터를 생성

반사실적 쌍(Pair) 데이터 생성

❖ 주의

- **현실성 검토 필요:** 보호 속성만 바꾸었을 때 현실적으로 불가능하거나 부자연스러운 데이터가 생성될 수 있음
- **대리 변수 처리 필요:** 성별, 인종을 직접 바꾸어도 이름, 지역, 학교, 표현 방식 같은 proxy 변수가 남아 있으면 효과가 제한됨



DD-4: 프록시 (대리변수) 탐지

❖ 개념

- 남은 특성만으로 보호속성을 예측할 수 있는지 시험
- 각 특성이 예측 격차에 얼마나 기여하는지 분석

❖ 예시

- 우편번호 → 인증·소득수준 등 보호속성 유추
 - ✓ 소득수준에 따른 대출 승인 결정에 영향을 줄 수 있는가?
 - ✓ 물류센터와의 거리, 교통 상황, 배송 경로를 반영하기 위해 사용되는가?

❖ 주의

- **프록시 (대리변수)**라고 해서 반드시 제거해야 하는 것은 아니라, 다음 두 가지를 함께 검토
 - ✓ 유지 가능 : 예측에 정당한 정보이고, 차별을 야기하지 않는 경우
 - ✓ 제거 또는 재설계: 직무와 무관한데, 차별을 유발하는 경우

모델 학습 설계

공정성을 위한 모델 학습 설계

❖ 데이터가 균형 잡혀도 학습 방식에 따라 특정 집단에 불리한 모델이 나올 수 있습니다.

➤ "공정성을 위한 모델 설계·학습"은 평균 정확도가 아니라 "집단별 오류와 기회 차이"를 함께 줄이는 활동

설계 기술	설명
MT1. 비용 민감 학습	특정 집단에서 발생하는 중요한 오류에 더 큰 비용(손실)을 부여하여 모델이 해당 오류를 우선적으로 줄이도록 학습
MT2. 공정성 제약 학습	모델 학습시, "공정성 제약 조건" 하에서 정확도를 최적화 시키는 학습 방법
MT3. 일관성 제약 학습	입력 특성이 유사한 개인 쌍에 대해 모델 출력 차이가 과도하게 커지지 않도록 학습

MD-1: 비용 민감 학습

(Cost-sensitive Learning)

❖ 개념

- 특정 집단에서 발생하는 중요한 오류에 더 큰 비용(손실)을 부여하여 모델이 그 오류를 우선적으로 줄이도록 학습시킵니다
- 언제 사용해야 할까?
 - ✓ 특정 오류의 사회적 비용이 클 때 --> 의료 오진, 안전 관련 시스템
 - ✓ 집단별 오류 유형이 다를 때 --> A 집단은 미탐이 많고, B 집단은 오탐이 많음
 - ✓ 법적 윤리적 요구가 있을 때 --> 차별 방지 규정, 의료 가이드라인

❖ 예시

비용 민감 학습

특정 인종의 **미탐 손실 = 10점**, **오탐 손실 = 1점**으로 설정

$$\text{Loss} = 10 \times \text{미탐} + 1 \times \text{오탐}$$

→ 모델이 **미탐을 우선 줄이도록** 학습

❖ 주의

- 비용을 너무 높이면 다수집단 정확도가 크게 떨어질 수 있음
-

MD-2: 공정성 제약 학습 (Constraint-based Fairness Learning)

❖ 개념

- 모델 학습시, “공정성 제약 조건” 하에서 정확도를 최적화 시키는 방법

목적 함수 (Objective)

min 예측 오류

제약 조건 (Constraint)

s.t. 집단 간 공정성 차이 $\leq \epsilon$ (허용 한계)

❖ 예시



목표

채용 모델의 정확도는 **최대화**하되,
남녀 실제 적격자의 추천률 차이가
5%포인트 이내가 되도록 제약

❖ 주의

- 학습 수렴이 어려울 수 있음
- 제약이 너무 엄격하면 정확도 급락
- 여러 제약이 서로 충돌할 수 있음

MD-3: 일관성 제약 학습 (Consistency-based Learning)

❖ 개념

- 입력 특성이 유사한 개인 쌍에 대해 모델 출력 차이가 과도하게 커지지 않도록, 일관성 제약을 손실 함수에 포함

손실 함수

$$L = \text{정확도 손실} + \lambda \times \text{일관성 제약}$$

❖ 예시

- 신용 점수 산정 모델에서 소득, 부채비율, 상환 이력, 신용 기간이 거의 같은 두 신청자가 인접한 우편번호나 나이 1세 차이만으로 대출 승인 확률이 급격히 달라지지 않도록, 유사 개인 쌍의 출력 차이를 제한하는 일관성 제약(regularization)을 적용함.

❖ 주의

- 제약을 너무 강력하게 규제하면 모델이 데이터의 복잡한 관계를 학습하지 못하는 저학습(Underfitting) 현상이 발생할 수 있으므로, 도메인의 특성에 맞는 규제 강도 설정이 필수적임.

추론 서비스 설계

공정성을 위한 추론 서비스 설계 기법 요약

단계 세부 영역	핵심 설계 기술	
입력 통제	IS-1 보호속성 최소화	불필요한 보호속성 제거·마스킹
	IS-2 대리 속성 정밀도 축소	대리 변수 제거·범주화·일반화
	IS-3 고위험 입력의 판정 보류	자동 판정 보류 및 전문가 검토 전환
	IS-4 차별 유도 프롬프트 및 공격 차단	차별·편견 유도 입력 탐지·차단
출력 통제	IS-5 차별편향 출력 통제	차별적 결과·표현 탐지 및 보정·차단
	IS-6 개인공정성 기반 출력 일관성	유사 개인 간 결과 차이 검사·재산정

❖ 개념:

- AI 모델의 의사결정에 법적·윤리적으로 사용해서는 안 되는 보호 속성이 입력 데이터에 포함되어 있을 경우, 이를 모델의 입력에서 제거

❖ 예시

- 신용카드 발급 심사 시스템에서 추론 엔진으로 데이터를 전달하기 전에 **종교, 정당 가입 여부, 출생지 등 신용도 판단에 정당하게 필요하지 않은 항목을 입력에서 제외함**
- 모델에는 소득, 직업, 연체 기록, 부채 비율 등 신용 평가에 필요한 핵심 지표만 전달함.

❖ 주의

- 보호 속성을 단순히 제거해도 우편번호, 학교명, 직장, 언어, 이름, 주소 등 **대리 변수를 통해 보호 속성이 우회적으로 추론될 수 있음**. 따라서 보호 속성 최소화는 대리 변수 점검, 정밀도 축소, 공정성 지표 평가와 함께 적용해야 함



❖ 개념

- 보호 속성을 유추할 수 있게 하는 **대리 속성의 해상도와 식별력을 낮추는 방법**
- 상세 주소, 학교명, 이름, 출생지, 세부 지역, 특정 조직명 등을 보다 일반적이고 중립적인 범주로 변환함.

❖ 예시

- 채용 AI의 “이력서” 입력 데이터
 - ✓ 출신 학교명 → “학사 학위”, “전공 계열” 처럼 일반화함.
 - ✓ 상세 주소 → 광역 지자체 단위로 변환하여, 지역 편향이 발생하지 않도록 함.

❖ 주의

- 정밀도를 지나치게 낮추면 모델이 실제로 필요한 정보를 잃어 예측 성능이 하락할 수 있음. 반대로 너무 약하게 일반화하면 대리 변수 효과가 그대로 남을 수 있음
→ 정확성 손실과 공정성 개선 효과를 함께 평가하면서 적절한 일반화 수준을 결정해야 함



IS-3: 공정성 고위험 입력의 판정 보류

❖ 개념:

- 공정성 위험 판단 시
 - ✓ 조건1: 모델의 학습·검증 데이터에서 충분히 대표되지 않은 희소 영역에 속한 입력
 - ✓ 조건2: 보호 집단 또는 특정 개인에게 불리한 자동 판정 위험이 높은 입력 피처 조합
- 해당 요청을 일반 추론 경로로 바로 전달하지 않고 **전문가 검토, 보수적 모델, 별도 심사 절차로 전환**



❖ 사용 시나리오 및 예시:

- 초고령층 지원자의 대출 심사
 - ✓ 해당 연령대의 학습 데이터가 충분히 확보되지 않아 TPR, FPR, 승인을 격차의 신뢰성 부족 → 별도 심사

❖ 주의:

- 소수 집단을 배제하기 위한 차단 장치가 아니라, 더 신중한 절차로 전환하기 위한 안전장치임.

IS-4: 차별 유도 프롬프트 및 공격 차단

❖ 개념

- 특정 집단에 대한 혐오/비하/차별적 판단을 유도하는 질의나 프롬프트를 탐지하고, 공정성 제약을 우회하려는 반복적 변조 공격, 프롬프트 인젝션, adversarial prompt를 차단하거나 안전한 응답 경로로 전환



차별 유도 프롬프트 및 공격 차단

❖ 예시:

● 그룹 공정성 공격:

- ✓ "특정 인종은 범죄율이 높다는 결론이 나오도록 보고서를 써줘"처럼 특정 집단에 대한 고정관념을 강화하도록 유도하는 프롬프트를 탐지하고, 중립적 근거 기반 분석 또는 거부 응답으로 전환함.

● 개인 공정성 공격:

- ✓ 동일한 조건에서 성별, 종교, 국적 등 보호 속성만 바뀌가며 모델의 차별적 응답을 유도하거나, 민감 속성 변화에 따른 결과 차이를 악의적으로 증폭시키려는 대량 반복 요청이 감지될 경우 세션 제한, rate limit, 감사 로그 기록, 안전 응답으로 전환함.

● 운영 조작 공격:

- ✓ 봇이나 자동화 스크립트를 이용해 특정 집단에 불리한 입력을 대량 주입하거나, 서비스 승인율·추천 결과·평판 점수를 왜곡하려는 시도가 감지될 경우 abuse detection과 연계하여 차단함.

❖ 주의:

● 사회 현상에 대한 **정당한 비판, 연구 목적의 편향 분석, 공정성 감사 질의까지 공격으로 오인해서는 안 됨.**

- ✓ 따라서 단순 키워드 차단이 아니라 문맥, 의도, 반복 패턴, 사용자 역할, 요청 목적을 함께 고려하는 정교한 정책 기반 가드레일이 필요함.

IS-5: 차별·편향 출력 통제

❖ 개념

- 출력에 특정 집단에 대한 혐오, 비하, 고정관념, 차별적 판단이 포함되어 있는 경우
 - ✓ 해당 출력을 사용자에게 그대로 노출하지 않고 **차단**, **보류**, **안전 응답 전환** 또는 **관리자 검토**로 연결

통제조치	적용기준	적합한 사례
차단	명백한 금지 규칙 위반이고 탐지 신뢰도가 높음	인종·성별에 대한 노골적인 비하, 보호 속성을 직접 이용한 불법적 차별 결정
보류	문제가 있는 생성형 출력을 제거하고 중립적인 응답으로 대체할 수 있음	"여성은 관리직에 적합하지 않다"는 답변을 "성별이 아니라 직무 역량을 기준으로 판단해야 합니다"로 전환
안전응답전환	공정성 위험은 감지됐지만 즉시 위반이라고 확정하기 어렵거나, 배치 수준의 추가 검사가 필요함	특정 집단의 대출 거절률이 기준치를 초과하여 결과 통지를 잠시 중단
관리자검토	피해가 크거나 판단이 모호하고, 사람의 맥락 판단과 책임 있는 승인이 필요함	채용·대출·의료처럼 중대한 결정, 경계값 부근 사례, 사용자의 이익 제기

❖ 주의

- 차단 기준이 과도하면 정당한 분석, 사회 비판, 학술적 질의까지 막을 수 있으므로 단순 키워드 차단이 아니라 문맥, 목적, 사용 도메인, 피해 가능성을 함께 고려해야 함

❖ 개념:

- 모델의 개별 의사결정 결과를 유사 개인의 결과 또는 보호 속성만 변경한 반사실적 결과와 비교하고,
- 정당한 업무 요인으로 설명되지 않는 차이가 허용 기준을 초과하면 최종 결과를 즉시 확정하지 않고, **보류**, **재산정** 또는 **전문가 검토**를 통해 판단의 일관성을 확보한다.

❖ 예시

- 유사한 위험도를 가진 가입자 A와 B의 보험료가 각각 60만 원과 85만 원으로 산출되면 일관성 위반으로 탐지하고,
 - ✓ B의 보험료 통지를 우선 **보류**한다.
 - ✓ 성별이나 비승인 대리변수가 영향을 준 것으로 확인되면 해당 변수를 배제한 승인 모델로 **재산정**한다.
 - ✓ 결과 차이가 정당한 위험 요인 때문인지 간접 차별 때문인지 판단하기 어려우면 공정성-준법 담당자의 **전문가 검토**로 전환한다.

❖ 주의:

- 반사실적 검증과 유사 개인 비교는 계산 비용이 크고, 어떤 속성을 “비본질적 차이”로 볼 것인지에 대한 도메인 정의가 필요함.

배포 · 운영 관점 설계

공정성을 위한 배포 · 운영 설계 기법 요약

단계 세부 영역	핵심 설계 기술	
운영 감시	DO-1 그룹 공정성 지표 모니터링	집단 공정성 지표 지속 감시
	DO-2 개인 공정성 지표 모니터링	개인 공정성 지표 지속 감시
	DO-3 데이터 · 환경 변화 모니터링	집단 구성비, 입력 분포와 정책 변화 감시
운영 조치	DO-4 운영제어 파라미터 조정	임계값·검토구간·가드레일 강도 조정
	DO-5 공정성 강화 재학습	편향 사례를 반영한 데이터·모델 재학습
배포	DO-6 공정성 강화 모델 교체	검증된 공정성 강화 모델로 전환

DO-1: 그룹 공정성 지표 모니터링

❖ 개념

- 운영 중 발생하는 전체 추론 데이터를 성별·연령 등 보호 속성별로 그룹화하여, 인구 통계적 동등성, 기회의 평등 등 통계적 격차 지표를 실시간 또는 배치 단위로 상시 감시
- 연산 부하가 낮아 전수 조사가 가능하며, 대시보드를 통한 시각화 및 자동 알람 체계 구축에 적합함

❖ 그룹 공정성 지표

지표명	모니터링 관점 (예시)
인구 통계적 동등성 (Demographic Parity)	[채용] 남성 지원자의 합격률이 10%라면, 여성 지원자의 합격률도 지역/배경에 상관없이 10% 수준을 유지하는지 감시함.
예측 패러티 (Predictive Parity)	[사기 탐지] 시스템이 '이상 거래'로 진단했을 때, 실제 사기일 확률이 특정 국적의 사용자에게서만 유독 낮아 '과잉 단속'이 일어나는지 감시함.
기회의 평등 (Equal Opportunity)	[대출] 실제 상환 능력이 있는 우량 고객들 중에서, 특정 연령대라는 이유로 대출이 거절되는 '기회 박탈' 사례가 편중되지 않는지 감시함.
균형된 오차 (Equalized Odds)	[얼굴 인식] 특정 인종에서만 유독 오인식률이 높게 나타나 서비스 이용에 차별적인 불편을 겪고 있지 않은지 감시함.
처우의 평등 (Treatment Equality)	[인사 고과] 특정 부서원들이 성과 대비 과소평가(FN)받는 비중이 타 부서보다 비정상적으로 높아 보상에서 소외되지 않는지 감시함.

D2-2: 개인 공정성 지표 모니터링

❖ 개념


- 추론 데이터 중 일부를 샘플링하여 보호 속성을 변조한 후 재추론(반사실적 검증)하거나, 유사한 속성을 가진 개인 간의 결과 일관성을 분석하는 인과적 일관성 지표를 감시
- 추가적인 추론 연산이 필요하여 부하가 매우 높으므로, 고가치 사례나 무작위 샘플링을 통한 부분 조사(Sampling) 전략과 비정기적 정밀 진단 체계가 요구됨.

❖ 개인 공정성 지표

지표명	모니터링 관점 (예시)
유사도 기반 일관성	[대출] 소득·신용이 유사한 두 사용자가 거주지 차이만으로 한도가 급변하는지 감시함.
립시츠 연속성	[보험] 건강 지수 1점 차이로 인해 보험료가 계단식으로 급등하는 '불연속적 판단'을 감시함.
테일 지수	[의료] AI 오진이 특정 희귀 질환자나 소수 인종에게만 쏠려 발생하는 '오차의 편중'을 감시함.
반사실적 공정성	[인사] 동일 데이터에서 성별만 바꿨을 때 승진 결과가 뒤집히는 '인과적 모순'을 전수/샘플링 검사함.
인과적 공정성	[신용] 인종 정보가 '거주 지역'이라는 중간 경로를 타고 점수에 개입하는 '우회 차별' 경로를 추적함.

❖ 개념

- 집단 구성·입력 품질·정책 환경의 변화와 집단별·개인별 판정 결과를 연계하여, 실제 공정성 저하 여부와 원인을 탐지



변화 감시 대상	세부 내용	감시 목적	구체적인 방법
집단 구성 변화	성별·연령대·지역별 이용자 비율 변화	일부 집단의 과소대표·과대표 탐지	기준 기간과 현재 기간의 집단별 비율 비교
입력 분포 변화	소득, 경력, 센서값, 이용 시간 등의 분포 변화	학습 데이터와 운영 데이터의 차이 탐지	연속형 입력값: 평균·표준편차·분위수·전체 분포 비교 범주형 입력값: 범주별 발생 비율 비교
집단별 입력 품질	집단별 결측률, 오류율, 측정 정확도 차이	특정 집단에 집중되는 데이터 품질 문제 발견	결측·오류·이상치·중복 발생률 비교
정책·사회 환경 변화	심사 기준, 법규, 서비스 지역, 고객 정책 변화	기존 모델과 가드레일의 적합성 점검	정책·지역·기기·센서·SW 버전 변경 기록 비교

DO-4: 공정성 지향 운영 제어 파라미터 조정

❖ 개념

- 데이터 및 환경 변화로 발생한 일시적인 공정성 저하를 서비스 중단 없이 완화하기 위한 운영상 '소프트 처방'
- 운영 중 집단 또는 개인 공정성 지표가 허용 범위를 벗어나고, 그 변화가 통계적으로 유의한 것으로 확인되면 모델을 즉시 재학습하지 않고 승인된 범위 안에서 결정 임계값, 입력·출력 가드레일, 모델 라우팅 등의 제어 파라미터를 조정한다.

❖ 예시

적용지점	조정 파라미터	구체적인 조정
입력 가드레일	입력 품질 기준	결측률이 높은 입력을 자동 결정에서 제외하고 검토로 전환
모델 결정	승인 · 거절 임계값	임계값 기준을 승인된 범위에서 조정
출력 가드레일	차별 표현 탐지 기준	고정관념·혐오 표현 탐지 민감도를 높여 차단 또는 재작성
모델 서빙	모델 라우팅 가중치	공정성 성능이 검증된 대체 모델로 일부 요청 전환

❖ 개념


- 편향의 근본 원인을 제거하여, 모델이 시간이 흐를수록 더욱 정교하고 공정한 판단을 내릴 수 있도록 학습의 선순환 완성.
- 운영 중 공정성 모니터링, 오류 분석 및 사용자 이의 제기를 통해 확인된 편향의 원인을 데이터·특성·학습 목적함수에 반영하여 후보 모델을 재학습하고, 공정성 및 예측 성능을 검증한 후 단계적으로 재배포하는 기법

❖ 예시

- 특정 집단에서 적격 신청자의 오거절이 반복되면, 해당 집단의 데이터 대표성·레이블 오류·대리변수 영향을 분석한다.
- 이후 데이터 재표본화, 레이블 정제, 특성 수정, 공정성 제약 학습을 적용하여 후보 모델을 재학습하고,
- 집단별 TPR-FPR과 전체 정확도를 함께 검증한 후 카나리 방식으로 배포한다

❖ 주의

- 새로운 데이터 주입 시 예기치 못한 '역편향'이나 기존 정확성의 급격한 퇴보(Regression)가 발생할 수 있음



❖ 개념

- 출력 가드레일의 차단이 빈번하거나 지표 개선이 불가능할 경우, 정확도를 일부 희생하더라도 공정성/일관성 제약 학습이 강력히 주입된 백업 모델로 스위칭
- 근본적인 지능 편향이 확인되었을 때, 서비스의 윤리적 생존을 위해 '안전 모드' 모델로 페일오버(Fail-over)하여 리스크를 원천 차단함.

❖ 예시

- 메인 모델이 특정 인종에 대해 지속적으로 편향된 결과를 내놓아 사회적 논란이 예상될 때, 성능은 다소 낮지만 공정성 제약 학습이 검증된 '가디언(Guardian) 모델'로 트래픽을 즉시 전환함.

❖ 주의

- 모델 교체는 서비스 성능에 큰 변화를 줄 수 있으므로, 교체 시 사용자 영향을 최소화하기 위한 사전 테스트와 롤백 시나리오가 준비되어 있어야 함.

❖ 계층적 모델 관리 체계:

- 챔피언 모델 (Standard): 평상시 가동되는 모델. 높은 정확도를 유지하며 보정 기법에 의존함.
- 가디언 모델 (Fairness-Centric): 공정성/일관성 제약 학습이 적용된 모델. 특정 그룹에 대한 편향성이 수리적으로 강제 통제됨

구조적 설계 패턴


공정성 설계 패턴 개요

구조적 패턴	핵심 목적	대표 구성요소
분리·격리	공정성 평가의 독립성 확보	공정성 평가 모듈, 별도 평가 데이터
중복·대체	위험한 자동 결정을 다른 절차로 전환	인간 검토, 규칙 기반 판단, 안전한 기본 조치
추적·증거	불공정한 결정의 원인과 책임 확인	감사 로그, 버전 정보, 결정 이력

분리·격리 패턴

❖ 기본 개념

공정성 평가 기능을 모델 학습이나 서비스 기능에 섞어 두지 않고, 독립된 구성요소로 분리하는 패턴



❖ 장점

- 평가의 독립성과 일관성 확보
- 모델 학습자와 서비스 운영자는 원시 민감정보에 접근하지 못함


❖ 주의점

- 평가 모듈을 과도하게 격리하면 데이터·특징·모델 버전·의사결정 과정에 대한 정보가 단절되어, 편향을 탐지하더라도 그 발생 원인을 분석하고 개선하기 어려울 수 있음

중복 · 대체 패턴

❖ 기본 개념

하나의 자동화된 판단 경로에만 의존하지 않고, 공정성 위험이나 불확실성이 높은 경우 다른 판단 경로로 전환하는 구조



❖ 장점

- 불공정 판단이나 잘못된 결정으로 인한 피해를 사전에 차단
- 시스템 전체가 마비되지 않고, 대체 판단 경로로 유연하게 대응


❖ 주의점

- 대체 절차로 전환되는 비율도 집단별로 확인해야 합니다.
 - ✓ 특정 집단만 지나치게 자주 인간 검토 대상으로 전환되면 처리 지연이나 추가 부담이라는 새로운 불공정이 발생할 수 있음

추적 · 증거 패턴

❖ 기본 개념

각 결정이 어떤 데이터, 모델, 정책 및 인간 판단을 거쳐 만들어졌는지를 연결하여 기록하는 구조



Q & A
