

설명용이성 (Explainability) 설계

목차

❖ 설명용이성 설계 개요

❖ 활동 기반 설계

- 데이터 설계
- 모델 학습 설계
- 추론 서비스 설계
- 배포 · 운영 설계

❖ 구조적 설계 패턴

설명용이성 설계 개요

AI가 어떤 정보를 바탕으로 왜 이러한 결과를 냈는지 이해관계자가 이해하고, 운영자가 검증·추적·정정할 수 있도록 설계

01

데이터 설계

- 특성 의미·정의 관리
- 데이터 출처·계보 관리
- 변환·파생 이력 관리

02

모델 학습 설계

- 설명 가능한 모델 설계

03

설명 서비스 설계

- 사후 모델 기법 선택
- 사용자별 설명 제공

03

배포 · 운영 설계

- 설명 품질 모니터링
- 설명 문제 기반 운영 조치

구조적 설계 패턴

설명 서비스 분리, 다중 수준 설명·검증 게이트

데이터 설계

설명용이성을 위한 데이터 설계 기법

기법	설명
DD-1 특성 의미·정의 관리	각 특성 데이터 항목이 무엇을 나타내는지, 값의 단위·범위·형식이 무엇인지 명확하게 정의
DD-2 데이터 출처·계보 관리	데이터가 어디에서 수집되어, 어떤 전처리·학습·추론 과정을 거쳤는지 전체 이동·변경 경로를 추적
DD-3 변환·파생 특성 이력	원본 데이터가 정규화·인코딩·계산을 통해 어떤 특성으로 변환되었는지, 사용한 계산식과 버전을 기록

DD-1: 특성 의미·정의 관리

❖ 개념 (데이터의 의미를 설명 가능하게 만드는 것)

모델이 사용하는 각 특성이 무엇을 의미하고 어떤 범위와 단위를 갖는지 사람이 이해할 수 있게 정의

❖ 설계 기술

설계 기술	설명	예시
특성 정의서 작성	각 입력 특성의 의미와 단위를 기록	부채비율 = 총부채/연소득
데이터 출처 관리	데이터가 어디에서 수집되었는지 기록	고객 입력, 신용정보기관, 거래 기록
값의 범위·단위 관리	정상 범위와 단위를 명확히 정의	연소득: 원 단위, 0 이상
민감·보호 특성 표시	설명에 포함할 때 주의할 정보를 구분	성별, 장애 여부, 건강정보

❖ 주의

기술적 정의와 현업의 의미가 다르지 않도록 데이터 담당자와 업무 전문가가 공동 검토

DD-2: 데이터 출처·계보 관리

❖ 개념

- 예측·설명에 사용된 운영 데이터가 학습 데이터와 동일한 의미·변환 기준을 따르는지 확인하기 위해, “**입력-전처리·특성 버전-모델버전-학습 데이터 버전-출처**”를 추적할 수 있도록 연결 구조를 설계

❖ 필요한 연결 관계

연결 관계	확인 목적
모델 버전 ↔ 학습 데이터셋 버전	해당 모델이 어떤 데이터로 학습되었는지 확인
학습 데이터 ↔ 운영 입력의 스키마·의미	동일한 특성이 같은 의미·단위·범위로 사용되는지 확인
학습 전처리 ↔ 추론 전처리	정규화·인코딩·파생 특성 계산이 동일하게 적용되는지 확인
운영 입력 ↔ 학습 데이터 분포	운영 입력이 학습 범위와 크게 다른 OOD·드리프트 입력인지 확인
예측·설명 ↔ 입력·모델 버전	특정 결과가 어떤 입력과 모델에서 생성되었는지 역추적

❖ 주의

- 계보 정보에 원본 개인정보를 과도하게 복제하지 않고, 식별자·접근권한·보존기간을 통제

DD-3: 변환·파생 특성 이력 관리

❖ 개념

- 정규화·인코딩·결측치 처리·파생 계산으로 만들어진 내부 특성을 원래의 업무 의미로 되돌려 설명할 수 있도록 연결 관계를 관리
- 예시

“특성 X7의 값 0.82가 예측값을 0.13만큼 낮췄습니다.” (이해하기 어려움)



“최근 1년간 연체 횟수가 3회로 확인되어 승인 가능성이 낮아졌습니다” (이해하기 쉬움)

❖ 관리 항목

- 원본 특성과 변환 특성의 연결 관계
- 파생 특성의 계산식
- 데이터 처리 파이프라인 버전
- 예측 당시 실제로 사용된 입력값

❖ 주의

- 여러 원본 값을 결합한 파생 특성은 계산식과 데이터 시점을 함께 제시하고, 변환 버전이 달라지면 설명도 재검증

설명 근거 데이터의 관리 방법

분류	주요 기법	설명	예
의미	데이터 사전	특성의 업무 의미·단위·범위 정의	부채비율=총부채/연소득
출처	데이터 계보	수집·변환·사용 경로 추적	신용기관→전처리 v3→모델 v7
변환	원본-파생 매핑	내부 특성을 사용자 의미로 복원	X7→최근 1년 연체 횟수

모델 학습 설계

MT-1: 설명 가능 모델 설계

❖ 개념

- 설명 가능 모델 설계는 모델의 구조와 동작 자체를 사람이 이해하기 쉽도록 구성하는 방법

❖ 설계 기술

설계 기술	설명	예시
1. 해석 가능한 모델 선택	모델의 판단 규칙이나 계산 과정을 사람이 직접 이해할 수 있는 모델을 선택	대출 심사에 로지스틱 회귀, 얇은 결정트리, 점수카드 사용
2. 의미 있는 특성 및 적은 특성 사용	업무적으로 이해할 수 있는 특성을 선별하고, 불필요한 특성을 줄여 판단 근거를 명확하게 함	수백 개의 변수 대신 소득·부채비율·연체 이력 등 핵심 특성 사용
3. 가법적·분해 가능한 구조 설계	최종 예측값을 각 특성이나 구성요소의 기여도로 나누어 확인할 수 있도록 설계	대출 점수 = 소득 기여도 + 부채비율 기여도 + 연체 이력 기여도
4. 개념·사례 기반 판단 구조 설계	원시 데이터 대신 사람이 이해할 수 있는 개념이나 대표 사례를 이용해 판단하도록 구성	로봇청소기가 센서값을 '장애물·오염·사람 존재'로 변환한 후 이동·청소 행동 결정

❖ 주의

- 복잡한 문제에서는 성능이 낮아질 수 있으므로 성능-설명용이성 균형을 검토

설명 서비스 설계

설명 서비스 설계 기법 요약

기법	설명
ES-1 사후 모델 설명 선택	설명 목적과 대상에 따라 적절한 사후 설명 기법 선택
ES-2 사용자별 설명 제공	역할과 목적에 따라 설명의 용어·상세도·근거 범위를 다르게 제공

ES-1: 사후 모델 기법 선택

❖ 개념

- 사후 모델 설명 기법 선택은 학습된 모델을 변경하지 않고, **설명 목적·범위·대상·데이터 유형에 따라 적절한 설명 기법을 선택하는 활동**

❖ 핵심 사후 모델 설명 기법


기법	무엇을 설명하는가?	설명 방식	간단한 예	주의점
특성 중요도	모델 전체에서 중요한 특성	각 특성이 전체 예측에 기여한 정도를 순위로 표시	대출 심사에서 부채비율, 연체 횟수, 소득 순으로 중요	중요도가 높아도 영향 방향이나 인과관계는 알 수 없음
SHAP	전체 판단 경향 또는 개별 예측 이유	각 특성이 예측값을 기준값보다 얼마나 높이거나 낮췄는지 계산	연체 이력은 부결 가능성을 높이고, 소득은 낮춤	계산량이 많을 수 있으며 기준값과 출력 단위를 함께 설명해야 함
PDP	특정 특성값과 예측 결과의 전반적 관계	한 특성값을 변화시키면서 평균 예측값의 변화를 그래프로 표시	부채비율이 증가할수록 평균 부결 가능성이 어떻게 변하는지 표시	특성 간 상관관계가 높으면 현실에 없는 입력 조합이 생길 수 있음
LIME	특정 사례 주변에서의 판단 기준	해당 입력과 유사한 표본을 만든 뒤 단순 모델로 국소적으로 근사	특정 신청자 주변에서는 연체와 부채비율이 주요 판단 기준	표본 생성과 설정에 따라 설명이 달라질 수 있음
반사실적 설명	결과를 바꾸기 위해 필요한 입력 변화	현재 결과가 달라지는 최소 변경 조건을 탐색	부채비율이 55%에서 40% 이하로 낮아지면 추가 심사에서 벗어날 가능성	사용자가 변경할 수 있고 현실적으로 가능한 조건만 제시해야 함

(전역) 사후 모델 설명 기법

특성 중요도

FEATURE IMPORTANCE

각 특성의 기여도 순위



설명 대상

모델 전체에서 어떤 특성이 중요한지


작동 원리

각 특성이 전체 예측에 기여한 정도를 계산해 순위로 표시

SHAP

SHAPLEY ADDITIVE EXPLANATIONS

기준값 대비 +/- 기여도



설명 대상

전체 판단 경향 또는 개별 예측 이유


작동 원리

각 특성이 예측값을 기준값보다 얼마나 높이거나 낮았는지 정량 계산

PDP

PARTIAL DEPENDENCE PLOT

특성값 변화 → 평균 예측 변화



설명 대상

특정 특성값과 예측 결과의 전반적 관계

작동 원리

한 특성값을 변화시키며 평균 예측값 변화를 그래프로 표시

(지역) 사후 모델 설명 기법

LIME

LOCAL INTERPRETABLE MODEL-AGNOSTIC



설명 대상

특정 사례 주변에서의 판단 기준


작동 원리

해당 입력과 유사한 표본을 만든 뒤 단순 모델로 국소 근사

반사실적 설명

COUNTERFACTUAL EXPLANATION

결과를 뒤집는 최소 변경



설명 대상

결과를 바꾸기 위해 필요한 입력 변화

작동 원리

현재 결과가 달라지는 **최소 변경 조건**을 탐색

사후 모델 설명 기법

❖ 어떤 상황에서 무엇을 선택할 것인가?

설명하려는 질문	선택 기법	선택 이유
모델이 전체적으로 무엇을 중요하게 보는가?	특성 중요도	전체적인 중요 특성을 빠르게 파악할 수 있음
중요 특성이 예측에 어떤 방향으로 작용하는가?	전역 SHAP	영향의 크기뿐 아니라 증가·감소 방향도 분석 가능
특정 특성값과 예측 결과는 어떤 관계인가?	PDP	특성 변화에 따른 평균 예측 변화를 보여줌
특정 사례 주변의 판단 기준은 무엇인가?	LIME	복잡한 모델을 해당 사례 주변에서 단순하게 근사
결과를 바꾸려면 무엇을 변경해야 하는가?	반사실적 설명	결과 변경에 필요한 실행 가능한 조건을 제시

선택 기준	고려 내용
설명 범위	모델 전체를 이해하려면 특성 중요도·전역 SHAP·PDP , 개별 결과를 설명하려면 개별 SHAP·LIME·반사실적 설명
사용자	개발자는 상세 수치와 그래프, 일반 사용자는 주요 이유와 변경 가능한 조건이 적합
계산 비용	대규모 데이터와 복잡한 모델에서는 SHAP 계산 비용을 고려
설명의 안정성	설명 설정이나 작은 입력 변화에도 결과가 크게 달라지지 않는지 확인
업무 타당성	설명 내용이 업무 규칙과 상식에 맞고 민감정보를 노출하지 않는지 확인

ES-2: 사용자별 설명 제공

❖ 개념

- 동일한 예측이라도 사용자의 역할, 활용 목적에 따라 설명의 용어·상세도·근거 범위를 다르게 제공

❖ 설계 기법

대상	설명 내용	표현 방식	주요 목적
일반 사용자	결과·핵심 이유·후속 조치	쉬운 문장과 핵심 이유 2~3개	이해·이의 제기·대응
업무 담당자	입력·특성 기여도·적용 규칙·유사 사례	업무 용어와 상세 근거	판단 검토·업무 처리
개발자·모델 전문가	SHAP·LIME·오류 사례·모델 동작	기술 지표와 시각화	오류 진단·모델 개선
감사자	데이터·모델·정책·결정 이력	재현 가능한 증거 묶음	준수·책임성·재현성 검증
운영·위험관리자	설명 변화·실패율·이의 제기·품질 추세	운영 지표·대시보드·경보	이상 대응·재승인·사용 제한

❖ 주의

- 설명의 수준을 낮춘다는 이유로 중요한 제한이나 불확실성을 숨기지 않고, 권한 없는 사용자에게 민감한 내부 정보를 공개하지 않음

서비스 · 운영 관점 설계

배포 · 운영 단계의 설계 기법 요약

단계 세부 영역	핵심 설계 기술	
추적관리	예측-설명 추적 연결	입력·모델·예측·설명·정책·최종 결정을 동일한 추적 ID로 연결하여 재현·감사 지원
운영	설명 품질 모니터링	운영 중 생성되는 설명의 충실도·안정성·일관성·운영품질 을 지속적으로 감시하는 활동
	설명 문제 기반 운영 조치	문제에 따라, 설명을 재생성하거나 결과 제공을 보류하고, 필요하면 전문가 검토·이전 버전 복구·설명 기법 개선 등을 수행


DO-1: 예측-설명 추적 연결

❖ 개념

- 각 예측에 사용한 입력·전처리·모델·정책·설명과 최종 결정을 하나의 식별자로 연결하여 나중에 재현하고 감사할 수 있게 설계

❖ 연결 항목

- ① 요청·예측 ID
- ② 입력값과 전처리 버전
- ③ 모델 이름·버전과 예측 신뢰도
- ④ 설명 기법·파라미터·생성 결과
- ⑤ 적용 정책·임계값과 최종 결정
- ⑥ 인간 검토 및 변경 사유



❖ 주의

- 추적 로그 자체가 개인정보·모델 정보의 새로운 노출원이 되지 않도록 최소 기록, 접근통제, 무결성과 보존기간을 관리

❖ 개념

- 운영 중 생성되는 설명이 **모델의 실제 판단을 충실하게 반영하고, 안정적·일관되며** 사용자에게 **유용한지** 지속적으로 감시하는 활동

❖ 기법

- ① **충실도 감시**: 중요하다고 설명된 특성을 제거·변경했을 때 예측이 실제로 변하는지 확인
- ② **안정성 감시**: 유사 입력이나 반복 실행에서 설명이 과도하게 달라지는지 측정
- ③ **일관성 감시**: 사용자용·전문가용 설명의 핵심 근거와 결론이 서로 일치하는지 확인
- ④ **운영 품질 감시**: 설명 생성 실패율·응답 지연시간·재생성률·사용자 이의 제기율 감시

❖ 주의

- 모든 설명에 대해 **운영 품질을 실시간 감시**하고, 일반·저위험 결과는 **표본 기반**으로 설명 품질을 주기적으로 평가하며, 고위험 결과 또는 예측·설명 신뢰도가 낮은 결과는 **충실도·안정성·일관성을 정밀 검사**한다.

DO-3: 설명 문제 기반 운영 조치

❖ 개념

- 설명의 충실도·안정성·일관성 등에 문제가 발견되면 설명을 재생성하거나 결과 제공을 보류하고, 필요하면 전문가 검토·이전 버전 복구·설명 기법 개선 등을 수행

❖ 대표적인 문제별 운영 조치

감지된 문제	운영 조치
설명 생성 실패	제한된 횟수로 재생성 → 계속 실패하면 기본 안내 또는 전문가 검토
설명 충실도 부족	결과 제공 보류 → 다른 설명 기법 적용 → 모델 판단과의 일치 여부 재검증
유사 입력에서 설명이 크게 달라짐	설명 기법·파라미터 조정 → 설명 안정성 재검사
사용자용·전문가용 설명 불일치	두 설명의 핵심 근거 대조 → 공통 근거를 기준으로 재생성
설명 지연시간 증가	간소화된 설명 제공 → 상세 설명은 비동기로 생성

❖ 주의

- 설명의 문장만 그럴듯하게 수정하지 말고 실제 모델 판단과의 충실도를 재검증하며, 조치 이력을 기록해야 함

구조적 설계 패턴


설명용이성 설계 패턴 개요

구조적 패턴	핵심 목적
설명 서비스 분리 패턴	추론과 설명 생성을 분리하여 설명 기법·정책을 독립적으로 교체·검증
다중 수준 설명·검증 게이트 패턴	동일한 검증 근거를 바탕으로 대상별 상세 수준의 설명을 제공하고, 품질 기준을 통과한 설명만 배포

설명 서비스 분리 패턴

❖ 기본 개념

- 추론 서비스는 예측 결과를 생성하고, 독립된 설명 서비스가 입력·모델 정보·예측을 바탕으로 설명을 생성한 뒤 설명 정책 모듈이 대상별 표현으로 변환



❖ 장점

- 설명 기법을 예측 모델과 독립적으로 교체·검증
- 사용자 역할에 따라 설명 수준을 유연하게 변환
- 설명 생성이 느린 경우 비동기 처리 가능


❖ 주의점

- 설명 서비스와 모델·전처리 버전이 반드시 일치해야 함
- 설명 생성 지연·실패 시 기본 설명 또는 인간 검토로 안전하게 전환

다중 수준 설명·검증 게이트 패턴

❖ 기본 개념

- 하나의 검증된 근거를 바탕으로 사용자·담당자·개발자·감사자에게 서로 다른 수준의 설명을 제공하고, 배포 전에는 충실도·안정성·안전성 기준을 통과하도록 품질 게이트를 적용



다중 수준 설명·검증 게이트 패턴

❖ 장점

- **대상별 맞춤 설명 제공:** 사용자·업무 담당자·개발자·감사자에게 필요한 상세도와 표현 방식으로 설명할 수 있음
- **설명 품질 보장:** 충실도·안정성·일관성·안전성 기준을 통과한 설명만 제공하여 부정확하거나 오해를 유발하는 설명을 방지
- **고위험 판단의 통제 강화:** 검증 실패 시 설명 제공을 보류하고 재생성·보완 또는 전문가 검토로 전환 가능

❖ 주의점

- **응답 지연과 운영비용 증가:** 여러 수준의 설명 생성과 검증 과정이 추론 지연 및 계산 비용을 증가시킬 수 있음
- **설명 실패 시 처리 정책 필요:** 재생성 횟수, 제공 보류, 전문가 검토, 예측 결과만 제공할 수 있는 조건을 사전에 결정해야 함

Q & A