

기능 적응성 (Functional Adaptability) 설계

목차

❖ 기능 적응성 설계 개요

❖ 확정적 적응성 설계

❖ 진화적 적응성 설계

기능 적응성 설계 개요

설계 단계	확정적(deterministic) 적응	진화적(evolutionary) 적응
적응 상황 유형	사전 정의된 변화에 대한 대응	사전에 정의되지 않은 상황에 대한 대응
적응 필요성 판단	메타데이터(시간, 장소)를 보고 "지금은 야간 모드군!" 하고 판단함	운영 지표(예, Drift)를 보고 "모델 성능이 떨어졌네!" 하고 판단
적응 동작 수행	미리 준비된 '야간용 파라미터 팩'을 모델에 바로 설정함	시스템이 '재학습'을 시작하거나, 위험하면 '안전 모드'로 전환함

확정적 적응성 설계

❖ 적응 필요성 판단 설계

판단 기법	설명
Context-Aware Sensing (상황 인지 센싱)	메타데이터: GPS(위치), RTC(시간), 센서 로그(기상), 관리자 입력 API.
Rule-based Thresholding (임계치 판단)	사전에 정의된 환경 조건(예: 조도 < 10lux)에 부합하는지 즉시 판단하는 결정 트리.
Administrative Injection (직접 지정)	사회/논리적 제약의 변화를 관리자가 API나 설정 변경을 통해 시스템에 직접 주입

❖ 적응 동작 수행 설계

적응 수행 기법	설명
Parameter Profile Injection (파라미터 프로파일 주입)	모델 재시작 없이 환경에 최적화된 하이퍼파라미터 프로필을 즉시 주입.
Component Switching (컴포넌트 스위칭)	특정 환경에 특화된 추론 모듈로 실행 경로를 전환.
Output Guardrails (출력 가드레일)	환경에 따라 허용 가능한 출력값의 범위를 사전에 정의된 규칙으로 강제 제한.

진화적 적응성 설계

❖ 적응 필요성 판단 설계

판단 기법	설명
데이터·대상 변화 모니터링	입력 데이터의 분포 $P(X)$ 변화(Data Drift)와 실제 대상·정답의 구성 $P(Y)$ 변화(Target Drift)를 감시하여 운영 환경과 문제 대상의 변화를 조기에 탐지
모델 반응 변화 모니터링	예측값의 분포 $P(Y')$ 와 확신도 변화를 감시하여 새로운 입력에 대한 모델의 반응 이상을 탐지
관계·성과 변화 모니터링	입력-정답 관계 $P(Y X)$ 의 변화 (Concept Drift)와 정확도·오류율 등 실제 성능 변화를 분석하여 기존 모델의 유효성과 적응 필요성을 판단

❖ 적응 동작 수행 설계

적응 수행 기법	설명
Evolutionary Knowledge update (진화적 지식 갱신)	지식 축적형, 전면 갱신형, 구조 확장형 방식으로 기능적 진화 수행
Systematic safety state transition (시스템 수준 안전)	모델 판단 불능 시 관리자 통보, Fail-safe(정지), Fail-operational(제한적 작동) 모드 가동.

확정적 적응성 설계


적응 필요성 판단 기법

판단 기법	설명
Context-aware Sensing (상황 인지 센싱)	• 자연/물리적 조건: 시간(RTC), 기상 센서(강우/조도), 센서 데이터의 통계적 특성 등을 통해 현재 상황(예: 야간, 폭우)을 판단함 • 공간/지역적 특성: GPS 좌표나 정밀 지도(HD Map) 데이터를 활용하여 지역적 맥락(예: 스쿨존 진입, 영국 진입)을 판단함
Rule-based Dispatching (규칙 기반 디스패칭)	사전에 정의된 Context-to-Logic 매핑 테이블 을 사용하여, 감지된 환경 요소가 특정 임계치(Threshold)를 넘어서는 순간 적응 동작을 트리거함
Administrative Injection (직접 지정)	사회/논리적 제약의 변화를 관리자가 API나 설정 변경을 통해 시스템에 직접 주입하여 적응 필요성을 명시함

Context-aware Sensing — 상황 인지 센싱

❖ 개념

시간·날씨·위치·장치 상태 등 운영 환경을 감지하여, 현재 상황이 기존 환경과 달라졌는지를 식별하는 기법이 단계 자체는 적응을 실행하기보다 **판단에 필요한 상황 정보를 생성**



❖ 예시

자율주행 시스템은 현재 시각=22시, 조도=낮음, 강우량=높음, 카메라 가시성=낮음을 결합하여 단순히 "밤"이 아니라 **'야간 폭우·저가시성 상황'**으로 판단

❖ 주의

단일 센서 값만으로 판단하면 오탐이 발생할 수 있으므로 여러 신호를 결합하고, 일정 시간 이상 조건이 유지될 때 상황을 확정하는 것이 좋습니다. 또한 판단 결과에 상황 신뢰도와 데이터 품질 상태를 함께 제공해야 합니다.

Rule-based Dispatching — 규칙 기반 디스패칭

❖ 개념

- 상황 인지 결과를 사전에 정의한 규칙과 비교하여 어떤 모델·정책·기능을 적용할 것인지 결정하는 기법

❖ 예시 (Context-to-Logic 매핑 테이블)

상황 ID	조건	실행 대상	우선순위	해제 조건
C01	조도 < 20 lux	야간 모델	2	조도 > 30 lux가 10초 유지
C02	스쿨존 AND 등교 시간	저속 정책	1	스쿨존 이탈
C03	센서 신뢰도 < 0.6	안전 모드	0	신뢰도 > 0.8

❖ 주의

- 고정된 규칙이 실제 환경 변화를 충분히 반영하지 못할 수 있으므로, 오작동·빈번한 전환·특정 모델로의 쏠림 여부를 모니터링하고 규칙을 조정해야 함.

Administrative Injection — 관리자 직접 지정

❖ 개념

- 법규, 정책, 계약 또는 운영 전략처럼 센서만으로 알 수 없는 변화를 관리자가 시스템에 명시적으로 반영하는 기법

❖ 적용방식

방식	예시
정책 관리 화면	관리자가 '스쿨존 최대속도 정책'을 변경
설정 파일·Feature Flag	일부 로봇에서 신규 기능만 활성화
정책 API	지역 코드별 적용 모델과 규칙을 갱신
긴급 Override	문제 모델을 중지하고 이전 모델로 강제 전환
유효기간 설정	행사 기간에만 임시 운영 정책 적용

❖ 주의

- 관리자 지정은 자동 규칙보다 높은 우선순위를 가질 수 있으므로, 권한 통제, 이중 승인, 버전 관리, 감사 로그 및 롤백 기능이 필요

적응 동작 수행 기법

적응 수행 기법	설명
Parameter Profile Injection (파라미터 프로파일 주입)	시스템 재시작 없이 런타임에 사전에 정의된 적응 필요 상황 별 제어 가중치, 인식 임계값 등 하이퍼파라미터 세트를 실시간으로 변경
Component Switching (컴포넌트 스위칭)	특정 상황에 최적화된 별도의 모델(예: 야간 전용 인식 모델)이나 알고리즘 모듈을 수행 (Strategy Pattern 활용)
Output Guardrails (출력 가드레일)	환경에 따라 출력 값의 허용 범위를 강제로 제한하는 로직을 활성화함 (예: 스쿨존 내 최고 속도 하드 코딩 제한)

Parameter Profile Injection — 파라미터 프로파일 주입

❖ 개념

- 모델이나 제어 컴포넌트는 그대로 유지하면서, 현재 상황에 맞게 미리 정의된 파라미터 묶음을 런타임에 적용하는 기법
- 시스템을 재시작하거나 재배포하지 않고 동작의 민감도·우선순위·제어 수준을 변경

구분	조정 파라미터 예시
AI 추론	신뢰도 임계값, 탐지 민감도, Top-k, 생성 길이
센서 처리	센서별 가중치, 필터 강도, 샘플링 주기
제어 정책	최고 속도, 안전거리, 회피 민감도
시스템 운영	타임아웃, 재시도 횟수, 배치 크기
기능 정책	경고 기준, 사용자 확인 조건, 자동 실행 범위

❖ 주의

- 개별 값을 임의로 바꾸기보다 검증된 **프로파일 단위**로 관리
- 값의 허용 범위와 파라미터 간 호환성을 적용 전에 검사


Component Switching — 컴포넌트 스위칭

❖ 개념

- 현재 상황에 가장 적합한 모델, 알고리즘 또는 정책 컴포넌트를 선택하여 실행 경로를 전환하는 기법
- 동일 컴포넌트의 설정만 바꾸는 것으로 충분하지 않을 때 사용

❖ 전환가능 대상

전환 대상	예시
AI 모델	주간 인식 모델 → 야간 인식 모델
센서 처리 모듈	카메라 중심 인식 → LiDAR 중심 인식
알고리즘	일반 경로계획 → 악천후 안전 경로계획
제어 정책	정상 주행 정책 → 스쿨존 저속 정책
서비스 구성	고정밀 모델 → 경량 모델 또는 안전 폴백



❖ 주의


- 컴포넌트의 입력·출력 형식과 단위가 서로 호환되어야 함
- 전환할 모델을 미리 메모리에 적재하지 않으면 전환 지연이 발생
- 전환 중 요청 누락이나 상태 불일치가 발생하지 않도록 해야 함

Output Guardrails — 출력 가드레일

❖ 개념

- 모델이나 제어 컴포넌트가 생성한 결과를 그대로 실행하지 않고, **현재 환경·법규·안전 정책에 맞는지 검사한 후 허용·보정·차단**하는 기법
- 파라미터 주입과 컴포넌트 스위칭이 시스템의 동작 방식을 변경한다면, 출력 가드레일은 그 결과가 반드시 지켜야 할 경계를 설정

❖ 처리 과정



❖ 주의

- 가드레일 자체의 오류에 대비한 최종 안전 기본값이 필요
- 가드레일이 모델의 오류를 계속 감추지 않도록 원래 출력과 수정 결과를 함께 기록

진화적 적응성 설계

적응 필요성 판단 기법

판단 기법 대분류	설명	세부 판단 기법
데이터·대상 변화 모니터링	입력 데이터의 분포 $P(X)$ 변화(Data Drift)와 실제 대상·정답의 구성 $P(Y)$ 변화 (Target Drift)를 감시하여 운영 환경과 문제 대상의 변화를 조기에 탐지	• Data Drift 모니터링 • Target Drift 모니터링
모델 반응 변화 모니터링	예측값의 분포 $P(Y^{\wedge})$ 와 확신도 변화를 감시하여 새로운 입력에 대한 모델의 반응 이상을 탐지	• Prediction Drift 모니터링 • 확신도 기반 모니터링
관계·성과 변화 모니터링	입력-정답 관계 $P(Y X)$ 의 변화 (Concept Drift)와 정확도·오류율 등 실제 성능 변화를 분석하여 기존 모델의 유효성과 적응 필요성을 판단	• Concept Drift 모니터링 • 성능 모니터링

Data Drift 모니터링

❖ 개념

운영 중 입력 데이터의 분포 $P(X)$ 가 학습 당시와 달라졌는지 감시하는 기법

$$P_{train}(X) \neq P_{current}(X)$$

구분	내용
감시 대상	입력 특성의 평균·분산·범위·범주 비율, 결측치·이상치 비율
주요 방법	PSI, K-S 검정, 카이제곱 검정, Wasserstein Distance, JS Divergence
판단 목적	모델이 학습하지 못한 새로운 운영 환경의 출현을 조기에 탐지
예시	로봇청소기가 가정 이 아닌 사무실에서 사용되면서 케이블·회전의자 입력이 증가

❖ 주의

- 입력 분포가 변해도 모델 성능은 유지될 수 있음
- 전체 입력뿐 아니라 **성능에 중요한 특성별 변화**를 확인해야 함

Target Drift 모니터링

❖ 개념

운영 중 실제 대상이나 정답의 구성 $P(Y)$ 가 학습 당시와 달라졌는지 감시하는 기법

$$P_{train}(Y) \neq P_{current}(Y)$$

구분	내용
감시 대상	실제 클래스 비율, 사건 발생률, 수요·불량률 등 목표값의 분포
주요 방법	클래스 비율 비교, 카이제곱 검정, PSI, 시계열 변화점 탐지
판단 목적	AI가 다루는 실제 문제 대상의 종류나 발생 빈도가 변했는지 탐지
예시	실제 장애물 장면의 비율이 5%에서 25%로 증가

❖ 주의

- Target Drift는 **예측값 Y'** 이 아니라 실제 정답 Y 의 변화
- 정답이 늦게 확보되는 시스템(예, 신용카드 부정결제 탐지)에서는 실시간 탐지가 어려움
- 실제 대상의 비율 변화가 반드시 정확도 저하를 의미하지는 않음

Prediction Drift 모니터링

❖ 개념

모델이 생성한 예측값의 분포 $P(Y')$ 가 기준 기간과 달라졌는지 감시하는 기법

$$P_{baseline}(Y') \neq P_{current}(Y')$$

구분	내용
감시 대상	클래스별 예측 비율, 예측값의 평균·분산·범위, 출력 점수 분포
주요 방법	PSI, K-S 검정, 카이제곱 검정, 이동평균, 변화점 탐지
판단 목적	정답을 기다리지 않고 모델의 예측 행동 변화를 조기에 탐지
예시	'장애물 있음' 예측 비율이 평소 5%에서 30%로 급증

❖ 주의

- Prediction Drift가 발생했다고 해서 모델이 틀렸다고 단정할 수 없으므로, Data Drift, Target Drift 및 실제 성능과 함께 해석해야 합니다.

확신도 기반 모니터링

❖ 개념

모델이 자신의 예측을 얼마나 확실하게 구분하는지를 나타내는 신뢰도·불확실성의 변화를 감시하는 기법

감시 지표	의미
평균 확신도	전체 예측 확신도의 평균
저확신 예측 비율	임계값보다 낮은 예측의 비율
예측 엔트로피	여러 클래스에 확률이 분산된 정도
Top-1·Top-2 차이	가장 높은 두 클래스 점수의 차이

❖ 예시

예를 들어 평균 확신도가 0.90에서 0.65로 하락하고, 확신도 0.6 미만의 입력 비율이 5%에서 25%로 증가하면 새로운 환경이나 어려운 입력이 유입된 것으로 의심할 수 있음

❖ 주의

- 높은 확신도가 반드시 정확한 예측을 의미하지는 않음

Concept Drift 모니터링

❖ 개념

입력과 실제 정답 사이의 관계 $P(Y|X)$ 가 학습 당시와 달라졌는지 감시하는 기법

$$P_{train}(Y|X) \neq P_{current}(Y|X)$$

구분	내용
감시 대상	입력 조건별 실제 정답과 오류 패턴의 변화
주요 방법	기간별·구간별 오류율 비교, 조건부 분포 분석, 변화점 탐지
판단 목적	기존에 학습한 입력-정답 관계가 계속 유효한지 확인
예시	같은 형태의 케이블이라도 새로운 청소기 구조에서는 통과가 아닌 회피가 필요해짐

❖ 주의

- Concept Drift를 직접 검증하려면 일반적으로 실제 정답이 필요
- Concept Drift와 Data Drift는 다릅니다.
 - ✓ **Data Drift:** 들어오는 입력의 구성이 달라짐
 - ✓ **Concept Drift:** 같은 입력에 대해 적절한 정답이나 판단 규칙이 달라짐

성능 모니터링

❖ 개념

모델 예측 $\hat{Y}$ 와 실제 정답 Y 을 비교하여 모델의 실제 성능이 저하됐는지 감시 기법

AI 태스크	주요 성능 지표
분류	Accuracy, Precision, Recall, F1, ROC-AUC
회귀	MAE, RMSE, MAPE
이상 탐지	mAP, 미탐률, 오탐률
추천	NDCG, MRR

❖ 예시

최근 7일 동안 전체 정확도가 기준보다 5%p 하락하고, 야간 환경의 미탐률이 10%p 증가했다면 모델 적응이나 교체를 검토할 수 있음

❖ 주의

- 전체 평균뿐 아니라 환경·사용자·시간대·제품군별 성능을 확인해야 함
- 표본이 적은 구간은 일시적인 변동이 크게 나타날 수 있음

진화적 지식 갱신

적응 수행 기법 (대분류)	세부 적응 수행 기법	설명
Evolutionary Knowledge update (진화적 지식 갱신)	지식 축적형 (Incremental Learning)	기존 가중치를 유지하며 신규 데이터를 통해 지식을 점진적으로 업데이트
	구조 확장형 (Architectural Expansion)	기존 지식은 보존(Freeze)하고 신규 모듈을 추가하여 물리적으로 결합
	지식 쇄신형 (Full Retraining)	기존 가중치를 폐기하고 최신/양질의 데이터로 전체 모델을 재구축
Systematic safety state transition (시스템 수준 안전)	Fail-operational (제한적 작동)	고수준의 지능적 판단이 불가능할 경우, 최소한의 기능만 유지하는 단순 로직으로 전환함
	Fail-safe (안전 정지)	- 더 이상의 운용이 위험하다고 판단될 경우 시스템을 안전하게 정지시키고 제어권을 반납함 - 제어 주체가 제어 로직 수행(by 제어 가능성)

지식축적형 갱신

❖ 개념

- 신규 데이터로 기존 모델의 가중치를 점진적으로 갱신하여 변화한 환경과 지식을 모델 내부에 반영.

❖ 기법

- **미세 조정(Fine-tuning)**: 사전 학습된 모델의 가중치를 새로운 특정 데이터셋에 맞춰 미세하게 재학습함.
- **망각 완화 학습**: 리플레이·지식 증류로 기존 지식 보존
 - ✓ 리플레이- 새로운 데이터를 학습할 때 과거 데이터의 일부도 함께 학습
 - ✓ 지식증류- 학습 전의 기존 모델을 교사 모델로 두고, 새 모델이 기존 모델의 판단 결과도 가능한 한 유지하도록 학습

❖ 장점

- 지식의 연속성을 유지하며 학습 자원과 시간의 효율적 활용이 가능함.

❖ 단점

- 새 지식 습득 시 기존 지식을 소실하는 파괴적 망각(Catastrophic Forgetting) 리스크가 존재함.

구조 확장형 갱신

❖ 개념

- 기존 모델은 고정(Freeze)하고, 신규 환경 대응용 모듈을 물리적으로 결합해 지식을 확장하는 방식임.

❖ 기법

- 어댑터: 레이어 사이에 소규모 학습 모듈을 추가하고 주로 해당 모듈만 학습
- **MoE(Mixture of Experts)**: 영역별 전문가를 구성하고 상황에 적합한 전문가를 선택.

❖ 장점

- 과거 지식을 100% 보존하며 망각 리스크 없이 무한한 확장이 가능함.

❖ 단점

- 아키텍처 복잡도가 높아지고 추론 시 연산 부하 및 지연 시간(Latency)이 증가함.

지식 쇄신형 갱신

❖ 개념

- 이전 지식을 완전히 폐기하고 최신/양질의 데이터를 사용하여 모델 전체를 새롭게 재구축하는 방식임.

❖ 기법

- **Full Retraining**: 가용한 전량의 양질 데이터를 사용하여 모델의 모든 파라미터를 처음부터 다시 학습시킴.
- **슬라이딩 윈도우(Sliding Window)**: 데이터의 최신성을 극대화하기 위해 일정 기간 내의 최신 데이터셋만을 선별하여 학습에 활용함.

❖ 장점

- 과거의 편향과 낡은 논리를 제거해 현재 환경에 가장 최적화된 지능을 확보함.

❖ 단점

- 데이터 준비 및 전체 학습에 막대한 리소스와 비용, 시간이 투입되는 최고 비용 전략임.

Drift 유형 별 지식 갱신 방법

Drift 유형	방법	설명
Data Drift	지식 축적	• "세상에 이런 물체도 있네?" 하는 상황임. • 기존의 인식 능력은 유지하되, 새롭게 유입된 데이터의 특성만 기존 모델에 '덧칠'하듯 학습시켜 지식의 폭을 넓히는 것이 가장 효율적임
Target Drift	구조 확장	• "이 지역(또는 그룹)은 정답 분포가 완전히 다르네?" 하는 상황임. • 전체 모델을 건드리면 기존 성능이 망가질 수 있으므로, 해당 특정 도메인만 전담하는 '새로운 방(Expert/Adapter)'을 만들어 지능을 물리적으로 확장하는 것이 안전함
Concept Drift	지식 쇄신	• "이제는 이게 정답이 아니네?" 하는 상황임. • 과거의 데이터로 학습된 가중치(W)가 현재의 정답(Y)을 맞히는 데 방해가 되기 때문에, 낡은 지식을 깨끗이 비우고 '새로 태어나는' 것이 정확도 측면에서 유리함

Q & A
